


矩阵分析教程

(电子版)

董增福

哈尔滨工业大学数学系



矩阵分析解决下述三大问题


问题一 相容线性方程组 $Ax = b$ 的极小范数解

矛盾线性方程组 $Ax = b$ 的极小范数最小二乘解

方法与工具 Moore-Penrose 广义逆 A^+

相容线性方程组的通解, 矛盾线性方程组的通式

$$x = A^+b + (I_n - A^+A)y, \quad y \in C^n$$



问题二 线性常系数齐次, 非齐次微分方程组初值问题


$$\begin{cases} \frac{dx}{dt} = Ax, \\ x(t_0) = x_0. \end{cases} \quad \begin{cases} \frac{dx}{dt} = Ax + f(t), \\ x(t_0) = x_0. \end{cases}$$

方法与工具 矩阵的Jordan标准形

矩阵微分与矩阵积分

向量 矩阵的Laplace变换

问题三 Lyapunov 矩阵方程 $AX + XB = F$



矩阵微分方程

$$\begin{cases} \frac{dX(t)}{dt} = AX(t) + X(t)B \\ X(0) = X_0 \end{cases}$$


方法与工具 矩阵的Kronecker 积

矩阵的按行拉直列向量 $\text{vec}X$

矩阵方程转化成线性方程组

$$(A \otimes I_n + I_m \otimes B^T) \text{vec}X = \text{vec}F$$


矩阵微分方程的解 $X(t) = e^{At} X_0 e^{Bt}$



第一章 线性空间与线性变换

核心内容

1. 线性空间
2. 线性空间的基与坐标
3. 线性子空间
4. 线性映射与线性变换
5. 线性变换的矩阵表示




线性空间的定义

定义1.1 设 F 是一数域, V 是一**非空集合**,如果对于任意两个元素 $\alpha, \beta \in V$,总有**惟一**的一个元素 $\gamma \in V$ 与之对应,称 γ 为 α 与 β 的**和**,记为 $\gamma = \alpha + \beta$;


又对于任一**数** $k \in F$ 及任一元素 $\alpha \in V$,有**惟一**的一个元素 $\delta \in V$ 与之对应,称 δ 为 k 与 α 的**数量乘积(数乘)**,记为 $\delta = k\alpha$;(上述情况称 V 对**加法**与**数乘**运算**封闭**)

并且这两种运算满足以下**8 条规则**:

(设 $\alpha, \beta, \gamma \in V$; $k, l \in F$)




加法	① 交换律	$\alpha + \beta = \beta + \alpha$
	② 结合律	$(\alpha + \beta) + \gamma = \alpha + (\beta + \gamma)$
	③ 零元素	$\alpha + \theta = \alpha$
	④ 负元素	$\alpha + (-\alpha) = \theta$
数乘	⑤ 单位 1	$1\alpha = \alpha$
	⑥ 结合律	$k(l\alpha) = (kl)\alpha$
两者	⑦ 分配律	$k(\alpha + \beta) = k\alpha + k\beta$
	⑧ 分配律	$(k + l)\alpha = k\alpha + l\alpha$



那么，称 V 为数域 F 上的**线性空间**，记为 $V(F)$.

由于**线性空间** $V(F)$ 与 n 维**向量空间** R^n 在本质上十分**相似**，故**线性空间** 也常称为**向量空间**，其元素统称为**向量** .



三个重要的线性空间

例1.1 所有 $m \times n$ **实矩阵** 的全体构成实数域上的**线性空间**，记为 $R^{m \times n}$.

例1.2 **次数小于 n 的实多项式** 的全体构成实数域 R 上的**线性空间**，记为 $P[x]_n$.

例1.3 区间 $[a, b]$ 上全体**连续实函数** 构成实数域 R 上的**线性空间**，记为 $C[a, b]$.



两个复杂的线性空间的例子

例1.4 设 $V = \{\mathbf{x} \mid \mathbf{x} = (x_1, x_2), x_1, x_2 \in \mathbf{R}\},$

$$\mathbf{x} = (x_1, x_2), \mathbf{y} = (y_1, y_2), k \in \mathbf{R}$$

定义加法与数乘运算为

$$\mathbf{x} \oplus \mathbf{y} \triangleq (x_1 + y_1, x_2 + y_2 + x_1 y_1);$$

$$k \circ \mathbf{x} \triangleq (kx_1, kx_2 + \frac{k(k-1)}{2} x_1^2).$$

则按照如此定义的加法与数乘， V 构成 $\mathbf{R}$ 上的线性空间.



证 封闭性显然, 以下检验**8条规则**成立

$$\textcircled{1} \mathbf{x} \oplus \mathbf{y} = (x_1 + y_1, x_2 + y_2 + x_1 y_1) = (y_1 + x_1, y_2 + x_2 + y_1 x_1) \\ = \mathbf{y} \oplus \mathbf{x}.$$

$$\textcircled{2} (\mathbf{x} \oplus \mathbf{y}) \oplus \mathbf{z} = (x_1 + y_1, x_2 + y_2 + x_1 y_1) \oplus (z_1, z_2) \\ = (x_1 + y_1 + z_1, x_2 + y_2 + x_1 y_1 + z_2 + x_1 z_1 + y_1 z_1); \\ \mathbf{x} \oplus (\mathbf{y} \oplus \mathbf{z}) = (x_1, x_2) \oplus (y_1 + z_1, y_2 + z_2 + y_1 z_1) \\ = (x_1 + y_1 + z_1, x_2 + y_2 + z_2 + y_1 z_1 + x_1 y_1 + x_1 z_1);$$

故 $(\mathbf{x} \oplus \mathbf{y}) \oplus \mathbf{z} = \mathbf{x} \oplus (\mathbf{y} \oplus \mathbf{z}).$


③ $\theta = (0, 0) \in V$ 为 **零元素**,

$$\mathbf{x} \oplus \theta = (x_1, x_2) \oplus (0, 0) = (x_1 + 0, x_2 + 0 + x_1 \cdot 0) = \mathbf{x}.$$

④ $-\mathbf{x} = (-x_1, -x_2 + \underline{x_1^2})$ 为 $\mathbf{x}$ 的 **负元素**,

$$\mathbf{x} \oplus (-\mathbf{x}) = (x_1 - x_1, x_2 - x_2 + x_1^2 + x_1(-x_1)) = (0, 0) = \theta.$$


$$\textcircled{5} \mathbf{1} \circ \mathbf{x} = (1x_1, 1x_2 + \frac{1(1-1)}{2} x_1^2) = (x_1, x_2) = \mathbf{x}.$$



$$\textcircled{6} \quad k \circ (l \circ \mathbf{x}) = k \circ \left(lx_1, lx_2 + \frac{l(l-1)}{2} x_1^2 \right)$$

$$= (klx_1, k(lx_2 + \frac{l(l-1)}{2} x_1^2) + \frac{k(k-1)}{2} (lx_1)^2)$$


$$= (klx_1, \underline{klx_2 + \frac{kl(kl-1)}{2} x_1^2}) = (kl) \circ \mathbf{x}.$$



$$\textcircled{7} \boxed{(k+l) \circ \mathbf{x}} = (\underline{(k+l)x_1}, \underline{(k+l)x_2} + \frac{(k+l)(k+l-1)}{2} x_1^2)$$

$$= (\underline{kx_1 + lx_1}, \underline{kx_2} + \frac{k(k-1)}{2} x_1^2 + \underline{lx_2} + \frac{l(l-1)}{2} x_1^2 + \underline{(kx_1)(lx_1)})$$

$$= (kx_1, kx_2 + \frac{k(k-1)}{2} x_1^2) \oplus (lx_1, lx_2 + \frac{l(l-1)}{2} x_1^2) = \boxed{k \circ \mathbf{x}} \oplus \boxed{l \circ \mathbf{x}}$$



$$\textcircled{8} \quad k \circ (\mathbf{x} \oplus \mathbf{y}) = k \circ (x_1 + y_1, x_2 + y_2 + x_1 y_1)$$

$$= (k(x_1 + y_1), k(x_2 + y_2 + x_1 y_1) + \frac{k(k-1)}{2} (x_1 + y_1)^2)$$

$$= (kx_1 + ky_1, (kx_2 + \frac{k(k-1)}{2} x_1^2) + (ky_2 + \frac{k(k-1)}{2} y_1^2) + \underline{kx_1 \cdot ky_1})$$


$$= (kx_1, kx_2 + \frac{k(k-1)}{2} x_1^2) \oplus (ky_1, ky_2 + \frac{k(k-1)}{2} y_1^2)$$

$$= \boxed{k \circ \mathbf{x}} \oplus \boxed{k \circ \mathbf{y}}.$$

■

由定义1.1可见 V 构成实数域 R 上的线性空间，

记之为 $\boxed{R^2(\oplus, \circ)}$.




例1.5 设**正实数集** $R^+ = \{a \mid a > 0, a \in R\}$

定义加法与**数乘**运算分别为:

$$a \oplus b = ab, \forall a, b \in R^+;$$

$$k \circ a = a^k, k \in R$$

试证明 R^+ 是实数域 R 上的**线性空间**.



证 显然在 R^+ 上如此定义的加法与数乘运算保持封闭，再需验证运算满足8条规则.

$\forall a, b, c \in R^+, \forall k, l \in R$ 有

- ① $a \oplus b = ab = ba = b \oplus a.$
- ② $(a \oplus b) \oplus c = ab \oplus c = abc = a \oplus bc = a \oplus (b \oplus c).$
- ③ $a \oplus 1 = a, 1$ 为 R^+ 的零元素.



$$\textcircled{4} \quad a \oplus \frac{1}{a} = 1, \quad \boxed{\frac{1}{a} \text{ 为 } R^+ \text{ 的负元素}}.$$


$$\textcircled{5} \quad 1 \circ a = a^1 = a.$$

$$\textcircled{6} \quad k \circ (l \circ a) = k \circ a^l = (a^l)^k = a^{kl} = (kl) \circ a.$$

$$\textcircled{7} \quad (k+l) \circ a = a^{k+l} = a^k a^l = a^k \oplus a^l = (k \circ a) \oplus (l \circ a).$$

$$\begin{aligned} \textcircled{8} \quad k \circ (a \oplus b) &= k \circ (ab) = (ab)^k = a^k b^k \\ &= a^k \oplus b^k = (k \circ a) \oplus (k \circ b). \quad \blacksquare \end{aligned}$$

由定义1.1可见 R^+ 构成实数域 R 上的线性空间，
仍记为 R^+



- 设 $x_1, x_2, \dots, x_m$ 为线性空间 $V(F)$ 中的 m 个向量，由于线性空间 $V(F)$ 与线性代数中的 n 维向量空间 R^n 在本质上十分相似，类似地可以定义 $V(F)$ 中的向量组的线性相关、线性无关、线性组合；两个向量组的等价.....

例1.6 在线性空间 $R^{m \times n}$ 中:

$$E_{ij} = (e_{st})_{m \times n}, \text{ 其中 } e_{st} = \begin{cases} 1, & s=i; t=j \\ 0, & \text{其余} \end{cases} \quad (i=1,2,\dots,m; j=1,2,\dots,n),$$


即 $m \times n$ 的矩阵 E_{ij} 中仅第 i 行第 j 列元素为 1, 其余皆 0.

则 $E_{ij} (i=1,2,\dots,m; j=1,2,\dots,n)$ 线性无关.

证 考查线性表达式

$$k_{11}E_{11} + k_{12}E_{12} + \cdots + k_{ij}E_{ij} + \cdots + k_{m1}E_{m1} + \cdots + k_{mn}E_{mn} = O_{m \times n}$$

则有



$$\begin{bmatrix} k_{11} & \cdots & k_{1j} & \cdots & k_{1n} \\ \vdots & & \vdots & & \vdots \\ k_{i1} & \cdots & k_{ij} & \cdots & k_{in} \\ \vdots & & \vdots & & \vdots \\ k_{m1} & \cdots & k_{mj} & \cdots & k_{mn} \end{bmatrix} = \mathbf{0}_{m \times n}.$$

即 $k_{ij} = 0$ ($i = 1, 2, \cdots, m$; $j = 1, 2, \cdots, n$).

所以 $\mathbf{E}_{11}, \cdots, \mathbf{E}_{ij}, \cdots, \mathbf{E}_{mn}$ 线性无关.





§ 1.2 线性空间的基与坐标

定义1.2 线性空间 $V(F)$ 中的向量组 $x_1, x_2, \dots, x_n$


称为 $V(F)$ 的基或基向量组, 如果它满足

① $x_1, x_2, \dots, x_n$ 线性无关;

② $V(F)$ 中的任一向量 x 皆可写成 $x_1, x_2, \dots, x_n$


的线性组合.

线性空间 $V(F)$ 中的基所含向量的个数 n 称为 $V(F)$ 的维数, 记为 $\dim V(F) = n$, 也称为 n 维线性空间, 记为 $V_n(F)$.



设 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 为 $V_n(F)$ 的一个基, 对任意 $\mathbf{x} \in V_n(F)$, 有唯一的线性表达式 $\mathbf{x} = \sum_{i=1}^n k_i \mathbf{x}_i, k_i \in F, i = 1, 2, \dots, n$ 称 $k_1, k_2, \dots, k_n$ 为向量 $\mathbf{x}$ 在基 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 下的坐标.

对于确定的基, 向量在此基下的坐标是唯一的. 为方便计, 往往将其表成列向量



例1.7 在线性空间 $R^{m \times n}$ 中, 设 $A = (a_{ij})_{m \times n}$

显然有

$$A = \sum_{i=1}^m \sum_{j=1}^n a_{ij} E_{ij}$$

由例1.6知 $E_{11}, \dots, E_{ij}, \dots, E_{mn}$ 线性无关, 故

$E_{11}, \dots, E_{ij}, \dots, E_{mn}$ 为线性空间 $R^{m \times n}$ 的基. 且

$\dim R^{m \times n} = m \times n$ 而 $A = (a_{ij})_{m \times n}$ 在此基下的坐标, 记为 $(a_{11}, \dots, a_{ij}, \dots, a_{mn})^T$.



例1.8 例1.5中的正实数集 $R^+ = \{a \mid a > 0, a \in R\}$


在加法与数乘运算分别定义为：

$$a \oplus b = ab, \forall a, b \in R^+$$

$$k \circ a = a^k, k \in R$$

前已证明 R^+ 是实数域 R 上的线性空间.

求 R^+ 的基与维数.




解 由 $a \oplus 1 = a$, 知 1 为 R^+ 的零元素. 于是有:

$$\forall a \neq 1, a \in R^+, \forall b \in R^+$$

$$b = a^{\log_a b} = (\log_a b) \circ a$$

这说明中任一元素 b 均可表成非零元素 a 的线性组合, 故任何非零元素 a (R^+ 中除 1 之外的所有数) 均为 R^+ 的基, 且显然有


$$\dim R^+ = 1.$$

定义1.3 设 $\alpha_1, \alpha_2, \dots, \alpha_n$ 及 $\beta_1, \beta_2, \dots, \beta_n$ 是
线性空间的两个基, 且

$$\begin{cases} \beta_1 = p_{11}\alpha_1 + p_{21}\alpha_2 + \cdots + p_{n1}\alpha_n \\ \beta_2 = p_{12}\alpha_1 + p_{22}\alpha_2 + \cdots + p_{n2}\alpha_n \\ \dots\dots\dots \\ \beta_n = p_{1n}\alpha_1 + p_{2n}\alpha_2 + \cdots + p_{nn}\alpha_n \end{cases} \quad (1.1)$$


约定上式写成紧缩形式如下:



$$(\beta_1, \beta_2, \dots, \beta_n) = (\alpha_1, \alpha_2, \dots, \alpha_n)P \quad (1.2)$$

其中 $P = (p_{ij})_{n \times n}$, 称式 (1.2) 为**基变换公式**, 称矩阵 P 为由**基** $\alpha_1, \alpha_2, \dots, \alpha_n$ 到**基** $\beta_1, \beta_2, \dots, \beta_n$ 的**过渡矩阵**. 因为 $\beta_1, \beta_2, \dots, \beta_n$ **线性无关**, 所以显然 P 是**可逆**的(反证).

注意式(1.1)中的系数 p_{ij} **横排竖放**构成 P .



横排竖放构成 P


$$P = (p_{ij})_{n \times n} = \begin{bmatrix} p_{11} & p_{12} & \cdots & p_{1n} \\ p_{21} & p_{22} & \cdots & p_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ p_{n1} & p_{n2} & \cdots & p_{nn} \end{bmatrix}.$$



定理1.1 设 P 是 $V_n(F)$ 的基 $\alpha_1, \alpha_2, \dots, \alpha_n$ 到 $\beta_1, \beta_2, \dots, \beta_n$ 的过渡矩阵, $V_n(F)$ 中的元素 γ 在基 $\alpha_1, \alpha_2, \dots, \alpha_n$ 及基 $\beta_1, \beta_2, \dots, \beta_n$ 下的坐标分别为 $(x_1, x_2, \dots, x_n)^T, (y_1, y_2, \dots, y_n)^T$, 则有坐标变换公式

$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = P \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \quad \text{或} \quad \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = P^{-1} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \quad (1.3)$$

证 略




例1.10 在 $R^{2 \times 2}$ 中,求由基

$$A_1 = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}, A_2 = \begin{bmatrix} -1 & 1 \\ 0 & 0 \end{bmatrix}, A_3 = \begin{bmatrix} 0 & 0 \\ 1 & 0 \end{bmatrix}, A_4 = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix}$$

到基

$$B_1 = \begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix}, B_2 = \begin{bmatrix} -1 & 1 \\ 0 & 0 \end{bmatrix}, B_3 = \begin{bmatrix} -1 & 0 \\ 1 & 0 \end{bmatrix}, B_4 = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix}$$

的过渡矩阵.



解 由基变换公式有

$$(B_1, B_2, B_3, B_4) = (A_1, A_2, A_3, A_4)P$$

其中

$$P = (p_{ij})_{4 \times 4} \in R^{4 \times 4},$$

$$B_j = \sum_{i=1}^4 p_{ij} A_i, \quad j = 1, 2, 3, 4$$

把上述每个矩阵方程转化成等价的线性方程组:

将 A_1, A_2, A_3, A_4 中的元素横排竖放得到 4 维列向量,


将其并成矩阵 $A \in R^{4 \times 4}$, 于是


$$A = \begin{bmatrix} 1 & -1 & 0 & -1 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} = (\alpha_1, \alpha_2, \alpha_3, \alpha_4), \alpha_j \in R^4, j=1,2,3,4.$$

将 B_1, B_2, B_3, B_4 中的元素横排竖放得到 4 维列向量,

将其并成矩阵 $B \in R^{4 \times 4}$, 于是

$$B = (\beta_1, \beta_2, \beta_3, \beta_4) = \begin{bmatrix} 1 & -1 & -1 & -1 \\ 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \beta_j \in R^4, j=1,2,3,4.$$




因此有 $\beta_j = \sum_{i=1}^4 p_{ij} \alpha_i = (\alpha_1, \alpha_2, \alpha_3, \alpha_4) \begin{bmatrix} p_{1j} \\ p_{2j} \\ p_{3j} \\ p_{4j} \end{bmatrix}, j=1,2,3,4$

故 $(\beta_1, \beta_2, \beta_3, \beta_4) = (\alpha_1, \alpha_2, \alpha_3, \alpha_4)P, P = (p_{ij})_{4 \times 4}.$

此即 $B = AP.$

于是过渡矩阵 $P = A^{-1}B = \begin{bmatrix} 1 & 0 & -1 & 0 \\ 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}.$

□



§ 1.3 线性子空间


定义1.4 设 V_1 是数域 F 上的线性空间 V 的一个非空子集, 且对 V 中线性运算满足

① 如果 $\forall \alpha, \beta \in V_1$, 有 $\alpha + \beta \in V_1$;

② 如果 $\forall \alpha \in V_1, \forall k \in F$, 有 $k\alpha \in V_1$.

则称 V_1 为 V 的线性子空间, 简称子空间.

显然 $\dim V_1 \leq \dim V$



几个重要的线性子空间

例1.11 n 元齐次线性方程组 $Ax = \theta$ 解的集合构成线性空间，称为解空间，记为 $N(A)$ ，它是 R^n 的子空间，若 $\text{rank} A = r$ ，则 $\dim N(A) = n - r$ 。

例1.12 设 $A \in R^{n \times n}$ ， $A\xi = \lambda_i \xi$ ，则 A 的属于特征值 λ_i 的所有特征向量加上零向量 θ 构成 R^n 的子空间，称为特征子空间，记为 V_{λ_i} 。

例1.13 设 $\alpha_1, \alpha_2, \dots, \alpha_m$ 是 $V(F)$ 的一组向量, 令

$$V_1 = \{k_1\alpha_1 + \dots + k_i\alpha_i + \dots + k_m\alpha_m \mid k_i \in F, i=1, 2, \dots, m\}$$

则 V_1 表示由 $\alpha_1, \alpha_2, \dots, \alpha_m$ 生成子空间. 记为

$$V_1 = \text{span}(\alpha_1, \alpha_2, \dots, \alpha_m).$$

注意 这里并没要求 $\alpha_1, \alpha_2, \dots, \alpha_m$ 线性无关

作为特例, 当 $\alpha_1, \alpha_2, \dots, \alpha_m$ 是一组列向量时, 则

$V_1 = \text{span}(\alpha_1, \alpha_2, \dots, \alpha_m)$ 就是由列向量组

$\alpha_1, \alpha_2, \dots, \alpha_m$ 所生成的子空间, 将 $\alpha_1, \alpha_2, \dots, \alpha_m$

并排一起即为矩阵.

矩阵的值域与核

例1.14 设 $A = (a_{ij})_{m \times n} = (\alpha_1, \dots, \alpha_j, \dots, \alpha_n) \in R^{m \times n}$,

则 $\text{span}(\alpha_1, \alpha_2, \dots, \alpha_n)$ 是 m 维线性空间 R^m 的子空间, 称为矩阵 A 的列空间, 记为 $R(A)$.

$\forall y \in \text{span}(\alpha_1, \alpha_2, \dots, \alpha_n) = R(A)$, $\exists x_1, x_2, \dots, x_n$, 使

$$y = x_1 \alpha_1 + x_2 \alpha_2 + \cdots + x_n \alpha_n = (\alpha_1, \alpha_2, \cdots, \alpha_n) \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = Ax$$

其中 $x = (x_1, x_2, \cdots, x_n)^T$.

所以 $R(A)$ 可以表成

$$R(A) = \{y \mid y = Ax, x \in R^n\}$$

矩阵 A 的 **列空间** 也叫矩阵 A 的 **值域** (*Range*).

称集合 $\{x \mid Ax = \theta, x \in R^n\}$ 为 A 的 **核空间** (**零空间**), 简称为矩阵 A 的 **核** (*Null*), 显然它恰为 **齐次线性方程组** $Ax = \theta$ 的 **解空间** $N(A)$. A 的 **核空间** 的 **维数** 称为 A 的 **零度**.

易见 $\alpha_1, \alpha_2, \dots, \alpha_n$ 的 **极大无关组** 即为 $R(A)$ 的 **基**, 且

$$\dim R(A) = \dim \text{span}(\alpha_1, \alpha_2, \dots, \alpha_n) = \text{rank} \{\alpha_1, \alpha_2, \dots, \alpha_n\} = \text{rank } A,$$

于是有

$$\dim R(A) + \dim N(A) = n.$$


AB 与 A 值域的关系

AB 与 B 核的关系

例1.15 设 $A \in \mathbb{C}^{m \times n}$, $B \in \mathbb{C}^{n \times p}$, 则

① $R(AB) \subset R(A)$;

② $N(AB) \supset N(B)$.



证 ① $\forall y \in R(AB), \exists x \in C^p$, 使


$$y = (AB)x = A(Bx), \text{ 这里 } Bx \in C^n.$$

故 $y \in R(A)$, 因此 $R(AB) \subset R(A)$;

② $\forall x \in N(B)$, 则 $Bx = \theta$, 于是

$$(AB)x = A(Bx) = \theta.$$

故 $x \in N(AB)$, 因此 $N(AB) \supset N(B)$. 




与矩阵的情况类似,对于一般的线性空间有如下定理:

定理1.2 设 $\alpha_i \in V(F)$, $i=1,2,\dots,m$, 则

$$\dim \operatorname{span}(\alpha_1, \alpha_2, \dots, \alpha_m) = \operatorname{rank}\{\alpha_1, \alpha_2, \dots, \alpha_m\}$$

这里 $\operatorname{rank}\{\alpha_1, \alpha_2, \dots, \alpha_m\}$ 表示向量组 $\alpha_1, \alpha_2, \dots, \alpha_m$ 的秩, 即极大无关组中向量的个数.


对于列向量来说结论显然, 这里泛指的是广义的向量.




证 不妨设 $\alpha_1, \alpha_2, \dots, \alpha_r$ ($r \leq m$) 为向量组 $\alpha_1, \alpha_2, \dots, \alpha_m$ 的一个极大无关组, 于是

$\text{rank}\{\alpha_1, \alpha_2, \dots, \alpha_m\} = r$, 则对

$\forall \alpha \in \text{span}(\alpha_1, \alpha_2, \dots, \alpha_m)$, $\exists k_i \in F$, $i = 1, \dots, m$,
使



$$\begin{aligned}
 \alpha &= \sum_{i=1}^m k_i \alpha_i \\
 &= \sum_{i=1}^r k_i \alpha_i + \sum_{i=r+1}^m k_i \alpha_i = \sum_{i=1}^r k_i \alpha_i + \sum_{j=r+1}^m k_j \alpha_j \\
 &= \sum_{i=1}^r k_i \alpha_i + \sum_{j=r+1}^m k_j \left(\sum_{i=1}^r p_{ij} \alpha_i \right) \\
 &= \sum_{i=1}^r k_i \alpha_i + \sum_{i=1}^r \left(\sum_{j=r+1}^m k_j p_{ij} \right) \alpha_i \\
 &= \sum_{i=1}^r \left(k_i + \sum_{j=r+1}^m k_j p_{ij} \right) \alpha_i
 \end{aligned}$$



这说明 α 可表成 $\alpha_1, \alpha_2, \dots, \alpha_r$ 的线性组合，
故 $\alpha_1, \alpha_2, \dots, \alpha_r$ 是 $\text{span}(\alpha_1, \alpha_2, \dots, \alpha_m)$
的一组基，因此

$$\dim \text{span}(\alpha_1, \alpha_2, \dots, \alpha_m) = r = \text{rank}\{\alpha_1, \alpha_2, \dots, \alpha_m\}. \quad \blacksquare$$

定理1.3 $\text{span}(\alpha_1, \alpha_2, \dots, \alpha_r) = \text{span}(\beta_1, \beta_2, \dots, \beta_s)$ 的充要条件是 $\alpha_1, \alpha_2, \dots, \alpha_r$ 与 $\beta_1, \beta_2, \dots, \beta_s$ 等价.

证 先证必要性 $\Rightarrow$

设 $\text{span}(\alpha_1, \alpha_2, \dots, \alpha_r) = \text{span}(\beta_1, \beta_2, \dots, \beta_s)$.

故 $\alpha_1, \alpha_2, \dots, \alpha_r \in \text{span}(\beta_1, \beta_2, \dots, \beta_s)$, 因此 $\alpha_1, \alpha_2, \dots, \alpha_r$ 可由 $\beta_1, \beta_2, \dots, \beta_s$ 线性表示;

反之同理可证 $\beta_1, \beta_2, \dots, \beta_s$ 也可由 $\alpha_1, \alpha_2, \dots, \alpha_r$ 线性表示.

即 $\alpha_1, \alpha_2, \dots, \alpha_r$ 与 $\beta_1, \beta_2, \dots, \beta_s$ 等价.

再证充分性 $\Leftarrow$


由 $\alpha_1, \alpha_2, \dots, \alpha_r$ 与 $\beta_1, \beta_2, \dots, \beta_s$ 等价知 $\alpha_1, \alpha_2, \dots, \alpha_r$ 可由 $\beta_1, \beta_2, \dots, \beta_s$ 线性表示, 于是有形式写法

$$(\alpha_1, \dots, \alpha_j, \dots, \alpha_r) = (\beta_1, \dots, \beta_i, \dots, \beta_s)A, \text{ 其中 } A = (a_{ij})_{s \times r}$$

$$\alpha_j = \sum_{i=1}^s a_{ij} \beta_i, \quad j = 1, 2, \dots, r.$$

$$\forall \alpha \in \text{span}(\alpha_1, \dots, \alpha_j, \dots, \alpha_r)$$

$$\alpha = \sum_{j=1}^r k_j \alpha_j = \sum_{j=1}^r k_j \left(\sum_{i=1}^s a_{ij} \beta_i \right) = \sum_{i=1}^s \left(\sum_{j=1}^r k_j a_{ij} \right) \beta_i.$$



这说明 $\alpha \in \text{span}(\beta_1, \beta_2, \dots, \beta_s)$,

因此有 $\text{span}(\alpha_1, \alpha_2, \dots, \alpha_r) \subset \text{span}(\beta_1, \beta_2, \dots, \beta_s)$;

同理 $\text{span}(\alpha_1, \alpha_2, \dots, \alpha_r) \supset \text{span}(\beta_1, \beta_2, \dots, \beta_s)$,

可见 $\text{span}(\alpha_1, \alpha_2, \dots, \alpha_r) = \text{span}(\beta_1, \beta_2, \dots, \beta_s)$. ■




定理1.4（基的扩充定理）设 $W_m(F)$ 是 $V_n(F)$ 的子空间, $\alpha_1, \alpha_2, \dots, \alpha_m$ 是 $W_m(F)$ 的一个基, 则可将该基扩充为 $V_n(F)$ 的基.

对维数的差 $n-m$ 用数学归纳法证明该定理.

证略

以下研究子空间之间的运算及关系




两个子空间的交空间

定义1.5 设 V_1, V_2 是 $V(F)$ 的两个子空间，称

$$V_1 \cap V_2 = \{a \mid a \in V_1, a \in V_2\}$$

为 V_1, V_2 的交空间.

定理1.5 两个子空间的交空间仍是子空间.



两个子空间的和空间

定义1.6 设 V_1, V_2 是 $V(F)$ 的两个子空间，称

$$V_1 + V_2 = \{\alpha \mid \alpha = \alpha_1 + \alpha_2, \alpha_1 \in V_1, \alpha_2 \in V_2\}$$

为 V_1, V_2 的和空间.

定理1.6 两个子空间的和空间仍是子空间.



定理1.7 (子空间的维数定理)

设 V_1, V_2 是 $V(F)$ 的两个子空间, 则

$$\dim V_1 + \dim V_2 = \dim(V_1 + V_2) + \dim(V_1 \cap V_2).$$

证 设 $\dim V_1 = r$, $\dim V_2 = s$, $\dim(V_1 \cap V_2) = m$,



只需证明 $\dim(V_1 + V_2) = r + s - m$.

① 若 $m = r$, 由 $V_1 \cap V_2 \subset V_1$ 知 $V_1 \cap V_2 = V_1$;

又由 $V_1 \cap V_2 \subset V_2$, 故 $V_1 \subset V_2$, 因此 $V_1 + V_2 = V_2$.

所以 $\dim(V_1 + V_2) = \dim V_2 = s = r + s - r = r + s - m$.

② 同理 若 $m = s$, $\dim(V_1 + V_2) = r + s - m$ 亦成立.





③以下设 $m < r$, $m < s$; $\alpha_1, \alpha_2, \dots, \alpha_m$ 为 $V_1 \cap V_2$

的基. 因为 $V_1 \cap V_2$ 分别为 V_1, V_2 的子空间,

由定理1.4知: $\alpha_1, \alpha_2, \dots, \alpha_m$ 可分别扩充为

V_1 的基 $\alpha_1, \alpha_2, \dots, \alpha_m, \xi_{m+1}, \dots, \xi_r$


V_2 的基 $\alpha_1, \alpha_2, \dots, \alpha_m, \eta_{m+1}, \dots, \eta_s$

易证 $V_1 + V_2 = \text{span}(\alpha_1, \alpha_2, \dots, \alpha_m, \xi_{m+1}, \dots, \xi_r, \eta_{m+1}, \dots, \eta_s)$

因此只要证出 $\alpha_1, \alpha_2, \dots, \alpha_m, \xi_{m+1}, \dots, \xi_r, \eta_{m+1}, \dots, \eta_s$

线性无关即可.

子空间的维数定理示意图



考虑线性表达式

$$k_1\alpha_1 + k_2\alpha_2 + \dots + k_m\alpha_m + l_{m+1}\xi_{m+1} + \dots + l_r\xi_r + c_{m+1}\eta_{m+1} + \dots + c_s\eta_s = \theta \quad (1.6)$$

其中 $k_1, \dots, k_m, l_{m+1}, \dots, l_r, c_{m+1}, \dots, c_s \in F$.


移项, 令

$$\begin{aligned} \beta &= k_1\alpha_1 + k_2\alpha_2 + \dots + k_m\alpha_m + l_{m+1}\xi_{m+1} + \dots + l_r\xi_r \\ &= -c_{m+1}\eta_{m+1} - \dots - c_s\eta_s \end{aligned} \quad (1.7)$$

显然 $\beta \in V_1$, 且 $\beta \in V_2$, 所以 $\beta \in V_1 \cap V_2$, 因此存在

$t_1, t_2, \dots, t_m \in F$ 使

$$\beta = t_1\alpha_1 + t_2\alpha_2 + \dots + t_m\alpha_m$$



将其代入式(1.7)移项有

$$t_1\alpha_1 + t_2\alpha_2 + \dots + t_m\alpha_m + c_{m+1}\eta_{m+1} + \dots + c_s\eta_s = \theta$$

因 $\alpha_1, \alpha_2, \dots, \alpha_m, \eta_{m+1}, \dots, \eta_s$ 为 V_2 的基,
所以它们线性无关, 故

$$t_1 = t_2 = \dots = t_m = c_{m+1} = \dots = c_s = 0.$$

将其代回式(1.6)得

$$k_1\alpha_1 + k_2\alpha_2 + \dots + k_m\alpha_m + l_{m+1}\xi_{m+1} + \dots + l_r\xi_r = \theta.$$



因为 $\alpha_1, \alpha_2, \dots, \alpha_m, \xi_{m+1}, \dots, \xi_r$ 为 V_1 的基, 故

$$k_1 = k_2 = \dots = k_m = l_{m+1} = \dots = l_r = 0$$

由式(1.6)知 $\alpha_1, \alpha_2, \dots, \alpha_m, \xi_{m+1}, \dots, \xi_r, \eta_{m+1}, \dots, \eta_s$

线性无关, 即

$$\dim(V_1 + V_2) = r + s - m$$



定义1.7 设 V_1, V_2 是 $V(F)$ 的两个子空间, 若

$V_1 \cap V_2 = \{\theta\}$, 则称它们的和为直和, 记为 $V_1 \oplus V_2$.



定理1.8 设 V_1, V_2 是 $V(F)$ 的两个子空间,
则下列命题等价:

- ① $V_1 + V_2$ 是直和;
- ② $\alpha \in V_1 + V_2$ 表达式惟一;
- ③ 若 $\alpha_1, \alpha_2, \dots, \alpha_r$ 是 V_1 的基, $\beta_1, \beta_2, \dots, \beta_s$ 是 V_2 的基,
则 $\alpha_1, \alpha_2, \dots, \alpha_r, \beta_1, \beta_2, \dots, \beta_s$ 是 $V_1 + V_2$ 的基;
- ④ $\dim(V_1 + V_2) = \dim V_1 + \dim V_2$.

证 采用循环论证 $\textcircled{1} \Rightarrow \textcircled{2} \Rightarrow \textcircled{3} \Rightarrow \textcircled{4} \Rightarrow \textcircled{1}$

$\textcircled{1} \Rightarrow \textcircled{2}$ 设 $V_1 + V_2 = V_1 \oplus V_2$, 则 $V_1 \cap V_2 = \theta$.

(反证法) 如果 $\alpha \in V_1 + V_2$ 的表达式不惟一, 则

$$\alpha = \alpha_1 + \beta_1 = \alpha_2 + \beta_2, \quad \alpha_1, \alpha_2 \in V_1; \beta_1, \beta_2 \in V_2$$

其中 $\alpha_1 \neq \alpha_2$, 从而 $\beta_1 \neq \beta_2$.

令 $\gamma = \alpha_1 - \alpha_2 = \beta_2 - \beta_1$, 则 $\gamma \neq \theta$.

但 $\gamma \in V_1$, $\gamma \in V_2$, 于是 $\theta \neq \gamma \in V_1 \cap V_2$,

这与 $V_1 \cap V_2 = \{\theta\}$ 矛盾, 故 $\textcircled{2}$ 成立.

② $\Rightarrow$ ③ 显然 $V_1 + V_2 = \text{span}(\alpha_1, \alpha_2, \dots, \alpha_r, \beta_1, \beta_2, \dots, \beta_s)$,

故只需证明 $\alpha_1, \alpha_2, \dots, \alpha_r, \beta_1, \beta_2, \dots, \beta_s$ 线性无关.

(反证法) 如若不然存在不全为零的数

$k_1, k_2, \dots, k_r, c_1, c_2, \dots, c_s \in F$, 使

$$k_1\alpha_1 + k_2\alpha_2 + \dots + k_r\alpha_r + c_1\beta_1 + c_2\beta_2 + \dots + c_s\beta_s = \theta,$$

另有

$$0\alpha_1 + 0\alpha_2 + \dots + 0\alpha_r + 0\beta_1 + 0\beta_2 + \dots + 0\beta_s = \theta.$$

于是

θ 就有两种不同的表达式, 这与②矛盾, 故③成立.



③ $\Rightarrow$ ④ 由③知

$$\dim V_1 = r, \dim V_2 = s, \dim(V_1 + V_2) = r + s.$$

于是 $\dim(V_1 + V_2) = \dim V_1 + \dim V_2$, 故④成立.

④ $\Rightarrow$ ① 由④根据**定理1.7**知

$$\dim(V_1 \cap V_2) = 0, \text{ 因此有 } V_1 \cap V_2 = \{\theta\}.$$

即 $V_1 + V_2$ 是直和, 故①成立. ■




例1. 16 设 V_1, V_2 是 $V(F)$ 的两个子空间, $V(F)$ 的子集

$$V_1 \cup V_2 = \{\alpha \mid \alpha \in V_1, \text{或} \alpha \in V_2\} (\text{空间的并})$$


问 $V_1 \cup V_2$ 是否构成子空间?

解 不构成子空间, 因为对加法运算
不封闭.



$$V_1 \cup V_2 = x\text{轴} \cup y\text{轴}$$

$$\alpha_1 \in V_1, \alpha_2 \in V_2, \alpha_1 + \alpha_2 \notin V_1 \cup V_2$$



例1.18 设 $\mathbf{R}^{2 \times 2}$ 的两个子空间为

$$V_1 = \{A \mid A = \begin{bmatrix} x_1 & x_2 \\ x_3 & x_4 \end{bmatrix}, x_1 - x_2 + x_3 - x_4 = 0\}$$

$$V_2 = \text{span}(B_1, B_2), B_1 = \begin{bmatrix} 1 & 0 \\ 1 & 3 \end{bmatrix}, B_2 = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix}$$

试将 $V + V_2$ 表示为生成子空间，并求它的一个基与维数.


解 先将 V_1 表为生成子空间的形式, 容易求

得方程 $x_1 - x_2 + x_3 - x_4 = 0$ 的基础解系为

$$\alpha_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \\ 0 \end{bmatrix}, \alpha_2 = \begin{bmatrix} -1 \\ 0 \\ 1 \\ 0 \end{bmatrix}, \alpha_3 = \begin{bmatrix} 1 \\ 0 \\ 0 \\ 1 \end{bmatrix}$$

它们对应着 V_1 的一个基

$$A_1 = \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix}, A_2 = \begin{bmatrix} -1 & 0 \\ 1 & 0 \end{bmatrix}, A_3 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$




于是 $V_1 = \text{span}(A_1, A_2, A_3)$, 从而有

$$V_1 + V_2 = \text{span}(A_1, A_2, A_3, B_1, B_2)$$

显然矩阵 B_1, B_2 对应的向量为

$$\beta_1 = \begin{bmatrix} 1 \\ 0 \\ 1 \\ 3 \end{bmatrix}, \quad \beta_2 = \begin{bmatrix} 1 \\ -1 \\ 0 \\ 1 \end{bmatrix}.$$



容易求得 $\alpha_1, \alpha_2, \alpha_3, \beta_1, \beta_2$ 的一个极大无关组为

$$\alpha_1, \alpha_2, \alpha_3, \beta_1,$$

所以矩阵 A_1, A_2, A_3, B_1, B_2 的一个极大无关组为

$$A_1, A_2, A_3, B_1,$$

它们即为 $V_1 + V_2$ 的一个基,

且 $\dim(V_1 + V_2) = 4$.


□



§ 1.4 线性映射与线性变换

定义1.8 设 S 和 T 是任意两个非空集合，如果存在某个对应关系 σ ，使 $\forall s \in S$ 在 T 中存在唯一的元素 t 与 s 相对应，则称此 σ 是 S 到 T 的一个映射，记为 $\sigma: s \rightarrow t$ ，或 $\sigma(s) = t$ ，称 t 为 s 在 σ 之下的像，而 s 为 t 在 σ 之下的一个原像。

如果对应关系 σ 是映射，它应该满足
(1) S 中任一元素都有像；(2)像必在 T 中；(3)且像惟一。




如果 $\sigma(S) = T$ ，即 T 中任一元素 t 在 σ 之下至少有一个原像， $s : \sigma(s) = t$ ，则称 σ 是 S 映到 T 的**满射**。

如果 $\forall s_1, s_2 \in S$ ，在 T 中的像同，即 $\sigma(s_1) = \sigma(s_2)$ 时必有 $s_1 = s_2$ ，则称 σ 是 S 映入 T 的**单射**。

如果 σ 既是**满射**又是**单射**，则说 σ 是 S 到 T 的**双射**或**一一对应**。

满射 单射 双射






例1.19


$$\forall \alpha \in R^n, \alpha = (a_1, \dots, a_i, \dots, a_n)^T, \|\alpha\| = \sqrt{\sum_{i=1}^n a_i^2}$$

则 $\sigma: \alpha \rightarrow \|\alpha\|$ 是 R^n 映入 R 的映射. 因为不同的向量可以有相同的长度, 所以 σ 不是单射, 由于 $\|\alpha\| \geq 0$, 即任一向量的长度不会是负数, 也就是说负数无原像, 所以 σ 不是满射.



■ 例1.20 $\forall A \in R^{n \times n}$, $\sigma : A \rightarrow \det A$,

因为不同的矩阵的行列式可以相等, 所以 σ 不是单射; 对一任一实数 k , 一定存在一对角阵 $D = \text{diag}(1, 1, \dots, k)$, 使 $\det D = k$, 所以 σ 是 $R^{n \times n} \rightarrow R$ 的满射.



定义1.9 若 S 到 T 的映射 σ 满足

$$\forall s_1, s_2 \in S \text{ 有 } \sigma(s_1 + s_2) = \sigma(s_1) + \sigma(s_2);$$

$$\forall s \in S, \forall k \in F, \text{ 有 } \sigma(ks) = k\sigma(s),$$

则称 σ 是从 S 到 T 的线性映射.

例1.21 映射

$$\sigma: P[x]_{n+1} \rightarrow P[x]_n, \forall f(x) \in P[x]_{n+1}, \sigma(f(x)) = \frac{d}{dx} f(x)$$

是线性映射，即多项式求导运算是线性映射。

例1.22 映射

$$\sigma: P[x]_n \rightarrow P[x]_{n+1}, \forall f(x) \in P[x]_n, \sigma(f(x)) = \int_0^x \frac{d}{dt} f(t)$$


是线性映射，即多项式积分运算是线性映射。

例1.23 映射

$$\forall A \in R^{n \times n}, \sigma: A \rightarrow \det A$$

不是线性映射。

- 定理1.9 设 $\sigma: V(F) \rightarrow U(F)$ 是线性映射, 则
 - (1) $\sigma(\theta_V) \rightarrow \theta_U$, 即 V 中的零元素映成 U 中的零元素.
 - (2) $\sigma(-\alpha) = -\sigma(\alpha)$
 - (3) σ 将 $V(F)$ 中的线性相关的向量组映射为 $U(F)$ 中的线性相关向量组, 但将线性无关的向量组不一定映射为 $U(F)$ 中的线性无关向量组.
 - (4) 设 $V_1(F)$ 是 $V(F)$ 的子空间, 令 $\sigma(V_1(F)) = \{\sigma(\alpha) \mid \alpha \in V_1(F)\}$ 则 $\sigma(V_1(F))$ 是 $U(F)$ 的子空间, 称为 $V_1(F)$ 的像空间, 也叫 $V_1(F)$ 的值域. 且有 $\dim \sigma(V_1(F)) \leq \dim V_1(F)$




定义1.10 线性空间 $V(F)$ 到自身的线性映射
称为 $V(F)$ 中的线性变换，记为 $\mathcal{A}$.

若 $\mathcal{A}_1, \mathcal{A}_2$ 都是 $V_n(F)$ 中的线性变换，

$\forall \alpha \in V_n(F), \mathcal{A}_1(\alpha) = \mathcal{A}_2(\alpha)$ 则说 $\mathcal{A}_1, \mathcal{A}_2$ 相等，记
为 $\mathcal{A}_1 = \mathcal{A}_2$. 易见 $\mathcal{A}_1 = \mathcal{A}_2$ 的充分必要条件
为 $\mathcal{A}_1(\varepsilon_i) = \mathcal{A}_2(\varepsilon_i), i = 1, 2, \dots, n$

其中 $\varepsilon_1, \dots, \varepsilon_i, \dots, \varepsilon_n$ 为 $V_n(F)$ 的基.



- $\forall k \in F, \forall \alpha \in V_n(F)$, 定义 $\mathcal{A}(\alpha) = k\alpha$

易证 $\mathcal{A}$ 是线性变换, 称 $\mathcal{A}$ 为由数所决定的数乘变换, 几何上表示像 $\mathcal{A}(\alpha)$ 与 α 共线.
当 $k=1$, 称为恒等变换, 记为 $\mathcal{E}$,
即 $\mathcal{E}(\alpha) = \alpha$; 当 $k=0$, 称为零变换, 记为 $\mathcal{O}$, 即 $\mathcal{O}(\alpha) = \theta$.

定义1.11 设 $\mathcal{A}_1, \mathcal{A}_2$ 为 $V_n(F)$ 中的线性变换,

$\forall k \in F, \forall \alpha \in V_n(F)$, 定义 $(\mathcal{A}_1 + \mathcal{A}_2)(\alpha) = \mathcal{A}_1(\alpha) + \mathcal{A}_2(\alpha)$


称 $\mathcal{A}_1 + \mathcal{A}_2$ 为线性变换 $\mathcal{A}_1$ 与 $\mathcal{A}_2$ 的和.

定义 $(k\mathcal{A})(\alpha) = k\mathcal{A}(\alpha)$

称 $k\mathcal{A}$ 为 k 与线性变换 $\mathcal{A}$ 的数量乘积.


记 $(-1)\mathcal{A} = -\mathcal{A}$, 称 $-\mathcal{A}$ 是 $\mathcal{A}$ 的负变换,

显然 $\mathcal{A} + (-\mathcal{A}) = \mathcal{O}$.



定义 $(\mathcal{A}_1\mathcal{A}_2)(\alpha) = \mathcal{A}_1(\mathcal{A}_2(\alpha))$, 称 $\mathcal{A}_1\mathcal{A}_2$ 为线性变换 $\mathcal{A}_1$ 与 $\mathcal{A}_2$ 的积. 线性变换的乘积**不满足交换律**.


易证 $\mathcal{A}_1 + \mathcal{A}_2, k\mathcal{A}, \mathcal{A}_1\mathcal{A}_2$ 都是线性变换.



■ **线性变换**的**加法**与**数乘**有如下性质:


- ① 交换律 $\mathcal{A}_1 + \mathcal{A}_2 = \mathcal{A}_2 + \mathcal{A}_1$
- ② 结合律 $(\mathcal{A}_1 + \mathcal{A}_2) + \mathcal{A}_3 = \mathcal{A}_1 + (\mathcal{A}_2 + \mathcal{A}_3)$
- ③ 零元素 $\mathcal{A} + \mathcal{O} = \mathcal{A}$
- ④ 负元素 $\mathcal{A} + (-\mathcal{A}) = \mathcal{O}$
- ⑤ 1 数乘 $1\mathcal{A} = \mathcal{A}$
- ⑥ 数结合 $k(l\mathcal{A}) = (kl)\mathcal{A}$
- ⑦ 分配律 $(k+l)\mathcal{A} = k\mathcal{A} + l\mathcal{A}$
- ⑧ 分配律 $k(\mathcal{A}_1 + \mathcal{A}_2) = k\mathcal{A}_1 + k\mathcal{A}_2$

由定义1.1知 $V_n(F)$ 上**所有线性变换的集合**构成一个
线性空间, 记为**End**(V)



定义1.12 设 $\mathcal{A}$ 为 $V_n(F)$ 中的线性变换, 若存在 $V_n(F)$ 的变换 $\mathcal{B}$, 使 $\mathcal{A}\mathcal{B} = \mathcal{B}\mathcal{A} = \mathcal{E}$, 则称变换 $\mathcal{B}$ 为 $\mathcal{A}$ 的逆变换, 此时称 $\mathcal{A}$ 为可逆线性变换.

易证若线性变换 $\mathcal{A}$ 可逆, 则其逆变换惟一, 将其记为 $\mathcal{A}^{-1}$, 且可证 $\mathcal{A}^{-1}$ 也是线性变换.



线性变换 $\mathcal{A}$ 的值域与核


定义1.13 设 $\mathcal{A}$ 为 $V_n(F)$ 中的线性变换，将

$$\mathcal{A}(V_n(F)) = \{\mathcal{A}(\alpha) \mid \alpha \in V_n(F)\}$$

$$\mathcal{A}^{-1}(\theta) = \{\alpha \in V_n(F) \mid \mathcal{A}(\alpha) = \theta\}$$

分别称为 $\mathcal{A}$ 的值域与核.

为了与矩阵 A 的值域与核相对应，也将线性变换 $\mathcal{A}$ 的值域与核分别记为 $R(\mathcal{A})$, $N(\mathcal{A})$.



定理1.10 设 $\mathcal{A}$ 为 $V_n(F)$ 中的线性变换, 则 $\mathcal{A}$ 的**值域** $R(\mathcal{A})$ 与 **核** $N(\mathcal{A})$ 都是 $V_n(F)$ 的**子空间**.

定义1.14 设 $\mathcal{A}$ 为 $V_n(F)$ 中的线性变换, 称 $\mathcal{A}(V_n(F))$ 的**维数** 为 $\mathcal{A}$ 的**秩**, 称 $\mathcal{A}^{-1}(\theta)$ 的**维数** 为 $\mathcal{A}$ 的**零度**.

线性变换值域与核的维数公式

定理1.11 设 $\mathcal{A}$ 为 $V_n(F)$ 中的线性变换, 则

$$\dim \mathcal{A}(V_n(F)) + \dim \mathcal{A}^{-1}(\theta) = n$$

证 设 $\dim \mathcal{A}^{-1}(\theta) = r$, $\epsilon_1, \epsilon_2, \dots, \epsilon_r$ 为 $\mathcal{A}^{-1}(\theta)$ 中的一组基, 将其扩充为 $V_n(F)$ 的基 $\epsilon_1, \epsilon_2, \dots, \epsilon_r, \epsilon_{r+1}, \dots, \epsilon_n$.

$\forall \alpha \in \mathcal{A}(V_n(F))$, 设

$$\alpha = k_1 \epsilon_1 + \dots + k_r \epsilon_r + k_{r+1} \epsilon_{r+1} + \dots + k_n \epsilon_n$$

$$\begin{aligned} \text{则 } \mathcal{A}(\alpha) &= k_1 \mathcal{A}(\epsilon_1) + \dots + k_r \mathcal{A}(\epsilon_r) + k_{r+1} \mathcal{A}(\epsilon_{r+1}) + \dots + k_n \mathcal{A}(\epsilon_n) \\ &= k_{r+1} \mathcal{A}(\epsilon_{r+1}) + \dots + k_n \mathcal{A}(\epsilon_n) \end{aligned}$$

于是 $\mathcal{A}(\alpha) \in \text{span}(\mathcal{A}(\varepsilon_{r+1}), \dots, \mathcal{A}(\varepsilon_n))$,

所以 $\mathcal{A}(V_n(F)) \subset \text{span}(\mathcal{A}(\varepsilon_{r+1}), \dots, \mathcal{A}(\varepsilon_n))$,

显然 $\mathcal{A}(V_n(F)) \supset \text{span}(\mathcal{A}(\varepsilon_{r+1}), \dots, \mathcal{A}(\varepsilon_n))$,

因此 $\mathcal{A}(V_n(F)) = \text{span}(\mathcal{A}(\varepsilon_{r+1}), \dots, \mathcal{A}(\varepsilon_n))$.

以下只需证明 $\mathcal{A}(\varepsilon_{r+1}), \dots, \mathcal{A}(\varepsilon_n)$ 线性无关

考虑线性表达式

$$c_{r+1}\mathcal{A}(\varepsilon_{r+1}) + c_{r+2}\mathcal{A}(\varepsilon_{r+2}) + \dots + c_n\mathcal{A}(\varepsilon_n) = \theta \quad (*)$$

则有 $\mathcal{A}(c_{r+1}\varepsilon_{r+1} + c_{r+2}\varepsilon_{r+2} + \dots + c_n\varepsilon_n) = \theta$.

因此可得 $c_{r+1}\epsilon_{r+1} + c_{r+2}\epsilon_{r+2} + \dots + c_n\epsilon_n \in \mathcal{A}^{-1}(\theta)$.

故存在常数 $c_1, c_2, \dots, c_r$, 使

$$c_{r+1}\epsilon_{r+1} + c_{r+2}\epsilon_{r+2} + \dots + c_n\epsilon_n = c_1\epsilon_1 + c_2\epsilon_2 + \dots + c_r\epsilon_r.$$

因为 $\epsilon_1, \epsilon_2, \dots, \epsilon_r, \epsilon_{r+1}, \dots, \epsilon_n$ 是 $V_n(F)$ 的基, 必有

$$c_{r+1} = c_{r+2} = \dots = c_n = 0.$$

由(*)式可知 $\mathcal{A}(\epsilon_{r+1}), \dots, \mathcal{A}(\epsilon_n)$ 线性无关.

这表明 $\dim \mathcal{A}(V_n(F)) = n - r$.

由 $\dim \mathcal{A}^{-1}(\theta) = r$ 立得

$$\dim \mathcal{A}(V_n(F)) + \dim \mathcal{A}^{-1}(\theta) = n.$$

即 $\mathcal{A}$ 的秩 + $\mathcal{A}$ 的零度 = n .

线性变换的表示矩阵


定义1.15 设 $\mathcal{A}$ 是 $V_n(F)$ 上的线性变换, $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 是 $V_n(F)$ 的基, 于是 $\mathcal{A}(\varepsilon_1), \mathcal{A}(\varepsilon_2), \dots, \mathcal{A}(\varepsilon_n)$ 可由基 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 线性表示, 且表法惟一.

$$\begin{aligned} \text{设 } \mathcal{A}(\varepsilon_1) &= a_{11}\varepsilon_1 + a_{21}\varepsilon_2 + \dots + a_{n1}\varepsilon_n \\ \mathcal{A}(\varepsilon_2) &= a_{12}\varepsilon_1 + a_{22}\varepsilon_2 + \dots + a_{n2}\varepsilon_n \end{aligned} \quad (1.8)$$

.....

$$\mathcal{A}(\varepsilon_n) = a_{1n}\varepsilon_1 + a_{2n}\varepsilon_2 + \dots + a_{nn}\varepsilon_n$$


令 $A = (a_{ij})_{n \times n}$, 称 A 为线性变换 $\mathcal{A}$ 在基 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 下的表示矩阵.

- 
- 将式(1.8)形式上写成


$$\mathcal{A}(\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n) = (\mathcal{A}(\varepsilon_1), \mathcal{A}(\varepsilon_2), \dots, \mathcal{A}(\varepsilon_n)) = (\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n)A \quad (1.9)$$

这样给定一组基 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ ，由式(1.8)知，线性变换 $\mathcal{A}$ 可惟一确定方阵 A ；反之，给定一个方阵 A ，在基 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 下可惟一确定一个线性变换 $\mathcal{A}$ 。

由式(1.9)容易证明在基 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 下线性变换的表示矩阵 A 有如下的性质：



- 线性变换的和对应于表示矩阵的和；
- 线性变换的乘积对应于表示矩阵的乘积；
- 线性变换的数乘对应于表示矩阵的数乘；
- 可逆的线性变换的表示矩阵可逆，且
逆变换对应于逆矩阵。



即

$$(\mathcal{A} + \mathcal{B})(\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n) = (\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n)(\mathcal{A} + \mathcal{B})$$

$$(\mathcal{A}\mathcal{B})(\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n) = (\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n)(\mathcal{A}\mathcal{B})$$

$$(k\mathcal{A})(\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n) = (\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n)(k\mathcal{A})$$


$$\mathcal{A}^{-1}(\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n) = (\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n)\mathcal{A}^{-1}$$

变换前后向量的坐标之间的关系

定理1.12 设线性变换 $\mathcal{A}$ 在基 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 下的表示矩阵为 A ，向量 α 在基 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 下的坐标为 $(x_1, x_2, \dots, x_n)^T$ ， $\mathcal{A}(\alpha)$ 在此基下的坐标为 $(y_1, y_2, \dots, y_n)^T$ ，则

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = A \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \quad (1.10)$$

■ 证 因为 $\alpha = \sum_{i=1}^n x_i \varepsilon_i$, 所以


$$\mathcal{A}(\alpha) = \mathcal{A}\left(\sum_{i=1}^n x_i \varepsilon_i\right) = \sum_{i=1}^n x_i \mathcal{A}(\varepsilon_i)$$

$$= (\mathcal{A}(\varepsilon_1), \mathcal{A}(\varepsilon_2), \dots, \mathcal{A}(\varepsilon_n)) \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

$$= (\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n) \mathcal{A} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$




又因为 $\mathcal{A}(\alpha) = \sum_{i=1}^n y_i \varepsilon_i = (\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n) \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$

由 $\mathcal{A}(\alpha)$ 在基 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 下坐标的惟一性得

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = A \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}.$$






线性变换在两组基下的表示矩阵的关系

定理1.13 设 $\alpha_1, \alpha_2, \dots, \alpha_n$; $\beta_1, \beta_2, \dots, \beta_n$ 为线性空间 $V_n(F)$ 的两组基, 它们之间的过渡矩阵为 P , $V_n(F)$ 中的线性变换 $\mathcal{A}$ 在这两组基下的表示矩阵分别为 A 和 B , 则

$$B = P^{-1}AP \quad (1.11)$$



证 由已知条件有


$$\mathcal{A}(\alpha_1, \alpha_2, \dots, \alpha_n) = (\alpha_1, \alpha_2, \dots, \alpha_n)A,$$

$$\mathcal{A}(\beta_1, \beta_2, \dots, \beta_n) = (\beta_1, \beta_2, \dots, \beta_n)B.$$

基变换公式为

$$(\beta_1, \beta_2, \dots, \beta_n) = (\alpha_1, \alpha_2, \dots, \alpha_n)P.$$


$$\text{故 } (\alpha_1, \alpha_2, \dots, \alpha_n) = (\beta_1, \beta_2, \dots, \beta_n)P^{-1}.$$



$$\begin{aligned}
 \text{于是有 } (\beta_1, \beta_2, \dots, \beta_n) B &= \mathcal{A}(\beta_1, \beta_2, \dots, \beta_n) \\
 &= \mathcal{A}[(\alpha_1, \alpha_2, \dots, \alpha_n) P] \\
 &= [\mathcal{A}(\alpha_1, \alpha_2, \dots, \alpha_n)] P \\
 &= [(\alpha_1, \alpha_2, \dots, \alpha_n) A] P \\
 &= (\alpha_1, \alpha_2, \dots, \alpha_n) A P \\
 &= (\beta_1, \beta_2, \dots, \beta_n) P^{-1} A P
 \end{aligned}$$

由于在这个基下线性变换 $\mathcal{A}$ 的表示矩阵是唯一的
故 $B = P^{-1} A P$. ■

定理1.13 表示在线性空间 $V_n(F)$ 中，线性变换在不同基下的表示矩阵是相似的，其相似变换矩阵是相应的过渡矩阵。



■ 例1.31 $\mathcal{A}$ 是 $R^{2 \times 2}$ 上的线性变换, $\forall M \in R^{2 \times 2}$
有 $\mathcal{A}(M) = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} M$, 求 $\mathcal{A}$ 在基

$$A_1 = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}, A_2 = \begin{bmatrix} -1 & 1 \\ 0 & 0 \end{bmatrix}, A_3 = \begin{bmatrix} -1 & 0 \\ 1 & 0 \end{bmatrix}, A_4 = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix},$$

下的表示矩阵 A .

解 第一步:


求基 A_j 的像 $\mathcal{A}(A_j)$, $j = 1, 2, 3, 4$.

$$\mathcal{A}(A_1) = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix},$$

$$\mathcal{A}(A_2) = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} -1 & 1 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} -1 & 1 \\ 0 & 0 \end{bmatrix},$$

$$\mathcal{A}(A_3) = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} -1 & 0 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} -1 & 0 \\ -1 & 0 \end{bmatrix},$$

$$\mathcal{A}(A_4) = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} -1 & 0 \\ 0 & -1 \end{bmatrix}.$$




第二步：

将 A_j 横排竖放得到的列向量
记为 $\varepsilon_j, j = 1, 2, 3, 4$.

于是有

$$\varepsilon_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}, \varepsilon_2 = \begin{bmatrix} -1 \\ 1 \\ 0 \\ 0 \end{bmatrix}, \varepsilon_3 = \begin{bmatrix} -1 \\ 0 \\ 1 \\ 0 \end{bmatrix}, \varepsilon_4 = \begin{bmatrix} -1 \\ 0 \\ 0 \\ 1 \end{bmatrix}.$$



将像 $\mathcal{A}(A_j)$ 横排竖放得到的列向量
记为 $\eta_j, j=1,2,3,4$.

于是有

$$\eta_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}, \eta_2 = \begin{bmatrix} -1 \\ 1 \\ 0 \\ 0 \end{bmatrix}, \eta_3 = \begin{bmatrix} -1 \\ 0 \\ -1 \\ 0 \end{bmatrix}, \eta_4 = \begin{bmatrix} -1 \\ 0 \\ 0 \\ -1 \end{bmatrix}.$$




第三步：写出基像、基、表示矩阵的相关算式.

$$\mathcal{A}(A_j) = \sum_{i=1}^4 a_{ij} A_i = (A_1, A_2, A_3, A_4) \begin{bmatrix} a_{1j} \\ a_{2j} \\ a_{3j} \\ a_{4j} \end{bmatrix}, \quad j = 1, 2, 3, 4$$

$$(\mathcal{A}(A_1), \mathcal{A}(A_2), \mathcal{A}(A_3), \mathcal{A}(A_4)) = (A_1, A_2, A_3, A_4)A,$$

其中 $A = (a_{ij})_{4 \times 4}$.


$$(\eta_1, \eta_2, \eta_3, \eta_4) = (\varepsilon_1, \varepsilon_2, \varepsilon_3, \varepsilon_4)A.$$



第四步：求 $\mathcal{A}$ 在基 A_1, A_2, A_3, A_4 下的表示矩阵 A .


$$A = (\varepsilon_1, \varepsilon_2, \varepsilon_3, \varepsilon_4)^{-1} (\eta_1, \eta_2, \eta_3, \eta_4)$$

$$= \begin{bmatrix} 1 & -1 & -1 & -1 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}^{-1} \begin{bmatrix} 1 & -1 & -1 & -1 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & -1 & 0 \\ 0 & 0 & 0 & -1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & -2 & -2 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & -1 & 0 \\ 0 & 0 & 0 & -1 \end{bmatrix}. \square$$



定义1.16 设 $\mathcal{A}$ 是线性空间 $V_n(\mathbb{C})$ 上的线性变换, 对于 $\lambda \in \mathbb{C}$, 若存在非零向量 $\xi \in V_n(\mathbb{C})$, 使得, $\mathcal{A}\xi = \lambda\xi$ (为简单记 $\mathcal{A}\xi = \mathcal{A}(\xi)$) 则称 λ 为线性变换 $\mathcal{A}$ 的特征值, ξ 为 $\mathcal{A}$ 的属于特征值 λ 的特征向量.

由定义可知, 几何上表示特征向量的像 $\mathcal{A}\xi$ 与 ξ 共线.




设 $\boldsymbol{\varepsilon}_1, \boldsymbol{\varepsilon}_2, \dots, \boldsymbol{\varepsilon}_n$ 是线性空间 $V_n(\mathbf{C})$ 的基, 线性变换 $\mathcal{A}$ 在该基下的表示矩阵为 $A = (a_{ij})_{n \times n} \in \mathbf{C}^{n \times n}$. 于是有

$$\boldsymbol{\xi} = \sum_{i=1}^n x_i \boldsymbol{\varepsilon}_i = (\boldsymbol{\varepsilon}_1, \dots, \boldsymbol{\varepsilon}_i, \dots, \boldsymbol{\varepsilon}_n) \begin{bmatrix} x_1 \\ \vdots \\ x_i \\ \vdots \\ x_n \end{bmatrix}$$


令 $\boldsymbol{x} = (x_1, \dots, x_i, \dots, x_n)^T$, 则 $\boldsymbol{\theta} \neq \boldsymbol{x} \in \mathbf{C}^n$.

因而



$$\mathcal{A}\xi = \mathcal{A}(\xi) = \sum_{i=1}^n x_i \mathcal{A}(\varepsilon_i) = (\mathcal{A}(\varepsilon_1), \dots, \mathcal{A}(\varepsilon_i), \dots, \mathcal{A}(\varepsilon_n)) \begin{bmatrix} x_1 \\ \vdots \\ x_i \\ \vdots \\ x_n \end{bmatrix}$$


$$= (\varepsilon_1, \dots, \varepsilon_i, \dots, \varepsilon_n) \mathcal{A} \begin{bmatrix} x_1 \\ \vdots \\ x_i \\ \vdots \\ x_n \end{bmatrix}.$$



另一方面


$$\lambda \xi = \lambda \sum_{i=1}^n x_i \varepsilon_i = (\varepsilon_1, \dots, \varepsilon_i, \dots, \varepsilon_n) \lambda \begin{bmatrix} x_1 \\ \vdots \\ x_i \\ \vdots \\ x_n \end{bmatrix}.$$

由 $A\xi = \lambda\xi$ 得


$$(\varepsilon_1, \dots, \varepsilon_i, \dots, \varepsilon_n) A \begin{bmatrix} x_1 \\ \vdots \\ x_i \\ \vdots \\ x_n \end{bmatrix} = (\varepsilon_1, \dots, \varepsilon_i, \dots, \varepsilon_n) \lambda \begin{bmatrix} x_1 \\ \vdots \\ x_i \\ \vdots \\ x_n \end{bmatrix}.$$


由 $A\xi$ 在基 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 下坐标的唯一性有

$$A \begin{bmatrix} x_1 \\ \vdots \\ x_i \\ \vdots \\ x_n \end{bmatrix} = \lambda \begin{bmatrix} x_1 \\ \vdots \\ x_i \\ \vdots \\ x_n \end{bmatrix}, \text{ 即 } Ax = \lambda x, \quad x \neq \theta.$$



■ 三点结论:

- ① 线性变换 $\mathcal{A}$ 的特征值 λ 即为它在基 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 下的表示矩阵 A 的特征值;
- ② 线性变换 $\mathcal{A}$ 的属于特征值 λ 的特征向量 ξ 在基 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 下的坐标向量 x , 即为线性变换 $\mathcal{A}$ 在此基下的表示矩阵 A 的属于特征值 λ 的特征向量.
- ③ 线性变换 $\mathcal{A}$ 的特征值 λ 为不变量.



■ 设 $V_n(F)$ 中的线性变换 $\mathcal{A}$ 在两组基 $\alpha_1, \alpha_2, \dots, \alpha_n; \beta_1, \beta_2, \dots, \beta_n$ 下的表示矩阵分别为 A 和 B ，过渡矩阵为 P ，由定理1.13知 $B = P^{-1}AP$ ，即 A 与 B 相似，故它们有相同的特征值 λ 。若线性变换 $\mathcal{A}$ 的特征向量 ξ 在两组基下的坐标向量分别为 $x = (x_1, x_2, \dots, x_n)^T$ 与 $y = (y_1, y_2, \dots, y_n)^T$ 则

$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = P \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \quad \text{或} \quad \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = P^{-1} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

定义1.17 设 $\sigma: V_n(F) \rightarrow U_m(F)$ 是线性映射, 且

① $\sigma(V_n(F)) = U_m(F)$;

② 对 $\forall \alpha_1, \alpha_2 \in V_n(F)$ 若 $\sigma(\alpha_1) = \sigma(\alpha_2)$, 则 $\alpha_1 = \alpha_2$.

那么称 σ 为 $V_n(F)$ 与 $U_m(F)$ 之间的一个同构映射.

① 表示 σ 是满射;


② 表示 σ 是单射;

两者结合表明 σ 是双射.

因此双射的线性映射即是同构映射.

称 $V_n(F)$ 与 $U_m(F)$ 为同构的线性空间,

简称 $V_n(F)$ 与 $U_m(F)$ 同构. 记为 $V_n(F) \cong U_m(F)$.



定理1.14 线性空间 $V_n(F)$ 与 $U_m(F)$ 同构的
充要条件是 $n = m$.

证 先证必要性

设 $V_n(F)$ 与 $U_m(F)$ 同构, 则存在同构映射 σ ,
使 $\sigma(V_n(F)) = U_m(F)$.

令 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 为 $V_n(F)$ 的基, 易知

$$U_m(F) = \text{span}(\sigma(\varepsilon_1), \sigma(\varepsilon_2), \dots, \sigma(\varepsilon_n)).$$

以下证 $\sigma(\varepsilon_1), \sigma(\varepsilon_2), \dots, \sigma(\varepsilon_n)$ 线性无关.

考虑线性表达式

$$k_1\sigma(\varepsilon_1) + \dots + k_i\sigma(\varepsilon_i) + \dots + k_n\sigma(\varepsilon_n) = \theta_U$$

有 $\sigma(k_1\varepsilon_1) + \dots + \sigma(k_i\varepsilon_i) + \dots + \sigma(k_n\varepsilon_n) = \theta_U.$

即 $\sigma(k_1\varepsilon_1 + \dots + k_i\varepsilon_i + \dots + k_n\varepsilon_n) = \theta_U.$

因为 σ 是同构映射由 $\sigma(\theta_V) = \theta_U$ 得

$$k_1\varepsilon_1 + \dots + k_i\varepsilon_i + \dots + k_n\varepsilon_n = \theta_V$$

因此 $k_1 = \dots = k_i = \dots = k_n = 0$, 由(*)知

$\sigma(\varepsilon_1), \sigma(\varepsilon_2), \dots, \sigma(\varepsilon_n)$ 线性无关.

故 $\dim U_m(F) = n$, 所以 $m = n$.




再证充分性

设 $n = m$; 且 $\epsilon_1, \epsilon_2, \dots, \epsilon_n$ 与 $\eta_1, \eta_2, \dots, \eta_n$ 分别为 $V_n(F)$ 与 $U_n(F)$ 的基.

对 $\forall \alpha \in V_n(F)$, $\exists x_1, x_2, \dots, x_n \in F$, 使

$$\alpha = \sum_{i=1}^n x_i \epsilon_i, \text{ 令 } \sigma(\alpha) = \sum_{i=1}^n x_i \eta_i$$

以下证明 σ 为 $V_n(F)$ 到 $U_n(F)$ 的同构映射.



先证 σ 是线性映射.


$$\forall \alpha, \beta \in V_n(F), \forall k \in F, \alpha = \sum_{i=1}^n x_i \epsilon_i, \beta = \sum_{i=1}^n y_i \epsilon_i.$$

$$\alpha + \beta = \sum_{i=1}^n (x_i + y_i) \epsilon_i, \quad k\alpha = k \sum_{i=1}^n x_i \epsilon_i = \sum_{i=1}^n (kx_i) \epsilon_i$$

$$\boxed{\sigma(\alpha + \beta)} = \sum_{i=1}^n (x_i + y_i) \eta_i = \sum_{i=1}^n x_i \eta_i + \sum_{i=1}^n y_i \eta_i = \boxed{\sigma(\alpha) + \sigma(\beta)}$$

$$\boxed{\sigma(k\alpha)} = \sum_{i=1}^n (kx_i) \eta_i = k \sum_{i=1}^n x_i \eta_i = \boxed{k\sigma(\alpha)}$$

可见 σ 是线性映射.




再证 σ 是双射

① $\forall \tilde{\alpha} \in U_n(F), \exists x_1, x_2, \dots, x_n \in F$, 使

$$\tilde{\alpha} = \sum_{i=1}^n x_i \eta_i.$$

令 $\sum_{i=1}^n x_i \varepsilon_i = \alpha$, 则 $\alpha \in V_n(F)$,

且 $\sigma(\alpha) = \tilde{\alpha}$, 即 $\tilde{\alpha}$ 有原像 α . 这说明 σ 是满射.



$$\textcircled{2} \forall \alpha_1, \alpha_2 \in V_n(F), \alpha_1 = \sum_{i=1}^n a_i \varepsilon_i, \alpha_2 = \sum_{i=1}^n b_i \varepsilon_i,$$

$$a_i, b_i \in F; i = 1, 2, \dots, n.$$

$$\text{于是 } \sigma(\alpha_1) = \sum_{i=1}^n a_i \eta_i, \sigma(\alpha_2) = \sum_{i=1}^n b_i \eta_i.$$


$$\text{若 } \sigma(\alpha_1) = \sigma(\alpha_2), \text{ 有 } \sum_{i=1}^n a_i \eta_i = \sum_{i=1}^n b_i \eta_i$$

因为 $\eta_1, \eta_2, \dots, \eta_n$ 是 $U_n(F)$ 的基, 故 $a_i = b_i, i = 1, 2, \dots, n.$

所以 $\alpha_1 = \alpha_2$, 这说明 σ 是单射.

综上所述由定义1.17知 $V_n(F)$ 与 $U_n(F)$ 同构.





由**定理1.14**易得以下结果.

例1.32 $V_n(F)$ 与 F^n **同构**, $V_n(R)$ 与 R^n **同构**.

实数域上的 $m \times n$ **矩阵**全体所组成的**线性空间** $R^{m \times n}$
与实数域上 mn **维向量**的全体所组成的**线性空间** R^{mn} **同构**.

特别对于**2阶方阵**与**4维向量**有 $R^{2 \times 2}$ 与 R^4 **同构**.

例1.33 求线性空间 $V_n(F)$ 上一切线性变换
所组成的线性空间 $\text{End}(V)$ 的一个基与维数.

解：方法一

设 $\varepsilon_1, \dots, \varepsilon_k, \dots, \varepsilon_n$ 是 $V_n(F)$ 的一组基. 则存在
线性变换 $\mathcal{E}_{ij} \in \text{End}(V)$, 使

$$\mathcal{E}_{ij}(\varepsilon_k) = \delta_{jk} \varepsilon_i, \quad i, j, k = 1, 2, \dots, n.$$


考虑线性表达式: $\sum_{i=1}^n \sum_{j=1}^n c_{ij} \mathcal{E}_{ij} = \mathcal{O}$, 其中 $c_{ij} \in F$.

上式两端对 ε_k 作线性变换, $k = 1, 2, \dots, n$.

$$\sum_{i=1}^n \sum_{j=1}^n c_{ij} \mathcal{E}_{ij}(\varepsilon_k) = \mathcal{O}(\varepsilon_k) = \theta.$$

$$\sum_{i=1}^n \sum_{j=1}^n c_{ij} \delta_{jk} \varepsilon_i = \theta.$$

$$\sum_{i=1}^n c_{ik} \varepsilon_i = \theta.$$



因为 $\varepsilon_1, \dots, \varepsilon_k, \dots, \varepsilon_n$ 线性无关, 所以
 $c_{ik} = 0; i, k = 1, 2, \dots, n$. 即 $c_{ij} = 0; i, j = 1, 2, \dots, n$
这说明 $\mathcal{E}_{ij} (i, j = 1, 2, \dots, n)$ 线性无关.

以下只要证出 $\forall \mathcal{A} \in \text{End}(V)$, $\mathcal{A}$ 可以表成
 $\mathcal{E}_{ij} (i, j = 1, 2, \dots, n)$ 的线性组合即可.

记 $\mathcal{A}(\varepsilon_k) = \sum_{i=1}^n a_{ik} \varepsilon_i$, $k = 1, 2, \dots, n$; $a_{ik} \in F$. 于是有

$$\left(\sum_{i=1}^n \sum_{j=1}^n a_{ij} \mathcal{E}_{ij} \right) (\varepsilon_k) = \sum_{i=1}^n \sum_{j=1}^n a_{ij} \delta_{jk} \varepsilon_i = \sum_{i=1}^n a_{ik} \varepsilon_i = \mathcal{A}(\varepsilon_k), \quad k = 1, 2, \dots, n$$

由于线性变换 $\sum_{i=1}^n \sum_{j=1}^n a_{ij} \mathcal{E}_{ij}$ 与线性变换 $\mathcal{A}$ 对于基

$\varepsilon_1, \dots, \varepsilon_k, \dots, \varepsilon_n$ 的变换相等, 故 $\mathcal{A} = \sum_{i=1}^n \sum_{j=1}^n a_{ij} \mathcal{E}_{ij}$.

从而证出 $\mathcal{A}$ 可以表成 $\mathcal{E}_{ij}$ ($i, j = 1, 2, \dots, n$) 的线性组合.

这表明 $\mathcal{E}_{ij}$ ($i, j = 1, 2, \dots, n$) 是 $\text{End}(V)$ 的一组基,

且有 $\dim \text{End}(V) = n^2$.

方法二（各种符号的含义同方法一）

(一) $\forall \mathcal{A} \in \text{End}(V), \exists A \in R^{n \times n}$, 使

$$\mathcal{A}(\varepsilon_1, \dots, \varepsilon_i, \dots, \varepsilon_j, \dots, \varepsilon_n) = (\varepsilon_1, \dots, \varepsilon_i, \dots, \varepsilon_j, \dots, \varepsilon_n)A \quad (*)$$

这里 A 为线性变换 $\mathcal{A}$ 在基 $\varepsilon_1, \dots, \varepsilon_i, \dots, \varepsilon_j, \dots, \varepsilon_n$ 下的表示矩阵.


$$\text{由 } \mathcal{E}_{ij}(\varepsilon_i) = \delta_{ji} \varepsilon_i = 0 \varepsilon_i = 0 \varepsilon_1 + \dots + 0 \varepsilon_i + \dots + 0 \varepsilon_j + \dots + 0 \varepsilon_n,$$

$$\mathcal{E}_{ij}(\varepsilon_j) = \delta_{jj} \varepsilon_i = 1 \varepsilon_i = 0 \varepsilon_1 + \dots + 1 \varepsilon_i + \dots + 0 \varepsilon_j + \dots + 0 \varepsilon_n$$

($i, j = 1, 2, \dots, n$), 于是有

$$\mathcal{E}_{ij}(\varepsilon_1, \dots, \varepsilon_i, \dots, \varepsilon_j, \dots, \varepsilon_n) = (\varepsilon_1, \dots, \varepsilon_i, \dots, \varepsilon_j, \dots, \varepsilon_n) E_{ij},$$

这里 $E_{ij} \in R^{n \times n}$, $E_{ij} = (e_{st})_{n \times n}$, 其中 $e_{st} = \begin{cases} 1, & s = i \text{ 且 } t = j; \\ 0, & \text{其余.} \end{cases}$ 122




(二). 构造映射 $\sigma(\mathcal{A}) = A$,

①由(*)知 σ 是线性映射;

②由线性变换 $\mathcal{A}$ 在基 $\varepsilon_1, \dots, \varepsilon_i, \dots, \varepsilon_j, \dots, \varepsilon_n$ 下的表示矩阵 A 惟一知 σ 是单射;

③由 $\sigma(\text{End}(V)) = R^{n \times n}$ 知 σ 是满射.

所以线性空间 $\text{End}(V)$ 与 $R^{n \times n}$ 同构.




(三).

因为 E_{ij} ($i, j = 1, 2, \dots, n$) 是 $R^{n \times n}$ 的基,

且 $\dim R^{n \times n} = n^2$,

所以 $\mathcal{E}_{ij}$ ($i, j = 1, 2, \dots, n$) 是 $\text{End}(V)$ 的基,


且 $\dim \text{End}(V) = n^2$. ■

- 
- 定义1.18 设 $\mathcal{A}$ 是 $V_n(F)$ 线性空间上的线性变换, $W(F)$ 是 $V_n(F)$ 的子空间, 若 $\mathcal{A}(W(F)) \subset W(F)$, 则称 $W(F)$ 是 $\mathcal{A}$ 的不变子空间, 简称 $\mathcal{A}$ 子空间.
 - 显然 $V_n(F)$ 的平凡子空间是任一线性变换的不变子空间; 任一子空间都是数乘变换的不变子空间; 特别也是恒等变换的不变子空间.
 - $P[x_m]$ 是 $P[x_n]$ ($m \leq n$) 关于求导变换的不变子空间; $\mathcal{A}$ 的特征值 λ 的特征子空间 V_λ 是 $\mathcal{A}$ 的不变子空间.
 - 线性变换 $\mathcal{A}$ 的值域与核都是 $\mathcal{A}$ 的不变子空间.

■ 重要结论:

$\mathcal{A}$ 是线性空间 $V_n(F)$ 上的线性变换, 设 $V_n(F)$ 分解为 s 个 $\mathcal{A}$ 的不变子空间的直和

$$V_n(F) = V_1 \oplus V_2 \oplus \dots \oplus V_s$$




设 $\varepsilon_{i1}, \varepsilon_{i2}, \dots, \varepsilon_{in_i}$ ($i=1, 2, \dots, s; \sum_{i=1}^s n_i = n$) 是**不变子空间** V_i 的**基**，将它们合并起来就是 $V_n(F)$ 的**基**。若 A_i 为 $\mathcal{A}$ 在**不变子空间** V_i 的**基** $\varepsilon_{i1}, \varepsilon_{i2}, \dots, \varepsilon_{in_i}$ 下的**表示矩阵**，则 $\mathcal{A}$ 在 $V_n(F)$ 的**基**

$$\varepsilon_{11}, \dots, \varepsilon_{1n_1}, \dots, \varepsilon_{i1}, \varepsilon_{i2}, \dots, \varepsilon_{in_i}, \dots, \varepsilon_{s1}, \dots, \varepsilon_{sn_s}$$

下的**表示矩阵**即为 $A = \text{diag}(A_1, \dots, A_i, \dots, A_s)$

表示矩阵为**分块对角阵**与**线性空间分解为不变子空间的直和**是**对应**的。




本章总结

一. 重要定义及概念


(一) 线性空间

- ① 线性子空间, 交空间, 和空间, 直和.
- ② 三个常用的线性空间, $R^{m \times n}$, $P[x]_n$, $C[a, b]$.
- ③ 三个复杂的线性空间, $R^2(\oplus \circ)$, R^+ , $\text{End}(V)$.
- ④ 矩阵的两个重要的线性空间
 矩阵的列空间 (值域), $R(A)$,
 矩阵的核空间 (零空间), $N(A)$.
- ⑤ 线性空间的基, 维数, 坐标.



(二) 线性映射与线性变换

- ① 映射 σ , 满射, 单射, 双射, 线性映射.
- ② 线性变换 $\mathcal{A}$, 恒等变换 $\mathcal{E}$, 零变换 $\mathcal{O}$.
- ③ 线性变换的运算: 加法, 数乘, 乘法, 逆变换.
- ④ 线性变换的值域 $\mathcal{A}(V_n(F))[\underline{R(\mathcal{A})}]$, 与核 $\mathcal{A}^{-1}(\mathbf{0})[\underline{N(\mathcal{A})}]$.
- ⑤ 线性变换的秩与零度.
- ⑥ 线性变换的特征值与特征向量.
- ⑦ 同构映射, 线性空间的同构.



二. 重要的定理, 公式.


① 基变换公式与坐标变换公式

$$(\beta_1, \beta_2, \dots, \beta_n) = (\alpha_1, \alpha_2, \dots, \alpha_n)P$$

$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = P \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

② 子空间维数定理

$$\dim V_1 + \dim V_2 = \dim(V_1 + V_2) + \dim(V_1 \cap V_2)$$



③ 子空间直和的四个等价命题.


④ 线性变换的秩与零度的关系:

$$\dim \mathcal{A}(V_n(F)) + \dim \mathcal{A}^{-1}(\theta) = n$$

⑤ 线性变换在两组基下的表示矩阵与过渡矩阵的关系:


$$B = P^{-1}AP$$

⑥ 线性空间 $V_n(F), U_m(F)$ 同构的充要条件: $m = n$.



三. 计算

- ① 两组基的过渡矩阵.
- ② 基与维数.
- ③ 线性变换在基下的表示矩阵.
- ④ 线性变换的特征值与特征向量.




矩阵分析教程

(电子版)

董增福

哈尔滨工业大学数学系



第二章 内积空间

核心内容

1. 欧氏空间与酉空间
2. 内积空间的度量
- 3 酉变换与**Hermite**变换
4. 正交子空间与正交投影

§ 2.1 欧氏空间与酉空间

定义2.1 设 V 是实数域 R 上的 n 维线性空间, 对任给的 $\alpha, \beta \in V$, 按某种法则对应着一个实数, 记为 (α, β) , 如果满足下面四个条件:

- ① **交换律** $(\alpha, \beta) = (\beta, \alpha)$;
- ② **齐次性** $(k\alpha, \beta) = k(\alpha, \beta)$, k 为任意实数;
- ③ **分配律** $(\alpha + \beta, \gamma) = (\alpha, \gamma) + (\beta, \gamma)$, $\gamma \in V$; (2.1)
- ④ **非负性** $(\alpha, \alpha) \geq 0$; $(\alpha, \alpha) = 0$, 当且仅当 $\alpha = \theta$.

则称实数 (α, β) 为定义在 V 上的内积, 定义了这样内积的 n 维线性空间 V 为 n 维欧几里得(Euclid)空间, 简称欧氏空间, 记为 $V_n(R, E)$.



三个重要的欧氏空间

例2.1 在 n 维线性空间 R^n 中,


$$\forall \alpha = (a_1, \cdots, a_i, \cdots, a_n)^T, \beta = (b_1, \cdots, b_i, \cdots, b_n)^T,$$

若规定

$$(\alpha, \beta) = \alpha^T \beta = \beta^T \alpha = \sum_{i=1}^n a_i b_i \quad (2.2)$$

则式(2.2)满足式(2.1), 故 R^n 是欧氏空间,
仍以 R^n 记之.


式(2.2)所定义的内积为 R^n 中向量的标准内积.



例2.2 对于 n^2 维线性空间 $\mathbf{R}^{n \times n}$ 中任意两个向量(即 n 阶方阵), 规定内积为

$$(\mathbf{A}, \mathbf{B}) = \text{tr}(\mathbf{A}^T \mathbf{B}) \quad (2.3)$$

可以验证 $\mathbf{R}^{n \times n}$ 为**欧氏空间**, 仍记之为 $\mathbf{R}^{n \times n}$.




例2.3 定义在闭区间 $[a,b]$ 上实连续函数的全体的线性空间 $C[a,b]$ 的内积为:

$\forall f(x), g(x) \in C[a,b]$ 规定

$$(f(x), g(x)) = \int_a^b f(x)g(x)dx \quad (2.4)$$

容易验证它满足内积的四个条件, 故式 (2.4) 是内积, $C[a,b]$ 是欧氏空间.



欧氏空间的内积有如下性质：


① $(\alpha, k\beta) = k(\alpha, \beta);$

② $(\alpha, \beta + \gamma) = (\alpha, \beta) + (\alpha, \gamma);$

③ $(\sum_{i=1}^r k_i \alpha_i, \sum_{j=1}^s l_j \beta_j) = \sum_{i=1}^r \sum_{j=1}^s k_i l_j (\alpha_i, \beta_j);$

其中 $k_i, l_j \in \mathbf{R}, \alpha_i, \beta_j \in V; i = 1, 2, \dots, r; j = 1, 2, \dots, s$

④ $(\alpha, \theta) = (\theta, \alpha) = 0.$



基的度量矩阵

定义2.2 设 V 是 n 维欧氏空间, $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$

是它的一个基, 令 $g_{ij} = (\varepsilon_i, \varepsilon_j)$, $G = (g_{ij})_{n \times n}$, 则称

G 为基 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 的度量矩阵(**Metric matrix**), 也称为基的Gram 矩阵.



定理2.1 设 A 为 n 维欧氏空间 V 的基 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 的度量矩阵, 则

① $A^T = A$, 即 A 是实对称矩阵;


② $\forall \alpha, \beta \in V$; α, β 在基 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 下的坐标分别为

$\mathbf{x} = (x_1, \dots, x_i, \dots, x_n)^T, \mathbf{y} = (y_1, \dots, y_i, \dots, y_n)^T$, 则

$$(\alpha, \beta) = \mathbf{x}^T A \mathbf{y}$$

③ $\theta \neq \forall \alpha \in V, \alpha = (\varepsilon_1, \dots, \varepsilon_n) \mathbf{x}$, 必有 $\mathbf{x}^T A \mathbf{x} > 0$,

即 A 是正定矩阵.




证 ① $a_{ij} = (\boldsymbol{\varepsilon}_i, \boldsymbol{\varepsilon}_j) = (\boldsymbol{\varepsilon}_j, \boldsymbol{\varepsilon}_i) = a_{ji}, \quad i, j = 1, 2, \dots, n.$

故 $\boldsymbol{A}^T = \boldsymbol{A}$, 即 $\boldsymbol{A}$ 是实对称矩阵.

② 由内积性质③


$$\begin{aligned} (\boldsymbol{\alpha}, \boldsymbol{\beta}) &= \left(\sum_{i=1}^n x_i \boldsymbol{\varepsilon}_i, \sum_{i=1}^n y_i \boldsymbol{\varepsilon}_i \right) = \left(\sum_{i=1}^n x_i \boldsymbol{\varepsilon}_i, \sum_{j=1}^n y_j \boldsymbol{\varepsilon}_j \right) \\ &= \sum_{i=1}^n \sum_{j=1}^n x_i (\boldsymbol{\varepsilon}_i, \boldsymbol{\varepsilon}_j) y_j = \sum_{i=1}^n \sum_{j=1}^n x_i a_{ij} y_j \end{aligned}$$



$$= \sum_{i=1}^n x_i \left(\sum_{j=1}^n a_{ij} y_j \right) = (x_1, \dots, x_i, \dots, x_n)$$

$$\begin{bmatrix} \sum_{j=1}^n a_{1j} y_j \\ \vdots \\ \sum_{j=1}^n a_{ij} y_j \\ \vdots \\ \sum_{j=1}^n a_{nj} y_j \end{bmatrix}$$

$$= (x_1, \dots, x_i, \dots, x_n) \begin{bmatrix} a_{11} & \cdots & a_{1j} & \cdots & a_{1n} \\ \vdots & & \vdots & & \vdots \\ a_{i1} & \cdots & a_{ij} & \cdots & a_{in} \\ \vdots & & \vdots & & \vdots \\ a_{n1} & \cdots & a_{nj} & \cdots & a_{nn} \end{bmatrix} \begin{bmatrix} y_1 \\ \vdots \\ y_j \\ \vdots \\ y_n \end{bmatrix} = \mathbf{x}^T \mathbf{A} \mathbf{y}$$




这说明欧氏空间中广义的向量的内积
可通过它们在基下的坐标及其度量矩
阵的双线性函数来计算.

③ 当 $\alpha = \theta$ 时, $(\alpha, \alpha) = 0$;

当 $\alpha \neq \theta$ 时, x 为 R^n 中非零的 n 元列向量,

$$x^T A x = (\alpha, \alpha) > 0,$$

这说明基的度量矩阵是正定矩阵. ■



两组基的度量矩阵有如下的关系:

定理2.2 设 $\boldsymbol{\varepsilon}_1, \boldsymbol{\varepsilon}_2, \dots, \boldsymbol{\varepsilon}_n; \boldsymbol{\eta}_1, \boldsymbol{\eta}_2, \dots, \boldsymbol{\eta}_n$ 为 n 维欧氏空间两个基, 它们的度量矩阵分别为 $\boldsymbol{A}, \boldsymbol{B}$.

$\boldsymbol{C}$ 是 $\boldsymbol{\varepsilon}_1, \boldsymbol{\varepsilon}_2, \dots, \boldsymbol{\varepsilon}_n$ 到 $\boldsymbol{\eta}_1, \boldsymbol{\eta}_2, \dots, \boldsymbol{\eta}_n$ 的过渡矩阵, 则


$$\boldsymbol{B} = \boldsymbol{C}^T \boldsymbol{A} \boldsymbol{C}$$

证 设 $\boldsymbol{A} = (a_{ij})_{n \times n}, \boldsymbol{B} = (b_{ij})_{n \times n}, \boldsymbol{C} = (c_{ij})_{n \times n}$

$$(\boldsymbol{\eta}_1, \dots, \boldsymbol{\eta}_i, \dots, \boldsymbol{\eta}_j, \dots, \boldsymbol{\eta}_n) = (\boldsymbol{\varepsilon}_1, \dots, \boldsymbol{\varepsilon}_k, \dots, \boldsymbol{\varepsilon}_l, \dots, \boldsymbol{\varepsilon}_n) \boldsymbol{C}$$

$$\text{则 } \boldsymbol{\eta}_i = \sum_{k=1}^n c_{ki} \boldsymbol{\varepsilon}_k, \quad \boldsymbol{\eta}_j = \sum_{k=1}^n c_{kj} \boldsymbol{\varepsilon}_k = \sum_{l=1}^n c_{lj} \boldsymbol{\varepsilon}_l.$$


于是 $b_{ij} = (\boldsymbol{\eta}_i, \boldsymbol{\eta}_j) = \left(\sum_{k=1}^n c_{ki} \boldsymbol{\varepsilon}_k, \sum_{l=1}^n c_{lj} \boldsymbol{\varepsilon}_l \right) = \sum_{k=1}^n \sum_{l=1}^n c_{ki} (\boldsymbol{\varepsilon}_k, \boldsymbol{\varepsilon}_l) c_{lj}$



$$= \sum_{k=1}^n \sum_{l=1}^n c_{ki} a_{kl} c_{lj} = \sum_{k=1}^n c_{ki} \left[\sum_{l=1}^n a_{kl} c_{lj} \right]$$

$$= (c_{1i}, \dots, c_{ki}, \dots, c_{ni}) \begin{bmatrix} \sum_{l=1}^n a_{1l} c_{lj} \\ \vdots \\ \sum_{l=1}^n a_{kl} c_{lj} \\ \vdots \\ \sum_{l=1}^n a_{nl} c_{lj} \end{bmatrix} = \boxed{C_i^T A C_j}$$

其中 $\mathbf{C} = (\mathbf{C}_1, \dots, \mathbf{C}_i, \dots, \mathbf{C}_j, \dots, \mathbf{C}_n)$



$$\mathbf{B} = (b_{ij})_{n \times n} = \begin{bmatrix} \mathbf{C}_1^T \mathbf{A} \mathbf{C}_1 & \dots & \mathbf{C}_1^T \mathbf{A} \mathbf{C}_j & \dots & \mathbf{C}_1^T \mathbf{A} \mathbf{C}_n \\ \vdots & & \vdots & & \vdots \\ \mathbf{C}_i^T \mathbf{A} \mathbf{C}_1 & \dots & \mathbf{C}_i^T \mathbf{A} \mathbf{C}_j & \dots & \mathbf{C}_i^T \mathbf{A} \mathbf{C}_n \\ \vdots & & \vdots & & \vdots \\ \mathbf{C}_n^T \mathbf{A} \mathbf{C}_1 & \dots & \mathbf{C}_n^T \mathbf{A} \mathbf{C}_j & \dots & \mathbf{C}_n^T \mathbf{A} \mathbf{C}_n \end{bmatrix}$$

$$= \begin{bmatrix} \mathbf{C}_1^T \\ \vdots \\ \mathbf{C}_i^T \\ \vdots \\ \mathbf{C}_n^T \end{bmatrix} (\mathbf{A} \mathbf{C}_1, \dots, \mathbf{A} \mathbf{C}_j, \dots, \mathbf{A} \mathbf{C}_n) = \mathbf{C}^T \mathbf{A} \mathbf{C}. \quad \blacksquare$$



定理2.2说明欧氏空间中**不同基的度量矩阵是相合矩阵**(congruent matrices).

例2.4 设欧氏空间 $P[x]_3$ 中的内积定义为

$$(f(x), g(x)) = \int_{-1}^1 f(x)g(x)dx$$

求: (1) 求**基** $1, x, x^2$ 的**度量矩阵**;

(2) 求 $f(x) = 1 - x + x^2$ 与 $g(x) = 1 - 4x + 5x^2$ 的内积.



解 (1) 设基 $1, x, x^2$ 的度量矩阵 $A = (a_{ij})_{3 \times 3}$,
由**对称性**, 故仅需计算 $a_{ij} (i \leq j)$.

$$a_{11} = (1, 1) = \int_{-1}^1 1 \cdot 1 dx = 2,$$


$$a_{22} = (x, x) = \int_{-1}^1 x \cdot x dx = \frac{2}{3}$$

$$a_{12} = (1, x) = \int_{-1}^1 1 \cdot x dx = 0,$$

$$a_{23} = (x, x^2) = \int_{-1}^1 x \cdot x^2 dx = 0$$

$$a_{13} = (1, x^2) = \int_{-1}^1 1 \cdot x^2 dx = \frac{2}{3},$$

$$a_{33} = (x^2, x^2) = \int_{-1}^1 x^2 \cdot x^2 dx = \frac{2}{5}$$




所以 $A = \begin{bmatrix} 2 & 0 & \frac{2}{3} \\ 0 & \frac{2}{3} & 0 \\ \frac{2}{3} & 0 & \frac{2}{5} \end{bmatrix}$

(2) 因为 $f(x) = 1 - x + x^2$ 与 $g(x) = 1 - 4x - 5x^2$

在 **基** $1, x, x^2$ 下的坐标分别为

$$\alpha = (1, -1, 1)^T, \beta = (1, -4, -5)^T,$$

由定理 2.1 之②


$$(f(x), g(x)) = \alpha^T A \beta = (1, -1, 1) \begin{bmatrix} 2 & 0 & \frac{2}{3} \\ 0 & \frac{2}{3} & 0 \\ \frac{2}{3} & 0 & \frac{2}{5} \end{bmatrix} \begin{bmatrix} 1 \\ -4 \\ -5 \end{bmatrix} = 0$$


这与直接计算定积分得到的结果是一致的.

现将上述结果推广到复数域向量空间.

定义2.3 设 V 是复数域 C 上的 n 维线性空间, 对任给的 $\alpha, \beta \in V$, 按某种法则对应着一个复数, 记为 (α, β) , 如果满足下面四个条件:

- ① 共轭交换律 $(\alpha, \beta) = \overline{(\beta, \alpha)}$;
- ② 共轭齐次性 $(k\alpha, \beta) = \overline{k}(\alpha, \beta)$, k 为任意复数;
- ③ 分配律 $(\alpha + \beta, \gamma) = (\alpha, \gamma) + (\beta, \gamma)$, $\gamma \in V$; (2.5)
- ④ 非负性 $(\alpha, \alpha) \geq 0$; $(\alpha, \alpha) = 0$, 当且仅当 $\alpha = \theta$.

则称复数 (α, β) 为定义在 V 上的内积, 定义了这样内积的 n 维线性空间为 n 维酉空间 (unitary space), 记为 $V_n(C, U)$



酉空间内积的性质


① $(\alpha, l\beta) = l(\alpha, \beta);$

② $(\alpha, \beta + \gamma) = (\alpha, \beta) + (\alpha, \gamma);$

③* $(\sum_{i=1}^r k_i \alpha_i, \sum_{j=1}^s l_j \beta_j) = \sum_{i=1}^r \sum_{j=1}^s \overline{k_i} l_j (\alpha_i, \beta_j) (\text{前轆后不轆});$

其中 $k_i, l_j \in \mathbf{C}, \alpha_i, \beta_j \in V; i = 1, 2, \dots, r; j = 1, 2, \dots, s.$

④ $(\alpha, \theta) = (\theta, \alpha) = 0.$



例2.5 在 n 维线性空间 $\mathbf{C}^n$ 中,

$\forall \boldsymbol{\alpha} = (a_1, \dots, a_i, \dots, a_n)^T, \boldsymbol{\beta} = (b_1, \dots, b_i, \dots, b_n)^T$, 定义**内积**

$$(\boldsymbol{\alpha}, \boldsymbol{\beta}) \triangleq \boldsymbol{\alpha}^H \boldsymbol{\beta} = \sum_{i=1}^n \overline{a_i} b_i.$$

其中 $\boldsymbol{\alpha}^H = (\overline{a_1}, \dots, \overline{a_i}, \dots, \overline{a_n})^T$, 则 $\mathbf{C}^n$ 构成一个**酉空间**, 仍以 $\mathbf{C}^n$ 记之.

上述定义的**内积**称为**酉空间** $\mathbf{C}^n$ 中向量的**标准内积**.




定义 2.4 设 $A = \mathbf{C}^{m \times n}$, $\overline{A}$ 表示由 A 的元素的
共轭复数 所组成的矩阵; 令 $A^H = (\overline{A})^T$,
则称 A^H 为 A 的 **共轭转置阵**.

特别若

$A^H = A$, 则称 A 为 **Hermite矩阵**;

$A^H = -A$, 则称 A 为 **反 Hermite矩阵**.

Hermite矩阵 与 **反 Hermite矩阵** 是 **对称阵** 与 **反对称阵** 的推广.



容易验证共轭转置阵有如下性质：

$$(1) \mathbf{A}^{\mathrm{H}} = \overline{\mathbf{A}^{\mathrm{T}}};$$


$$(2) (\mathbf{A} + \mathbf{B})^{\mathrm{H}} = \mathbf{A}^{\mathrm{H}} + \mathbf{B}^{\mathrm{H}};$$

$$(3) (k\mathbf{A})^{\mathrm{H}} = \overline{k}\mathbf{A}^{\mathrm{H}};$$

$$(4) (\mathbf{AB})^{\mathrm{H}} = \mathbf{B}^{\mathrm{H}}\mathbf{A}^{\mathrm{H}};$$

$$(5) (\mathbf{A}^{\mathrm{H}})^{\mathrm{H}} = \mathbf{A};$$

$$(6) \mathbf{A} \text{ 可逆时, } (\mathbf{A}^{\mathrm{H}})^{-1} = (\mathbf{A}^{-1})^{\mathrm{H}}.$$



酉空间有与欧氏空间相类似的结论.

■ **定理2.3** 设 A 为 n 维酉空间 V 的**基** $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 的**度量矩阵**, 则


① $A = A^H$, 即 A 是**Hermite矩阵**;

② $\forall \alpha, \beta \in V$; α, β 在**基** $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 下的坐标分别为

$\mathbf{x} = (x_1, \dots, x_i, \dots, x_n)^T, \mathbf{y} = (y_1, \dots, y_i, \dots, y_n)^T$, 则

$$(\alpha, \beta) = \mathbf{x}^H A \mathbf{y}$$

③ $\theta \neq \forall \alpha \in V, \alpha = (\varepsilon_1, \dots, \varepsilon_n) \mathbf{x}$, 必有 $\mathbf{x}^H A \mathbf{x} > 0$, 即
 A 是**正定矩阵**.




■ **定理2.4** 设 $\boldsymbol{\varepsilon}_1, \boldsymbol{\varepsilon}_2, \dots, \boldsymbol{\varepsilon}_n; \boldsymbol{\eta}_1, \boldsymbol{\eta}_2, \dots, \boldsymbol{\eta}_n$

为 n 维酉空间两个基，它们的度量矩阵分别为 A 和 B , C 是 $\boldsymbol{\varepsilon}_1, \boldsymbol{\varepsilon}_2, \dots, \boldsymbol{\varepsilon}_n$ 到 $\boldsymbol{\eta}_1, \boldsymbol{\eta}_2, \dots, \boldsymbol{\eta}_n$ 的过渡矩阵，则

$$B = C^H A C$$

即酉空间中不同基的度量矩阵是复相合矩阵(complex congruent matrices).



§ 2.2 内积空间的度量

- **定义2.5** 设 V 是酉（欧氏）空间，
 $\forall \alpha \in V$, α 的 **长度** 定义为 $\|\alpha\| = \sqrt{(\alpha, \alpha)}$.
长度为 **1** 的向量称为 **单位向量**，如果
 $\alpha \neq \theta$, 则 $\frac{\alpha}{\|\alpha\|}$ 是一个 **单位向量**.
 $\forall \alpha, \beta \in V$, 称 $\|\alpha - \beta\|$ 为 α, β 之间的 **距离**,
记为 $d(\alpha, \beta)$

定理2.5 设 V 是酉(欧氏)空间, 则向量的长度

具有以下性质:


① $\|\alpha\| \geq 0, \quad \|\alpha\| = 0 \Leftrightarrow \alpha = \theta;$

② $\|k\alpha\| = |k| \|\alpha\|;$

③ $|(\alpha, \beta)| \leq \|\alpha\| \|\beta\|$ (**Cauchy-Schwarz不等式**);

等号成立的充要条件是 α, β 线性相关.

④ $\|\alpha + \beta\| \leq \|\alpha\| + \|\beta\|$ (**三角不等式**).



证 ①, ② 显然; 以下证③.


若 $\beta = \theta$ 则 ③ 显然成立。以下设 $\beta \neq \theta$, 有

$\overline{(\beta, \beta)} = (\beta, \beta) > 0, \forall k \in F, \alpha - k\beta \in V$, 则

$$0 \leq (\alpha - k\beta, \alpha - k\beta)$$

$$= (\alpha, \alpha) - \bar{k}(\beta, \alpha) - k(\alpha, \beta) + \bar{k}k(\beta, \beta)$$

$$\text{上式中令 } k = \frac{\overline{(\alpha, \beta)}}{(\beta, \beta)},$$



$$\begin{aligned} 0 &\leq (\alpha, \alpha) - \frac{|(\alpha, \beta)|^2}{(\beta, \beta)} - \frac{|(\alpha, \beta)|^2}{(\beta, \beta)} + \frac{|(\alpha, \beta)|^2}{(\beta, \beta)} \\ &= (\alpha, \alpha) - \frac{|(\alpha, \beta)|^2}{(\beta, \beta)}, \end{aligned}$$

$$|(\alpha, \beta)|^2 \leq (\alpha, \alpha)(\beta, \beta) = \|\alpha\|^2 \|\beta\|^2$$

$$\text{即} \quad |(\alpha, \beta)| \leq \|\alpha\| \|\beta\|$$

以下证 ③ 中等号成立的充要条件.

当 α, β 线性相关时, $\beta = k\alpha$,

$$|(\alpha, \beta)| = |(\alpha, k\alpha)| = |k|(\alpha, \alpha) = \|\alpha\| \|k\alpha\| = \|\alpha\| \|\beta\|, \text{等号成立};$$

反之, 如果 $|(\alpha, \beta)| = \|\alpha\| \|\beta\|$, 则 α, β 必线性相关.

如若不然, α, β 线性无关, 则 $\forall k \in F$, 应 $\alpha - k\beta \neq \theta$,
于是 $(\alpha - k\beta, \alpha - k\beta) > 0$,

$$\text{取 } k = \frac{(\alpha, \beta)}{(\beta, \beta)}, \text{ 有 } |(\alpha, \beta)|^2 < (\alpha, \alpha)(\beta, \beta) = \|\alpha\|^2 \|\beta\|^2 ,$$

与等号成立矛盾, 故 α, β 线性相关.

再证 ④


$$\|\alpha + \beta\|^2 = (\alpha + \beta, \alpha + \beta)$$

$$= (\alpha, \alpha) + \overline{(\alpha, \beta)} + (\alpha, \beta) + (\beta, \beta)$$

$$= \|\alpha\|^2 + 2 \operatorname{Re}(\alpha, \beta) + \|\beta\|^2$$


$$\leq \|\alpha\|^2 + 2|(\alpha, \beta)| + \|\beta\|^2$$

$$\leq \|\alpha\|^2 + 2\|\alpha\|\|\beta\| + \|\beta\|^2$$

$$= (\|\alpha\| + \|\beta\|)^2.$$

所以 $\|\alpha + \beta\| \leq \|\alpha\| + \|\beta\|$






Cauchy-Schwarz不等式在欧氏空间中 有十分重要的应用：

在 R^n 中的离散形式为

$$\left(\sum_{i=1}^n a_i b_i\right)^2 \leq \left(\sum_{i=1}^n a_i^2\right) \left(\sum_{i=1}^n b_i^2\right)$$

在 $C[a, b]$ 中的连续形式为

$$\left(\int_a^b f(x)g(x)dx\right)^2 \leq \int_a^b f^2(x)dx \int_a^b g^2(x)dx$$



定义2.6 设 α, β 为欧氏空间两个非零向量，它们之间的夹角 $\langle \alpha, \beta \rangle$ 定义为：

$$\langle \alpha, \beta \rangle \triangleq \arccos \frac{(\alpha, \beta)}{\|\alpha\| \|\beta\|}, \quad 0 \leq \langle \alpha, \beta \rangle \leq \pi$$

对于酉空间的非零向量，其夹角定义为：

$$\cos^2 \langle \alpha, \beta \rangle \triangleq \frac{(\alpha, \beta)(\beta, \alpha)}{(\alpha, \alpha)(\beta, \beta)} = \frac{|(\alpha, \beta)|^2}{(\alpha, \alpha)(\beta, \beta)}$$

当 $(\alpha, \beta) = 0$ 时，称 α 与 β **正交**，记为 $\alpha \perp \beta$ ； θ 与所有向量**正交**。

定义2.7 $\alpha_1, \dots, \alpha_i, \dots, \alpha_m$ 是不含零向量的向量组,


若它们两两正交, 则说其为正交向量组.

若正交向量组内每一个向量都是单位向量, 则说该向量组是标准正交向量组.

显然 $\alpha_1, \dots, \alpha_i, \dots, \alpha_m$ 是标准正交向量组的充要条件是

$$(\alpha_i, \alpha_j) = \delta_{ij} = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases} \quad i, j = 1, 2, \dots, m$$

定理2.6 正交向量组是线性无关向量组.



定义2.8 在 n 维空间中，由 n 个**正交**向量所组成的**基**为**正交基**，由 n 个**标准正交**向量所组成的**基**为**标准正交基**.

显然 $\alpha_1, \dots, \alpha_2, \dots, \alpha_n$ 是**标准正交基**的**充要条件**是它的**Gram矩阵**，即它的**度量矩阵**是**单位矩阵**.

对于酉(欧氏)空间，总能从一组线性无关的极大组出发，由 **Gram-Schmidt 正变化**方法，构造一个**标准正交基**.

设 $\alpha_1, \dots, \alpha_2, \dots, \alpha_r$ 是线性无关的向量组

Gram-Schmidt正交化过程:


(1) 正交化

$$\text{令 } \beta_1 = \alpha_1$$

$$\beta_2 = \alpha_2 - \frac{\overline{(\alpha_2, \beta_1)}}{(\beta_1, \beta_1)} \beta_1 = \alpha_2 - \frac{(\beta_1, \alpha_2)}{(\beta_1, \beta_1)} \beta_1$$

.....

$$\begin{aligned} \beta_r &= \alpha_r - \frac{\overline{(\alpha_r, \beta_1)}}{(\beta_1, \beta_1)} \beta_1 - \frac{\overline{(\alpha_r, \beta_2)}}{(\beta_2, \beta_2)} \beta_2 - \dots - \frac{\overline{(\alpha_r, \beta_{r-1})}}{(\beta_{r-1}, \beta_{r-1})} \beta_{r-1} \\ &= \alpha_r - \frac{(\beta_1, \alpha_r)}{(\beta_1, \beta_1)} \beta_1 - \frac{(\beta_2, \alpha_r)}{(\beta_2, \beta_2)} \beta_2 - \dots - \frac{(\beta_{r-1}, \alpha_r)}{(\beta_{r-1}, \beta_{r-1})} \beta_{r-1} \end{aligned}$$



(2)标准(单位)化


$$\gamma_1 = \frac{\beta_1}{\|\beta_1\|}$$

$$\gamma_2 = \frac{\beta_2}{\|\beta_2\|}$$

.....

$$\gamma_r = \frac{\beta_r}{\|\beta_r\|}.$$

则 $\gamma_1, \gamma_2, \dots, \gamma_r$ 为 $\text{span}(\alpha_1, \alpha_2, \dots, \alpha_r)$ 一个**标准正交基**.



例2.8 设


$$\alpha_1 = \begin{bmatrix} 1 \\ i \\ 0 \end{bmatrix}, \quad \alpha_2 = \begin{bmatrix} 1 \\ 0 \\ i \end{bmatrix}, \quad \alpha_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$

试用**Gram-Schmidt方法**将其**标准正交化**。

解 (1) 正交化

令 $\beta_1 = \alpha_1$


$$\begin{aligned}\beta_2 &= \alpha_2 - \frac{(\beta_1, \alpha_2)}{(\beta_1, \beta_1)} \beta_1 = \begin{bmatrix} 1 \\ 0 \\ i \end{bmatrix} - \frac{(1, -i, 0)}{(1, -i, 0)} \begin{bmatrix} 1 \\ 0 \\ i \end{bmatrix} \\ &= \begin{bmatrix} 1 \\ 0 \\ i \end{bmatrix} - \frac{1}{2} \begin{bmatrix} 1 \\ i \\ 0 \end{bmatrix} = \begin{bmatrix} 1/2 \\ -i/2 \\ i \end{bmatrix} = \frac{1}{2} \begin{bmatrix} 1 \\ -i \\ 2i \end{bmatrix}\end{aligned}$$



$$\beta_3 = \alpha_3 - \frac{(\beta_1, \alpha_3)}{(\beta_1, \beta_1)} \beta_1 - \frac{(\beta_2, \alpha_3)}{(\beta_2, \beta_2)} \beta_2$$


$$= \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} - \frac{\begin{matrix} (1, -i, 0) \\ \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} \\ (1, -i, 0) \end{matrix}}{\begin{matrix} \begin{bmatrix} 1 \\ i \\ 0 \end{bmatrix} \end{matrix}} - \frac{\begin{matrix} (\frac{1}{2}, \frac{i}{2}, -i) \\ \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} \\ (\frac{1}{2}, \frac{i}{2}, -i) \end{matrix}}{\begin{matrix} \begin{bmatrix} 1 \\ \frac{1}{2} \\ -\frac{i}{2} \end{bmatrix} \end{matrix}} \begin{bmatrix} 1 \\ i \\ 0 \end{bmatrix} - \frac{\begin{matrix} \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} \\ \begin{bmatrix} 1 \\ \frac{1}{2} \\ -\frac{i}{2} \end{bmatrix} \end{matrix}}{\begin{matrix} \begin{bmatrix} \frac{1}{2} \\ i \end{bmatrix} \end{matrix}}$$

红色行向量为取共轭




$$\beta_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} - \frac{0}{2} \begin{bmatrix} 1 \\ i \\ 0 \end{bmatrix} + \frac{i}{3/2} \begin{bmatrix} \frac{1}{2} \\ -\frac{i}{2} \\ i \end{bmatrix} = \begin{bmatrix} \frac{i}{3} \\ \frac{1}{3} \\ \frac{1}{3} \end{bmatrix} = \frac{1}{3} \begin{bmatrix} i \\ 1 \\ 1 \end{bmatrix}$$

(2) 单位化


$$(\beta_1, \beta_1) = \beta_1^H \beta_1 = (1, -i, 0) \begin{bmatrix} 1 \\ i \\ 0 \end{bmatrix} = 2, \quad \|\beta_1\| = \sqrt{2}.$$

$$(\beta_2, \beta_2) = \beta_2^H \beta_2 = \frac{1}{4} (1, i, -2i) \begin{bmatrix} 1 \\ -i \\ 2i \end{bmatrix} = \frac{6}{4}, \quad \|\beta_2\| = \frac{\sqrt{6}}{2}.$$

$$(\beta_3, \beta_3) = \beta_3^H \beta_3 = \frac{1}{9} (-i, 1, 1) \begin{bmatrix} i \\ 1 \\ 1 \end{bmatrix} = \frac{1}{3}, \quad \|\beta_3\| = \frac{1}{\sqrt{3}}.$$



$$\gamma_1 = \frac{\beta_1}{\|\beta_1\|} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ i \\ 0 \end{bmatrix}.$$

$$\gamma_2 = \frac{\beta_2}{\|\beta_2\|} = \frac{1}{\sqrt{6}} \begin{bmatrix} 1 \\ -i \\ 2i \end{bmatrix}.$$

$$\gamma_3 = \frac{\beta_3}{\|\beta_3\|} = \frac{1}{\sqrt{3}} \begin{bmatrix} i \\ 1 \\ 1 \end{bmatrix}.$$

则 $\gamma_1, \gamma_2, \gamma_3$ 为 $\mathbf{C}^3$ 中的标准正交基.






例2.9 按例2.4中内积的定义将 $P[x]_3$ 中的基 $1, x, x^2$ 标准正交化, 并求 $1, x, x^2$ 到标准正交基的过渡矩阵.

解 $\alpha_1 = 1, \alpha_2 = x, \alpha_3 = x^2$

(1) 正交化


$$\beta_1 = \alpha_1 = 1$$



$$\beta_2 = \alpha_2 - \frac{(\alpha_2, \beta_1)}{(\beta_1, \beta_1)} \beta_1 = x - \frac{\int_{-1}^1 x \cdot 1 dx}{\int_{-1}^1 1 \cdot 1 dx} \cdot 1 = x.$$

$$\begin{aligned} \beta_3 &= \alpha_3 - \frac{(\alpha_3, \beta_1)}{(\beta_1, \beta_1)} \beta_1 - \frac{(\alpha_3, \beta_2)}{(\beta_2, \beta_2)} \beta_2 \\ &= x^2 - \frac{\int_{-1}^1 x^2 \cdot 1 dx}{\int_{-1}^1 1 \cdot 1 dx} \cdot 1 - \frac{\int_{-1}^1 x^2 \cdot x dx}{\int_{-1}^1 x \cdot x dx} \cdot x = x^2 - \frac{1}{3}. \end{aligned}$$


(2) 标准化


$$\gamma_1 = \frac{\beta_1}{\|\beta_1\|} = \frac{\beta_1}{\sqrt{(\beta_1, \beta_1)}} = \frac{1}{\sqrt{2}} = \sqrt{\frac{1}{2}}.$$

$$\gamma_2 = \frac{\beta_2}{\|\beta_2\|} = \frac{\beta_2}{\sqrt{(\beta_2, \beta_2)}} = \frac{x}{\sqrt{\int_{-1}^1 x^2 dx}} = \sqrt{\frac{3}{2}}x.$$

$$\gamma_3 = \frac{\beta_3}{\|\beta_3\|} = \frac{\beta_3}{\sqrt{(\beta_3, \beta_3)}} = \frac{x^2 - 1/3}{\sqrt{\int_{-1}^1 (x^4 - 2/3x^2 + 1/9) dx}} = \sqrt{\frac{5}{2}}\left(\frac{3x^2 - 1}{2}\right).$$

则 $\gamma_1, \gamma_2, \gamma_3$ 为 $\mathbf{C}^3$ 中的 **标准正交基**.




显然

$$\sqrt{\frac{1}{2}} = \sqrt{\frac{1}{2}} \cdot 1 + 0 \cdot x + 0 \cdot x^2 ,$$

$$\sqrt{\frac{3}{2}}x = 0 \cdot 1 + \sqrt{\frac{3}{2}} \cdot x + 0 \cdot x^2 ,$$

$$\sqrt{\frac{5}{2}}\left(\frac{3x^2 - 1}{2}\right) = -\frac{1}{2}\sqrt{\frac{5}{2}} \cdot 1 + 0 \cdot x + \frac{3}{2}\sqrt{\frac{5}{2}}x^2 .$$

于是



$$\left(\sqrt{\frac{1}{2}}, \sqrt{\frac{3}{2}}x, \sqrt{\frac{5}{2}}\left(\frac{3x^2-1}{2}\right) \right) = (1, x, x^2) \begin{bmatrix} \sqrt{\frac{1}{2}} & 0 & -\frac{1}{2}\sqrt{\frac{5}{2}} \\ 0 & \sqrt{\frac{3}{2}} & 0 \\ 0 & 0 & \frac{3}{2}\sqrt{\frac{5}{2}} \end{bmatrix}$$

令 $C = \begin{bmatrix} \sqrt{\frac{1}{2}} & 0 & -\frac{1}{2}\sqrt{\frac{5}{2}} \\ 0 & \sqrt{\frac{3}{2}} & 0 \\ 0 & 0 & \frac{3}{2}\sqrt{\frac{5}{2}} \end{bmatrix}$

则为基 $1, x, x^2$ 到标准正交基 $\gamma_1, \gamma_2, \gamma_3$ 的过渡矩阵.

例2.10 线性空间 $P[x]_n$ 的基为 $1, x, \dots, x^{n-1}$.在

$(f(x), g(x)) = \int_{-1}^1 f(x) \cdot g(x) dx$ 定义的内积下

$$\varepsilon_{k+1} = \sqrt{\frac{2k+1}{2}} L_k(x) \quad k = 0, 1, 2, \dots, n-1$$

是 $P[x]_n$ 中的**标准正交基**, 其中 $L_k(x) = \frac{1}{2^k k!} \frac{d^k}{dx^k} (x^2 - 1)^k$

称为**Legendre(勒让德)多项式**.

$$L_0(x) = 1, \quad L_1(x) = x, \quad L_2(x) = \frac{1}{2}(3x^2 - 1), \dots$$

$$\text{且有} \quad \int_{-1}^1 L_m(x) L_n(x) dx = \begin{cases} 0, & m \neq n \\ \frac{2}{2n+1}, & m = n \end{cases}$$

标准正交基有如下性质:

定理2.7 若 $\varepsilon_1, \dots, \varepsilon_i, \dots, \varepsilon_n$ 为 $V_n(C, U)$ 的**标准正交基**, 则

(1) $\varepsilon_1, \dots, \varepsilon_i, \dots, \varepsilon_n$ 的**度量矩阵为单位阵**;

(2) $\forall \alpha, \beta \in V_n(C, U), \exists \mathbf{x}, \mathbf{y} \in C^n$, 其中


$$\mathbf{x} = (x_1, \dots, x_i, \dots, x_n)^T, \alpha = \sum_{i=1}^n x_i \varepsilon_i;$$

$$\mathbf{y} = (y_1, \dots, y_i, \dots, y_n)^T, \beta = \sum_{i=1}^n y_i \varepsilon_i,$$

则 $(\alpha, \beta) = (\mathbf{x}, \mathbf{y})$ (抽象向量的**内积**等于 **n 维向量的内积**);

(3) 若 $\eta_1, \dots, \eta_i, \dots, \eta_n$ 也是 $V_n(C, U)$ 的**标准正交基**, 且 $\varepsilon_1, \dots, \varepsilon_i, \dots, \varepsilon_n$

到 $\eta_1, \dots, \eta_i, \dots, \eta_n$ 的**过渡矩阵**为 C , 则 $C^H C = I$ (**酉矩阵**).




定义2.9 设 $A \in \mathbb{C}^{n \times n}$, 若 A 满足

$$A^H A = A A^H = I_n$$

则称 A 是酉矩阵, 记之为 $A \in U^{n \times n}$.

显然酉矩阵是正交矩阵的推广, 定理2.7之(3)


表明两个标准正交基的过渡矩阵是酉矩阵.



酉矩阵有以下性质：

设 $A, B \in U^{n \times n}$, 则

- ① $A^{-1} = A^H$;
- ② A 的列向量为 C^n 的**标准正交基**;
- ③ $A^T \in U^{n \times n}$;
- ④ $AB, BA \in U^{n \times n}$.




§ 2.3 酉变换与Hermite变换

定义2.10 若酉空间 $V_n(C, U)$ 的变换 $\mathcal{A}$ 满足

$$(\mathcal{A}(\alpha), \mathcal{A}(\beta)) = (\alpha, \beta), \quad \alpha, \beta \in V_n(C, U),$$

则称 $\mathcal{A}$ 为 $V_n(C, U)$ 的酉变换.

由定义可知酉变换是不变内积的变换,
在欧氏空间 $V_n(R, E)$ 中即为我们熟知的
正交变换.



例2. 11 (Household变换) 设 $H = I_n - 2uu^H \in \mathbb{C}^{n \times n}$,

$u, \alpha \in \mathbb{C}^n$, 且 $u^H u = 1$. 则由矩阵 H 所确定的
线性变换

$$\mathcal{H}(\alpha) = H\alpha$$

是 $\mathbb{C}^n$ 中的酉变换.

证 对 $\forall \alpha, \beta \in \mathbb{C}^n$ 有

$$(\mathcal{H}(\alpha), \mathcal{H}(\beta)) = (H\alpha, H\beta)$$


$$= (\alpha - 2uu^H\alpha, \beta - 2uu^H\beta)$$

$$= (\alpha - 2uu^H\alpha)^H (\beta - 2uu^H\beta)$$

$$= \alpha^H \beta - 4\alpha^H uu^H \beta + 4\alpha^H uu^H uu^H \beta = \alpha^H \beta$$

$$= (\alpha, \beta).$$

故 $\mathcal{H}$ 是 $\mathbb{C}^n$ 中的酉变换, 称为Household变换,
称矩阵 H 为Household矩阵.



Household矩阵有如下性质：

① $H^H = H$; (Hermite矩阵)

② $H^H H = I_n$; (酉矩阵)

③ $H^2 = I_n$; (对合阵 involutory matrix)

④ 若 $u \in R^n$, 则 $\det H = |H| = -1$.

Household变换也称为初等反射变换,

Household矩阵也称为初等反射矩阵.

例2.13 设 $A \in \mathbf{R}^{n \times n}$, 实数 c 与 s 满足 $c^2 + s^2 = 1$



$$A = \begin{bmatrix} 1 & & & & \\ & \ddots & & & \\ & & c & & s \\ & & & \ddots & \\ & & & & 1 \\ & & -s & & c \\ & & & & & \ddots \\ & & & & & & 1 \\ & & & & & & & \ddots \\ & & & & & & & & 1 \end{bmatrix}$$

i 列 j 列



称 A 为 **Givens矩阵**,

变换 $\mathcal{A}(\alpha) = A\alpha$ 为 **Givens变换**.

容易验证

$$A^T A = I_n, \quad \forall \alpha, \beta \in R^T$$

$$(\mathcal{A}(\alpha), \mathcal{A}(\beta)) = (A\alpha, A\beta) = \alpha^T A^T A \beta = (\alpha, \beta)$$

故 $\mathcal{A}$ 是 R^n 上的 **正交变换**.

Givens矩阵 也称为 **初等旋转变阵**,

Givens变换 也称为 **初等旋转变换**.

Givens矩阵是两个Household矩阵的乘积

在Givens矩阵中, 设 $c = \cos \theta$, $s = \sin \theta$, 记之为 G_{ij} .

记 $u = (0, \dots, 0, \sin \frac{\theta}{4}, 0, \dots, 0, \cos \frac{\theta}{4}, 0, \dots, 0)^T$,

其中 $\sin \frac{\theta}{4}, \cos \frac{\theta}{4}$ 分别为 u 的第 i 个, 第 j 个分量;

类似地 $v = (0, \dots, 0, \sin \frac{3\theta}{4}, 0, \dots, 0, \cos \frac{3\theta}{4}, 0, \dots, 0)^T$.

令 $H_u = I - 2uu^T$, $H_v = I - 2vv^T$.

容易验证 $G_{ij} = H_u H_v$




定理2.8 酉变换是线性变换.

证 设 $\mathcal{A}$ 是 $V_n(C, U)$ 的酉变换, $\forall \alpha, \beta \in V_n(C, U)$

$$(\mathcal{A}(\alpha + \beta) - \mathcal{A}(\alpha) - \mathcal{A}(\beta), \mathcal{A}(\alpha + \beta) - \mathcal{A}(\alpha) - \mathcal{A}(\beta))$$

$$\begin{aligned} &= (\mathcal{A}(\alpha + \beta), \mathcal{A}(\alpha + \beta)) - (\mathcal{A}(\alpha + \beta), \mathcal{A}(\alpha)) \\ &\quad - (\mathcal{A}(\alpha + \beta), \mathcal{A}(\beta)) - (\mathcal{A}(\alpha), \mathcal{A}(\alpha + \beta)) + (\mathcal{A}(\alpha), \mathcal{A}(\alpha)) \\ &\quad + (\mathcal{A}(\alpha), \mathcal{A}(\beta)) - (\mathcal{A}(\beta), \mathcal{A}(\alpha + \beta)) + (\mathcal{A}(\beta), \mathcal{A}(\alpha)) \\ &\quad + (\mathcal{A}(\beta), \mathcal{A}(\beta)). \end{aligned}$$


$$\begin{aligned} &= (\alpha + \beta, \alpha + \beta) - (\alpha + \beta, \alpha) - (\alpha + \beta, \beta) \\ &\quad - (\alpha, \alpha + \beta) + (\alpha, \alpha) + (\alpha, \beta) \\ &\quad - (\beta, \alpha + \beta) + (\beta, \alpha) + (\beta, \beta) = 0. \end{aligned}$$

故 $\mathcal{A}(\alpha + \beta) - \mathcal{A}(\alpha) - \mathcal{A}(\beta) = 0$.


即

$$\mathcal{A}(\alpha + \beta) = \mathcal{A}(\alpha) + \mathcal{A}(\beta)$$

同理可证

$$\mathcal{A}(k\alpha) = k\mathcal{A}(\alpha)$$


这说明 $\mathcal{A}$ 是线性变换.



定理2.9 设 $\mathcal{A}$ 是 $V_n(C, U)$ 的线性变换, 则下列命题等价:

- (1) $\mathcal{A}$ 是酉变换;
- (2) $\|\mathcal{A}(\alpha)\| = \|\alpha\|, \forall \alpha \in V_n(C, U)$, 即不变长度;
- (3) 若 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 是 $V_n(C, U)$ 的一组标准正交基, 则
 $\mathcal{A}(\varepsilon_1), \mathcal{A}(\varepsilon_2), \dots, \mathcal{A}(\varepsilon_n)$ 也是 $V_n(C, U)$ 的一组标准正交基;
- (4) $\mathcal{A}$ 在 $V_n(C, U)$ 的任意一组标准正交基下的表示矩阵是酉矩阵.

证略



例2.14 设 $\mathcal{E}$ 是 C^n 的**恒等变换**, 即 $\forall \alpha \in C^n, \mathcal{E}(\alpha) = \alpha$,
则 $\mathcal{E}$ 是**酉变换**.

证 显然恒等变换 $\mathcal{E}$ 是**线性变换**.

$$\text{由 } (\mathcal{E}(\alpha), \mathcal{E}(\alpha)) = (\alpha, \alpha)$$

故 $\|\mathcal{E}(\alpha)\| = \|\alpha\|$, 由定理2.9之(2)知

$(\mathcal{E}(\alpha), \mathcal{E}(\beta)) = (\alpha, \beta)$, 故结论正确. ■

本例题说明**恒等变换**是**酉变换**.

例2. 15 设 $\mathcal{A}$ 是 C^n 的线性变换, $\mathcal{A}$ 是酉变换的充要条件是

$$\forall \alpha, \beta \in C^n, \text{ 有 } \|\mathcal{A}(\alpha) - \mathcal{A}(\beta)\| = \|\alpha - \beta\|.$$


证 先证必要性

设 $\mathcal{A}$ 是酉变换, 由定理2.8知 $\mathcal{A}$ 是线性变换. 由定理2.9

$$\|\mathcal{A}(\alpha) - \mathcal{A}(\beta)\| = \|\mathcal{A}(\alpha - \beta)\| = \|\alpha - \beta\|.$$

再证充分性

$$\forall \alpha, \beta \in C^n, \text{ 由 } \|\mathcal{A}(\alpha) - \mathcal{A}(\beta)\| = \|\alpha - \beta\|,$$



特取 $\beta = \theta$, 则 $\|\mathcal{A}(\alpha)\| = \|\alpha\|$, 由定理2.9知

$\mathcal{A}$ 是酉变换. ■

本例题说明不变距离的线性变换是酉变换.

在 $\mathbf{R}^3$ 中, 平移不改变几何向量的长度, 因此不改变几何向量的距离. 但是由于平移变换不是线性变换, 所以它不是正交变换.



酉矩阵的性质

定理2.10 设 $A \in U^{n \times n}$, 即 A 是酉矩阵, 则

- (1) $(A\alpha, A\beta) = (\alpha, \beta)$;
- (2) $\|A\alpha\| = \|\alpha\|$;
- (3) A 的特征值的模为1;
- (4) $|\det A| = 1$, 即 A 的行列式的模为1.

证 略

Hermite变换与对称变换

定义2.11 若酉空间 $V_n(C, U)$ 的线性变换 $\mathcal{A}$ 满足

$$(\mathcal{A}(\alpha), \beta) = (\alpha, \mathcal{A}(\beta)), \quad \forall \alpha, \beta \in V_n(C, U)$$

则称 $\mathcal{A}$ 为酉空间 $V_n(C, U)$ 的Hermite变换.

若欧氏空间 $V_n(R, E)$ 的线性变换 $\mathcal{A}$ 满足

$$(\mathcal{A}(\alpha), \beta) = (\alpha, \mathcal{A}(\beta)), \quad \forall \alpha, \beta \in V_n(R, E)$$

则称 $\mathcal{A}$ 为欧氏空间 $V_n(R, E)$ 的对称变换.

定理 2.11 酉(欧氏)空间 $V_n(\mathbf{C}, \mathbf{U})$ ($V_n(\mathbf{R}, \mathbf{E})$) 的

线性变换 $\mathcal{A}$ 是 Hermite(对称) 变换的充要条件

为它在标准正交基下的表示矩阵是 Hermite(对称) 矩阵.

证 以下在酉空间 $V_n(\mathbf{C}, \mathbf{U})$ 中证明.

设 $\varepsilon_1, \dots, \varepsilon_i, \dots, \varepsilon_j, \dots, \varepsilon_n$ 为酉空间 $V_n(\mathbf{C}, \mathbf{U})$ 的

标准正交基, 线性变换 $\mathcal{A}$ 在此基下的

表示矩阵为 A .

欲证对于 α, β 的一般结论, 先证 $\varepsilon_i, \varepsilon_j$ 的特殊情况.

于是有

$$\mathcal{A}(\varepsilon_1, \dots, \varepsilon_i, \dots, \varepsilon_j, \dots, \varepsilon_n) = (\varepsilon_1, \dots, \varepsilon_k, \dots, \varepsilon_n)A.$$

因此

$$\mathcal{A}(\varepsilon_i) = \sum_{k=1}^n a_{ki} \varepsilon_k,$$

$$\text{故 } (\mathcal{A}(\varepsilon_i), \varepsilon_j) = \left(\sum_{k=1}^n a_{ki} \varepsilon_k, \varepsilon_j \right) = \overline{a_{ji}}; \quad \textcircled{1} \text{ (前轭)}$$

$$\mathcal{A}(\varepsilon_j) = \sum_{k=1}^n a_{kj} \varepsilon_k,$$

$$\text{故 } (\varepsilon_i, \mathcal{A}(\varepsilon_j)) = \left(\varepsilon_i, \sum_{k=1}^n a_{kj} \varepsilon_k \right) = a_{ij}. \quad \textcircled{2} \text{ (后不轭)}$$

先证必要性 $\Rightarrow$

设 $\mathcal{A}$ 是酉空间 $V_n(C, U)$ 的 Hermite 变换, 则
对于指定的 $\varepsilon_i, \varepsilon_j$ 有

$$(\mathcal{A}(\varepsilon_i), \varepsilon_j) = (\varepsilon_i, \mathcal{A}(\varepsilon_j)),$$

由①② 两式得 $\overline{a_{ji}} = a_{ij}.$

这说明 $A^H = A$, 即 A 是 Hermite 矩阵,
必要性得证.

再证充分性 $\Leftarrow$


设 $A^H = A$, 则 $\overline{a_{ji}} = a_{ij}$. 故

$$(\mathcal{A}(\varepsilon_i), \varepsilon_j) = (\varepsilon_i, \mathcal{A}(\varepsilon_j))$$

对 $\forall \alpha, \beta \in V_n(C, U)$, 有

$$\text{由 } \alpha = \sum_{i=1}^n x_i \varepsilon_i, \text{ 则 } \mathcal{A}(\alpha) = \sum_{i=1}^n x_i \mathcal{A}(\varepsilon_i),$$

$$\text{由 } \beta = \sum_{j=1}^n y_j \varepsilon_j, \text{ 则 } \mathcal{A}(\beta) = \sum_{j=1}^n y_j \mathcal{A}(\varepsilon_j).$$



$$(\mathcal{A}(\alpha), \beta) = \left(\sum_{i=1}^n x_i \mathcal{A}(\varepsilon_i), \sum_{j=1}^n y_j \varepsilon_j \right)$$

$$= \sum_{i=1}^n \sum_{j=1}^n \overline{x_i y_j} (\mathcal{A}(\varepsilon_i), \varepsilon_j),$$

$$(\alpha, \mathcal{A}(\beta)) = \left(\sum_{i=1}^n x_i \varepsilon_i, \sum_{j=1}^n y_j \mathcal{A}(\varepsilon_j) \right)$$

$$= \sum_{i=1}^n \sum_{j=1}^n \overline{x_i y_j} (\varepsilon_i, \mathcal{A}(\varepsilon_j)).$$

故 $(\mathcal{A}(\alpha), \beta) = (\alpha, \mathcal{A}(\beta))$, 即 $\mathcal{A}$ 是 Hermite 变换. ■




类似地有:

定义2.11* 若酉(欧氏)空间 $V_n(\mathbf{C}, \mathbf{U})$ 的变换 $\mathcal{A}$ 满足

$$(\mathcal{A}(\alpha), \beta) = -(\alpha, \mathcal{A}(\beta)), \quad \forall \alpha, \beta \in V_n(\mathbf{C}, \mathbf{U})$$


则称 $\mathcal{A}$ 为 $V_n(\mathbf{C}, \mathbf{U})$ 的**反Hermite(对称)变换**.

定理2.11* 酉(欧氏)空间 $V_n(\mathbf{C}, \mathbf{U})$ 的线性变换 $\mathcal{A}$ 是**反Hermite(对称)变换**的充要条件为它在**标准正交基**下的表示矩阵是**反Hermite(对称)矩阵**.



与**实对称矩阵**相类似，**Hermite矩阵**的**特征值**与**特征向量**有以下**性质**：


- (1). **Hermite矩阵**的**特征值**全是**实数**；
- (2). **Hermite矩阵**的**不同特征值**所对应的**特征向量**是**正交**的.



例2.16 设 e 是欧氏空间 V 中的单位向量, 定义变换:

$$\mathcal{A}(\alpha) = \alpha - 2(\alpha, e)e, \quad \alpha \in V.$$


- 求证: (1) $\mathcal{A}$ 是线性变换;
(2) $\mathcal{A}$ 是正交变换;
(3) $\mathcal{A}$ 是对称变换.



证 (1) 设 $\alpha, \beta \in V$, 对 $\forall k_1, k_2 \in R$,

$$\begin{aligned}\mathcal{A}(k_1\alpha + k_2\beta) &= (k_1\alpha + k_2\beta) - 2(k_1\alpha + k_2\beta, e)e \\ &= k_1(\alpha - 2(\alpha, e)e) + k_2(\beta - 2(\beta, e)e) \\ &= k_1\mathcal{A}(\alpha) + k_2\mathcal{A}(\beta).\end{aligned}$$


故 $\mathcal{A}$ 是线性变换.



$$\begin{aligned}(2) \quad (\mathcal{A}(\alpha), \mathcal{A}(\alpha)) &= (\alpha - 2(\alpha, e)e, \alpha - 2(\alpha, e)e) \\ &= (\alpha, \alpha) - 4(\alpha, e)(\alpha, e) + 4(\alpha, e)(\alpha, e) \\ &= (\alpha, \alpha).\end{aligned}$$

即 $\|\mathcal{A}(\alpha)\| = \|\alpha\|.$


由(1)已证出 $\mathcal{A}$ 是线性变换, 故 $\mathcal{A}$ 是正交变换.



$$\begin{aligned}(3) \quad (\mathcal{A}(\alpha), \beta) &= (\alpha - 2(\alpha, e)e, \beta) \\ &= (\alpha, \beta) - 2(\alpha, e)(e, \beta); \\ (\alpha, \mathcal{A}(\beta)) &= (\alpha, \beta - 2(\beta, e)e) \\ &= (\alpha, \beta) - 2(\beta, e)(\alpha, e).\end{aligned}$$

故 $(\mathcal{A}(\alpha), \beta) = (\alpha, \mathcal{A}(\beta))$,


即 $\mathcal{A}$ 是对称变换. ■



§ 2.4 正交子空间与正交投影

定义2.12 设 V_1, V_2 是 $V_n(C, U)$ 的子空间, 若 $\forall \beta \in V_2$, 有 α , 使 $(\alpha, \beta) = 0$, 则说向量 α 与子空间 V_2 **正交**, 记为 $\alpha \perp V_2$; 若 $\forall \alpha \in V_1$, 有 $\alpha \perp V_2$, 则说子空间 V_1, V_2 **正交**, 记为 $V_1 \perp V_2$.

在三维空间 R^3 中, 设 $V_1 = \text{span}(\mathbf{k})$, $V_2 = \text{span}(\mathbf{i}, \mathbf{j})$, 则 $V_1 \perp V_2$.



定理2.12 设 V_1, V_2 是 V_n 的**子空间**, 且 $V_1 \perp V_2$, 则

(1) $V_1 \cap V_2 = \{\theta\};$

(2) $\dim(V_1 + V_2) = \dim V_1 + \dim V_2.$

证 $\forall \alpha \in V_1 \cap V_2$, 则 $\alpha \in V_1, \alpha \in V_2$.

于是 $(\alpha, \alpha) = 0$, 故 $\alpha = \theta$, 即 $V_1 \cap V_2 = \{\theta\};$

由(1)根据子空间维数定理1.7知(2)成立. ■



定义2.13 设 V_1, V_2 是 $V_n(C, U)$ 的子空间, 且 $V_1 \perp V_2$, 若 $V_1 + V_2 = V_n$, 则称 V_1 与 V_2 互为 **正交补** 空间, 记为 $V_1 = V_2^\perp$, 或 $V_2 = V_1^\perp$, 并记 $V_n = V_1 \oplus V_2$.

(注: 这里 $\oplus$ 表示 **正交和**, 即 **直和** $\oplus$ 且 **正交**)

在定理1.8的推论中, 线性空间可分解成两个子空间的直和, 且不惟一, 但对正交分解而言是**惟一**的, 这就是下面的定理.




定理2.13 设 V_1 是 V_n 的任一子空间, 则存在唯一的子空间 $V_2 \subset V_n$, 使 $V_1 \oplus V_2 = V_n$.

证 设 $\dim V_1 = r$, $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_r$ 为 V_1 的正交基, 将 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_r$ 扩充为 V_n 的正交基 $\varepsilon_1, \dots, \varepsilon_r, \varepsilon_{r+1}, \dots, \varepsilon_n$. 令

$V_2 = \text{span}(\varepsilon_{r+1}, \dots, \varepsilon_n)$, 显然 $V_1 \perp V_2$, 且 $V_1 + V_2 = V_n$,

故 $V_1 \oplus V_2 = V_n$.



再证惟一性.

若存在 $V_3 \subset V_n$, 使 $V_1 \oplus V_3 = V_n$, 则对 $\theta \neq \forall \beta \in V_3$,

但 $\beta \notin V_1$, $\forall \alpha \in V_1$, 应有 $(\alpha, \beta) = 0$,

这说明 $\beta \in V_2$, 所以 $V_3 \subset V_2$; 同理可证 $V_2 \subset V_3$.

故 $V_3 = V_2$, 惟一性得证. ■



定理 2.14 设 $A \in \mathbf{C}^{m \times n}$, 则

(1) $R(A) \perp N(A^H)$;

(2) $N(A) \perp R(A^H)$.

证 $\forall \beta \in R(A)$, 则 $\beta \in \mathbf{C}^m$, 于是 $\exists \alpha \in \mathbf{C}^n$, 使 $\beta = A\alpha$.

$\forall \gamma \in N(A^H)$, 则 $\gamma \in \mathbf{C}^m$, 有 $A^H \gamma = \theta$.

于是 $(\gamma, \beta) = \gamma^H \beta = \gamma^H A\alpha = (A^H \gamma)^H \alpha = 0$.

这说明 $R(A) \perp N(A^H)$.

在(1)中以 A 代替 A^H 即得 (2). ■



推论 (1) $R(A) \oplus N(A^H) = \mathbf{C}^m$;

(2) $N(A) \oplus R(A^H) = \mathbf{C}^n$.

证 由定理1.2

$$\begin{aligned} & \dim N(A) + \dim R(A^H) \\ &= \dim N(A) + \text{rank}(A^H) \\ &= (n - \text{rank}(A)) + \text{rank}(A^H) = n \end{aligned}$$

显然 $N(A) \oplus R(A^H) \subset \mathbf{C}^n$

故 (2) 成立. 类似可证得 (1). ■

例 2.17 设 $A \in \mathbb{C}^{m \times n}$, 则

① $N(AA^H) = N(A^H);$

② $R(AA^H) = R(A).$

证 ① 由例 1.15 应有 $N(AA^H) \supset N(A^H),$

$\forall \mathbf{x} \in N(AA^H),$ 有 $AA^H \mathbf{x} = \mathbf{0},$

上式左乘 $\mathbf{x}^H$ 得 $\mathbf{x}^H AA^H \mathbf{x} = 0,$

即 $(A^H \mathbf{x}, A^H \mathbf{x}) = 0,$ 故 $A^H \mathbf{x} = \mathbf{0}, \mathbf{x} \in N(A^H).$

因此 $N(AA^H) \subset N(A^H),$

所以 $N(AA^H) = N(A^H).$



② 由例1.15应有 $R(AA^H) \subset R(A)$. (*)

又由①知 $N(AA^H) = N(A^H)$,

因此 $\dim N(AA^H) = \dim N(A^H)$.

于是 $m - \text{rank}(AA^H) = m - \text{rank}(A^H)$,

故有 $\text{rank}(AA^H) = \text{rank}(A^H) = \text{rank}(A)$,

所以 $\dim R(AA^H) = \dim R(A)$. (**)

由(*)与(**)即得 $R(AA^H) = R(A)$. 



证明两个线性空间相等一般有**两种方法**

方法一: 证明两个空间**互相包含**. 如①

方法二: 证明**单向包含**且**维数相等**. 如②

在例2.17中若用 A^H 代换 A , 则有

①* $N(A^H A) = N(A);$

②* $R(A^H A) = R(A^H).$



定义 2.14 设 S, T 是 C^n 的子空间, 且 $C^n = S \oplus T$,

于是 $\forall \alpha \in C^n$ 均可**惟一**地表示成

$$\alpha = x + y, \quad x \in S, y \in T$$

则称 x 是 α 沿 T 到 S 的**投影**, 由上式所确定的变换称为 C^n 沿 T 到 S 的**投影变换**, 记为 $\mathcal{P}_{S,T}$. 为了方便, 简记为 $\mathcal{P}$, 于是有 $\mathcal{P}(\alpha) = x$.

若 $\alpha \in S$, 则 $\mathcal{P}(\alpha) = \alpha$; 若 $\alpha \in T$, 则 $\mathcal{P}(\alpha) = \theta$.

所以 $R(\mathcal{P}) = S, \quad N(\mathcal{P}) = T$.

定理2.15 设 S, T 为 C^n 的子空间, 且 $C^n = S \oplus T$,

$\mathcal{P}$ 为 C^n 沿 T 到 S 的**投影变换**, 则 $\mathcal{P}$ 为**线性变换**.

证 $\forall \alpha_1, \alpha_2 \in C^n$, 有

$$\alpha_1 = \mathbf{x}_1 + \mathbf{y}_1, \text{ 其中 } \mathbf{x}_1 \in S, \mathbf{y}_1 \in T;$$


$$\alpha_2 = \mathbf{x}_2 + \mathbf{y}_2, \text{ 其中 } \mathbf{x}_2 \in S, \mathbf{y}_2 \in T.$$

于是 $\mathcal{P}(\alpha_1) = \mathbf{x}_1, \quad \mathcal{P}(\alpha_2) = \mathbf{x}_2.$

$\forall k_1, k_2 \in C$, 则

$$k_1 \alpha_1 = k_1(\mathbf{x}_1 + \mathbf{y}_1) = k_1 \mathbf{x}_1 + k_1 \mathbf{y}_1, k_1 \mathbf{x}_1 \in S, k_1 \mathbf{y}_1 \in T;$$

$$k_2 \alpha_2 = k_2(\mathbf{x}_2 + \mathbf{y}_2) = k_2 \mathbf{x}_2 + k_2 \mathbf{y}_2, k_2 \mathbf{x}_2 \in S, k_2 \mathbf{y}_2 \in T.$$



故 $\mathcal{P}(k_1\alpha_1) = k_1\mathbf{x}_1 = k_1\mathcal{P}(\alpha_1),$

$\mathcal{P}(k_2\alpha_2) = k_2\mathbf{x}_2 = k_2\mathcal{P}(\alpha_2).$

因为 $k_1\alpha_1 + k_2\alpha_2 = k_1(\mathbf{x}_1 + \mathbf{y}_1) + k_2(\mathbf{x}_2 + \mathbf{y}_2),$
 $= (k_1\mathbf{x}_1 + k_2\mathbf{x}_2) + (k_1\mathbf{y}_1 + k_2\mathbf{y}_2),$

其中 $(k_1\mathbf{x}_1 + k_2\mathbf{x}_2) \in S, (k_1\mathbf{y}_1 + k_2\mathbf{y}_2) \in T.$

所以 $\mathcal{P}(k_1\alpha_1 + k_2\alpha_2) = k_1\mathbf{x}_1 + k_2\mathbf{x}_2,$

即 $\mathcal{P}(k_1\alpha_1 + k_2\alpha_2) = k_1\mathcal{P}(\alpha_1) + k_2\mathcal{P}(\alpha_2),$

这说明 $\mathcal{P}$ 是线性变换.

例2.18 在三维空间 $\mathbf{R}^3$ 中, 设 $S = \text{span}(\mathbf{i}, \mathbf{j})$, $T = \text{span}(\mathbf{k})$,

求 $\mathbf{R}^3$ 中沿 T 到 S 的投影 $\mathcal{P}$.

解 显然 $\mathbf{R}^3 = S \oplus T$

$\forall \alpha = (x, y, z)^T \in \mathbf{R}^3$, 有

$$\alpha = (x, y, 0)^T + (0, 0, z)^T = \alpha_1 + \alpha_2$$

其中 $\alpha_1 = (x, y, 0)^T \in S$, $\alpha_2 = (0, 0, z)^T \in T$.

故 $\mathcal{P}(\alpha) = \alpha_1$, $\mathcal{P}((x, y, z)^T) = (x, y, 0)^T$.

其几何意义见图2.1.




图2.1

定义2.15 投影变换 $\mathcal{P}$ 在 C^n 上的自然基 $e_1, \dots, e_i, \dots, e_n$


下的表示矩阵称为投影矩阵, 记为 $P_{S,T}$, 简记为 P .

其中 $(e_1, \dots, e_i, \dots, e_n) = I_n$.

由表示矩阵有

$$\mathcal{P}(e_1, \dots, e_i, \dots, e_n) = (\mathcal{P}(e_1), \dots, \mathcal{P}(e_i), \dots, \mathcal{P}(e_n)) = (e_1, \dots, e_i, \dots, e_n)P$$


$$\forall \alpha = \begin{bmatrix} a_1 \\ \vdots \\ a_i \\ \vdots \\ a_n \end{bmatrix} \in C^n, \text{ 有 } \alpha = \sum_{i=1}^n a_i e_i, \text{ 由于投影变换 } \mathcal{P} \text{ 是线性变换, 故}$$



$$\mathcal{P}(\alpha) = \sum_{i=1}^n a_i \mathcal{P}(\mathbf{e}_i) = (\mathcal{P}(\mathbf{e}_1), \dots, \mathcal{P}(\mathbf{e}_i), \dots, \mathcal{P}(\mathbf{e}_n)) \begin{bmatrix} a_1 \\ \vdots \\ a_i \\ \vdots \\ a_n \end{bmatrix}$$

$$= (\mathbf{e}_1, \dots, \mathbf{e}_i, \dots, \mathbf{e}_n) \mathbf{P} \begin{bmatrix} a_1 \\ \vdots \\ a_i \\ \vdots \\ a_n \end{bmatrix}.$$

故 $\mathcal{P}(\alpha) = \mathbf{P}\alpha.$



这说明抽象的**投影变换** $\mathcal{P}$ 对 α 的**投影**可由**投影矩阵** P 与 α 的**乘积** $P\alpha$ 表示, 可见**投影矩阵** P 的重要性.

当 $A^2 = A$ 时, 称 A 为**幂等阵** (idempotent matrix), 事实上**投影矩阵**与**幂等阵**有着密切的关系.



定理2.16 矩阵 P 为投影矩阵的充要条件是 P 是幂等阵.

证 先证必要性.

设 P 是投影变换 $\mathcal{P}$ 的投影矩阵, $\forall \alpha \in C^n$,

$\alpha = x + y$, $x \in S$, $y \in T$, 则

$$P\alpha = \mathcal{P}(\alpha) = x = \mathcal{P}(x) = Px.$$

$$P^2\alpha = P(P\alpha) = Px = P\alpha.$$

由 α 的任意性, 故 $P^2 = P$, 即 P 是幂等阵.

再证充分性.

(即证 $P^2 = P$ 时, P 是某投影变换 $\mathcal{P}$ 的投影矩阵)


首先证明 $N(P) = R(I - P)$.

设 P 是幂等阵于是, $P(I - P) = O$.

$\forall \beta \in R(I - P), \exists \alpha$, 使 $\beta = (I - P)\alpha$,

于是 $P\beta = P(I - P)\alpha = O$, 故 $\beta \in N(P)$.

所以 $R(I - P) \subset N(P)$ (*)



$\forall \alpha \in N(P), \text{ 则 } P\alpha = \theta.$

$\alpha = \alpha - P\alpha = (I - P)\alpha, \text{ 故 } \alpha \in R(I - P)$

所以

$$N(P) \subset R(I - P)$$

(**)

由(*), (**) 得 $N(P) = R(I - P).$



于是 $\forall \alpha \in C^n, \alpha = \alpha + P\alpha - P\alpha = P\alpha + (I - P)\alpha$,
其中 $P\alpha \in R(P)$.


因为 $P(I - P)\alpha = \theta$, 故 $(I - P)\alpha \in N(P)$

因此 $C^n \subset R(P) + N(P)$,

显然 $C^n \supset R(P) + N(P)$,

所以 $C^n = R(P) + N(P)$.

以下证 $R(P) + N(P)$ 是直和.



$\forall \gamma \in R(P) \cap N(P),$ 则

$$\gamma \in R(P), \gamma \in N(P) = R(I - P).$$

因此存在 $u, v \in C^n, \gamma = Pu = (I - P)v.$

从而 $\gamma = P^2 u = P(I - P)v = \theta,$

故 $R(P) \cap N(P) = \{\theta\},$

所以 $C^n = R(P) \oplus N(P).$

令 $\mathcal{P}(\alpha) = P\alpha,$ 则 $\mathcal{P}$ 是 α 沿着 $N(P)$ 到 $R(P)$ 的投影变换, P 为投影矩阵. 这表明幂等阵与投影矩阵一一对应.



幂等阵的性质

设 A 幂等阵, 即 $A^2 = A$, 则

- ① A 的特征值只能为 1 或 0;
- ② 不是单位阵的幂等阵是奇异阵.

证 因 A, B 是幂等阵, 故 $A^2 = A, B^2 = B$.

- ① 设 λ 是 A 的特征值, ξ 为属于 λ 的特征向量, 则

$$A\xi = \lambda\xi,$$

$$\text{故 } \lambda\xi = A\xi = A^2\xi = \lambda A\xi = \lambda^2\xi,$$

$$\text{即 } (\lambda^2 - \lambda)\xi = 0,$$

由 $\lambda^2 - \lambda = 0$, 因此 λ 只能为 1 或 0.



②. 因 A 是**幂等阵**, 故 $A^2 = A$, 于是

$$A(A - I) = \mathbf{O},$$

由**Sylvester**不等式知: $r(A) + r(A - I) \leq n$

由 $A \neq I$, 故 $A - I \neq \mathbf{O}$, 因此 $r(A - I) \geq 1$,

所以 $r(A) \leq n - 1 < n$.

这说明 A 不可逆, 即 A 是**奇异阵**. ■

幂等阵与对合阵的关系

例 设 $A = \frac{1}{2}(B + I)$, 则 A 是幂等阵 $\Leftrightarrow B$ 是对合阵 $_{\infty}$
(involutory matrix $B^2 = I$).

证 先证必要性 $\Rightarrow$

设 A 是幂等阵, 故 $A^2 = A$, 将 $A = \frac{1}{2}(B + I)$ 代入得
$$\frac{1}{4}(B^2 + 2B + I) = \frac{1}{2}(B + I),$$
 因此 $B^2 = I$, 即 B 是对合阵.

再证充分性 $\Leftarrow$

设 B 是对合阵, 故 $B^2 = I$, 因此有

$$A^2 = \frac{1}{4}(B^2 + 2B + I) = \frac{1}{2}(B + I) = A,$$
 即 A 是幂等阵.



例 设 A, B 是幂等阵, 则


- ① $A+B$ 是幂等阵 $\Leftrightarrow AB=BA=O$;
- ② $A-B$ 是幂等阵 $\Leftrightarrow AB=BA=B$;
- ③ 若 $AB=BA$, 则 AB, BA 是幂等阵.

证 因 A, B 是幂等阵, 故 $A^2=A, B^2=B$.

① 先证必要性 $\Rightarrow$

设 $A+B$ 是幂等阵, $(A+B)^2=A+B$, 于是 $AB+BA=O$. (1)

将(1)式左乘 A , 右乘 A , 分别得



$$AB + ABA = \mathbf{0}$$

$$ABA + BA = \mathbf{0}$$

将上述二式相减得 $AB + BA = \mathbf{0}$. (2)

(1), (2) 联立解之得 $AB = BA = \mathbf{0}$.

再证充分性 $\Leftarrow$

由 $AB = BA = \mathbf{0}$, 显然有

$$(A + B)^2 = A^2 + AB + BA + B^2 = A + B,$$

这说明 $A + B$ 是幂等阵.

②先证必要性 $\Rightarrow$

设 $A-B$ 是**幂等阵**, $(A-B)^2 = A-B$, 于是 $AB+BA=2B$. (3)

将(3)式左乘 B , 右乘 B , 分别得

$$BAB+BA=2B$$

$$AB+BAB=2B$$

将上述二式相减得

$$AB-BA=O. \quad (4)$$

将(4)代回(3)得

$$AB=BA=B.$$

再证充分性 $\Leftarrow$

由 $AB = BA = \mathbf{O}$, 显然有

$$(A - B)^2 = A^2 - AB - BA + B^2 = A - B,$$

这说明 $A - B$ 是幂等阵.

③ 若 $AB = BA$, 则

$$\begin{aligned}(AB)^2 &= (AB)(AB) = A(BA)B \\ &= A(AB)B = A^2B^2 = AB,\end{aligned}$$

这说明 AB 是幂等阵.

同理 BA 也是幂等阵.



投影矩阵的求法

设 $\mathcal{P}$ 为 $\mathbf{C}^n$ 沿 T 到 S 的投影变换, P 为其投影矩阵.

设 $\varepsilon_1, \dots, \varepsilon_i, \dots, \varepsilon_r$ 为 S 的基; $\eta_1, \dots, \eta_j, \dots, \eta_{n-r}$ 为 T 的基,

则 $\varepsilon_1, \dots, \varepsilon_i, \dots, \varepsilon_r, \eta_1, \dots, \eta_j, \dots, \eta_{n-r}$ 为 $\mathbf{C}^n$ 的基, 且

$$\mathcal{P}(\varepsilon_i) = \varepsilon_i, \quad P\varepsilon_i = \varepsilon_i, \quad i = 1, \dots, r,$$

$$\mathcal{P}(\eta_j) = \theta, \quad P\eta_j = \theta, \quad j = 1, \dots, n-r.$$

令 $M = (\varepsilon_1, \dots, \varepsilon_i, \dots, \varepsilon_r)$, $N = (\eta_1, \dots, \eta_j, \dots, \eta_{n-r})$, 则

$$P(M, N) = (M, O)$$

因为 (M, N) 是 n 阶可逆阵, 所以

$$P = (M, O)(M, N)^{-1}$$

例2.19 在二维空间 $\mathbf{R}^2$ 中, 设 $S = \text{span} \begin{bmatrix} 1 \\ 0 \end{bmatrix}$, $T = \text{span} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$,

$\mathcal{P}$ 为 $\mathbf{R}^2$ 中沿 T 到 S 的投影变换, 求投影矩阵及向量

$\alpha = \begin{bmatrix} 3 \\ 1 \end{bmatrix}$ 沿 T 到 S 的投影.

解 $P = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}^{-1} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & -1 \\ 0 & 0 \end{bmatrix}.$

$$\mathcal{P}(\alpha) = P\alpha = \begin{bmatrix} 1 & -1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 3 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 0 \end{bmatrix}.$$

本题的几何意义如图2.2所示:





图2.2



定义2.16 设 $S \oplus T = \mathbb{C}^n$, $\alpha = x + y$, $x \in S$; $y \in T$.

线性变换 $\mathcal{P}(\alpha) = x$, 则称 $\mathcal{P}$ 是 $\mathbb{C}^n$ 中由 T 到 S 的**正交投影变换**, 简称**正交投影**. 将 $\mathcal{P}$ 的投影矩阵称为**正交投影矩阵**.

由于 S 的正交补 $T = S^\perp$ **惟一**, 所以在**正交投影**中不再提沿着 T 的**正交投影**.

定理2.17 矩阵 P 为正交投影矩阵的充要条件为 P 是
Hermite幂等阵, 即 $P^2 = P = P^H$.


证 先证必要性.

设 P 是正交投影变换 $\mathcal{P}$ 的正交投影矩阵, 由
定理2.16知 P 是幂等阵, 即 $P^2 = P$.

$\forall \alpha \in C^n, \alpha = x + y, \quad x \in S, y \in S^\perp$, 则

$$P\alpha = \mathcal{P}(\alpha) = x \in S,$$

$$(I - P)\alpha = \alpha - P\alpha = \alpha - x = y \in S^\perp.$$



所以 $\mathbf{P}\alpha$ 与 $(\mathbf{I} - \mathbf{P})\alpha$ 应正交, 即

$$(\mathbf{P}\alpha)^{\mathrm{H}}(\mathbf{I} - \mathbf{P})\alpha = \alpha^{\mathrm{H}}[\mathbf{P}^{\mathrm{H}}(\mathbf{I} - \mathbf{P})]\alpha = 0.$$

由 α 的任意性, 必有


$$\mathbf{P}^{\mathrm{H}}(\mathbf{I} - \mathbf{P}) = \mathbf{O},$$

即
$$\mathbf{P}^{\mathrm{H}} = \mathbf{P}^{\mathrm{H}}\mathbf{P}.$$

取共轭转置有 $\mathbf{P} = \mathbf{P}^{\mathrm{H}}\mathbf{P},$

故 $\mathbf{P}^{\mathrm{H}} = \mathbf{P}.$

所以 $\mathbf{P}^2 = \mathbf{P} = \mathbf{P}^{\mathrm{H}}.$



再证充分性.

设 $P^2 = P = P^H$.

由定理2.16充分性的证明知 $C^n = R(P) \oplus N(P)$.

因为 $P^H = P$, 由定理2.13的推论(1)有

$$C^n = R(P) \oplus N(P^H) = R(P) \oplus N(P) = R(P) \oplus R^\perp(P)$$

$\forall \alpha \in C^n$, 令 $\mathcal{P}(\alpha) = P(\alpha)$, 则 $\mathcal{P}$ 为 C^n 中沿着 $R^\perp(P)$ 到 $R(P)$ 的正交投影, P 为正交投影矩阵. ■

正交投影矩阵的求法

设 S 的基为 $\boldsymbol{\varepsilon}_1, \dots, \boldsymbol{\varepsilon}_i, \dots, \boldsymbol{\varepsilon}_r$, $S^\perp$ 的基为 $\boldsymbol{\eta}_1, \dots, \boldsymbol{\eta}_j, \dots, \boldsymbol{\eta}_{n-r}$.


于是 $\mathbf{C}^n = S \oplus S^\perp$, 且 $\boldsymbol{\varepsilon}_i^H \boldsymbol{\eta}_j = 0, i = 1, \dots, r; j = 1, \dots, n-r$.

记 $\boldsymbol{M} = (\boldsymbol{\varepsilon}_1, \dots, \boldsymbol{\varepsilon}_i, \dots, \boldsymbol{\varepsilon}_r)$, $\boldsymbol{N} = (\boldsymbol{\eta}_1, \dots, \boldsymbol{\eta}_j, \dots, \boldsymbol{\eta}_{n-r})$,

则 $\boldsymbol{M}^H \boldsymbol{N} = \mathbf{O}_{r \times (n-r)}$.

于是 $\boldsymbol{P} = (\boldsymbol{M}, \mathbf{O})(\boldsymbol{M}, \boldsymbol{N})^{-1}$

$$= (\boldsymbol{M}, \mathbf{O})(\boldsymbol{M}, \boldsymbol{N})^{-1} [(\boldsymbol{M}, \boldsymbol{N})^H]^{-1} (\boldsymbol{M}, \boldsymbol{N})^H$$



$$\mathbf{P} = (\mathbf{M}, \mathbf{O})(\mathbf{M}, \mathbf{N})^{-1} [(\mathbf{M}, \mathbf{N})^{\mathrm{H}}]^{-1} (\mathbf{M}, \mathbf{N})^{\mathrm{H}}$$

$$= (\mathbf{M}, \mathbf{O}) [(\mathbf{M}, \mathbf{N})^{\mathrm{H}} (\mathbf{M}, \mathbf{N})]^{-1} (\mathbf{M}, \mathbf{N})^{\mathrm{H}}$$

$$= (\mathbf{M}, \mathbf{O}) \begin{bmatrix} \mathbf{M}^{\mathrm{H}} \\ \mathbf{N}^{\mathrm{H}} \end{bmatrix} (\mathbf{M}, \mathbf{N})^{-1} (\mathbf{M}, \mathbf{N})^{\mathrm{H}}$$

$$= (\mathbf{M}, \mathbf{O}) \begin{bmatrix} \mathbf{M}^{\mathrm{H}} \mathbf{M} & \mathbf{M}^{\mathrm{H}} \mathbf{N} \\ \mathbf{N}^{\mathrm{H}} \mathbf{M} & \mathbf{N}^{\mathrm{H}} \mathbf{N} \end{bmatrix}^{-1} \begin{bmatrix} \mathbf{M}^{\mathrm{H}} \\ \mathbf{N}^{\mathrm{H}} \end{bmatrix}$$

$$= (\mathbf{M}, \mathbf{O}) \begin{bmatrix} \mathbf{M}^{\mathrm{H}} \mathbf{M} & \mathbf{O} \\ \mathbf{O} & \mathbf{N}^{\mathrm{H}} \mathbf{N} \end{bmatrix}^{-1} \begin{bmatrix} \mathbf{M}^{\mathrm{H}} \\ \mathbf{N}^{\mathrm{H}} \end{bmatrix}$$

$$= \mathbf{M} (\mathbf{M}^{\mathrm{H}} \mathbf{M})^{-1} \mathbf{M}^{\mathrm{H}}.$$

例 2. 20 在二维空间 $\mathbf{R}^2$ 中, 设 $S = \text{span} \begin{bmatrix} 2 \\ 2 \end{bmatrix}$, $\mathcal{P}$ 为 $\mathbf{R}^2$ 中沿

$S^\perp$ 到 S 的正交投影变换.

求: (1) 正交投影矩阵; (2) $\alpha = \begin{bmatrix} 0 \\ 2 \end{bmatrix}$ 沿 $S^\perp$ 到 S 的投影.

解 (1) 这里 $M = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$, $P = \begin{bmatrix} 2 \\ 2 \end{bmatrix} [(2, 2) \begin{bmatrix} 2 \\ 2 \end{bmatrix}]^{-1} (2, 2) = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$,

$$(2) \mathcal{P}(\alpha) = P\alpha = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 0 \\ 2 \end{bmatrix} = \frac{1}{2} \begin{bmatrix} 2 \\ 2 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

本题的几何意义如图2.3所示:




图2.3



标准正交基下正交投影矩阵的求法

若 $\boldsymbol{\varepsilon}_1, \dots, \boldsymbol{\varepsilon}_k, \dots, \boldsymbol{\varepsilon}_r$ 是 S 的标准正交基, 则正交投影矩阵 $\boldsymbol{P}$ 的计算公式可简化如下:

记 $\boldsymbol{M} = (\boldsymbol{\varepsilon}_1, \dots, \boldsymbol{\varepsilon}_i, \dots, \boldsymbol{\varepsilon}_j, \dots, \boldsymbol{\varepsilon}_r)$, $\boldsymbol{\varepsilon}_i^H \boldsymbol{\varepsilon}_j = \delta_{ij}$, 其中 $i, j = 1, \dots, r$.

于是
$$\boldsymbol{M}^H \boldsymbol{M} = \boldsymbol{I}_r, :$$

故
$$\boldsymbol{P} = \boldsymbol{M} \boldsymbol{M}^H .$$

称上述的矩阵 $\boldsymbol{M}$ 为次酉矩阵, 它恰为某个酉矩阵的列数为 r 的子阵.

例 2. 21 在二维空间 $\mathbf{R}^2$ 中, 设 $S = \text{span} \begin{bmatrix} 1 \\ 0 \end{bmatrix}$, $S^\perp = \text{span} \begin{bmatrix} 0 \\ 1 \end{bmatrix}$,

$\mathcal{P}$ 为 $\mathbf{R}^2$ 中到 S 的正交投影变换, 求**正交投影矩阵**

及向量 $\alpha = \begin{bmatrix} 3 \\ 1 \end{bmatrix}$ 到 S 的**正交投影**.

解 $M = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$, $M^T = [1, 0]$,

$$P = MM^T = \begin{bmatrix} 1 \\ 0 \end{bmatrix} [1, 0] = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix},$$

$$\mathcal{P}(\alpha) = P\alpha = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 3 \\ 1 \end{bmatrix} = \begin{bmatrix} 3 \\ 0 \end{bmatrix}.$$

本题的几何意义如图2.4所示:




图2.4



本章总结

一. 重要定义及概念

(一) 欧氏空间与酉空间

- ① 欧氏空间内积的定义及性质
- ② 四个常用的欧氏空间 $\mathbf{R}^n, \mathbf{R}^{n \times n}, P[x]_n, C[a, b]$ 中内积的定义
- ③ 酉空间内积的定义及性质, $\mathbf{C}^n$ 中内积的定义
- ④ 欧氏空间与酉空间中基的度量矩阵及性质
- ⑤ 内积空间的度量, 标准正交基, 标准正交基的度量矩阵是单位矩阵.



(二)酉变换(正交变换)


- ① 酉变换的定义.
- ② 两种重要的酉变换.

Household变换, Givens变换

- ③ 酉矩阵及其性质, 两个标准正交基的过渡矩阵是酉矩阵.

(三)正交子空间与正交投影

- ① 正交补空间.
- ② 投影变换与投影矩阵.
- ③ 正交投影变换与正交投影矩阵.
- ④ Hermite变换.



二. 重要的定理, 公式.

① 欧氏空间的度量矩阵是**实对称正定**阵

酉空间的度量矩阵是**Hermite正定**阵


② 欧氏空间两个基的度量矩阵是**实相合**矩阵

$$B = C^T A C$$

酉空间两个基的度量矩阵是**复相合**矩阵

$$B = C^H A C$$

③ **线性变换是酉变换**的四个**等价命题**.



④ 恒等变换是酉变换

不变距离的线性变换是酉变换

⑤ 矩阵 A 的列(核)空间与矩阵 A^H 的核(列)空间的关系

$$R(A) \perp N(A^H) = \mathbb{C}^m$$

$$N(A) \perp R(A^H) = \mathbb{C}^n$$

⑥ 投影变换是线性变换

⑦ 矩阵为投影矩阵的充要条件是幂等阵

矩阵为正交投影矩阵的充要条件是幂等的Hermite阵



三. 计算

① 两欧氏空间与酉空间中 **内积** 的计算

② **度量矩阵** 的计算

③ **Gram - Schmidt** 正交化方法

④ **投影矩阵** 的求法: $P = (M, O)(M, N)^{-1}$

正交投影矩阵 的求法: $P = M(M^H M)^{-1} M^H$

标准正交基 下 **正交投影矩阵** 的求法: $P = MM^H$



第三章 Jordan标准形及矩阵分解

核心内容：

1. 矩阵的Jordan标准形
2. Cayley-Hamilton定理
3. 矩阵的满秩分解
4. 矩阵的谱分解
5. 矩阵的奇异值分解

§ 3.1 矩阵的不变因子与初等因子


基本概念：形如

$$A(\lambda) = \begin{bmatrix} a_{11}(\lambda) & a_{12}(\lambda) & \cdots & a_{1n}(\lambda) \\ a_{21}(\lambda) & a_{22}(\lambda) & \cdots & a_{2n}(\lambda) \\ \vdots & \vdots & a_{ij}(\lambda) & \vdots \\ a_{m1}(\lambda) & a_{m2}(\lambda) & \cdots & a_{mn}(\lambda) \end{bmatrix}$$

的 $m \times n$ 矩阵称为 λ 矩阵. 它的元素 $a_{ij}(\lambda) (i=1, \dots, m; j=1, \dots, n)$ 是 λ 的多项式, 数字矩阵可看作是它的特例.

类似可定义 λ 矩阵的相等, 加法, 数乘, 乘法等运算, n

阶 λ 方阵的行列式, λ 矩阵的秩等等. 当 n 阶 λ 矩阵的秩为 n 时, 称其为满秩的或非奇异的.




定义3.1 若对于 n 阶 λ 方阵 $A(\lambda)$, $B(\lambda)$ 有

$$A(\lambda)B(\lambda) = B(\lambda)A(\lambda) = \mathbf{I}_n \quad (3.1)$$

则称 $A(\lambda)$ 可逆, 称 $B(\lambda)$ 为 $A(\lambda)$ 的逆矩阵, 记为 $A^{-1}(\lambda)$.

若 $A(\lambda)$ 有逆, 则唯一. 与数字矩阵不同的是满秩矩阵不一定可逆.

定理3.1 $A(\lambda)$ 可逆的充要条件是 $A(\lambda)$ 的行列式为
不等于零的常数.



初等变换与初等矩阵

λ 矩阵的**三种**重要的**初等变换**及相应的**初等矩阵**:

(1) **换法变换**: 交换 $A(\lambda)$ 的第 i 行(列)与第 j 行(列);

其相应的**初等矩阵**为 E_{ij} .

(2) **倍法变换**: 用**不等于零**的数 k 乘 $A(\lambda)$ 的第 i 行(列);

其相应的**初等矩阵**为 $E_i(k)$.

(3) **消法变换**: 将 $A(\lambda)$ 的第 j 行(列)的 $\phi(\lambda)$ 倍加入第 i 行(列)

($\phi(\lambda)$ 为 λ 的多项式);

其相应的**初等矩阵**为 $E_{ij}(\phi(\lambda))$.



其中

$$\underline{E_{ij}(\phi(\lambda))} = \begin{bmatrix} 1 & & & & & \\ & \ddots & & & & \\ & & 1 & \cdots & \phi(\lambda) & \\ & & & \ddots & \vdots & \\ & & & & 1 & \\ & & & & & \ddots \\ & & & & & & 1 \end{bmatrix} \begin{matrix} \\ \\ i\text{行} \\ \\ j\text{行} \\ \\ \end{matrix}$$

$E_{ij}, E_i(k)$ 即为我们熟知的数字初等矩阵.

初等矩阵的性质

初等阵	行列式	逆矩阵	转置阵
E_{ij}	1	E_{ij}	E_{ij}
$E_i(k)$	k	$E_i(\frac{1}{k})$	$E_i(k)$
$E_{ij}(\varphi(\lambda))$	1	$E_{ij}(-\varphi(\lambda))$	$E_{ji}(\varphi(\lambda))$

表3.1



定义3.2 $A(\lambda), B(\lambda)$ 为两个 $m \times n$ 的矩阵, 若经过有限次行与列的**初等变换**可将 $A(\lambda)$ 化为 $B(\lambda)$, 则称 $A(\lambda)$ 与 $B(\lambda)$ **相抵**, 记为 $A(\lambda) \cong B(\lambda)$.

由矩阵**初等变换**的**可逆性**知道**相抵**满足**自反性**, **对称性**, **传递性**, 故**相抵**是一种**等价关系**.

易知 $A(\lambda) \cong B(\lambda)$ 的**充要条件**是存在一些 m 阶与 n 阶的初等矩阵分别左乘与右乘 $A(\lambda)$ 得到 $B(\lambda)$.

注意: **秩相同**的两个同型 λ 矩阵**不一定相抵**.


Smith 标准形

定理3.2 若 $\text{rank}(A(\lambda))=r$, 则

$$A(\lambda) \cong D(\lambda) = \begin{bmatrix} \varphi_1(\lambda) & & & & \\ & \varphi_2(\lambda) & & & \\ & & \ddots & & \\ & & & \varphi_r(\lambda) & \\ & & & & 0 \\ & & & & & \ddots \\ & & & & & & 0 \end{bmatrix} \quad (3.2)$$

其中 $\varphi_i(\lambda) \mid \varphi_{i+1}(\lambda)$; $\varphi_i(\lambda)$ 为首1多项式, $i=1, 2, \dots, r-1$.


$D(\lambda)$ 为 $A(\lambda)$ 的相抵标准形, 称为 Smith 标准形或法式.



用初等变换求 λ 矩阵的Smith标准形

例 3.1 化 $A(\lambda) = \begin{bmatrix} 1-\lambda & \lambda^2 & \lambda \\ \lambda & \lambda & -\lambda \\ 1+\lambda^2 & \lambda^2 & -\lambda^2 \end{bmatrix}$ 为Smith标准形.


解 $A(\lambda) = \begin{bmatrix} 1-\lambda & \lambda^2 & \lambda \\ \lambda & \lambda & -\lambda \\ 1+\lambda^2 & \lambda^2 & -\lambda^2 \end{bmatrix} \xrightarrow{c_1+c_3} \begin{bmatrix} 1 & \lambda^2 & \lambda \\ 0 & \lambda & -\lambda \\ 1 & \lambda^2 & -\lambda^2 \end{bmatrix}$



$$\xrightarrow{r_3 - r_1} \begin{bmatrix} 1 & \lambda^2 & \lambda \\ 0 & \lambda & -\lambda \\ 0 & 0 & -\lambda^2 - \lambda \end{bmatrix} \xrightarrow[\substack{c_2 - \lambda^2 c_1 \\ c_3 - \lambda c_1}]{} \begin{bmatrix} 1 & 0 & 0 \\ 0 & \lambda & -\lambda \\ 0 & 0 & -\lambda^2 - \lambda \end{bmatrix}$$

$$\xrightarrow[\substack{c_3 + c_2 \\ c_3 \times (-1)}]{} \begin{bmatrix} 1 & 0 & 0 \\ 0 & \lambda & 0 \\ 0 & 0 & \lambda^2 + \lambda \end{bmatrix}.$$





行列式因子

定义3.3 $m \times n$ 的 λ 矩阵 $A(\lambda)$ 中所有 k 阶子式的首项系数为1的**最大公因式**称为 $A(\lambda)$ 的 k 阶**行列式因子**, 记为 $D_k(\lambda)$.

当 $m = n$ 时, 由定义知 $D_n(\lambda)$ 即为 $A(\lambda)$ 的行列式的值.

显然 $D_k(\lambda) \mid D_{k+1}(\lambda)$ (**依次相除性**), $k = 1, \dots, n-1$.

若 $\exists s, s \leq n$, 有 $D_s(\lambda) = 1$, 则必有 $D_k(\lambda) = 1, k = 1, \dots, s$.

不变因子

定义3.4 若 $A(\lambda)$ 的秩为 r , 则 $D_r(\lambda) \neq 0$, 但 $D_{r+1}(\lambda) = 0$.


记

$$d_1(\lambda) = D_1(\lambda),$$

$$d_k(\lambda) = \frac{D_k(\lambda)}{D_{k-1}(\lambda)}, \quad k = 2, \dots, r. \quad (3.3)$$

则 $d_i(\lambda) (i=1, \dots, r)$ 这 r 个首1的多项式称为 $A(\lambda)$ 的不变因子.

式(3.2)里 $A(\lambda)$ 的Smith标准形中的 $\phi_1(\lambda), \dots, \phi_r(\lambda)$ 就是它的不变因子.



定理3.3 相抵的 n 阶 λ 矩阵有相同的各阶行列式因子及不变因子;两个 n 阶矩阵相抵,当且仅当它们有相同的行列式因子或不变因子.

由此可知 n 阶 λ 矩阵的Smith标准形惟一.

例3.2 在例3.1中 $\phi_1(\lambda) = 1, \phi_2(\lambda) = \lambda, \phi_3(\lambda) = \lambda(\lambda+1)$ 即为 $A(\lambda)$ 不变因子.

以下在复数域内讨论问题

秩为 r 的 λ 矩阵 $A(\lambda)$ 的不变因子在复数域内可分解为互异的一次式的乘积:

$$d_1(\lambda) = (\lambda - \lambda_1)^{k_{11}} \dots (\lambda - \lambda_j)^{k_{1j}} \dots (\lambda - \lambda_s)^{k_{1s}}$$

.....

$$d_i(\lambda) = (\lambda - \lambda_1)^{k_{i1}} \dots (\lambda - \lambda_j)^{k_{ij}} \dots (\lambda - \lambda_s)^{k_{is}} \quad (3.4)$$

.....

$$d_r(\lambda) = (\lambda - \lambda_1)^{k_{r1}} \dots (\lambda - \lambda_j)^{k_{rj}} \dots (\lambda - \lambda_s)^{k_{rs}}$$

因为 $d_{i-1}(\lambda) \mid d_i(\lambda)$, $i = 2, \dots, r$, 所以 $k_{1j} \leq \dots \leq k_{ij} \leq \dots \leq k_{rj}$;

若 $\exists k_{ij} = 0$, 必有 $k_{1j} = \dots = k_{i-1j} = 0$; $j = 1, \dots, s$.



例3.3 设 $A(\lambda) = \begin{bmatrix} \lambda(\lambda+1) & & \\ & \lambda & \\ & & (\lambda+1)^2 \end{bmatrix},$

求 $A(\lambda)$ 的 **Smith标准形** 及 **不变因子**.

解 $A(\lambda)$ 虽是对角阵, 但对角元素不依次相除, 故不是 **Smith标准形**.

方法一 用 **初等变换** 计算:

$$A(\lambda) \rightarrow \begin{bmatrix} 1 & & \\ & \lambda(\lambda+1) & \\ & & \lambda(\lambda+1)^2 \end{bmatrix}$$

化成 **Smith标准形**.

不变因子 为 $d_1(\lambda) = 1, d_2(\lambda) = \lambda(\lambda+1), d_3(\lambda) = \lambda(\lambda+1)^2$.

注:对角阵的行列式因子易计算

方法二 用定义计算:

根据最大公因式计算知 $A(\lambda)$ 的行列式因子为

$$D_1(\lambda) = 1, D_2(\lambda) = \lambda(\lambda+1), D_3(\lambda) = \lambda^2(\lambda+1)^3.$$

故不变因子为 $d_1(\lambda) = 1$,

$$d_2(\lambda) = \frac{D_2(\lambda)}{D_1(\lambda)} = \lambda(\lambda+1),$$

$$d_3(\lambda) = \frac{D_3(\lambda)}{D_2(\lambda)} = \lambda(\lambda+1)^2.$$

所以 $A(\lambda)$ 的Smith标准形为
$$\begin{bmatrix} 1 & & \\ & \lambda(\lambda+1) & \\ & & \lambda(\lambda+1)^2 \end{bmatrix}.$$



初等因子

定义3.5 式(3.4)的**不变因子**中所有**幂指数不为零者**,

即**不是常数1**的 $(\lambda - \lambda_j)^{k_{ij}}$ **因式**, $i = 1, 2, \dots, r; j = 1, 2, \dots, s$

连同它的**指数幂**称为 $A(\lambda)$ 的**初等因子**,全体初等因子的集合称为**初等因子组**.

由定义可知**初等因子**可以有相同者.

例3.3中 $A(\lambda)$ 的**不变因子**为 $1, \lambda(\lambda+1), \lambda(\lambda+1)^2$, 所以它的**初等因子组**为 $\lambda, (\lambda+1), \lambda, (\lambda+1)^2$.

定理3.4 n 阶 λ 矩阵 $A(\lambda), B(\lambda)$ 相抵的充要条件是它们有相同的初等因子组且秩相等.

注意: 仅仅初等因子组相同不能保证相抵, 例如

$$A(\lambda) = \begin{bmatrix} 1 & & \\ & \lambda-2 & \\ & & (\lambda-2)^2 \end{bmatrix}, B(\lambda) = \begin{bmatrix} \lambda-2 & & \\ & (\lambda-2)^2 & \\ & & 0 \end{bmatrix}$$

尽管它们的初等因子组相同, 但因为秩不等, 显然不相抵.

附注: 若分块对角阵 $A(\lambda) = \text{diag}(A_1(\lambda), \dots, A_i(\lambda), \dots, A_t(\lambda))$, 则 $A_1(\lambda), \dots, A_i(\lambda), \dots, A_t(\lambda)$ 的初等因子组的全体即为 $A(\lambda)$ 的初等因子组. 例3.3 即说明此结论.

例3.4 设

$$J_{ik} = \begin{bmatrix} \lambda_i & 1 & & \\ & \lambda_i & \ddots & \\ & & \ddots & 1 \\ & & & \lambda_i \end{bmatrix}_{n_{ik} \times n_{ik}},$$

$$\text{求 } \lambda I_{n_{ik}} - J_{ik} = \begin{bmatrix} \lambda - \lambda_i & -1 & & \\ & \lambda - \lambda_i & \ddots & \\ & & \ddots & -1 \\ & & & \lambda - \lambda_i \end{bmatrix}_{n_{ik} \times n_{ik}}$$

的不变因子和初等因子组, 其中 λ_i 是常数.

若想化成**Smith标准形**或分块对角阵较难.

以下计算**最高阶行列式因子**有

$$D_{n_{ik}}(\lambda) = (\lambda - \lambda_i)^{n_{ik}},$$


由其右上角的 $n_{ik}-1$ 阶子式的值为 $(-1)^{n_{ik}-1}$, 于是 $D_{n_{ik}-1}(\lambda) = 1$,

故 $D_1(\lambda) = D_2(\lambda) = \dots = D_{n_{ik}-2}(\lambda) = D_{n_{ik}-1}(\lambda) = 1$.

所以它的**不变因子**为

$$d_1(\lambda) = d_2(\lambda) = \dots = d_{n_{ik}-1}(\lambda) = 1, \quad d_{n_{ik}}(\lambda) = (\lambda - \lambda_i)^{n_{ik}}.$$

因此它的**初等因子组**仅有一个, 为 $d_{n_{ik}}(\lambda) = (\lambda - \lambda_i)^{n_{ik}}$.



§ 3.2 矩阵的Jordan标准形

定理 3.5 设 $A, B \in C^{n \times n}$, $A \sim B \Leftrightarrow \lambda I - A \cong \lambda I - B$.

约定: 将 $\lambda I - A$ 的不变因子, 初等因子称为 A 的不变因子, 初等因子.

定理 3.6 $A \sim B \Leftrightarrow A, B$ 有相同的不变因子.

因为 $\text{rank}(\lambda I - A) = n$, 由定理 3.4, 定理 3.5 可得到:

定理 3.7 $A \sim B \Leftrightarrow A, B$ 有相同的初等因子组.

定义3.6 设 λ_i 为 A 的互异特征值, $i = 1, 2, \dots, s$, 其特征多项式

$$\det(\lambda I - A) = (\lambda - \lambda_1)^{m_1} \dots (\lambda - \lambda_i)^{m_i} \dots (\lambda - \lambda_s)^{m_s}$$

其中 $\sum_{i=1}^s m_i = n$, 称 m_i 为 A 的特征值 λ_i 的代数重数, $\dim V_{\lambda_i} = r_i$

为 λ_i 的几何重数.

定理3.8 设 λ_i 为 A 的互异特征值, $i = 1, 2, \dots, s$; m_i, r_i

分别为 A 的特征值 λ_i 的代数重数与几何重数, 则

$$r_i \leq m_i \quad i = 1, 2, \dots, s.$$

定义3.7 若 $r_i = m_i, i = 1, 2, \dots, s$, 则称 A 为单纯矩阵.

定理3.9 单纯矩阵与对角阵相似.


矩阵 A 的 Jordan 标准形 J

定义 3.8 设 λ_i 为 A 的互异特征值, $i = 1, 2, \dots, s$,

m_i 为 A 的特征值 λ_i 的代数重数, r_i 为 λ_i 的几何重数.

$$J = \begin{bmatrix} J_1 & & & \\ & \ddots & & \\ & & J_i & \\ & & & \ddots \\ & & & & J_s \end{bmatrix}_{n \times n}$$

$$J_i = \begin{bmatrix} J_{i1} & & \\ & \ddots & \\ & & J_{ik} & \\ & & & \ddots \\ & & & & J_{ir_i} \end{bmatrix}_{m_i \times m_i}$$




$$J_{ik} = \begin{bmatrix} \lambda_i & 1 & & \\ & \ddots & \ddots & \\ & & \ddots & 1 \\ & & & \lambda_i \end{bmatrix}_{n_{ik} \times n_{ik}},$$

其中 $\sum_{k=1}^{r_i} n_{ik} = m_i$; $\sum_{i=1}^s m_i = n$, n_{ik} 为 A 的初等因子 $(\lambda - \lambda_i)^{n_{ik}}$


的指数幂. 称 J 为 A 的 Jordan 标准形, J_i 为 Jordan 块,

J_{ik} 为与初等因子 $(\lambda - \lambda_i)^{n_{ik}}$ 对应的 Jordan 子块.



定理 3.10 方阵 A 与它的 Jordan 标准形相似.

$$\text{证 } \lambda I_n - J = \begin{bmatrix} \lambda I_{m_1} - J_1 & & & \\ & \ddots & & \\ & & \boxed{\lambda I_{m_i} - J_i} & \\ & & & \ddots \\ & & & & \lambda I_{m_s} - J_s \end{bmatrix}_{n \times n},$$



$$\lambda I_{m_i} - J_i = \begin{bmatrix} \lambda I_{n_{i1}} - J_{i1} & & & \\ & \ddots & & \\ & & \lambda I_{n_{ik}} - J_{ik} & \\ & & & \ddots \\ & & & & \lambda I_{n_{ir_i}} - J_{ir_i} \end{bmatrix}_{m_i \times m_i}.$$

由例3.4知 $\lambda I_{n_{ik}} - J_{ik}$ 的初等因子为 $(\lambda - \lambda_i)^{n_{ik}}$, $i = 1, 2, \dots, s$.
 故 A 与 J 有相同的初等因子组, 由定理3.7知 $A \sim J$. ■



Jordan标准形的结构

- (1) A 的互异特征值 $\lambda_1, \dots, \lambda_i, \dots, \lambda_s$ 与Jordan块 $J_1, \dots, J_i, \dots, J_s$ 相对应;
- (2) 每个Jordan块 J_i 的子块 J_{ik} 对应着属于 λ_i 的一个特征向量, 子块 J_{ik} 的个数 r_i 表明 λ_i 有 r_i 个线性无关的特征向量, 即 λ_i 的几何重数为 r_i , 而 J_i 的阶数 m_i 即为它的代数重数, 显然
- $$r_i \leq m_i, \quad i = 1, 2, \dots, s;$$
- (3) 每个Jordan子块 J_{ik} 对应于一个与 λ_i 有关的初等因子 $(\lambda - \lambda_i)^{n_{ik}}$, 而 J_{ik} 的阶数 n_{ik} 为这个初等因子的指数幂, 对应于特征值 λ_i , A 有 r_i 个初等因子(子块 J_{ik} 的个数);

(4) A 总共有 $\sum_{i=1}^s r_i$ 个初等因子. 若 $r_i = m_i, i=1,2,\dots,s$, 则 A 有 n 个

初等因子, 即 A 的初等因子都是一次的, 于是 A 为单纯矩阵,

此时 A 相似对角化.

$$(5) J = \begin{bmatrix} J_1 & & & \\ & \ddots & & \\ & & J_i & \\ & & & \ddots \\ & & & & J_s \end{bmatrix} = \begin{bmatrix} \lambda_1 & k_1 & & & \\ & \lambda_2 & \ddots & & \\ & & \ddots & k_i & \\ & & & \lambda_{i+1} & \ddots \\ & & & & \ddots & k_{n-1} \\ & & & & & \lambda_n \end{bmatrix},$$

$k_i = 1$ 或 $0, i=1,2,\dots,n-1; \lambda_1,\dots,\lambda_n$ 为 A 的 n 个特征值.

J 是与对角阵形式上最为接近的矩阵.

定理3.11 $A \sim D \Leftrightarrow A$ 的所有初等因子都是一次的.

求矩阵 A 的Jordan标准形 J 的方法


例3.5 求矩阵 $A = \begin{bmatrix} -1 & -2 & 6 \\ -1 & 0 & 3 \\ -1 & -1 & 4 \end{bmatrix}$ 的Jordan标准形.

解 方法一 首先求初等因子组.

$$\lambda I - A = \begin{bmatrix} \lambda+1 & 2 & -6 \\ 1 & \lambda & -3 \\ 1 & 1 & \lambda-4 \end{bmatrix} \rightarrow \begin{bmatrix} 1 & 0 & 0 \\ 0 & \lambda-1 & 0 \\ 0 & 0 & (\lambda-1)^2 \end{bmatrix}.$$

因此 A 的初等因子组 $\lambda-1, (\lambda-1)^2$.

故 A 的Jordan标准形为 $J = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix}$.



方法二 求 A 的特征值及特征子空间的维数.

$$|\lambda I - A| = \begin{vmatrix} \lambda + 1 & 2 & -6 \\ 1 & \lambda & -3 \\ 1 & 1 & \lambda - 4 \end{vmatrix} = (\lambda - 1)^3 = 0$$

故 A 的特征值为 $\lambda_1 = \lambda_2 = \lambda_3 = 1$ (三重根).

$$\lambda_1 I - A = \begin{bmatrix} 2 & 2 & -6 \\ 1 & 1 & -3 \\ 1 & 1 & -3 \end{bmatrix} \xrightarrow{\text{行}} \begin{bmatrix} 1 & 1 & -3 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

由 $\text{rank}(\lambda_1 I - A) = 1$, 故 $\dim V_{\lambda_1} = 3 - 1 = 2$.

对应于特征值 $\lambda_1 = \lambda_2 = \lambda_3 = 1$, 有2个线性无关的特征向量.

所以 A 的 Jordan 标准形为(两个 Jordan 子块)

$$J = \begin{bmatrix} \boxed{1} & 0 & 0 \\ 0 & \boxed{1} & 1 \\ 0 & 0 & 1 \end{bmatrix} \text{ 或 } \begin{bmatrix} \boxed{1} & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & \boxed{1} \end{bmatrix}.$$

而不是 $\begin{bmatrix} \boxed{1} & 0 & 0 \\ 0 & \boxed{1} & 0 \\ 0 & 0 & \boxed{1} \end{bmatrix}$ 或 $\begin{bmatrix} \boxed{1} & 1 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix}$. (优于方法一)

Jordan子块的乘幂

例3.6 设Jordan子块 J_{ik}


$$J_{ik} = \begin{bmatrix} \lambda_i & 1 & & \\ & \lambda_i & \ddots & \\ & & \ddots & 1 \\ & & & \lambda_i \end{bmatrix}_{n_{ik} \times n_{ik}}, \text{ 则}$$

$$J_{ik}^p = \begin{bmatrix} \lambda_i^p & C_p^1 \lambda_i^{p-1} & C_p^2 \lambda_i^{p-2} & \cdots & C_p^{n_{ik}-1} \lambda_i^{p-n_{ik}+1} \\ & \lambda_i^p & C_p^1 \lambda_i^{p-1} & \cdots & C_p^{n_{ik}-2} \lambda_i^{p-n_{ik}+2} \\ & & \lambda_i^p & \ddots & \vdots \\ & & & \ddots & C_p^1 \lambda_i^{p-1} \\ & & & & \lambda_i^p \end{bmatrix}_{n_{ik} \times n_{ik}}$$



$$= \begin{bmatrix} \lambda^p & (\lambda^p)' & \frac{(\lambda^p)''}{2!} & \dots & \frac{(\lambda^p)^{(n_{ik}-1)}}{(n_{ik}-1)!} \\ & \lambda^p & (\lambda^p)' & \dots & \frac{(\lambda^p)^{(n_{ik}-2)}}{(n_{ik}-2)!} \\ & & \lambda^p & \ddots & \vdots \\ & & & \ddots & (\lambda^p)' \\ & & & & \lambda^p \end{bmatrix} \Big|_{\lambda=\lambda_i}$$

其中 $C_p^t = \frac{p!}{t!(p-t)!}$, 规定 $C_p^t = 0 (t > p)$, $= 1, 2, \dots, r_i$.




$P^{-1}AP = J$ 中相似变换矩阵 P 的求法

例 3.7 设矩阵 $A = \begin{bmatrix} -1 & -2 & 6 \\ -1 & 0 & 3 \\ -1 & -1 & 4 \end{bmatrix}$, 求: P , 使 $P^{-1}AP = J$.

解 由例 3.5 知 A 的 Jordan 标准形 $J = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix}$, 故存在

可逆矩阵 P 使 $P^{-1}AP = J$, 即 $AP = PJ$.


记 $P = (P_1, P_2, P_3)$, 于是有



$$(AP_1, AP_2, AP_3) = (P_1, P_2, P_3) \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix}.$$

比较上式两边得

$$\begin{cases} AP_1 = P_1 \\ AP_2 = P_2 \\ AP_3 = P_2 + P_3 \end{cases} \quad (3.13)$$



可见 P_1, P_2 为 A 的属于特征值 1 的
两个线性无关的特征向量.

由齐次线性方程组 $(1 \cdot I - A)x = \theta$

可求得其基础解系为 $\xi_1 = \begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}, \quad \xi_2 = \begin{bmatrix} 3 \\ 0 \\ 1 \end{bmatrix}$

可以选取 $P_1 = \xi_1$




P_2 的选取较为复杂，它要做到以下两点：

(1). P_2 是与 P_1 线性无关的解；

(2). P_2 要保证非齐次线性方程组 $(I - A)P_3 = -P_2$ 有解.

$$\text{令 } P_2 = k_1 \xi_1 + k_2 \xi_2 = \begin{bmatrix} -k_1 \\ k_1 \\ 0 \end{bmatrix} + \begin{bmatrix} 3k_2 \\ 0 \\ k_2 \end{bmatrix} = \begin{bmatrix} -k_1 + 3k_2 \\ k_1 \\ k_2 \end{bmatrix}.$$



其中 k_1, k_2 是不为**零**的待定常数,
应使(3.13)第三个方程有**解**.


由**增广矩阵**

$$\begin{bmatrix} 2 & 2 & -6 & k_1 - 3k_2 \\ 1 & 1 & -3 & -k_1 \\ 1 & 1 & -3 & -k_2 \end{bmatrix}$$

行 $\rightarrow$

$$\begin{bmatrix} 1 & 1 & -3 & -k_1 \\ 0 & 0 & 0 & 3k_1 - 3k_2 \\ 0 & 0 & 0 & k_1 - k_2 \end{bmatrix}.$$


因此只要满足 $k_1 = k_2 \neq 0$ 即可.



令 $k_1 = k_2 = 1$, 则有 $\mathbf{P}_2 = \boldsymbol{\xi}_1 + \boldsymbol{\xi}_2 = \begin{bmatrix} 2 \\ 1 \\ 1 \end{bmatrix}$,


求得特解 $\mathbf{P}_3 = \begin{bmatrix} -1 \\ 0 \\ 0 \end{bmatrix}$.

故 $\mathbf{P} = (\mathbf{P}_1, \mathbf{P}_2, \mathbf{P}_3) = \begin{bmatrix} -1 & 2 & -1 \\ 1 & 1 & 0 \\ 0 & 1 & 0 \end{bmatrix}$.



算得 $\boldsymbol{P}^{-1} = \begin{bmatrix} 0 & 1 & -1 \\ 0 & 0 & 1 \\ -1 & -1 & 3 \end{bmatrix},$

于是 $\boldsymbol{P}^{-1} \boldsymbol{A} \boldsymbol{P} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix} = \boldsymbol{J}.$



本例中 P_3 不是 A 的特征向量, 因为对 $\lambda = 1$,
由式(3.13)第 3 个方程有

$$(I - A)P_3 = -P_2 \neq \theta.$$

但是有

$$(I - A)^2 P_3 = -(I - A)P_2 = \theta.$$

称 P_3 为 A 的属于特征值 $\lambda = 1$ 的广义特征向量.

一阶线性微分方程

一阶齐次线性微分方程

$$\frac{dy}{dx} + P(x)y = 0$$

由分离变量得通解公式

$$y = Ce^{-\int P(x)dx} \quad (*)$$

一阶非齐次线性微分方程

$$\frac{dy}{dx} + P(x)y = Q(x)$$

由常数变易法得通解公式

$$y = e^{-\int P(x)dx} \left(C + \int Q(x)e^{\int P(x)dx} dx \right) \quad (**)$$

线性常系数微分方程组的求解

求解线性常系数齐次微分方程组初值问题:

$$\begin{cases} \frac{d\mathbf{x}}{dt} = A\mathbf{x}, & A = (a_{ij})_{n \times n} \in \mathbf{R}^{n \times n}. \\ \mathbf{x}(0) = \mathbf{x}_0. \end{cases}$$

其中 $\mathbf{x} = \mathbf{x}(t) = (x_1, \dots, x_i, \dots, x_n)^T$; $\mathbf{x}_0 = (x_1^0, \dots, x_i^0, \dots, x_n^0)^T \in \mathbf{R}^n$.

(一). $A = D = \text{diag}(\lambda_1, \dots, \lambda_i, \dots, \lambda_n)$, A 是对角阵,.

于是化为 n 个一阶线性齐次微分方程.

$$\frac{dx_i}{dt} = \lambda_i x_i, \quad \text{故 } x_i = x_i^0 e^{\lambda_i t}, \quad i = 1, 2, \dots, n.$$

满足初值的解为 $\mathbf{x} = (x_1^0 e^{\lambda_1 t}, \dots, x_i^0 e^{\lambda_i t}, \dots, x_n^0 e^{\lambda_n t})^T$.

(二). $A \neq D = \text{diag}(\lambda_1, \dots, \lambda_i, \dots, \lambda_n)$, A 不是对角阵,

于是分以下两种情况:

(1) $A \sim D$, A 是单纯矩阵.


故存在可逆阵 P , 使 $P^{-1}AP = D$,

P 的列向量即为 A 的 n 个线性无关的特征向量.

令 $\boxed{x = Py}$, 则 $\frac{dPy}{dt} = APy$, 即

$$\frac{dy}{dt} = P^{-1}APy = Dy$$

回到式(一)解出 y , 代入 $x = Py$ 即可.



(2) $A \sim J$, A 不是单纯矩阵


于是存在可逆阵 P , 使 $P^{-1}AP = J$.

此时 A 没有 n 个线性无关的特征向量,

难点为求 P, J .


下面以 $n = 3$ 为实例说明如何计算 P, J ,
来解齐次微分方程组.

例3.8 求解线性常系数齐次微分方程组初值问题


$$\begin{cases} \frac{d\mathbf{x}}{dt} = A\mathbf{x}, \\ \mathbf{x}(0) = \mathbf{x}_0 = (1, 0, 0)^T. \end{cases} \quad (3.14) \text{ 其中 } A = \begin{bmatrix} -1 & -2 & 6 \\ -1 & 0 & 3 \\ -1 & -1 & 4 \end{bmatrix}.$$

解 由例3.7知存在 $P = \begin{bmatrix} -1 & 2 & -1 \\ 1 & 1 & 0 \\ 0 & 1 & 0 \end{bmatrix}$, 使

$$P^{-1}AP = J = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix}, \text{ 其中 } P^{-1} = \begin{bmatrix} 0 & 1 & -1 \\ 0 & 0 & 1 \\ -1 & -1 & 3 \end{bmatrix}.$$




令 $\mathbf{x} = \mathbf{P}\mathbf{y}$, $\mathbf{y} = (y_1, y_2, y_3)^\top$, 代入式(3.14)得

$$\frac{d\mathbf{P}\mathbf{y}}{dt} = \mathbf{A}\mathbf{P}\mathbf{y}, \text{ 故 } \frac{d\mathbf{y}}{dt} = \mathbf{P}^{-1}\mathbf{A}\mathbf{P}\mathbf{y} = \mathbf{J}\mathbf{y}.$$

即

$$\begin{bmatrix} \frac{dy_1}{dt} \\ \frac{dy_2}{dt} \\ \frac{dy_3}{dt} \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix}.$$



即

$$\begin{cases} \frac{dy_1}{dt} = y_1, \\ \frac{dy_2}{dt} = y_2 + y_3, \\ \frac{dy_3}{dt} = y_3. \end{cases}$$

上述方程组中**第一个**与**第三个**方程分别为一阶线性**齐次**方程, 直接解得 $y_1 = C_1 e^t, y_3 = C_3 e^t$.

第二个方程为一阶线性**非齐次**方程, 将 $y_3 = C_3 e^t$ 代入后解得 $y_2 = (C_2 + C_3 t) e^t$.

代回 $\mathbf{x} = \mathbf{P}\mathbf{y}$ 得


$$x_1 = (-C_1 + 2C_2 - C_3 + 2C_3t)e^t,$$

$$x_2 = (C_1 + C_2 + C_3t)e^t,$$

$$x_3 = (C_2 + C_3t)e^t.$$

写成**矩阵形式**为 $\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} -1 & 2 & -1+2t \\ 1 & 1 & t \\ 0 & 1 & t \end{bmatrix} \begin{bmatrix} C_1 \\ C_2 \\ C_3 \end{bmatrix} e^t,$

代入**初始条件**有 $\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} -1 & 2 & -1 \\ 1 & 1 & 0 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} C_1 \\ C_2 \\ C_3 \end{bmatrix}.$



$$\text{故} \begin{bmatrix} C_1 \\ C_2 \\ C_3 \end{bmatrix} = \mathbf{P}^{-1} \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 & 1 & -1 \\ 0 & 0 & 1 \\ -1 & -1 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ -1 \end{bmatrix},$$


$$\text{所以 } \mathbf{x} = \begin{bmatrix} -1 & 2 & -1+2t \\ 1 & 1 & t \\ 0 & 1 & t \end{bmatrix} \begin{bmatrix} 0 \\ 0 \\ -1 \end{bmatrix} e^t = \begin{bmatrix} 1-2t \\ -t \\ -t \end{bmatrix} e^t$$

为齐次微分方程组(3.14)满足初始条件的解. $\square$

例3.8* 求解线性常系数非齐次微分方程组初值问题

$$\begin{cases} \frac{d\mathbf{x}}{dt} = \mathbf{A}\mathbf{x} + \mathbf{f}(t) \\ \mathbf{x}(0) = \mathbf{x}_0 = (1, 0, 0)^T. \end{cases} \quad (3.14)^*$$

$$\text{其中 } \mathbf{A} = \begin{bmatrix} -1 & -2 & 6 \\ -1 & 0 & 3 \\ -1 & -1 & 4 \end{bmatrix}, \mathbf{f}(t) = \begin{bmatrix} -e^t \\ 0 \\ e^t \end{bmatrix}.$$




解 由例 3.8 知存在 $\mathbf{P} = \begin{bmatrix} -1 & 2 & -1 \\ 1 & 1 & 0 \\ 0 & 1 & 0 \end{bmatrix}$, 使

$$\mathbf{P}^{-1} \mathbf{A} \mathbf{P} = \mathbf{J} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix}, \text{ 其中 } \mathbf{P}^{-1} = \begin{bmatrix} 0 & 1 & -1 \\ 0 & 0 & 1 \\ -1 & -1 & 3 \end{bmatrix}.$$

令 $\mathbf{x} = \mathbf{P}\mathbf{y}$, $\mathbf{y} = (y_1, y_2, y_3)^T$, 代入式(3.14)*得

$$\frac{d\mathbf{P}\mathbf{y}}{dt} = \mathbf{A}\mathbf{P}\mathbf{y} + \mathbf{f}(t).$$

$$\text{故 } \frac{d\mathbf{y}}{dt} = \mathbf{P}^{-1} \mathbf{A} \mathbf{P} \mathbf{y} + \mathbf{P}^{-1} \mathbf{f}(t) = \mathbf{J} \mathbf{y} + \mathbf{P}^{-1} \mathbf{f}(t).$$



即

$$\begin{bmatrix} \frac{dy_1}{dt} \\ \frac{dy_2}{dt} \\ \frac{dy_3}{dt} \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} + \begin{bmatrix} 0 & 1 & -1 \\ 0 & 0 & 1 \\ -1 & -1 & 3 \end{bmatrix} \begin{bmatrix} -e^t \\ 0 \\ e^t \end{bmatrix},$$

$$\begin{cases} \frac{dy_1}{dt} = y_1 - e^t, \\ \frac{dy_2}{dt} = y_2 + y_3 + e^t, \\ \frac{dy_3}{dt} = y_3 + 4e^t. \end{cases}$$



上述方程组中第一个与第三个方程分别为一阶线性非齐次方程,

直接解得 $y_1 = e^t(C_1 - t), \quad y_3 = e^t(C_3 + 4t).$

将 $y_3 = C_3 e^t + 4t$ 代入第二个方程解得

$$y_2 = (C_2 + C_3 t + t + 2t^2)e^t.$$

$$\text{故 } \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} = \begin{bmatrix} (C_1 - t)e^t \\ (C_2 + C_3 t + t + 2t^2)e^t \\ (C_3 + 4t)e^t \end{bmatrix} = \begin{bmatrix} (C_1 - t) \\ (C_2 + C_3 t + t + 2t^2) \\ (C_3 + 4t) \end{bmatrix} e^t.$$




代回 $\mathbf{x} = \mathbf{P}\mathbf{y} = \begin{bmatrix} -1 & 2 & -1 \\ 1 & 1 & 0 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} (C_1 - t) \\ (C_2 + C_3 t + t + 2t^2) \\ (C_3 + 4t) \end{bmatrix} e^t. (*)$

为求出待定常数 C_1, C_2, C_3 , 将初始条件代入(*)式, 则

$$\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} -1 & 2 & -1 \\ 1 & 1 & 0 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} (C_1 - 0) \\ (C_2 + C_3 \cdot 0 + 0 + 2 \cdot 0^2) \\ (C_3 + 4 \cdot 0) \end{bmatrix} e^0,$$

即

$$\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} -1 & 2 & -1 \\ 1 & 1 & 0 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} C_1 \\ C_2 \\ C_3 \end{bmatrix}.$$


$$\text{故} \begin{bmatrix} C_1 \\ C_2 \\ C_3 \end{bmatrix} = \begin{bmatrix} -1 & 2 & -1 \\ 1 & 1 & 0 \\ 0 & 1 & 0 \end{bmatrix}^{-1} \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ -1 \end{bmatrix},$$

将 C_1, C_2, C_3 的值代入 (*) 得

$$\begin{aligned} \mathbf{x}(t) &= \begin{bmatrix} -1 & 2 & -1 \\ 1 & 1 & 0 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} (0-t) \\ (0-1t+t+2t^2) \\ (-1+4t) \end{bmatrix} e^t \\ &= \begin{bmatrix} 1-3t+4t^2 \\ -t+2t^2 \\ 2t^2 \end{bmatrix} e^t \end{aligned}$$

为 **非齐次** 微分方程组 (3.14)* 的解.





线性常系数微分方程组的求解步骤

若 $A = D$ (对角阵) 或 $A \sim D$, 问题简明勿需赘述,
以下仅论及 A 不是单纯矩阵的情况: 即 $P^{-1}AP = J$.

- ①. 求 A 的特征值与特征向量;
- ②. 确定 A 的 Jordan 标准形 J ;
- ③. 计算 A 的广义特征向量, 求得 P ;
- ④. 作变换 $x = Py$ 化简微分方程组, 求得 y 代回求得 x ;
- ⑤. 代入初始条件确定任意常数的值.

§ 3.3 Cayley-Hamilton定理

定理3.12 (Cayley - Hamilton) 设 $A \in C^{n \times n}$, A 的特征多项式


$$\varphi(\lambda) = \det(\lambda I - A) = \lambda^n + a_1 \lambda^{n-1} + \dots + a_{n-1} \lambda + a_n$$

则 $\varphi(A) = O$.

证 设 J 为 A 的 Jordan 标准形, 则存在可逆矩阵 P , 使

$$P^{-1}AP = J = \begin{bmatrix} \lambda_1 & k_1 & & & \\ & \lambda_2 & \ddots & & \\ & & \ddots & k_i & \\ & & & \lambda_{i+1} & \ddots \\ & & & & \ddots & k_{n-1} \\ & & & & & \lambda_n \end{bmatrix}$$

其中 $\lambda_1, \lambda_2, \dots, \lambda_n$ 为 A 的特征值; k_i 为 1 或 0, $i = 1, \dots, n-1$.



于是 $\varphi(\lambda) = \det(\lambda \mathbf{I} - \mathbf{A}) = (\lambda - \lambda_1)(\lambda - \lambda_2) \dots (\lambda - \lambda_n)$,

由 $\mathbf{A} = \mathbf{P} \mathbf{J} \mathbf{P}^{-1}$, 从而

$$\begin{aligned}\varphi(\mathbf{A}) &= (\mathbf{A} - \lambda_1 \mathbf{I})(\mathbf{A} - \lambda_2 \mathbf{I}) \dots (\mathbf{A} - \lambda_n \mathbf{I}) \\ &= (\mathbf{P} \mathbf{J} \mathbf{P}^{-1} - \lambda_1 \mathbf{I})(\mathbf{P} \mathbf{J} \mathbf{P}^{-1} - \lambda_2 \mathbf{I}) \dots (\mathbf{P} \mathbf{J} \mathbf{P}^{-1} - \lambda_n \mathbf{I}) \\ &= \mathbf{P}(\mathbf{J} - \lambda_1 \mathbf{I})(\mathbf{J} - \lambda_2 \mathbf{I}) \dots (\mathbf{J} - \lambda_n \mathbf{I}) \mathbf{P}^{-1}.\end{aligned}$$

$$\begin{aligned}
 &= \mathbf{P} \begin{bmatrix} 0 & k_1 & & & \\ \lambda_2 - \lambda_1 & \ddots & & & \\ & \ddots & k_i & & \\ & & \ddots & k_{n-1} & \\ & & & \lambda_n - \lambda_1 \end{bmatrix} \begin{bmatrix} \lambda_1 - \lambda_2 & k & & & \\ 0 & \ddots & & & \\ & \ddots & k_i & & \\ & & \ddots & k_{n-1} & \\ & & & \lambda_{i+1} - \lambda_2 & \ddots \\ & & & & \ddots & k_{n-1} \\ & & & & & \lambda_n - \lambda_2 \end{bmatrix} \dots \\
 &\dots \begin{bmatrix} \lambda_1 - \lambda_n & k & & & \\ \lambda_2 - \lambda_n & \ddots & & & \\ & \ddots & k_i & & \\ & & \lambda_{i+1} - \lambda_n & \ddots & \\ & & & \ddots & k_{n-1} \\ & & & & 0 \end{bmatrix} \mathbf{P}^{-1}.
 \end{aligned}$$

$$\begin{aligned}
 &= \mathbf{P} \begin{bmatrix} 0 & 0 & & & \\ 0 & 0 & \ddots & & \\ \vdots & \vdots & \ddots & * & \\ \vdots & \vdots & & \ddots & \\ 0 & 0 & & & * \\ 0 & 0 & & & * \end{bmatrix} \begin{bmatrix} \lambda_1 - \lambda_3 & k_1 & & & \\ & \lambda_2 - \lambda_3 & k_2 & & \\ & & 0 & & \\ & & & \ddots & \\ & & & & \lambda_{n-1} - \lambda_3 & k_{n-1} \\ & & & & & \lambda_n - \lambda_3 \end{bmatrix} \dots \\
 &\dots \begin{bmatrix} \lambda_1 - \lambda_n & k_1 & & & \\ & \lambda_2 - \lambda_n & \ddots & & \\ & & \ddots & k_i & \\ & & & \lambda_{i+1} - \lambda_n & \ddots \\ & & & & \ddots & k_{n-1} \\ & & & & & 0 \end{bmatrix} \mathbf{P}^{-1} = \mathbf{O}.
 \end{aligned}$$



用 Cayley-Hamilton 定理简化矩阵计算


例3.9 设 $A = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \end{bmatrix}$, 求 $A^{10} - A^6 + 2A$.

解 $\varphi(\lambda) = \det(\lambda I - A) = \lambda^4 - 1$.

由 **Cayley - Hamilton 定理**

$$\varphi(A) = A^4 - 1I_4 = O,$$

因此 $A^{10} - A^6 + 2A = A^6(A^4 - I_4) + 2A = 2A$. $\square$



例3. 10 $A = \begin{bmatrix} -1 & 1 & 0 \\ -4 & 3 & 0 \\ 1 & 0 & 2 \end{bmatrix}$, 计算 $A^5 - 4A^4 + 6A^3 - 6A^2 + 6A - 3I$.

解 $\varphi(\lambda) = \det(\lambda I - A) = (\lambda - 1)^2(\lambda - 2) = \lambda^3 - 4\lambda^2 + 5\lambda - 2$.

令 $f(\lambda) = \lambda^5 - 4\lambda^4 + 6\lambda^3 - 6\lambda^2 + 6\lambda - 3$, 易得

$$f(\lambda) = (\lambda^2 + 1)\varphi(\lambda) + \lambda - 1.$$

由于 $\varphi(A) = \mathbf{O}$, 故 $f(A) = A - I = \begin{bmatrix} -2 & 1 & 0 \\ -4 & 2 & 0 \\ 1 & 0 & 1 \end{bmatrix}$. □


定义3.9 设 $A \in C^{n \times n}$, $f(\lambda)$ 是 λ 的多项式, 若 $f(A) = \mathbf{0}$, 则称

$f(\lambda)$ 为 A 的化零多项式.

A 的化零多项式一定存在, A 的特征多项式即为它的一个化零多项式.

显然若 $f(\lambda)$ 为 A 的化零多项式, 则对任意的多项式 $g(\lambda)$, $f(\lambda)g(\lambda)$ 也是 A 的化零多项式. 可见 A 的化零多项式无最高次数者.


人们转而考虑是否存在比特征多项式 $\varphi(\lambda)$ 次数低的化零多项式.



定义3.10 设 $A \in C^{n \times n}$, 在 A 的化零多项式中, 次数最低的首1多项式称为最小多项式记为 $m_A(\lambda)$.

定理3.13 A 的最小多项式 $m_A(\lambda)$ 整除 A 的任一化零多项式, 特别有 $m_A(\lambda) | \varphi(\lambda)$, 且最小多项式 $m_A(\lambda)$ 惟一.

定理3.14 相似矩阵有相同的最小多项式; n 阶方阵相似对角阵的充分必要条件是它的最小多项式无重根, 且最小多项式是它的第 n 个不变因子.



定理3.15 设 $\lambda_1, \dots, \lambda_t, \dots, \lambda_s$ 是 n 阶方阵 A 的互异特征值, 则

$$m_A(\lambda) = (\lambda - \lambda_1)^{q_1} \dots (\lambda - \lambda_t)^{q_t} \dots (\lambda - \lambda_s)^{q_s}$$

其中 q_i 是 A 的Jordan标准形的Jordan块 J_i 中, Jordan子块 J_{ik} 里 $J_{i1}, \dots, J_{ir_i}$ 方阵中阶数最高者, $i = 1, 2, \dots, s$.

关于最小多项式还有以下结论:

- (1). Jordan子块 J_{ik} 的最小多项式为 $(\lambda - \lambda_i)^{n_{ik}}$;
- (2). 分块对角阵 $A = \text{diag}(A_1, \dots, A_t, \dots, A_s)$ 的最小多项式为分块阵 $A_1, \dots, A_t, \dots, A_s$ 的最小多项式的最小公倍式.

最小多项式的计算方法

例3.11 求 $A = \begin{bmatrix} -1 & -2 & 6 \\ -1 & 0 & 3 \\ -1 & -1 & 4 \end{bmatrix}$ 的最小多项式.


解 方法一: 经计算 $\varphi(\lambda) = \det(\lambda I - A) = (\lambda - 1)^3$

由定理 3.13, $m_A(\lambda) \mid \varphi(\lambda)$

所以 $m_A(\lambda)$ 只能为 $(\lambda - 1), (\lambda - 1)^2, (\lambda - 1)^3$.

经验证 $A - I \neq O, (A - I)^2 = O$.

故 $m_A(\lambda) = (\lambda - 1)^2 = \lambda^2 - 2\lambda + 1$.




方法二: 由例3.5, A 的Jordan标准形为

$$J = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \boxed{\begin{matrix} 1 & 1 \\ 0 & 1 \end{matrix}} \\ 0 & 0 & 1 \end{bmatrix}$$

对于 $\lambda = 1$ 有两个子块, 由定理3.15, $q_i = 2$.

(Jordan 块 J_i 中, $J_{i1}, \dots, J_{i2}$ 方阵中阶数最高者)

故 $m_A(\lambda) = (\lambda - 1)^2 = \lambda^2 - 2\lambda + 1.$ $\square$



§ 3.4 矩阵的满秩分解


定义 3.11 设 $A \in C_r^{m \times n}$ ($r > 0$), 若存在矩阵 $F \in C_r^{m \times r}$ 和 $G \in C_r^{r \times n}$, 即 F 是**列满秩**矩阵, G 是**行满秩**矩阵, 使

$$A = FG \quad (3.15)$$

则称式(3.15)为矩阵 A 的**满秩分解**.

定理 3.16 $\forall A \in C_r^{m \times n}$, 则 A 有**满秩分解** (3.15).

证 由 $\text{rank} A = r$, 故存在**可逆**矩阵 $P \in C_m^{m \times m}$, $Q \in C_n^{n \times n}$, 使



$$PAQ = \begin{bmatrix} \mathbf{I}_r & \mathbf{O} \\ \mathbf{O} & \mathbf{O} \end{bmatrix} = \begin{bmatrix} \mathbf{I}_r \\ \mathbf{O}_{(m-r) \times r} \end{bmatrix} \cdot \begin{bmatrix} \mathbf{I}_r, \mathbf{O}_{r \times (n-r)} \end{bmatrix}.$$

于是 $A = P^{-1} \begin{bmatrix} \mathbf{I}_r \\ \mathbf{O}_{(m-r) \times r} \end{bmatrix} \cdot \begin{bmatrix} \mathbf{I}_r, \mathbf{O}_{r \times (n-r)} \end{bmatrix} Q^{-1}$

令 $\mathbf{F} = P^{-1} \begin{bmatrix} \mathbf{I}_r \\ \mathbf{O}_{(m-r) \times r} \end{bmatrix}$, $\mathbf{G} = \begin{bmatrix} \mathbf{I}_r, \mathbf{O}_{r \times (n-r)} \end{bmatrix} Q^{-1}$; 其中
 $\mathbf{F} \in \mathbf{C}_r^{m \times r}$, $\mathbf{G} \in \mathbf{C}_r^{r \times n}$, 则 $A = \mathbf{F}\mathbf{G}$. ■

定义 3.12 设 $H \in C_r^{m \times n}$ ($r > 0$), 且满足:

(1) H 的前 r 行至少含一个**非零元素**, 且**第一个非零元素**是 1, 后 $m - r$ 行元素皆为**零**;

(2) 若 H 的第 i 行的**第一个非零元素**在第 j_i 列 ($i = 1, 2, \dots, r$), 则 $j_1 < j_2 < \dots < j_r$;

(3) H 中的 $j_1, j_2, \dots, j_r$ 列为**单位阵** I_m 的**前 r 列**.

则称 H 为**Hermite标准形**.

$\forall A \in C_r^{m \times n}$, 仅由**初等行变换**可将 A 化为**Hermite标准形**.

定义 3.13 设 $I_n = (e_1, e_2, \dots, e_n)$, 则 $S = (e_{j_1}, e_{j_2}, \dots, e_{j_n})$

称为**置换矩阵**, 这里 $j_1, j_2, \dots, j_n$ 为 $1, 2, \dots, n$ 的一个**排列**.




矩阵满秩分解的计算方法($AFHG$)

定理 3.17 设 $A \in C_r^{m \times n}$ 的 Hermite 标准形为 H , 那么在 A 的满秩分解式(3.15)中, F 可取为 A 的第 $j_1, j_2, \dots, j_r$ 列构成的 $m \times r$ 矩阵, G 为 H 的前 r 行的 $r \times n$ 矩阵.

证略


例 3.12 求矩阵 $A = \begin{bmatrix} 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 0 \\ 1 & 2 & 1 & 1 \end{bmatrix}$ 的满秩分解.



解 $A = \begin{bmatrix} 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 0 \\ 1 & 2 & 1 & 1 \end{bmatrix} \xrightarrow{\text{行}} \begin{bmatrix} 1 & 0 & -1 & 1 \\ 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix} = H,$

故 $F = \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 2 \end{bmatrix},$

$G = \begin{bmatrix} 1 & 0 & -1 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix},$ 于是 $A = FG.$ $\square$



易见矩阵的**满秩分解不惟一**,但**不同的分解**有如下的**关系**:

定理3.18 设 $A \in C_r^{m \times n}$, 且 A 有**两种不同的分解**,

$$A = F_1 G_1 = F_2 G_2, \text{ 则}$$

(1) 存在可逆阵 $Q \in C_r^{r \times r}$, 使得 $F_1 = F_2 Q$; $G_1 = Q G_2$,

(2) $G_1^H (G_1 G_1^H)^{-1} (F_1^H F_1)^{-1} F_1^H = G_2^H (G_2 G_2^H)^{-1} (F_2^H F_2)^{-1} F_2^H.$

尽管**满秩分解不惟一**, 上述式(2)表明乘积

$$G^H (G G^H)^{-1} (F^H F)^{-1} F^H$$

保持**形式不变**, 这一乘积表达式恰为 A 的**广义逆矩阵** A^+ .

即

$$A^+ = G^H (GG^H)^{-1} (F^H F)^{-1} F^H$$

由于 F 列满秩, 故 $F = F I_r$ 为 F 的满秩分解, 于是

$$F^+ = I_r^H (I_r I_r^H)^{-1} (F^H F)^{-1} F^H = (F^H F)^{-1} F^H$$


由于 G 行满秩, 故 $G = I_r G$ 为 G 的满秩分解, 于是

$$G^+ = G^H (GG^H)^{-1} (I_r^H I_r)^{-1} I_r^H = G^H (GG^H)^{-1}$$

所以对于任意 $A \in C^{m \times n}$, 存在唯一的广义逆矩阵


$A^+ \in C^{n \times m}$, 有

$$A^+ = G^+ F^+$$



§ 3.5 矩阵的三角分解. QR分解

定义3.14 对于 n 阶方阵 A , 若有**下三角阵** L 与**上三角阵** U , 使得 $A = LU$, 是称 A 可三角分解, 称 $A = LU$ 为 A 的三角分解或 **LU 分解**. 特别若 L 为**单位**(**对角元**为1) **下三角阵**时, 称之为 A 的**Doolittle分解**; 若 U 为**单位**(**对角元**为1) **上三角阵**时, 称之为 A 的**Crout分解**.



定理3.19 设 A 是 n 阶非奇异矩阵, 则存在惟一的 **Doolittle分解** 或 **Crout分解**, 使得 $A = LU$ 的 **充要条件** 是 A 的所有 **顺序主子式** 均非零, 即


$\Delta_k = \det A_k \neq 0, k = 1, \dots, n.$ A_k 为 A 的顺序主子阵.

定理3.20 (**LDU 分解定理**) 设 A 是 n 阶非奇异矩阵, 则存在惟一的 **单位下三角阵** L , **对角阵** $D = \text{diag}(d_1, \dots, d_k, \dots, d_n), d_k > 0$ 和 **单位上三角阵** U , 使 A 有如下的 **LDU 分解式**

$$A = LDU \quad (3.23)$$

的 **充要条件** 是 $\Delta_k = \det A_k \neq 0$, 并且

$$d_1 = a_{11}, \quad d_k = \Delta_k / \Delta_{k-1}, \quad k = 2, \dots, n.$$



类似于**实对称正定矩阵**,有如下结论:

若 $A \in \mathbb{C}^{n \times n}$ 是**Hermite正定矩阵**,则存在 n 阶**可逆阵** Q ,使

$$A = Q^H Q.$$


进一步还有下面的结论:

定理3.21 设 $A \in \mathbb{C}^{n \times n}$ 是**Hermite正定矩阵**,则存在具有**正对角元素**的**下三角矩阵** L 使,

$$A = LL^H$$

(3.24)

称为**正定矩阵** A 的**Cholesky分解**.



定理3.22 设 $A \in R_n^{n \times n} (C_n^{n \times n})$, 则存在**正交(酉)矩阵** Q 与**非奇异实(复)的上三角矩阵** R , 使得

$$A = QR \quad (3.25)$$


且除去**对角元素绝对值(模)**全等于1的**对角阵因子**外, 分解式(3.25)是**惟一**的.

式(3.25)称为矩阵 A 的 **QR 分解**或**正交(酉)三角分解**.

§ 3.6 单纯矩阵与正规矩阵的谱分解

定理 3.24 设 $A \in \mathbb{C}^{n \times n}$ 是单纯矩阵, $\lambda_1, \dots, \lambda_i, \dots, \lambda_s$ 是它的互异特征值, m_i, r_i 分别是 λ_i 的代数重数与几何重数, 则存在

$E_i \in \mathbb{C}^{n \times n}, i = 1, 2, \dots, s$; 使得



$$(1) \mathbf{A} = \sum_{i=1}^s \lambda_i \mathbf{E}_i; \quad (3.26)$$

$$(2) \mathbf{E}_i \mathbf{E}_j = \delta_{ij} \mathbf{E}_i = \begin{cases} \mathbf{E}_i & i = j \\ \mathbf{O} & i \neq j \end{cases}; \quad (3.27)$$

$$(3) \sum_{i=1}^s \mathbf{E}_i = \mathbf{I}_n; \quad (3.28)$$

$$(4) \mathbf{E}_i \mathbf{A} = \mathbf{A} \mathbf{E}_i = \lambda_i \mathbf{E}_i; \quad (3.29)$$

$$(5) \text{rank } \mathbf{E}_i = m_i = r_i; \quad (3.30)$$

(6) 满足以上性质的 $\mathbf{E}_i$ 是唯一的, 称为投影矩阵.

证 因 A 是单纯矩阵, $\exists P \in C_n^{n \times n}$, 使


$$P^{-1}AP = D = \text{diag}(D_1, \dots, D_i, \dots, D_s),$$

其中 $D_i = \text{diag}(\lambda_i, \dots, \lambda_i)$ 为 m_i 阶对角阵, $i = 1, 2, \dots, s$.


将 P 按 D_i 的列数分块, $P = (P_1, \dots, P_i, \dots, P_s)$,

其中 $P_i \in C_{m_i}^{n \times m_i}$.

$$\text{记 } P^{-1} = (\tilde{P}_1, \dots, \tilde{P}_i, \dots, \tilde{P}_s)^T = \begin{bmatrix} \tilde{P}_1^T \\ \vdots \\ \tilde{P}_i^T \\ \vdots \\ \tilde{P}_s^T \end{bmatrix}.$$




$$\begin{aligned} P P^{-1} &= (P_1, \dots, P_i, \dots, P_s) \begin{bmatrix} \widetilde{P}_1^T \\ \vdots \\ \widetilde{P}_i^T \\ \vdots \\ \widetilde{P}_s^T \end{bmatrix} \\ &= P_1 \widetilde{P}_1^T + \dots + P_i \widetilde{P}_i^T + \dots + P_s \widetilde{P}_s^T \\ &= \sum_{i=1}^s P_i \widetilde{P}_i^T = \mathbf{I}_n. \end{aligned}$$



$$P^{-1}P = \begin{bmatrix} \tilde{P}_1^T \\ \vdots \\ \tilde{P}_i^T \\ \vdots \\ \tilde{P}_s^T \end{bmatrix} (P_1, \dots, P_i, \dots, P_s) = \begin{bmatrix} \tilde{P}_1^T P_1 & \dots & \tilde{P}_1^T P_i & \dots & \tilde{P}_1^T P_s \\ \vdots & \ddots & \vdots & \vdots & \vdots \\ \tilde{P}_i^T P_1 & \dots & \tilde{P}_i^T P_i & \dots & \tilde{P}_i^T P_s \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \tilde{P}_s^T P_1 & \dots & \tilde{P}_s^T P_i & \dots & \tilde{P}_s^T P_s \end{bmatrix}$$


$$= \text{diag}(\mathbf{I}_{m_1}, \dots, \mathbf{I}_{m_i}, \dots, \mathbf{I}_{m_s}) = \mathbf{I}_n. \quad (\tilde{P}_i^T P_j = \mathbf{O}_{m_i \times m_j}, i \neq j)$$



(1). 由 $P^{-1}AP = \text{diag}(\lambda_1, \dots, \lambda_n)$,

故 $A = P \text{diag}(\lambda_1, \dots, \lambda_n) P^{-1}$

$$= (P_1, \dots, P_i, \dots, P_s) \begin{bmatrix} \lambda_1 & & & \\ & \ddots & & \\ & & \lambda_i & \\ & & & \ddots \\ & & & & \lambda_s \end{bmatrix} \begin{bmatrix} \tilde{P}_1^T \\ \vdots \\ \tilde{P}_i^T \\ \vdots \\ \tilde{P}_s^T \end{bmatrix} = \sum_{i=1}^s \lambda_i P_i \tilde{P}_i^T.$$




令 $P_i \tilde{P}_i^T = E_i$, 则 $A = \sum_{i=1}^s \lambda_i E_i$, 即(1)成立.

式(3.26)称为单纯矩阵 A 的谱分解,

A 的特征值的集合 $\{\lambda_1, \dots, \lambda_i, \dots, \lambda_s\}$ 称为 A 的谱,

$E_1, \dots, E_i, \dots, E_s$ 称为 A 的谱族, 也叫 A 的投影矩阵.

$$(2). \mathbf{E}_i \mathbf{E}_j = (\mathbf{P}_i \tilde{\mathbf{P}}_i^T)(\mathbf{P}_j \tilde{\mathbf{P}}_j^T) = \mathbf{P}_i (\tilde{\mathbf{P}}_i^T \mathbf{P}_j) \tilde{\mathbf{P}}_j^T = \delta_{ij} \mathbf{E}_i; (2) \text{成立.}$$




$$(3). \sum_{i=1}^s \mathbf{E}_i = \sum_{i=1}^s \mathbf{P}_i \tilde{\mathbf{P}}_i^T = (\mathbf{P}_1, \dots, \mathbf{P}_s) \begin{bmatrix} \tilde{\mathbf{P}}_1^T \\ \vdots \\ \tilde{\mathbf{P}}_i^T \\ \vdots \\ \tilde{\mathbf{P}}_s^T \end{bmatrix} = \mathbf{P} \mathbf{P}^{-1} = \mathbf{I}_n.$$

(3)成立.

$$(4). \mathbf{A} \mathbf{E}_i = \left(\sum_{j=1}^s \lambda_j \mathbf{E}_j \right) \mathbf{E}_i = (\lambda_i \mathbf{E}_i) \mathbf{E}_i = \lambda_i \mathbf{E}_i;$$

$$\mathbf{E}_i \mathbf{A} = \mathbf{E}_i \left(\sum_{j=1}^s \lambda_j \mathbf{E}_j \right) = \mathbf{E}_i (\lambda_i \mathbf{E}_i) = \lambda_i \mathbf{E}_i.$$

故 $\mathbf{A} \mathbf{E}_i = \mathbf{E}_i \mathbf{A} = \lambda_i \mathbf{E}_i \quad i = 1, 2, \dots, s. \quad (4) \text{成立.}$ ⁸⁸



(5). 由 $E_i = P_i \tilde{P}_i^T$ 知 $\text{rank} E_i \leq \text{rank} P_i = m_i$;

且有 $\sum_{i=1}^s E_i = I_n$,

又由 $\sum_{i=1}^s \text{rank} E_i \geq \text{rank}(\sum_{i=1}^s E_i) = \text{rank} I_n = n = \sum_{i=1}^s m_i$,

即 $\text{rank} E_i \geq m_i$.

故 $\text{rank} E_i = m_i = r_i$.

(5)成立.



(6). 若还有 $F_i, i = 1, 2, \dots, s$, 也满足以上结论, 则考察

$$\begin{aligned} & (\lambda_j - \lambda_i) E_i F_j = \lambda_j E_i F_j - \lambda_i E_i F_j \\ & = E_i (A F_j) - (A E_i) F_j = A E_i F_j - A E_i F_j = O. \end{aligned}$$

这说明当 $i \neq j$ 时, 必有 $E_i F_j = O$.

于是对于 $i = 1, 2, \dots, s$, 有

$$E_i = E_i I_n = E_i \left(\sum_{j=1}^s F_j \right) = E_i F_i = \left(\sum_{j=1}^s E_j \right) F_i = I_n F_i = F_i.$$

即 A 的谱族惟一.

(6) 成立. 



例 3.13 $A = \begin{bmatrix} 4 & 6 & 0 \\ -3 & -5 & 0 \\ -3 & -6 & 1 \end{bmatrix}$

(1) 说明 A 是单纯矩阵;

(2) 求 A 的谱分解.

解 (1) $\det(\lambda I - A) = \begin{vmatrix} \lambda-4 & -6 & 0 \\ 3 & \lambda+5 & 0 \\ 3 & 6 & \lambda-1 \end{vmatrix} = (\lambda+2)(\lambda-1)^2,$

故 A 的互异特征值个数 $s = 2$;

互异特征值为: $\lambda_1 = 1, \lambda_2 = -2$.




当 $\lambda_1 = 1$ 时,

$$1\mathbf{E} - \mathbf{A} = \begin{bmatrix} -3 & -6 & 0 \\ 3 & 6 & 0 \\ 3 & 6 & 0 \end{bmatrix} \xrightarrow{r} \begin{bmatrix} 1 & 2 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix},$$

基础解系为 $\xi_1 = \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix}$, $\xi_2 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$, 记 $\mathbf{P}_1 = (\xi_1, \xi_2) = \begin{bmatrix} -2 & 0 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}$,

$$m_1 = 2 = \dim V_{\lambda_1} = r_1.$$



当 $\lambda_2 = -2$ 时,

$$-2\mathbf{E} - \mathbf{A} = \begin{bmatrix} -6 & -6 & 0 \\ 3 & 3 & 0 \\ 3 & 6 & -3 \end{bmatrix} \xrightarrow{r} \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & -1 \\ 0 & 0 & 0 \end{bmatrix},$$

特征向量为 $\xi_3 = \begin{bmatrix} -1 \\ 1 \\ 1 \end{bmatrix}$, 记 $\mathbf{P}_2 = \xi_3 = \begin{bmatrix} -1 \\ 1 \\ 1 \end{bmatrix}$,

$m_2 = 1 = \dim V_{\lambda_2} = r_2$, 可见 $\mathbf{A}$ 为单纯矩阵.




(2) 令 $\mathbf{P} = (\mathbf{P}_1, \mathbf{P}_2) = (\xi_1, \xi_2, \xi_3) = \begin{bmatrix} -2 & 0 & -1 \\ 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix}$, 求得

$$\mathbf{P}^{-1} = \begin{bmatrix} -1 & -1 & 0 \\ -1 & -2 & 1 \\ 1 & 2 & 0 \end{bmatrix} = \begin{bmatrix} \widetilde{\mathbf{P}}_1^T \\ \widetilde{\mathbf{P}}_2^T \end{bmatrix};$$

其中 $\widetilde{\mathbf{P}}_1^T = \begin{bmatrix} -1 & -1 & 0 \\ -1 & -2 & 1 \end{bmatrix}$, $\widetilde{\mathbf{P}}_2^T = [1 \quad 2 \quad 0]$


于是 $\mathbf{E}_1 = \mathbf{P}_1 \widetilde{\mathbf{P}}_1^T = \begin{bmatrix} -2 & 0 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} -1 & -1 & 0 \\ -1 & -2 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 2 & 0 \\ -1 & -1 & 0 \\ -1 & -2 & 1 \end{bmatrix}$


$$E_2 = P_2 \widetilde{P_2^T} = \begin{bmatrix} -1 \\ 1 \\ 1 \end{bmatrix} [1 \quad 2 \quad 0] = \begin{bmatrix} -1 & -2 & 0 \\ 1 & 2 & 0 \\ 1 & 2 & 0 \end{bmatrix}.$$

于是单纯矩阵 A 有如下谱分解:

$$A = \lambda_1 E_1 + \lambda_2 E_2$$

$$= 1 \cdot \begin{bmatrix} 2 & 2 & 0 \\ -1 & -1 & 0 \\ -1 & -2 & 1 \end{bmatrix} + (-2) \begin{bmatrix} -1 & -2 & 0 \\ 1 & 2 & 0 \\ 1 & 2 & 0 \end{bmatrix}. \quad \square$$



定义3.15 设 $A \in R^{n \times n} (C^{n \times n})$, 若

$$A^T A = A A^T, \quad (A^H A = A A^H)$$

则称 A 为实(复)正规矩阵.

正规矩阵主要有以下七种:

- (1) 对称阵;
- (2) 实对称阵; (3) 实反对称阵;
- (4) Hermite阵; (5) 反Hermite阵;
- (6) 正交矩阵; (7) 酉矩阵.

七种矩阵之外的正规矩阵

例3.14(实反例) 设 $A = \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix}$, 则 $A^T = \begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix}$,

由 $A^T A = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} = AA^T$, 故 A 是正规矩阵.

但 A 既不是对角阵; 也不是对称阵, 反对称阵; 还不是正交阵.

(复反例) 设 $A = \begin{bmatrix} 1 & 1-2i \\ 2+i & 1 \end{bmatrix}$, $A^H = \begin{bmatrix} 1 & 2-i \\ 1+2i & 1 \end{bmatrix}$.

经验算 $A^H A = AA^H = \begin{bmatrix} 6 & 3-3i \\ 3+3i & 6 \end{bmatrix}$, 故 A 是正规矩阵.

显然 $A^H \neq A$; $A^H \neq -A$; $A^H A = AA^H \neq I$.

故 A 既不是对角阵; 也不是 Hermite 阵, 反 Hermite 阵; 还不是酉矩阵.

定理 3.25 (Schur) $\forall A \in \mathbf{C}^{n \times n}$, 存在酉矩阵 $U \in \mathbf{U}^{n \times n}$, 使

$$U^H A U = R = \begin{bmatrix} \lambda_1 & * & \dots & * & * \\ 0 & \ddots & \ddots & & * \\ \vdots & \ddots & \lambda_j & \ddots & \vdots \\ 0 & & \ddots & \ddots & * \\ 0 & 0 & \dots & 0 & \lambda_n \end{bmatrix}$$

其中 R 为对角元是 A 的特征值的上三角矩阵.

证 用数学归纳法可证之.

定理的深刻含义是任一 n 阶方阵均可酉相似一个对角元为其特征值的上三角矩阵.

定理 3.26 设 $A \in \mathbf{C}^{n \times n}$, 则 A 是**正规矩阵**的**充要条件**是

存在**酉矩阵** $U \in \mathbf{U}^{n \times n}$, 使

$$U^H A U = \text{diag}(\lambda_1, \dots, \lambda_i, \dots, \lambda_n) \quad (3.33)$$

其中 $\lambda_1, \dots, \lambda_i, \dots, \lambda_n$ 是 A 的**特征值**, 即 A **酉相似于对角阵**.

正规矩阵有以下**性质**:

性质1 **正规矩阵**有 n 个**线性无关**的**特征向量**;

性质2 **正规矩阵**属于**不同特征值**的**特征向量**相互**正交**;

性质3 与**正规矩阵**酉相似的矩阵仍是**正规矩阵**.

(1) 对于实矩阵 A , 若 A 不是正规矩阵, 则 A 一定不是正交相似对角阵, 但是它仍然可以相似对角阵.

例如取 $A = \begin{bmatrix} 1 & -1 \\ 0 & 2 \end{bmatrix}$, 易见

$$A^T A = \begin{bmatrix} 1 & -1 \\ -1 & 5 \end{bmatrix} \neq \begin{bmatrix} 2 & -2 \\ -2 & 4 \end{bmatrix} = A A^T$$

故 A 不是正规矩阵, 因此 A 不是正交相似对角阵; 但由于它的特征值互异, 显然 A 相似对角阵 $\begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix}$.

(2). **实正规矩阵**的特征值不一定是**实数**.

$$\text{设 } A = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix} \quad \text{则 } A^T A = A A^T = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix},$$

故 A (既是**反对称**阵, 又是**正交**矩阵) 是**正规矩阵**.

$$|\lambda I - A| = \begin{vmatrix} \lambda & -1 \\ 1 & \lambda \end{vmatrix} = \lambda^2 + 1 = 0, \quad \lambda = \pm i$$

可见 A 的**特征值不是实数**.

(3). 对于**实对称矩阵**, 因为它的**特征值**全是**实数**, 所以它可以**正交相似**对角阵; 但对于**实正规矩阵**, 由于它的**特征值可能是复数**, 所以此时为**酉相似**对角阵.




例3.15 设 $A = \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix}$, 考查 A 相似对角化问题.

解 由例3.14知 A 是正规矩阵.

$$|\lambda I - A| = \lambda^2 - 2\lambda + 2 = 0, \text{ 可求得}$$

A 的特征值为 $\lambda_1 = 1 + i$, $\lambda_2 = 1 - i$.

$$\text{特征向量为 } \xi_1 = \begin{bmatrix} 1 \\ -i \end{bmatrix}, \xi_2 = \begin{bmatrix} 1 \\ i \end{bmatrix}.$$



令 $U = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -i & i \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$, 则 $U^H = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{i}{\sqrt{2}} \\ 1 & -i \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$, 于是

$$\begin{aligned}
 U^H A U &= \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{i}{\sqrt{2}} \\ 1 & -i \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -i & i \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix} \\
 &= \begin{bmatrix} 1+i & 0 \\ 0 & 1-i \end{bmatrix}
 \end{aligned}$$

A 酉相似对角阵.



正规矩阵的谱分解

定理3.27 设 $A \in \mathbb{C}^{n \times n}$ 是正规矩阵, $\lambda_1, \dots, \lambda_i, \dots, \lambda_s$ 是它的互异特征值,

m_i, r_i 分别是 λ_i 的代数重数与几何重数, 则存在 $F_i \in \mathbb{C}^{n \times n}$, 其中

$F_i = U_i U_i^H$, $U_i \in \mathbb{C}^{n \times m_i}$ 为酉矩阵, $i = 1, 2, \dots, s$; 使得

$$(1) \quad A = \sum_{i=1}^s \lambda_i F_i; \quad (3.33)$$

$$(2) \quad F_i F_j = \delta_{ij} F_i; \quad (3.34)$$

$$(3) \quad \sum_{i=1}^s F_i = I_n; \quad (3.35)$$

$$(4) \quad F_i A = A F_i = \lambda_i F_i; \quad (3.36)$$

$$(5) \quad \text{rank } F_i = m_i = r_i; \quad (3.37)$$

$$(6) \quad F_i = F_i^2 = F_i^H, \text{ 即 } F_i \text{ 为正交投影矩阵; 满足以上性质的}$$

F_i 是惟一的.

§ 3.7 矩阵的奇异值分解

引理1 设 $A \in \mathbb{C}^{m \times n}$, 则

$$\text{rank}(A^H A) = \text{rank}(A A^H) = \text{rank} A. \quad (3.34)$$

引理2 设 $A \in \mathbb{C}^{m \times n}$, 则

(1) $A^H A$ 与 $A A^H$ 的特征值均为非负实数;

(2) $A^H A$ 与 $A A^H$ 的非零特征值相同,

且非零特征值的个数等于 $\text{rank} A$.

定义3.16 设 $A \in \mathbb{C}_r^{m \times n}$, $A^H A$ 的特征值为

$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r \geq \lambda_{r+1} = \dots = \lambda_n = 0$, 则称 $\sigma_i = \sqrt{\lambda_i} (i=1, 2, \dots, n)$ 为

A 的奇异值, $\sigma_i (i=1, 2, \dots, r)$ 为 A 的正奇异值, 其中 $r = \text{rank} A$.



奇异值分解定理

定理3. 29 设 $A \in \mathbb{C}^{m \times n}$, 则存在 m 阶酉矩阵 U 和 n 阶酉矩阵 V , 使

$$U^H A V = \begin{bmatrix} \Sigma & O \\ O & O \end{bmatrix}_{m \times n},$$

其中 $\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$, $\sigma_i (i=1, 2, \dots, r)$ 为 A 的正奇异值, 称

$$A = U \begin{bmatrix} \Sigma & O \\ O & O \end{bmatrix} V^H.$$

为 A 的奇异值分解 (Singular Value Decomposition).

上述定理说明任意矩阵皆有奇异值分解 (SVD).

证 由 $A \in \mathbf{C}_r^{m \times n}$, 故 $A^H A \in \mathbf{C}_r^{n \times n}$ 且为Hermite矩阵,

设其特征值为 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r \geq \lambda_{r+1} = \dots = \lambda_n = 0$, 因此

A 的奇异值为 $\sigma_i = \sqrt{\lambda_i} (i=1, 2, \dots, n)$.

由定理3.26, 存在 n 阶酉矩阵 V , 使得

$$V^H (A^H A) V = \text{diag}(\lambda_1, \dots, \lambda_r, 0, \dots, 0) = \begin{bmatrix} \Sigma^2 & \mathbf{O} \\ \mathbf{O} & \mathbf{O} \end{bmatrix}_{n \times n}.$$

记 $V = (V_1, V_2)$, 其中 $V_1 \in \mathbf{C}^{n \times r}$, $V_2 \in \mathbf{C}^{n \times (n-r)}$. 代入上式得

$$V_1^H A^H A V_1 = \Sigma^2, \quad V_2^H A^H A V_2 = \mathbf{O}.$$

于是 $\Sigma^{-1} V_1^H A^H A V_1 \Sigma^{-1} = I_r$, $(A V_2)^H (A V_2) = \mathbf{O}$.

令 $U_1 = A V_1 \Sigma^{-1}$, 由上面第一式得 $U_1^H U_1 = I_r$, 即 U_1 为次酉矩阵;

由第二式得 $A V_2 = \mathbf{O}$.

取 $U_2 \in \mathbb{C}^{m \times (m-r)}$, 使 $U = (U_1, U_2)$ 为 m 阶酉矩阵, 即

$$\underline{U_2^H U_1 = \mathbf{0}, \quad U_2^H U_2 = I_{m-r}.$$

注意到 $AV_1 = U_1 \Sigma$, $AV_2 = \mathbf{0}$, 最后有

$$\begin{aligned} U^H AV &= \begin{bmatrix} U_1^H \\ U_2^H \end{bmatrix} A(V_1, V_2) = \begin{bmatrix} U_1^H AV_1 & U_1^H AV_2 \\ U_2^H AV_1 & U_2^H AV_2 \end{bmatrix} \\ &= \begin{bmatrix} (U_1^H U_1) \Sigma & U_1^H \mathbf{0} \\ (U_2^H U_1) \Sigma & U_2^H \mathbf{0} \end{bmatrix} = \begin{bmatrix} \Sigma & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix}. \quad \blacksquare \end{aligned}$$

推论 设 $A \in \mathbb{C}_n^{n \times n}$, 则存在 n 阶酉矩阵 U 和 V , 使得

$$U^H AV = \text{diag}(\sigma_1, \dots, \sigma_i, \dots, \sigma_n).$$

其中 $\sigma_1, \dots, \sigma_i, \dots, \sigma_n$ 为 A 的 n 个正奇异值.



例3.17 设 $A = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}$, 求 A 的奇异值分解.

解 分四步进行:

第一步: 求 A 的奇异值.

$$A^T A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, |\lambda I - A^T A| = \lambda^2 - 4\lambda + 3 = 0.$$

故 $\lambda_1 = 3, \lambda_2 = 1$, 因此 A 的奇异值全为正数, 且有

$$\sigma_1 = \sqrt{3}, \sigma_2 = 1.$$

$$\Sigma = \begin{bmatrix} \sqrt{3} & 0 \\ 0 & 1 \end{bmatrix}, \Sigma^{-1} = \begin{bmatrix} \frac{1}{\sqrt{3}} & 0 \\ 0 & 1 \end{bmatrix}.$$

第二步:求 $A^H A$ 正交对角化的正交矩阵 V .

对于 $A^H A$ 的特征值 $\lambda_1 = 3$, 求得特征向量 $\xi_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$, 单位化得 $\begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$;

对于 $A^H A$ 的特征值 $\lambda_2 = 1$, 求得特征向量 $\xi_2 = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$, 单位化得 $\begin{bmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$.

于是 $V = \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$, $V^T (A^H A) V = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix} = \Sigma^2$.

第三步:求正交矩阵 U .


因为 A 的秩为 2, 故 $V_1 = V$.

$$U_1 = AV_1\Sigma^{-1} = \begin{bmatrix} \frac{1}{\sqrt{6}} & \frac{-1}{\sqrt{2}} \\ \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} \\ \frac{2}{\sqrt{6}} & 0 \end{bmatrix}.$$

为求 U_2 , 需作向量积.

注① U_1 简单时可直接写出 U_2 ,

② 若 U_1 为列向量, 需用正交条件解齐次线性方程组.



取 $\alpha = \begin{bmatrix} 1 \\ 1 \\ 2 \end{bmatrix}$, $\beta = \begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}$, (与 U_1 的列向量共线的向量)


$$\gamma = \alpha \times \beta = \begin{bmatrix} -2 \\ -2 \\ 2 \end{bmatrix}, \text{取 } \gamma_1 = \begin{bmatrix} 1 \\ 1 \\ -1 \end{bmatrix}, \text{单位化得 } U_2 = \begin{bmatrix} \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{3}} \\ -\frac{1}{\sqrt{3}} \end{bmatrix}.$$

$$U = (U_1, U_2) = \begin{bmatrix} \frac{1}{\sqrt{6}} & \frac{-1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ \frac{2}{\sqrt{6}} & 0 & -\frac{1}{\sqrt{3}} \end{bmatrix}.$$

第四步：求 A 的奇异值分解.

最后有

$$A = U \begin{bmatrix} \Sigma \\ O \end{bmatrix} V^T = \begin{bmatrix} \frac{1}{\sqrt{6}} & \frac{-1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ \frac{2}{\sqrt{6}} & 0 & \frac{-1}{\sqrt{3}} \end{bmatrix} \begin{bmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{-1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}. \quad \square$$



本章总结

一. 重要定义及概念

(一) 矩阵的Jordan标准形

① 行列式因子, 不变因子, 初等因子组


② 矩阵的Smith标准形

矩阵的Hermite标准形

③ 特征值的代数重数与几何重数

④ 单纯矩阵与正规矩阵

⑤ 矩阵的化零多项式, 最少多项式



(二)矩阵的分解


① 矩阵的**Jordan**标准形相似分解 $A = PJP^{-1}$

② 矩阵的满秩分解 $A = FG$

③ 单纯矩阵与正规矩阵的谱分解 $A = \sum_{i=1}^s \lambda_i E_i$

④ 矩阵的奇异值分解 (SVD) $A = U \begin{bmatrix} \Sigma & O \\ O & O \end{bmatrix} V^H$

⑤ Hermite正定阵的Cholesky分解 $A = LL^H$



二. 重要的定理, 公式.

① $A \sim B \Leftrightarrow \lambda I - A \cong \lambda I - B$

$$A \sim B \Leftrightarrow A, B \text{ 有相同的不变因子}$$

$$\Leftrightarrow A, B \text{ 有相同的初等因子组}$$

② 矩阵相似 **对角阵** 的 **充要条件**

$$A \sim D \Leftrightarrow A \text{ 有 } n \text{ 个线性无关的特征向量}$$


$$\Leftrightarrow A \text{ 是 } \textbf{单纯矩阵} \text{ (代数重数等于几何重数)}$$

$$\Leftrightarrow A \text{ 的初等因子组全是一次的.}$$

③ 矩阵相似 **对角阵** 的 **充分条件**

$$A \text{ 的特征值互异则 } A \sim D$$

$$\textbf{Hermite}(\textbf{实对称}) \textbf{酉}(\textbf{正交}) \text{ 相似 } \textbf{对角阵}$$



④ 任何方阵与其**Jordan**标准形相似 $A \sim J$


Jordan标准形的结构

⑤ **Cayley - Hamilton**定理 $\varphi(A) = 0$

⑥ **Schur**定理 $U^H A U = R$


⑦ A 是**正规矩阵**的**充要条件**为 A 酉相似对角阵

$$U^H A U = D$$



三. 计算

- ① 计算矩阵的**Jordan标准形**
- ② 用矩阵的**Jordan标准形**解线性微分方程组
- ③ 求矩阵的**最小多项式**
- ④ 求矩阵的**满秩分解**
- ⑤ 求矩阵的**奇异值分解**
- ⑥ 求**单纯矩阵**的**谱分解**
- ⑦ 求**正规矩阵**的**谱分解**




矩阵分析教程

(电子版)

董增福

哈尔滨工业大学数学系



第四章 范数理论

核心内容

1. 向量范数
2. 矩阵范数
3. 算子范数
4. 范数的应用

§ 4.1 向量范数

定义 4.1 若对于 $\forall x \in C^n$, 都有一个实数 $\|x\|$ 与之对应, 且满足:

(1). **正定性**: 当 $x \neq \theta$, $\|x\| > 0$; 当 $x = \theta$, $\|x\| = 0$;

(2). **齐次性**: $\forall k \in C, \|kx\| = |k| \|x\|$;

(3). **三角不等式**: $\forall x, y \in C^n$, 都有 $\|x + y\| \leq \|x\| + \|y\|$.

则称 $\|x\|$ 为 x 的**向量范数**. 定义了**范数**的**线性空间**称为**赋范线性空间**. 上述三条称为**向量范数三公理**.

向量范数的性质

性质1 $\|-x\| = \|x\|$;

性质2 $|\|x\| - \|y\|| \leq \|x - y\|$.



三种基本的向量范数

例 4.1 设 $\mathbf{x} = (x_1, \dots, x_k, \dots, x_n)^T \in \mathbf{C}^n$, 定义

$$\|\mathbf{x}\|_1 \triangleq \sum_{k=1}^n |x_k| \quad (4.1)$$

则 $\|\mathbf{x}\|_1$ 是向量 $\mathbf{x}$ 的一种范数, 称为向量1范数.

证 (1). 正定性 显然;

(2). 齐次性 显然;



(3).三角不等式:

$\forall \mathbf{y} = (y_1, \dots, y_k, \dots, y_n)^T \in \mathbf{C}^n$, 有

$$\begin{aligned}\|\mathbf{x} + \mathbf{y}\|_1 &= \sum_{k=1}^n |x_k + y_k| \leq \sum_{k=1}^n (|x_k| + |y_k|) \\ &= \sum_{k=1}^n |x_k| + \sum_{k=1}^n |y_k| = \|\mathbf{x}\|_1 + \|\mathbf{y}\|_1.\end{aligned}$$

即三角不等式成立.

故 $\|\mathbf{x}\|_1$ 是 $\mathbf{C}^n$ 上的一种向量范数(向量1范数). ■

向量2范数: Euclid 范数 长度


例 4.2 设 $\mathbf{x} = (x_1, \dots, x_k, \dots, x_n)^T \in \mathbf{C}^n$, 定义

$$\|\mathbf{x}\|_2 \triangleq \sqrt{\sum_{k=1}^n |x_k|^2} = \sqrt{\sum_{k=1}^n \overline{x_k} x_k} = \sqrt{\mathbf{x}^H \mathbf{x}} = \sqrt{(\mathbf{x}, \mathbf{x})} \quad (4.2)$$

则 $\|\mathbf{x}\|_2$ 是向量 $\mathbf{x}$ 的一种范数, 称为向量2范数.

证 (1). 正定性显然;

(2). 齐次性显然;



(3).三角不等式:

由**定理** 2.5之(4)即知 $\forall \mathbf{x}, \mathbf{y} \in \mathbf{C}^n$, 有

$$\|\mathbf{x} + \mathbf{y}\|_2 \leq \|\mathbf{x}\|_2 + \|\mathbf{y}\|_2,$$

故 $\|\mathbf{x}\|_2$ 是 $\mathbf{C}^n$ 上的一种**向量范数**, 称为**向量 2 范数**, $\|\mathbf{x}\|_2$ 也叫**Euclid范数**, 即通常意义下**向量**的**长度**.


向量2范数的酉不变性

向量2范数的性质

对 $\forall \mathbf{x} \in \mathbf{C}^n$ 和任意的酉矩阵 U , 有

$$\|U\mathbf{x}\|_2 = \sqrt{(U\mathbf{x})^H (U\mathbf{x})} = \sqrt{\mathbf{x}^H U^H U \mathbf{x}} = \sqrt{\mathbf{x}^H \mathbf{x}} = \|\mathbf{x}\|_2. \quad (4.3)$$

上述的结果称为向量2范数的酉不变性.



向量 ∞ 范数


例 4.3 设 $\mathbf{x} = (x_1, \dots, x_k, \dots, x_n)^T \in \mathbf{C}^n$, 定义

$$\|\mathbf{x}\|_{\infty} \triangleq \max_k |x_k| \quad (4.4)$$

则 $\|\mathbf{x}\|_{\infty}$ 是向量 $\mathbf{x}$ 的一种范数, 称为向量 ∞ 范数.

证 (1). 正定性显然;

(2). 齐次性显然;




(3).三角不等式: $\forall \mathbf{y} = (y_1, \dots, y_k, \dots, y_n)^T \in \mathbf{C}^n$, 有

$$\begin{aligned}\|\mathbf{x} + \mathbf{y}\|_{\infty} &= \max_k |x_k + y_k| \leq \max_k |x_k| + \max_k |y_k| \\ &= \|\mathbf{x}\|_{\infty} + \|\mathbf{y}\|_{\infty}.\end{aligned}$$

即三角不等式成立.

故 $\|\mathbf{x}\|_{\infty}$ 是 $\mathbf{C}^n$ 上的一种向量范数(向量 ∞ 范数). ■



三个重要的不等式


引理(Young不等式) 对任意实数 $a \geq 0$ 和 $b \geq 0$, 都有

$$ab \leq \frac{a^p}{p} + \frac{b^q}{q}. \quad (4.5)$$

其中

$$p > 1, q > 1, \frac{1}{p} + \frac{1}{q} = 1;$$

p, q 称为共轭指数.



证 ①若 $ab = 0$, 结论显然成立;

②以下设 $a > 0, b > 0$, 构造函数

$$f(b) = \frac{a^p}{p} + \frac{b^q}{q} - ab.$$

求得惟一驻点 $b_0 = a^{\frac{1}{q-1}} = a^{p-1} = a^{\frac{p}{q}}$,

易知它为最小值点, 故 $0 = f(b_0) \leq f(b)$,

此即 $ab \leq \frac{a^p}{p} + \frac{b^q}{q}.$






定理 4.1 (**Holder不等式**) $\forall x_k, y_k \in \mathbf{C}, k = 1, \dots, n$, 有

$$\sum_{k=1}^n |x_k| |y_k| \leq \left(\sum_{k=1}^n |x_k|^p \right)^{\frac{1}{p}} \left(\sum_{k=1}^n |y_k|^q \right)^{\frac{1}{q}} \quad (4.6)$$

其中 p, q 为共轭指数.

证 ① 当 x_k 或 y_k ($k = 1, \dots, n$) 全为 0 时, 结论显然成立.

② 设 x_k 不全为 0, y_k 也不全为 0, 以下证明式(4.6)的
等价式. 由引理 **Young不等式** 得



$$\begin{aligned}
 & \sum_{k=1}^n \boxed{|x_k|} \boxed{|y_k|} \\
 & \frac{\sum_{k=1}^n \boxed{|x_k|} \boxed{|y_k|}}{\left(\sum_{k=1}^n |x_k|^p \right)^{\frac{1}{p}} \left(\sum_{k=1}^n |y_k|^q \right)^{\frac{1}{q}}} \\
 & = \sum_{k=1}^n \left[\frac{|x_k|}{\left(\sum_{k=1}^n |x_k|^p \right)^{\frac{1}{p}}} \right] \left[\frac{|y_k|}{\left(\sum_{k=1}^n |y_k|^q \right)^{\frac{1}{q}}} \right] \quad \left(\boxed{a} \boxed{b} \right) \\
 & \leq \sum_{k=1}^n \left[\frac{|x_k|^p}{p \left(\sum_{k=1}^n |x_k|^p \right)} + \frac{|y_k|^q}{q \left(\sum_{k=1}^n |y_k|^q \right)} \right] = \frac{1}{p} + \frac{1}{q} = 1
 \end{aligned}$$

去分母即为式(4.6). ■

取 $p = q = 2$, 就是有名的 **Cauchy - Schwarz不等式**.

定理 4.2(**Minkowski不等式**) 对任何 $p \geq 1$, 有

$$\left(\sum_{k=1}^n |x_k + y_k|^p \right)^{\frac{1}{p}} \leq \left(\sum_{k=1}^n |x_k|^p \right)^{\frac{1}{p}} + \left(\sum_{k=1}^n |y_k|^p \right)^{\frac{1}{p}}. \quad (4.7)$$

证 ① 若 $p = 1$, 式(4.7)显然成立;

② 以下设 $p > 1$. 设 q 为 p 的共轭指数,
由三角不等式有

$$\begin{aligned} \sum_{k=1}^n |x_k + y_k|^p &= \sum_{k=1}^n |x_k + y_k|^1 |x_k + y_k|^{p-1} \\ &\leq \sum_{k=1}^n |x_k| |x_k + y_k|^{p-1} + \sum_{k=1}^n |y_k| |x_k + y_k|^{p-1} \end{aligned}$$

上式右端两项各用**Holder不等式**得

$$\sum_{k=1}^n |x_k + y_k|^p$$

$$\leq \left(\sum_{k=1}^n |x_k|^p \right)^{\frac{1}{p}} \left(\sum_{k=1}^n |x_k + y_k|^{(\underline{(p-1)q}} \right)^{\frac{1}{q}} + \left(\sum_{k=1}^n |y_k|^p \right)^{\frac{1}{p}} \left(\sum_{k=1}^n |x_k + y_k|^{(\underline{(p-1)q}} \right)^{\frac{1}{q}}$$

$$= \left(\sum_{k=1}^n |x_k|^p \right)^{\frac{1}{p}} \left(\sum_{k=1}^n |x_k + y_k|^p \right)^{\frac{1}{q}} + \left(\sum_{k=1}^n |y_k|^p \right)^{\frac{1}{p}} \left(\sum_{k=1}^n |x_k + y_k|^p \right)^{\frac{1}{q}}$$

$$= \left[\left(\sum_{k=1}^n |x_k|^p \right)^{\frac{1}{p}} + \left(\sum_{k=1}^n |y_k|^p \right)^{\frac{1}{p}} \right] \left(\sum_{k=1}^n |x_k + y_k|^p \right)^{\frac{1}{q}}$$

若 $x_k + y_k = 0$, $k = 1, 2, \dots, n$, 式(4.7)显然成立.

否则 $\left(\sum_{k=1}^n |x_k + y_k|^p \right)^{\frac{1}{q}} > 0$,

不等式两端同除 $\left(\sum_{k=1}^n |x_k + y_k|^p \right)^{\frac{1}{q}}$, 注意到 $1 - \frac{1}{q} = \frac{1}{p}$, 故

$$\left(\sum_{k=1}^n |x_k + y_k|^p \right)^{\frac{1}{p}} \leq \left(\sum_{k=1}^n |x_k|^p \right)^{\frac{1}{p}} + \left(\sum_{k=1}^n |y_k|^p \right)^{\frac{1}{p}}.$$



例 4.4 设 $\mathbf{x} = (x_1, \dots, x_k, \dots, x_n)^T \in \mathbf{C}^n$, 定义

$$\|\mathbf{x}\|_p \triangleq \left(\sum_{k=1}^n |x_k|^p \right)^{\frac{1}{p}} \quad 1 \leq p \leq \infty \quad (4.8)$$


则 $\|\mathbf{x}\|_p$ 是向量 $\mathbf{x}$ 的一种范数, 称为向量 p 范数.

证 (1). 正定性显然;

(2). 齐次性显然;

(3). 三角不等式: $\forall \mathbf{y} = (y_1, \dots, y_k, \dots, y_n)^T \in \mathbf{C}^n$, 由

Minkowski不等式有


$$\left(\sum_{k=1}^n |x_k + y_k|^p\right)^{\frac{1}{p}} \leq \left(\sum_{k=1}^n |x_k|^p\right)^{\frac{1}{p}} + \left(\sum_{k=1}^n |y_k|^p\right)^{\frac{1}{p}}$$

这正是

$$\|\mathbf{x} + \mathbf{y}\|_p \leq \|\mathbf{x}\|_p + \|\mathbf{y}\|_p.$$

即**三角不等式**成立.

故 $\|\mathbf{x}\|_p$ 是 $\mathbf{C}^n$ 上的一种**向量范数**(**向量 p 范数**). ■

对于 $\|\mathbf{x}\|_p$, $p=1$, 即为**向量的1范数**;

$p=2$ 即为**向量的2范数**.

定理 4.3 设 $\mathbf{x} \in \mathbf{C}^n$, 则

$$\lim_{p \rightarrow \infty} \|\mathbf{x}\|_p = \|\mathbf{x}\|_\infty.$$

可以从**已知的向量范数**出发, 构造**无数新的向量范数**.

定理 4.4 设 $A \in \mathbf{C}_n^{m \times n}$ (**列满秩**), $\|\cdot\|_a$ 是 $\mathbf{C}^m$ 上的一种**向量范数**,

$$\text{对 } \forall \mathbf{x} \in \mathbf{C}^n, \text{ 定义 } \|\mathbf{x}\|_b \triangleq \|A\mathbf{x}\|_a \quad (4.9)$$

则 $\|\mathbf{x}\|_b$ 是 $\mathbf{C}^n$ 中的**向量范数**.

例 4.5 设 A 是 n 阶**正定矩阵**, 对 $\forall \mathbf{x} \in \mathbf{C}^n$, 定义

$$\|\mathbf{x}\|_A \triangleq \sqrt{\mathbf{x}^H A \mathbf{x}} \quad (4.10)$$

则 $\|\mathbf{x}\|_A$ 是 $\mathbf{C}^n$ 中的**向量范数**.



注意到 n 维线性空间 $V_n(C)$ 与 C^n 同构, 有如下结果:

例 4.6 设 $V_n(C)$ 是复数域 C 上的 n 维线性空间,
 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 是 $V_n(C)$ 的一组基. $\forall \alpha \in V_n(C)$ 可唯一地

表示为 $\alpha = \sum_{k=1}^n x_k \varepsilon_k$, 其中 $\mathbf{x} = (x_1, \dots, x_k, \dots, x_n)^T \in C^n$,

又设 $\|\cdot\|$ 是 C^n 上的向量范数, 定义

$$\|\alpha\|_v \triangleq \|\mathbf{x}\|$$

则如此定义 $\|\alpha\|_v$ 的就是 $V_n(C)$ 上的向量范数.

例 4.8 设 $\mathbf{x} = (x_1, \dots, x_k, \dots, x_n)^T \in \mathbf{C}^n$, 定义

$$\|\mathbf{x}\|_p \triangleq \left(\sum_{k=1}^n |x_k|^p \right)^{\frac{1}{p}} \quad \underline{\underline{0 < p < 1}}$$

由于它不满足式(4.1)中的(3), 故如此定义的

$\|\mathbf{x}\|_p$ 不是 $\mathbf{C}^n$ 上的向量范数.

例如若在 $\mathbf{R}^n$ 中, 取 $\mathbf{x} = (1, 0, \dots, 0)^T$, $\mathbf{y} = (0, 1, \dots, 0)^T$,

设 $p = \frac{1}{2}$, $\|\mathbf{x} + \mathbf{y}\|_{\frac{1}{2}} = 4$; $\|\mathbf{x}\|_{\frac{1}{2}} = 1$, $\|\mathbf{y}\|_{\frac{1}{2}} = 1$,

故 $\|\mathbf{x}\|_{\frac{1}{2}}$ 不是 $\mathbf{R}^n$ 上的向量范数.

向量范数的等价性

定义 4.2 设 $\|\cdot\|_a$ 和 $\|\cdot\|_b$ 是 C^n 上的两种向量范数,

若存在正数 c_1, c_2 , 使 $\forall x \in C^n$ 都有

$$c_1 \|\cdot\|_b \leq \|\cdot\|_a \leq c_2 \|\cdot\|_b$$

则称向量范数 $\|\cdot\|_a$ 与 $\|\cdot\|_b$ 等价.

易证向量范数的等价具有自反性, 对称性, 传递性.

定理 4.6 n 维线性空间 $V_n(F)$ 上的任意两个向量范数都是等价的.

定义4.3 设 $\{\mathbf{x}^{(k)}\}$ 是 C^n 中的**向量序列**, 其中 $\mathbf{x}^{(k)} = (x_1^{(k)}, \dots, x_i^{(k)}, \dots, x_n^{(k)})^T$,

若 $\lim_{k \rightarrow \infty} x_i^{(k)} = x_i \ (i=1, 2, \dots, n)$, 则称**向量序列** $\{\mathbf{x}^{(k)}\}$ 是**收敛**的, 并称

$\{\mathbf{x}^{(k)}\}$ 的**极限**为**向量** $\mathbf{x} = (x_1, \dots, x_i, \dots, x_n)^T$, 记为

$$\lim_{k \rightarrow \infty} \mathbf{x}^{(k)} = \mathbf{x}. \quad (4.17)$$

向量序列不收敛时称为**发散**的.

定理 4.7 C^n 中的**向量序列** $\{\mathbf{x}^{(k)}\}$ **收敛**于 $\mathbf{x}$ 的**充分必要条件**是对于 C^n 上的**任一向量范数** $\|\cdot\|$, 都有

$$\lim_{k \rightarrow \infty} \|\mathbf{x}^{(k)} - \mathbf{x}\| = 0. \quad (4.18)$$

§ 4.2 矩阵范数

定义 4.4 若对于 $\forall A \in C^{n \times n}$, 都有一个实数 $\|A\|$ 与之对应, 且满足:

- (1). **正定性**: 当 $A \neq O$, $\|A\| > 0$; 当 $A = O$, $\|A\| = 0$;
- (2). **齐次性**: $\forall k \in C, \|kA\| = |k| \|A\|$;
- (3). **三角不等式**: $\forall A, B \in C^{n \times n}$, 都有 $\|A + B\| \leq \|A\| + \|B\|$;
- (4). **相容性**: $\forall A, B \in C^{n \times n}$, 都有 $\|AB\| \leq \|A\| \|B\|$.

则称 $\|A\|$ 为 $C^{n \times n}$ 上矩阵 A 的**矩阵范数**. (先讨论**方阵**)

矩阵范数的性质

性质1 $\|-A\| = \|A\|$;

性质2 $\|A\| - \|B\| \leq \|A - B\|$.



例 4.9 设 $A = (a_{ij})_{n \times n} \in \mathbf{C}^{n \times n}$, 定义

$$\|A\|_{m_1} \triangleq \sum_{i=1}^n \sum_{j=1}^n |a_{ij}| \quad (4.22)$$

则 $\|A\|_{m_1}$ 是 $\mathbf{C}^{n \times n}$ 上的一种**矩阵范数**, 称为矩阵的 m_1 **范数**.

证 (1). **正定性** 显然;
(2). **齐次性** 显然;

(3).三角不等式, 设 $\mathbf{B} = (b_{ij})_{n \times n} \in \mathbf{C}^{n \times n}$, 则

$$\mathbf{A} + \mathbf{B} = (a_{ij} + b_{ij})_{n \times n}, \text{ 于是}$$

$$\begin{aligned} \|\mathbf{A} + \mathbf{B}\|_{m_1} &= \sum_{i=1}^n \sum_{j=1}^n |a_{ij} + b_{ij}| \\ &\leq \sum_{i=1}^n \sum_{j=1}^n (|a_{ij}| + |b_{ij}|) \\ &= \sum_{i=1}^n \sum_{j=1}^n |a_{ij}| + \sum_{i=1}^n \sum_{j=1}^n |b_{ij}| \\ &= \|\mathbf{A}\|_{m_1} + \|\mathbf{B}\|_{m_1}. \end{aligned}$$

(4) 相容性 $AB = (\sum_{k=1}^n a_{ik} b_{kj})_{n \times n}$.

$$\|AB\|_{m_1} = \sum_{i=1}^n \sum_{j=1}^n \left| \sum_{k=1}^n a_{ik} b_{kj} \right| \quad (\text{三角不等式})$$

$$\leq \sum_{i=1}^n \sum_{j=1}^n \left(\sum_{k=1}^n |a_{ik}| |b_{kj}| \right) \quad (n \text{ 项模和})$$

$$\leq \sum_{i=1}^n \sum_{j=1}^n \left[\left(\sum_{k=1}^n |a_{ik}| \right) \left(\sum_{k=1}^n |b_{kj}| \right) \right] \quad (n^2 \text{ 项模和})$$

$$= \sum_{i=1}^n \left(\sum_{k=1}^n |a_{ik}| \right) \sum_{j=1}^n \left(\sum_{k=1}^n |b_{kj}| \right) \quad (\text{移项换序})$$

$$= \left(\sum_{i=1}^n \sum_{k=1}^n |a_{ik}| \right) \left(\sum_{j=1}^n \sum_{k=1}^n |b_{kj}| \right) = \|A\|_{m_1} \|B\|_{m_1}$$

可见 $\|A\|_{m_1}$ 是 $\mathbf{C}^{n \times n}$ 上的一种矩阵范数.

矩阵的 F 范数 Frobenius 范数


例 4.10 设 $A = (a_{ij})_{n \times n} \in \mathbf{C}^{n \times n}$, 定义

$$\|A\|_F = \|A\|_{m_2} \triangleq \sqrt{\sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2} = \sqrt{\text{tr}(A^H A)} \quad (4.23)$$

则 $\|A\|_F$ 是 $\mathbf{C}^{n \times n}$ 上的一种**矩阵范数**, 称为矩阵的**Frobenius 范数**, 简称 **F 范数**, 或**迹范数**.

证 (1). **正定性** 显然;


(2). **齐次性** 显然;



(3).三角不等式, 设 $B = (b_{ij})_{n \times n} \in \mathbb{C}^{n \times n}$, 则

$$\|A + B\|_F = \left(\sum_{i=1}^n \sum_{j=1}^n |a_{ij} + b_{ij}|^2 \right)^{\frac{1}{2}} \quad (\text{Minkowski不等式})$$

$$\begin{aligned} &\leq \left(\sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2 \right)^{\frac{1}{2}} + \left(\sum_{i=1}^n \sum_{j=1}^n |b_{ij}|^2 \right)^{\frac{1}{2}} \quad (p=2, \sum_{i=1}^n \sum_{j=1}^n \text{号}) \\ &= \|A\|_F + \|B\|_F \end{aligned}$$



(4) 相容性 $AB = \left(\sum_{k=1}^n a_{ik} b_{kj} \right)_{n \times n}$

$$\|AB\|_F = \left(\sum_{i=1}^n \sum_{j=1}^n \left| \sum_{k=1}^n a_{ik} b_{kj} \right|^2 \right)^{\frac{1}{2}}$$

$$\leq \left[\sum_{i=1}^n \sum_{j=1}^n \left(\sum_{k=1}^n |a_{ik}| |b_{kj}| \right)^2 \right]^{\frac{1}{2}} \quad (\text{三角不等式})$$

$$\leq \left[\sum_{i=1}^n \sum_{j=1}^n \left(\sum_{k=1}^n |a_{ik}|^2 \right) \left(\sum_{k=1}^n |b_{kj}|^2 \right) \right]^{\frac{1}{2}}$$

(Cauchy - Schwarz不等式)

$$\begin{aligned}
&= \left[\sum_{i=1}^n \left(\sum_{k=1}^n |a_{ik}|^2 \right) \sum_{j=1}^n \left(\sum_{k=1}^n |b_{kj}|^2 \right) \right]^{\frac{1}{2}} \left(\sum_{j=1}^n \sum_{k=1}^n \text{换序} \right) \\
&= \left(\sum_{i=1}^n \sum_{k=1}^n |a_{ik}|^2 \right)^{\frac{1}{2}} \left(\sum_{j=1}^n \sum_{k=1}^n |b_{kj}|^2 \right)^{\frac{1}{2}} = \|A\|_F \|B\|_F
\end{aligned}$$

可见 $\|A\|_F$ 是 $\mathbf{C}^{n \times n}$ 上的一种**矩阵范数**. ■

例 设 $A = \begin{bmatrix} 2\sqrt{2} & 3+4i \\ 6i & -10 \end{bmatrix}$, 则

$$\|A\|_F = \sqrt{8 + 25 + 36 + 100} = 13.$$

矩阵 F 范数的性质

定理 4.8 设 $A \in \mathbb{C}^{n \times n}$, 记 $A = (\alpha_1, \dots, \alpha_j, \dots, \alpha_n)$,

$\alpha_j \in \mathbb{C}^n, j = 1, \dots, n$, 则

$$\textcircled{1} \|A\|_F^2 = \sum_{j=1}^n \|\alpha_j\|_2^2; \quad (4.24)$$


$$\textcircled{2} \|A\|_F^2 = \text{tr}(A^H A) = \sum_{i=1}^n \lambda_i(A^H A) \quad (4.25)$$

其中 $\lambda_i(A^H A) (i = 1, 2, \dots, n)$ 表示 $A^H A$ 的第 i 个特征值.

③ 对任意的 n 阶酉矩阵 U, V 有

$$\|UA\|_F = \|AV\|_F = \|UAV\|_F = \|U^H AV\|_F = \|A\|_F \quad (4.26)$$

称之为 F 范数的酉不变性.




证 ① $\|A\|_F^2 = \sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2.$

$$\|\alpha_j\|_2^2 = \sum_{i=1}^n |a_{ij}|^2, \quad j = 1, 2, \dots, n. \text{ 于是}$$

$$\sum_{j=1}^n \|\alpha_j\|_2^2 = \sum_{j=1}^n \sum_{i=1}^n |a_{ij}|^2 \xrightarrow{\text{换序}} \sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2 = \|A\|_F^2, \quad \text{①成立.}$$

①说明矩阵F范数的平方等于其列向量2范数的平方和.




②

由 $A = (\alpha_1, \dots, \alpha_j, \dots, \alpha_n)$, 有 $A^H =$

$$\begin{bmatrix} \alpha_1^H \\ \vdots \\ \alpha_j^H \\ \vdots \\ \alpha_n^H \end{bmatrix}.$$

$$A^H A = \begin{bmatrix} \alpha_1^H \\ \vdots \\ \alpha_j^H \\ \vdots \\ \alpha_n^H \end{bmatrix} (\alpha_1, \dots, \alpha_j, \dots, \alpha_n) = \begin{bmatrix} \alpha_1^H \alpha_1 & \cdots & \alpha_1^H \alpha_j & \cdots & \alpha_1^H \alpha_n \\ \vdots & & \vdots & & \vdots \\ \alpha_j^H \alpha_1 & \cdots & \alpha_j^H \alpha_j & \cdots & \alpha_j^H \alpha_n \\ \vdots & & \vdots & & \vdots \\ \alpha_n^H \alpha_1 & \cdots & \alpha_n^H \alpha_j & \cdots & \alpha_n^H \alpha_n \end{bmatrix}.$$




$$\text{而 } \mathbf{a}_j^H \mathbf{a}_j = (\overline{a_{1j}} \cdots \overline{a_{ij}} \cdots \overline{a_{nj}}) \begin{bmatrix} a_{1j} \\ \vdots \\ a_{ij} \\ \vdots \\ a_{nj} \end{bmatrix} = \sum_{i=1}^n \overline{a_{ij}} a_{ij} = \sum_{i=1}^n |a_{ij}|^2.$$

$$\text{则 } \text{tr}(\mathbf{A}^H \mathbf{A}) = \sum_{j=1}^n \mathbf{a}_j^H \mathbf{a}_j = \sum_{j=1}^n \sum_{i=1}^n |a_{ij}|^2 = \sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2 = \|\mathbf{A}\|_F^2.$$

$$\text{又因为 } \text{tr}(\mathbf{A}^H \mathbf{A}) = \sum_{i=1}^n \lambda_i(\mathbf{A}^H \mathbf{A}), \text{ 故 ② 成立.}$$

②说明矩阵 $\mathbf{A}$ 的 **F 范数**的平方等于矩阵 $\mathbf{A}^H \mathbf{A}$ 的**迹**或它的**特征值的和**.



③ 对任意的 n 阶酉矩阵 U, V 由②有

$$\|UA\|_F^2 = \text{tr}[(UA)^H(UA)] = \text{tr}[A^H(U^H U)A] = \text{tr}(A^H A) = \|A\|_F^2$$

$$\|AV\|_F^2 = \text{tr}[(AV)^H(AV)] = \text{tr}[V^H(A^H A)V] = \text{tr}(A^H A) = \|A\|_F^2.$$


同理可证其它等式, ③成立.

③说明矩阵的 F 范数具有酉不变性.

因为 $(A, A) \triangleq \text{tr}(A^H A)$,

所以 $\|A\|_F = \sqrt{\text{tr}(A^H A)} = \sqrt{(A, A)}$,

可见矩阵的Frobenius范数是向量的Euclid范数的推广.




例 4.11 式 设 $A = (a_{ij})_{n \times n} \in \mathbf{C}^{n \times n}$, 定义

$$\|A\|_{m_\infty} \triangleq n \max_{i,j} |a_{ij}| \quad (4.27)$$

则 $\|A\|_{m_\infty}$ 是 $\mathbf{C}^{n \times n}$ 上的一种**矩阵范数**, 称为矩阵的 m_∞ **范数**,
(为满足**相容性公理**, 式(4.27)中增加了因子 n).

证 (1). **正定性** 显然 ;
(2). **齐次性** 显然 ;



(3).三角不等式, 设 $B = (b_{ij})_{n \times n} \in C^{n \times n}$, 则


$$\|A + B\|_{m_\infty} = n \max_{i,j} |a_{ij} + b_{ij}| \quad (\text{三角不等式})$$

$$\leq n \max_{i,j} (|a_{ij}| + |b_{ij}|)$$

$$\leq n (\max_{i,j} |a_{ij}| + \max_{i,j} |b_{ij}|)$$

$$= n \max_{i,j} |a_{ij}| + n \max_{i,j} |b_{ij}|$$

$$= \|A\|_{m_\infty} + \|B\|_{m_\infty}.$$




(4) 相容性

$$AB = \left(\sum_{k=1}^n a_{ik} b_{kj} \right)_{n \times n}.$$

$$\|AB\|_{m_\infty} = n \max_{i,j} \left| \sum_{k=1}^n a_{ik} b_{kj} \right| \quad (\text{三角不等式})$$

$$\leq n \max_{i,j} \sum_{k=1}^n |a_{ik}| |b_{kj}|$$

$$\leq n \max_{i,j} \sum_{k=1}^n \left(\max_{i,j} |a_{ij}| \right) |b_{kj}| \quad (i\text{行 } |a_{ik}| \leq \max_{i,j} |a_{ij}| \text{ 全体})$$



$$= n \left(\max_{i,j} |a_{ij}| \right) \left(\max_{i,j} \sum_{k=1}^n |b_{kj}| \right)$$

$$\leq n \left(\max_{i,j} |a_{ij}| \right) (n \max_{i,j} |b_{kj}|) = \|A\|_{m_\infty} \|B\|_{m_\infty}.$$

可见 $\|A\|_{m_\infty}$ 是 $\mathbf{C}^{n \times n}$ 上的一种**矩阵范数**. ■

设 $A = \begin{bmatrix} 2i & -1 \\ -5 & 3-4i \end{bmatrix}$, 则 $\|A\|_{m_\infty} = 10$.



定理 4.9 设 $\|\cdot\|_m$ 是 $C^{n \times n}$ 上的**矩阵范数**, $A = (a_{ij})_{n \times n} \in C^{n \times n}$, 则

(1). $\|A\|_m$ 是 a_{ij} 的**连续函数**, $i = 1, \dots, n; j = 1, \dots, n$;


(2). $C^{n \times n}$ 上任意两个**矩阵范数等价**.

定义 4.5 设 $\|\cdot\|_m$ 是 $C^{n \times n}$ 上的**矩阵范数**, $\|\cdot\|_v$ 是 C^n 上的**向量范数**,

若对 $\forall A \in C^{n \times n}$ 和 $\forall x \in C^n$ 都有

$$\|Ax\|_v \leq \|A\|_m \|x\|_v, \quad (4.28)$$

则称**矩阵范数** $\|\cdot\|_m$ 与**向量范数** $\|\cdot\|_v$ 是**相容**的.



例 4.12 $C^{n \times n}$ 上的矩阵 m_1 范数与 C^n 上的向量 1 范数相容.

例 4.13 $C^{n \times n}$ 上的矩阵 m_∞ 范数与 C^n 上的向量 ∞ 范数相容.

例 4.14 $C^{n \times n}$ 上的矩阵 F 范数与 C^n 上的向量 2 范数相容.

证 设 $A = (a_{ij})_{n \times n}$, $\mathbf{x} = (x_1, \dots, x_j, \dots, x_n)^T$,

则 $A\mathbf{x} = (\sum_{j=1}^n a_{ij} x_j)_{n \times 1}$. 于是

用范数平方证

$$\|Ax\|_2^2 = \sum_{i=1}^n \left| \sum_{j=1}^n a_{ij} x_j \right|^2 \quad (\text{三角不等式})$$

$$\leq \sum_{i=1}^n \left(\sum_{j=1}^n |a_{ij}| |x_j| \right)^2 \quad (\text{Cauchy - Schwarz不等式})$$

$$\leq \sum_{i=1}^n \left[\left(\sum_{j=1}^n |a_{ij}|^2 \right) \left(\sum_{j=1}^n |x_j|^2 \right) \right] \quad (\text{对 } i \text{ 求和 } \sum_{j=1}^n |x_j|^2 \text{ 是常数})$$

$$= \left(\sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2 \right) \left(\sum_{j=1}^n |x_j|^2 \right) = \|A\|_F^2 \|x\|_2^2.$$

即 $\|Ax\|_2 \leq \|A\|_F \|x\|_2$, 故矩阵 F 范数与向量 2 范数相容. ■

用**矩阵范数** $\|\cdot\|_m$ 定义与其**相容**的**向量范数** $\|\cdot\|_v$

定理 4.10 设 $\|\cdot\|_m$ 是 $\mathbb{C}^{n \times n}$ 上的一种**矩阵范数**, 则在

$\mathbb{C}^n$ 上必存在与它**相容**的**向量范数**.

事实上任取 $\theta \neq \alpha \in \mathbb{C}^n, \forall x \in \mathbb{C}^n$, 定义

$$\|x\|_v \triangleq \|x\alpha^H\|_m, \quad (\text{用**矩阵范数**定义**向量范数**})$$

则这样定义的**向量范数** $\|\cdot\|_v$ 与**矩阵范数** $\|\cdot\|_m$ **相容**.

另一方面, 与**向量范数****类似**, 同一矩阵的**矩阵范数**有一定的**差别**.

$$\text{如 } \|I_n\|_{m_1} = n, \quad \|I_n\|_{m_2} (\|I_n\|_F) = \sqrt{n}, \quad \|I_n\|_{m_\infty} = n.$$

要找出一种**矩阵范数**, 使 $\|I_n\| = 1$, 此即**算子范数**.

用**向量范数** $\|\cdot\|_v$ 定义与其**相容**的**矩阵范数** $\|\cdot\|$

定理4.11 设 $\|\cdot\|_v$ 是 C^n 上的**向量范数**, $\forall A \in C^{n \times n}$ **定义**

$$\|A\| \triangleq \max_{x \neq \theta} \frac{\|Ax\|_v}{\|x\|_v} (= \max_{\|x\|_v=1} \|Ax\|_v) \quad (4.30)$$

则 $\|A\|$ 是 $C^{n \times n}$ 上与**向量范数** $\|\cdot\|_v$ **相容**的**矩阵范数**, 且 $\|I_n\|=1$.

证 由式(4.30)显然有 $\|I_n\|=1$. 又由

$$\|A\| = \max_{x \neq \theta} \frac{\|Ax\|_v}{\|x\|_v} \geq \frac{\|Ax\|_v}{\|x\|_v},$$

得
$$\|Ax\|_v \leq \|A\| \|x\|_v.$$

即**矩阵范数** $\|\cdot\|$ 与**向量范数** $\|\cdot\|_v$ **相容**.

以下证明 $\|\cdot\|$ 满足**矩阵范数四公理**.

(1) 若 $A = O$, 则 $\|A\| = 0$.

若 $A \neq O$, 则定有 $\theta \neq x_0 \in C^n$, 使 $Ax_0 \neq \theta$,

$$\|A\| \geq \frac{\|Ax_0\|_v}{\|x_0\|_v} > 0,$$

正定性得证.

(2) $\forall k \in C$,

$$\|kA\| = \max_{x \neq \theta} \frac{\|kAx\|_v}{\|x\|_v} = |k| \max_{x \neq \theta} \frac{\|Ax\|_v}{\|x\|_v} = |k| \|A\|$$

齐次性得证.

(3) 三角不等式

另设 $B \in C^{n \times n}$, 有


$$\|A+B\| = \max_{x \neq \theta} \frac{\|(A+B)x\|_v}{\|x\|_v} \leq \max_{x \neq \theta} \frac{\|Ax\|_v}{\|x\|_v} + \max_{x \neq \theta} \frac{\|Bx\|_v}{\|x\|_v} = \|A\| + \|B\|.$$

三角不等式成立.

(4) 相容性

$$\|AB\| = \max_{x \neq \theta} \frac{\|(AB)x\|_v}{\|x\|_v} \leq \max_{x \neq \theta} \frac{\|A\| \|Bx\|_v}{\|x\|_v} = \|A\| \max_{x \neq \theta} \frac{\|Bx\|_v}{\|x\|_v} = \|A\| \|B\|$$

相容性满足, 故 $\|\cdot\|$ 是 $C^{n \times n}$ 上的矩阵范数. ■



算子范数

定义 4.6 式(4.30)中所定义的**矩阵范数**称为**算子范数**或称之为由**向量范数** $\|\cdot\|_v$ 导出的**矩阵范数**, 也称为**导出范数**或**从属范数**.

定理 4.11表明对于任意给定的**向量范数**, 一定有与之**相容**的**矩阵范数**, 由它导出的**导出范数**即是其例.



定理 4.12 设 $A = (a_{ij})_{n \times n} \in \mathbb{C}^{n \times n}$, $\|A\|_1$ 是由 **向量 1 范数** 导出的 **算子范数**, 则

$$\|A\|_1 = \max_j \sum_{i=1}^n |a_{ij}| \quad (4.31)$$

称为 **矩阵 1 范数** 或 **列 (模) 和范数**.

$$\text{设 } A = \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix}, \text{ 则 } \|A\|_1 = 2.$$

定理 4.13 设 $A = (a_{ij})_{n \times n} \in \mathbb{C}^{n \times n}$, $\|A\|_2$ 是由**向量2范数**

导出的**算子范数**, 则


$$\|A\|_2 = \sqrt{\lambda_n} = \sqrt{\max_i \lambda_i(A^H A)} \quad (4.32)$$

称为**矩阵的2范数**或**谱范数**.

这里 λ_n 是矩阵 $A^H A$ 的**最大特征值**.

设 $A = \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix}$, 于是 $A^H A = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$, $A^H A$ 的**特征值**为

$\lambda_1 = \lambda_2 = 2$, 于是 $\|A\|_2 = \sqrt{2}$.




定理 4.14 设 $A = (a_{ij})_{n \times n} \in \mathbb{C}^{n \times n}$, $\|A\|_\infty$ 是由**向量 ∞ 范数**导出的**算子范数**, 则

$$\|A\|_\infty = \max_i \sum_{j=1}^n |a_{ij}| \quad (4.33)$$

称为**矩阵的 ∞ 范数**或**行(模)和范数**.

$$\text{设 } A = \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix}, \text{ 则 } \|A\|_\infty = 2.$$



$\|A\|_2$ 的性质

定理 4.15 设 $A \in \mathbf{C}^{n \times n}$, U 和 V 为 n 阶酉矩阵, 则

(1) $\|A^H\|_2 = \|A\|_2$;

(2) $\|UA\|_2 = \|AV\|_2 = \|UAV\|_2 = \|A\|_2$, 称为**矩阵2范数**的酉不变性;

(3) 若 A 是正规矩阵, $\lambda_1, \dots, \lambda_j, \dots, \lambda_n$ 是 A 的 n 个特征值, 则

$$\|A\|_2 = \max_j |\lambda_j| = \rho(A).$$

$A \in C^{m \times n}$ 矩阵范数的变化

(1) 矩阵范数的相容性公理应为 $\forall A \in C^{m \times n}, B \in C^{n \times p}$, 有

$$\|AB\| \leq \|A\| \|B\|, \text{ 其中 } \|AB\| \text{ 为 } C^{m \times p} \text{ 上的矩阵范数, } \|A\|$$

为 $C^{m \times n}$ 上的矩阵范数, $\|B\|$ 为 $C^{n \times p}$ 上的矩阵范数, 当

然, 这些矩阵范数必须取相同的类型.

(2), $\forall A \in C^{m \times n}, \forall x \in C^n$, 有 $\|Ax\|_v \leq \|A\|_m \|x\|_v$, 其中 $\|Ax\|_v$ 为

C^m 上的向量范数, $\|x\|_v$ 为 C^n 上的向量范数, 这两个向量

范数必须取相同的类型

(3) 在算子范数定义中, 对 $\forall A \in C^{m \times n}$, 有

$$\|A\| \triangleq \max_{x \neq \theta} \frac{\|Ax\|_v}{\|x\|_v}, \text{ 其中 } \|Ax\|_v \text{ 为 } C^m \text{ 上的向量范数, } \|x\|_v \text{ 为}$$

C^n 上的向量范数, 这两个向量范数必须取相同的类型.

$A \in \mathbb{C}^{m \times n}$ 的六种矩阵范数

$$(1) \|A\|_{m_1} \triangleq \sum_{i=1}^m \sum_{j=1}^n |a_{ij}| \quad m_1 \text{范数}$$

$$\textcircled{2} \|A\|_F = \|A\|_{m_2} \triangleq \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2} = \sqrt{\text{tr}(A^H A)} \quad F(\text{迹})\text{范数或 } m_2 \text{范数}$$

$$(3) \|A\|_{m_\infty} \triangleq \max\{m, n\} \max_{i,j} |a_{ij}| \quad m_\infty \text{范数}$$

$$(4) \|A\|_1 \triangleq \max_j \sum_{i=1}^m |a_{ij}| \quad 1 \text{范数或列模和范数}$$

$$\textcircled{5} \|A\|_2 \triangleq \sqrt{\max_j \lambda_j(A^H A)} = \sqrt{\rho(A^H A)} \quad 2 \text{范数或谱范数}$$

$$(6) \|A\|_\infty \triangleq \max_i \sum_{j=1}^n |a_{ij}| \quad \infty \text{范数或行模和范数}$$

矩阵的 p 范数和 m_p 范数都与向量的 p 范数相容, 这里 $p = 1, 2, \infty$.

§ 4.4 范数的应用

定义 4.7 设 $A \in \mathbb{C}^{n \times n}$, $\lambda_1, \dots, \lambda_j, \dots, \lambda_n$ 为 A 的 n 个特征值, 称

$$\rho(A) = \max_j |\lambda_j|$$

为 A 的谱半径.

定理 4.16 设 $A \in \mathbb{C}^{n \times n}$, 则

(1) $\rho(A^k) = [\rho(A)]^k$;

(2) $\rho(A^H A) = \rho(AA^H) = \|A\|_2^2$;

(3) 当 A 是正规矩阵时, $\rho(A) = \|A\|_2$.



定理 4.17 设 $A \in C^{n \times n}$, 则对 $C^{n \times n}$ 上的任一矩阵范数 $\|\cdot\|$, 皆有

$$\rho(A) \leq \|A\|. \quad (4.40)$$

定理 4.18 设 $A \in C^{n \times n}$, $\forall \varepsilon > 0$, 则存在某一矩阵范数 $\|\cdot\|_m$, 使得

$$\|A\|_m \leq \rho(A) + \varepsilon. \quad (4.41)$$

定理 4.19 设 $A \in C^{n \times n}$, 若对 $C^{n \times n}$ 上的某一矩阵范数 $\|\cdot\|_m$ 如果

$$\|A\|_m < 1, \text{ 则 } I - A \text{ 可逆.}$$




矩阵扰动分析的内容

设 $A \in C_n^{n \times n}$, $b \in C^n$, 对于线性方程组 $Ax = b$ 的扰动分析:

- (1) A, b 的微小变化 ΔA 和 Δb 对实际问题的解产生什么影响?
- (2) A^{-1} 与 $(A + \Delta A)^{-1}$ 是否非常接近?
- (3) 误差扰动 $\Delta A, \Delta b$ 引起解的误差 Δx 的大小如何变化?

略




本章总结

一. 重要定义及概念


(一) 向量范数

- ① 向量 1 范数
- ② 向量 2 范数 或 Euclid 范数
- ③ 向量 ∞ 范数
- ④ 向量 p 范数
- ⑤ 向量范数的等价



(二) 矩阵范数

- ① 矩阵的 m_1 范数
- ② 矩阵的 F (迹) 范数 或 m_2 范数
- ③ 矩阵的 m_∞ 范数
- ④ 矩阵范数与向量范数的相容性
- ⑤ 矩阵范数的等价




(三) 算子范数

- ① 矩阵的 1 范数 或 列和范数
- ② 矩阵的 2 范数 或 谱范数
- ③ 矩阵的 ∞ 范数 或 行和范数

(四) 矩阵的谱半径 $\rho(A)$

正规矩阵的谱半径 $\rho(A) = \|A\|_2$



二. 重要的定理, 公式.

① Young不等式

Holder不等式

Minkowski不等式

② n 维线性空间的任意两个向量范数等价

③ 向量2范数具有酉不变性

矩阵 F 范数或迹范数具有酉不变性

矩阵2范数或谱范数具有酉不变性


④ 矩阵的 p 范数和 m_p 范数都与向量的 p 范数相容,

这里 $p = 1, 2, \infty$.



三. 计算


- ① 计算 向量1范数, 向量2范数或Euclid范数,
向量 ∞ 范数
- ② 计算 矩阵的 m_1 范数, F (迹)范数或 m_2 范数,
矩阵的 m_∞ 范数
- ③ 计算矩阵的 算子范数
矩阵的1范数或列和范数, 矩阵的2范数或谱范数,
矩阵的 ∞ 范数或行和范数
- ④ 计算矩阵的谱半径



第五章 矩阵分析

核心内容：

1. 矩阵序列
2. 矩阵级数
3. 矩阵函数
4. 函数矩阵与矩阵值函数的微分
5. 矩阵微分的应用
6. Laplace变换



§ 5.1 矩阵序列

定义5.1 设矩阵序列 $\{A^{(k)}\}$, $A^{(k)} \in C^{m \times n}$, $A^{(k)} = (a_{ij}^{(k)})_{m \times n}$, 如果

$\lim_{k \rightarrow \infty} a_{ij}^{(k)} = a_{ij} (i = 1, 2, \dots, m; j = 1, 2, \dots, n)$, 则称矩阵序列 $\{A^{(k)}\}$

收敛到 $A = (a_{ij})_{m \times n}$, 称 A 为 $\{A^{(k)}\}$ 的**极限**, 记为

$$A^{(k)} \longrightarrow A, \text{ 当 } k \rightarrow +\infty, \text{ 或 } \lim_{k \rightarrow \infty} A^{(k)} = A.$$

矩阵序列**不收敛**称为矩阵序列**发散**, 由上述定义可知,
矩阵序列**收敛**要求 mn 个**常数序列**同时**收敛**.

与**数列收敛**相类似, 容易证明**矩阵序列的收敛**


具有以下**结论**:

- ① 设 $\{A^{(k)}\}, \{B^{(k)}\}$ 是 $C^{m \times n}$ 中两个**矩阵序列**, λ, μ 是两个**复常数**, $A, B \in C^{m \times n}$, 且 $\lim_{k \rightarrow \infty} A^{(k)} = A, \lim_{k \rightarrow \infty} B^{(k)} = B$, 则

$$\lim_{k \rightarrow \infty} (\lambda A^{(k)} + \mu B^{(k)}) = \lambda A + \mu B. \quad (5.1)$$

- ② 设 $A^{(k)}, A \in C^{m \times n}, B^{(k)}, B \in C^{n \times p}$, 则

$$\lim_{k \rightarrow \infty} A^{(k)} B^{(k)} = AB. \quad (5.2)$$



定理5.1 设 $A^{(k)}, A \in \mathbf{C}^{m \times n}, k = 1, 2, \dots$, 则 $\lim_{k \rightarrow \infty} A^{(k)} = A$

的充分必要条件是 $\lim_{k \rightarrow \infty} \|A^{(k)} - A\| = 0$,

其中 $\|\cdot\|$ 是 $\mathbf{C}^{m \times n}$ 上的任一矩阵范数.

特别若 $A = \mathbf{0}$, 则 $\lim_{k \rightarrow \infty} A^{(k)} = \mathbf{0}$ 的充分必要条件

是 $\lim_{k \rightarrow \infty} \|A^{(k)}\| = 0$.

(用矩阵的 F 范数及矩阵范数的等价性来证)



定理 5.2 设 $A^{(k)}, A \in \mathbf{C}^{m \times n}, k = 1, 2, \dots, \lim_{k \rightarrow \infty} A^{(k)} = A,$

$$\text{则 } \lim_{k \rightarrow \infty} \|A^{(k)}\| = \|A\|,$$

其中 $\|\cdot\|$ 是 $\mathbf{C}^{m \times n}$ 上的任一矩阵范数.

证 由矩阵范数性质 2 有

$$\left| \|A^{(k)}\| - \|A\| \right| \leq \|A^{(k)} - A\|,$$

即知结论正确.

特别若 $A = \mathbf{0}$, 则 $\lim_{k \rightarrow \infty} \|A^{(k)}\| = 0.$





需要**注意**的是**定理 5.2**的**逆命题并非正确**.


例 5.1 $A^{(k)} = \begin{bmatrix} 0 & 1 \\ \frac{1}{k} & (-1)^k \end{bmatrix}, A = \begin{bmatrix} 0 & 1 \\ 0 & 1 \end{bmatrix}$, 则

$$\lim_{k \rightarrow \infty} \|A^{(k)}\|_F = \|A\|_F = \sqrt{2}, \text{ 但显然 } A^{(k)} \text{ 不收敛.}$$

定理 5.3 设 $A^{(k)}, A \in \mathbb{C}^{n \times n}$, 且 $A^{(k)}, A$ 均可逆, $k = 1, 2, \dots$,

$$\lim_{k \rightarrow \infty} A^{(k)} = A, \text{ 则 } \lim_{k \rightarrow \infty} (A^{(k)})^{-1} = A^{-1} \quad (5.3)$$

需要**注意** **定理 5.3**的**条件** $A^{(k)}, A$ 均可逆不可缺少.



例5.2 $A^{(k)} = \begin{bmatrix} 1 + \frac{1}{k} & -1 \\ -1 & 1 \end{bmatrix}, [A^{(k)}]^{-1} = \begin{bmatrix} k & k \\ k & k+1 \end{bmatrix}, A = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix},$

$$\lim_{k \rightarrow \infty} A^{(k)} = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix} = A. \quad k=1, 2, \dots$$

但是,显然 A 是**不可逆**的.这表明尽管所有的 $A^{(k)}$ **可逆**,且有 $\lim_{k \rightarrow \infty} A^{(k)} = A$,

但**仍不能保证** A 的**可逆性**,式(5.3)**不成立**.

定义5.2 设 $A \in \mathbb{C}^{n \times n}$, 如果 $\lim_{k \rightarrow \infty} A^k = \mathbf{0}$, 则称 A 为收敛矩阵.

定理5.4 n 阶方阵 A 为收敛矩阵的充要条件是

$$\rho(A) < 1 \quad (5.4)$$

证 由定理4.16及定理4.17有

$$0 \leq [\rho(A)]^k = \rho(A^k) \leq \|A^k\| \quad (5.5)$$

其中 $\|\cdot\|$ 是 $\mathbb{C}^{n \times n}$ 上的任一矩阵范数.

先证必要性

设 A 为收敛矩阵, 故 $\lim_{k \rightarrow \infty} A^k = \mathbf{0}$. 由定理5.2有

$\lim_{k \rightarrow \infty} \|A^{(k)}\| = 0$, 由式(5.5)根据两边夹挤准则得

$\lim_{k \rightarrow \infty} [\rho(A)]^k = 0$, 从而 $\rho(A) < 1$.

再证充分性.

因为 $\rho(A) < 1$, 故存在 $\varepsilon > 0$, 使 $\rho(A) + \varepsilon < 1$. 由定理 4.18, 存在 $C^{n \times n}$ 上的某一种矩阵范数 $\|\cdot\|_m$, 使

$$\|A\|_m \leq \rho(A) + \varepsilon < 1.$$

于是由矩阵乘法范数的相容性, 得


$$\|A^k\|_m \leq \|A\|_m^k \leq (\rho(A) + \varepsilon)^k.$$

从而有 $\lim_{k \rightarrow \infty} \|A^k\|_m = 0$. 由定理 5.1, 故 $\lim_{k \rightarrow \infty} A^k = O$,

即 A 为收敛矩阵.

推论 设 $A \in C^{n \times n}$, 若 $C^{n \times n}$ 上存在某一种矩阵范数 $\|\cdot\|$, 使

$\|A\| < 1$, 则 A 为收敛矩阵.



例5.3 设 $A = \begin{bmatrix} 0.1 & 0.2 & -0.2 \\ -0.4 & 0.3 & 0.1 \\ 0.3 & 0.1 & 0.2 \end{bmatrix}$, 问 A 是否是收敛矩阵?

解 显然 $\|A\|_1 = 0.8 < 1$, 由推论知 A 是收敛矩阵. $\square$

例5.4 设 $A = \begin{bmatrix} 0 & a & a \\ a & 0 & a \\ a & a & 0 \end{bmatrix}$, 其中 a 为实数, 试问 a 取

何值时, A 为收敛矩阵?

解 经计算 A 的特征值为 $\lambda_1 = 2a$, $\lambda_2 = \lambda_3 = -a$,

所以 $\rho(A) = 2|a|$. 由定理 5.4 知 $\rho(A) < 1$,

即 $|a| < \frac{1}{2}$ 时, A 为收敛矩阵.

$\square$

§ 5.2 矩阵级数

定义 5.3 设矩阵序列 $\{A^{(k)}\}$, $A^{(k)} = (a_{ij}^{(k)})_{m \times n} \in \mathbb{C}^{m \times n}$, $S = (s_{ij})_{m \times n} \in \mathbb{C}^{m \times n}$,

无穷和 $A^{(0)} + A^{(1)} + A^{(2)} + \dots + A^{(k)} + \dots \quad (5.6)$

称为**矩阵级数**, 记为 $\sum_{k=0}^{\infty} A^{(k)}$. 记 $S^{(k)} = \sum_{i=0}^k A^{(i)}$, 称 $S^{(k)}$ 为**矩阵级数**

的**部分和**. 如果 $\lim_{k \rightarrow \infty} S^{(k)} = S$, 则称**矩阵级数** $\sum_{k=0}^{\infty} A^{(k)}$ **收敛**, 并称 S 为

矩阵级数的和, 记为 $\sum_{k=0}^{\infty} A^{(k)} = S$.

不收敛的矩阵级数称为**发散**的.


$\sum_{k=0}^{\infty} A^{(k)} = S$ **等价**于 mn 个**数项级数** $\sum_{k=0}^{\infty} a_{ij}^{(k)} = s_{ij}, i=1, \dots, m; j=1, \dots, n$.

例5.5 设 $A^{(k)} = \begin{bmatrix} \frac{1}{3^k} & 0 \\ 0 & \sqrt{k+2} - 2\sqrt{k+1} + \sqrt{k} \end{bmatrix}, k = 0, 1, \dots$

说明矩阵级数 $\sum_{k=0}^{\infty} A^{(k)}$ 的敛散性.

解 $S^{(k)} = \sum_{i=0}^k A^{(i)}$

$$= \begin{bmatrix} \sum_{i=0}^k \frac{1}{3^i} & 0 \\ 0 & \sum_{i=0}^k (\sqrt{i+2} - 2\sqrt{i+1} + \sqrt{i}) \end{bmatrix}$$



$$S = \lim_{k \rightarrow \infty} S^{(k)} = \begin{bmatrix} \frac{3}{2} & 0 \\ 0 & -1 \end{bmatrix}.$$

故矩阵级数 $\sum_{k=0}^{\infty} A^{(k)}$ 收敛,

其和为

$$\sum_{k=0}^{\infty} \begin{bmatrix} \frac{1}{3^k} & 0 \\ 0 & \sqrt{k+2} - 2\sqrt{k+1} + \sqrt{k} \end{bmatrix} = \begin{bmatrix} \frac{3}{2} & 0 \\ 0 & -1 \end{bmatrix}. \quad \square$$

收敛的矩阵级数的性质

性质1 若 $\sum_{k=0}^{\infty} A^{(k)}$ 收敛, 则

$$\lim_{k \rightarrow \infty} A^{(k)} = \mathbf{O}. \quad (5.7)$$

性质2 若 $\sum_{k=0}^{\infty} A^{(k)} = A$, $\sum_{k=0}^{\infty} B^{(k)} = B$, $\lambda, \mu \in C$ 是常数, 则

$$\sum_{k=0}^{\infty} (\lambda A^{(k)} + \mu B^{(k)}) = \lambda A + \mu B. \quad (5.8)$$

性质3 设 $P \in C^{m \times m}$, $Q \in C^{n \times n}$, $\sum_{k=0}^{\infty} A^{(k)}$ 收敛(发散),

则 $\sum_{k=0}^{\infty} P A^{(k)} Q$ 收敛(发散), 且收敛时有

$$\sum_{k=0}^{\infty} P A^{(k)} Q = P \left(\sum_{k=0}^{\infty} A^{(k)} \right) Q \quad (5.9)$$

定义 5.4 设 $\sum_{k=0}^{\infty} A^{(k)}$ 是**矩阵级数**, 其中 $A^{(k)} = (a_{ij}^{(k)})_{m \times n} \in \mathbb{C}^{m \times n}$, 如果

$m \times n$ 个级数 $\sum_{k=0}^{\infty} |a_{ij}^{(k)}|$ ($i=1, 2, \dots, m; j=1, 2, \dots, n$) 都**收敛**, 则称**矩阵**

级数 $\sum_{k=0}^{\infty} A^{(k)}$ **绝对收敛**.

定理 5.5 设 $A^{(k)} = (a_{ij}^{(k)})_{m \times n} \in \mathbb{C}^{m \times n}$, **矩阵级数** $\sum_{k=0}^{\infty} A^{(k)}$ **绝对收敛**的

充分必要条件是**正项级数** $\sum_{k=0}^{\infty} \|A^{(k)}\|$ **收敛**, 其中 $\|\cdot\|$ 是 $\mathbb{C}^{m \times n}$ 上的

任一矩阵范数.



矩阵幂级数

定义 5.5 称矩阵级数

$$\sum_{k=0}^{\infty} c_k A^k = c_0 I + c_1 A + c_2 A^2 + \dots + c_k A^k + \dots$$

为矩阵 A 的**幂级数**, 这里 $A \in C^{n \times n}$, $c_k \in C (k = 0, 1, 2, \dots)$.

将**矩阵 A 的幂级数** $\sum_{k=0}^{\infty} c_k A^k$ 看作是**复变量 z 的幂级数** $\sum_{k=0}^{\infty} c_k z^k$

的推广, 因此**矩阵幂级数** $\sum_{k=0}^{\infty} c_k A^k$ 与**复变量幂级数** $\sum_{k=0}^{\infty} c_k z^k$ 的

敛散性有密切的联系.

定理 5.6 设幂级数 $\sum_{k=0}^{\infty} c_k z^k$ 的收敛半径为 R , 则

(1) 当 $\rho(A) < R$ 时, 矩阵幂级数 $\sum_{k=0}^{\infty} c_k A^k$ 绝对收敛;

(2) 当 $\rho(A) > R$ 时, 矩阵幂级数 $\sum_{k=0}^{\infty} c_k A^k$ 发散.

证 (1) 设 $\rho(A) < R$, 则存在正数 ε , 使 $\rho(A) + \varepsilon < R$, 由定理 4.18 知, 存在某一种矩阵范数 $\|A\|_m$, 使

$$\|A\|_m \leq \rho(A) + \varepsilon < R.$$

于是有

$$\|c_k A^k\|_m \leq |c_k| \|A\|_m^k \leq |c_k| (\rho(A) + \varepsilon)^k.$$

因为幂级数 $\sum_{k=0}^{\infty} |c_k| (\rho(A) + \varepsilon)^k$ 收敛, 由数项级数

的 Weierstrass 比较判别法知 $\sum_{k=0}^{\infty} \|c_k A^k\|_m$ 收敛,

由定理 5.5 知 $\sum_{k=0}^{\infty} c_k A^k$ 绝对收敛.

(2) 设 $\rho(A) > R$, $\lambda_1, \lambda_2, \dots, \lambda_n$ 为 A 的 n 个特征值, 则至少存在一个特征值 λ_t , 使 $|\lambda_t| > R$.

由定理 3.10 之矩阵的 Jordan 标准形结论 ⑤, 存在 n 阶非奇异矩阵 P , 使



$$P^{-1}AP = J = \begin{bmatrix} \lambda_1 & k_1 & & \\ & \lambda_2 & \ddots & \\ & & \ddots & k_{n-1} \\ & & & \lambda_n \end{bmatrix}, \text{其中 } k_1, \dots, k_{n-1} \text{ 为 } 1 \text{ 或 } 0.$$


因为 J^k 的对角元素为 $\lambda_i^k (i = 1, 2, \dots, n)$, 故矩阵幂级数

$\sum_{k=0}^{\infty} c_k J^k$ 的对角元素为 $\sum_{k=0}^{\infty} c_k \lambda_i^k (i = 1, 2, \dots, n)$, 其中对于 t

$\sum_{k=0}^{\infty} c_k \lambda_t^k$ 发散, 所以 $\sum_{k=0}^{\infty} c_k J^k$ 发散.

又 $A = PJ P^{-1}$, 故 $A^k = PJ^k P^{-1}$, $c_k A^k = P(c_k J^k) P^{-1}$,

由性质 3 知 $\sum_{k=0}^{\infty} c_k A^k$ 发散. ■




推论1 若幂级数 $\sum_{k=0}^{\infty} c_k z^k$ 在整个平面上都收敛,

则对任意 $A \in \mathbb{C}^{n \times n}$, 矩阵幂级数 $\sum_{k=0}^{\infty} c_k A^k$ 收敛.

推论2 设幂级数 $\sum_{k=0}^{\infty} c_k z^k$ 的收敛半径为 R , $A \in \mathbb{C}^{n \times n}$.

如果存在 $\mathbb{C}^{n \times n}$ 上的某一矩阵范数 $\|\cdot\|$, 使 $\|A\| < R$,

则 $\sum_{k=0}^{\infty} c_k A^k$ 绝对收敛.




例 5.6 判断矩阵幂级数 $\sum_{k=0}^{\infty} A^k$ 的敛散性, 其中

$$A = \begin{bmatrix} \frac{1}{6} & -\frac{1}{3} \\ -\frac{4}{3} & \frac{1}{6} \end{bmatrix}.$$

解 A 的特征值为 $\lambda_1 = -\frac{1}{2}$, $\lambda_2 = \frac{5}{6}$, 故 $\rho(A) = \frac{5}{6} < 1$.

因为幂级数 $\sum_{k=0}^{\infty} z^k$ 的收敛半径为 $R = 1$, 由定理 5.6

之(1)知矩阵幂级数 $\sum_{k=0}^{\infty} A^k$ 绝对收敛.



定义 5.6 设 $A \in C^{n \times n}$, 矩阵幂级数 $\sum_{k=0}^{\infty} A^k$

称为Neumann级数.

定理 5.7 Neumann级数收敛的充分必要条件是 $\rho(A) < 1$, 并且在收敛时, 其和为

$$\sum_{k=0}^{\infty} A^k = (I - A)^{-1}. \quad (5.11)$$

例5.7 求Neumann级数 $\sum_{k=0}^{\infty} A^k$ 的和, 其中 $A = \begin{bmatrix} 0.2 & 0.5 \\ 0.7 & 0.4 \end{bmatrix}$.

解 因为 $\|A\|_1 = 0.9 < 1$, 由**定理** 4.17有 $\rho(A) < \|A\|_1 < 1$,

由**定理** 5.7知Neumann级数 $\sum_{k=0}^{\infty} A^k$ 收敛, 且其和为 $(I - A)^{-1}$.

易求得 $(I - A)^{-1} = \frac{10}{13} \begin{bmatrix} 6 & 5 \\ 7 & 8 \end{bmatrix}$, 故

$$\sum_{k=0}^{\infty} \begin{bmatrix} 0.2 & 0.5 \\ 0.7 & 0.4 \end{bmatrix}^k = \frac{10}{13} \begin{bmatrix} 6 & 5 \\ 7 & 8 \end{bmatrix}.$$

□

§ 5.3 矩阵函数

定义 5.7 设幂级数 $\sum_{k=0}^{\infty} c_k z^k$ 的收敛半径为 R , 当 $|z| < R$ 时,

幂级数收敛于 $f(z)$, 即

$$f(z) = \sum_{k=0}^{\infty} c_k z^k \quad (|z| < R) \quad (5.12)$$

如果 $A \in \mathbb{C}^{n \times n}$ 满足 $\rho(A) < R$, 则将收敛的矩阵幂级数

$\sum_{k=0}^{\infty} c_k A^k$ 的和定义为矩阵函数, 记为 $f(A)$, 即

$$f(A) \triangleq \sum_{k=0}^{\infty} c_k A^k \quad (5.13)$$

类似地

$$f(At) \triangleq \sum_{k=0}^{\infty} c_k (At)^k.$$

复变函数 矩阵函数幂级数对照

复变函数幂级数	收敛半径	矩阵函数幂级数	矩阵范围
$e^z = \sum_{k=0}^{\infty} \frac{z^k}{k!}$	$R = +\infty$	$e^A = \sum_{k=0}^{\infty} \frac{A^k}{k!}$	$\forall A \in \mathbb{C}^{n \times n}$
$\sin z = \sum_{k=0}^{\infty} \frac{(-1)^k}{(2k+1)!} z^{2k+1}$	$R = +\infty$	$\sin A = \sum_{k=0}^{\infty} \frac{(-1)^k}{(2k+1)!} A^{2k+1}$	$\forall A \in \mathbb{C}^{n \times n}$
$\cos z = \sum_{k=0}^{\infty} \frac{(-1)^k}{(2k)!} z^{2k}$	$R = +\infty$	$\cos A = \sum_{k=0}^{\infty} \frac{(-1)^k}{(2k)!} A^{2k}$	$\forall A \in \mathbb{C}^{n \times n}$
$(1-z)^{-1} = \sum_{k=0}^{\infty} z^k$	$R = 1$	$(I-A)^{-1} = \sum_{k=0}^{\infty} A^k$	$\rho(A) < 1$
$\ln(1+z) = \sum_{k=1}^{\infty} \frac{(-1)^{k-1}}{k} z^k$	$R = 1$	$\ln(I+A) = \sum_{k=1}^{\infty} \frac{(-1)^{k-1}}{k} A^k$	$\rho(A) < 1$



分别称 e^A , $\sin A$, $\cos A$ 为**矩阵指数函数**, **矩阵正弦函数**,
矩阵余弦函数, 且有如下**重要公式**:

$$e^{iA} = \cos A + i \sin A$$

$$\cos A = \frac{1}{2} (e^{iA} + e^{-iA})$$

$$\sin A = \frac{1}{2i} (e^{iA} - e^{-iA})$$

$$\sin(-A) = -\sin A$$

$$\cos(-A) = \cos A$$

定理 5.8 设 $A, B \in \mathbb{C}^{n \times n}$, 如果 $AB = BA$ (可交换), 则

① $e^A e^B = e^B e^A = e^{A+B};$

② $\sin(A+B) = \sin A \cos B + \cos A \sin B;$


③ $\cos(A+B) = \cos A \cos B - \sin A \sin B.$

推论 ① $e^A e^{-A} = e^{-A} e^A = e^O = I;$

(说明 e^A 可逆, 其逆为 e^{-A})

② $(e^A)^{-1} = e^{-A};$

③ $(e^A)^m = e^{mA}.$



$$\textcircled{4} \sin^2 A + \cos^2 A = \textcolor{violet}{I}$$

$$\textcircled{5} \sin 2A = 2 \sin A \cos A$$

$$\textcircled{6} \cos 2A = \cos^2 A - \sin^2 A$$

$$\textcircled{7} e^{A+2\pi i \textcolor{violet}{I}} = e^A \quad (e^{2\pi i \textcolor{violet}{I}} = \textcolor{violet}{I})$$

$$\textcircled{8} \sin(A + 2\pi \textcolor{violet}{I}) = \sin A$$

$$\textcircled{9} \cos(A + 2\pi \textcolor{violet}{I}) = \cos A$$



A, B 不可交换时定理 5.8①不成立


例 5.8 设 $A = \begin{bmatrix} 1 & -1 \\ 0 & 0 \end{bmatrix}$, $B = \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix}$, 则

$e^A e^B, e^B e^A, e^{A+B}$ 互不相等.

解 $AB = \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix}$, $BA = \begin{bmatrix} 1 & -1 \\ 0 & 0 \end{bmatrix}$, $AB \neq BA$ (A, B 不可交换).

由 $A^2 = A, B^2 = B$ 知 A, B 是幂等阵,

故 $A^k = A, B^k = B, k = 1, 2, \dots$




$$A+B=\begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}, (A+B)^k=2^{k-1}\begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}=2^{k-1}(A+B), k=1,2,\dots$$

$$\text{故 } e^A = \sum_{k=0}^{\infty} \frac{1}{k!} A^k = I + \sum_{k=1}^{\infty} \frac{1}{k!} A$$

$$= I + (e-1)A = \begin{bmatrix} e & 1-e \\ 0 & 1 \end{bmatrix},$$

$$e^B = \sum_{k=0}^{\infty} \frac{1}{k!} B^k = I + \sum_{k=1}^{\infty} \frac{1}{k!} B$$

$$= I + (e-1)B = \begin{bmatrix} e & e-1 \\ 0 & 1 \end{bmatrix},$$



$$e^A e^B = \begin{bmatrix} e & 1-e \\ 0 & 1 \end{bmatrix} \begin{bmatrix} e & e-1 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} e^2 & (e-1)^2 \\ 0 & 1 \end{bmatrix},$$

$$e^B e^A = \begin{bmatrix} e & e-1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} e & 1-e \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} e^2 & -(e-1)^2 \\ 0 & 1 \end{bmatrix},$$

$$\begin{aligned} e^{A+B} &= \sum_{k=0}^{\infty} \frac{1}{k!} (A+B)^k = I + \sum_{k=1}^{\infty} \frac{2^{k-1}}{k!} (A+B). \\ &= I + \frac{1}{2} (e^2 - 1) (A+B) = \begin{bmatrix} e^2 & 0 \\ 0 & 1 \end{bmatrix}. \end{aligned}$$

可见因 $AB \neq BA$, 导致 $e^A e^B, e^B e^A, e^{A+B}$ 互不相等. $\square$

注意: $\forall A \in \mathbb{C}^{n \times n}, e^A$ 总是**可逆**的. 这是因为

$$e^A e^{-A} = e^{\mathbf{0}} = \mathbf{I},$$

这说明 e^A 是**可逆**的, 且它的**逆矩阵**恰为 e^{-A} . 另外


$\det e^A = e^{\text{tr} A} \neq 0$ 也证明这一点,

但是 $\sin A, \cos A$ **不一定可逆**.

在**例5.8**中, 对于**特殊**的2阶**幂等阵**及**对角阵**通过**矩阵幂级数**, 求**和**计算出 e^A, e^B . 下面给出计算**一般矩阵函数** $f(A), f(At)$ 的**三种方法**.

设 $A \in \mathbb{C}^{n \times n}$, 且所论的矩阵**幂级数收敛**.

一. Jordan标准形法




I. $A = D = \text{diag}(d_1, \dots, d_i, \dots, d_n) = \text{diag}(\lambda_1, \dots, \lambda_i, \dots, \lambda_n)$

$$A^k = D^k = \text{diag}(\lambda_1^k, \dots, \lambda_i^k, \dots, \lambda_n^k)$$

$$\begin{aligned} f(A) &= \sum_{k=0}^{\infty} c_k A^k = \sum_{k=0}^{\infty} c_k D^k \\ &= \sum_{k=0}^{\infty} \text{diag}(c_k \lambda_1^k, \dots, c_k \lambda_i^k, \dots, c_k \lambda_n^k) \\ &= \text{diag}\left(\sum_{k=0}^{\infty} c_k \lambda_1^k, \dots, \sum_{k=0}^{\infty} c_k \lambda_i^k, \dots, \sum_{k=0}^{\infty} c_k \lambda_n^k\right) \\ &= \text{diag}(f(\lambda_1), \dots, f(\lambda_i), \dots, f(\lambda_n)). \end{aligned}$$

$$f(At) = \text{diag}(f(\lambda_1 t), \dots, f(\lambda_i t), \dots, f(\lambda_n t)).$$



例

$$A = \begin{bmatrix} 1 & & \\ & -2 & \\ & & 3 \end{bmatrix}, \text{ 则}$$

$$e^A = \begin{bmatrix} e^1 & & \\ & e^{-2} & \\ & & e^3 \end{bmatrix}, \quad e^{A^{\textcolor{red}{t}}} = \begin{bmatrix} e^{\textcolor{red}{t}} & & \\ & e^{-2\textcolor{red}{t}} & \\ & & e^{3\textcolor{red}{t}} \end{bmatrix};$$

$$\sin A = \begin{bmatrix} \sin 1 & & \\ & \sin(-2) & \\ & & \sin 3 \end{bmatrix}, \quad \sin A^{\textcolor{red}{t}} = \begin{bmatrix} \sin \textcolor{red}{t} & & \\ & \sin(-2)\textcolor{red}{t} & \\ & & \sin 3\textcolor{red}{t} \end{bmatrix}.$$

II. $A \sim D = \text{diag}(\lambda_1, \dots, \lambda_i, \dots, \lambda_n)$

这里 $\lambda_1, \dots, \lambda_i, \dots, \lambda_n$ 为 A 的特征值.


故存在可逆阵 P , 使 $P^{-1}AP = D$, 即有 $A = PDP^{-1}$,

$A^k = (PDP^{-1})^k = PD^kP^{-1}$, 于是

$$\begin{aligned} f(A) &= \sum_{k=0}^{\infty} c_k A^k = \sum_{k=0}^{\infty} c_k PD^kP^{-1} = P \left(\sum_{k=0}^{\infty} c_k D^k \right) P^{-1} \\ &= P \text{diag} \left(\sum_{k=0}^{\infty} c_k \lambda_1^k, \dots, \sum_{k=0}^{\infty} c_k \lambda_i^k, \dots, \sum_{k=0}^{\infty} c_k \lambda_n^k \right) P^{-1} \\ &= P \text{diag}(f(\lambda_1), \dots, f(\lambda_i), \dots, f(\lambda_n)) P^{-1}. \end{aligned}$$

$$f(At) = P \text{diag}(f(\lambda_1 t), \dots, f(\lambda_i t), \dots, f(\lambda_n t)) P^{-1}.$$

与 I 相比, II 需求 P 与 P^{-1} , 左右分别乘之.



例 3.13*

$$A = \begin{bmatrix} 4 & 6 & 0 \\ -3 & -5 & 0 \\ -3 & -6 & 1 \end{bmatrix}, \text{求 } e^A, e^{At}.$$

解 由例3.13知 A 是单纯矩阵, 且 A 的特征值为 $\lambda_1 = \lambda_2 = 1, \lambda_3 = -2$. 故 $A \sim D = \text{diag}(1, 1, -2)$.

前已算出

$$P = \begin{bmatrix} -2 & 0 & -1 \\ 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix}, \quad P^{-1} = \begin{bmatrix} -1 & -1 & 0 \\ -1 & -2 & 1 \\ 1 & 2 & 0 \end{bmatrix}.$$




因 $f(A) = \mathbf{P} \operatorname{diag}(f(\lambda_1), \dots, f(\lambda_i), \dots, f(\lambda_n)) \mathbf{P}^{-1}$. 故

$$e^A = \mathbf{P} \operatorname{diag}(e, e, e^{-2}) \mathbf{P}^{-1}$$

$$= \begin{bmatrix} -2 & 0 & -1 \\ 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} e & 0 & 0 \\ 0 & e & 0 \\ 0 & 0 & e^{-2} \end{bmatrix} \begin{bmatrix} -1 & -1 & 0 \\ -1 & -2 & 1 \\ 1 & 2 & 0 \end{bmatrix}$$

$$= e \begin{bmatrix} 2 - e^{-3} & 2 - 2e^{-3} & 0 \\ -1 + e^{-3} & -1 + 2e^{-3} & 0 \\ -1 + e^{-3} & -2 + 2e^{-3} & 1 \end{bmatrix}.$$




因 $f(A^t) = P \operatorname{diag}(f(\lambda_1 t), \dots, f(\lambda_i t), \dots, f(\lambda_n t)) P^{-1}$. 故

$$e^{A^t} = \begin{bmatrix} -2 & 0 & -1 \\ 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} e^t & 0 & 0 \\ 0 & e^t & 0 \\ 0 & 0 & e^{-2t} \end{bmatrix} \begin{bmatrix} -1 & -1 & 0 \\ -1 & -2 & 1 \\ 1 & 2 & 0 \end{bmatrix}$$

$$= e^t \begin{bmatrix} 2 - e^{-3t} & 2 - 2e^{-3t} & 0 \\ -1 + e^{-3t} & -1 + 2e^{-3t} & 0 \\ -1 + e^{-3t} & -2 + 2e^{-3t} & 1 \end{bmatrix}.$$


□



III. $A \sim J = \text{diag}(J_1, \dots, J_i, \dots, J_s),$

其中 $J_i = \begin{bmatrix} \lambda_i & 1 & & \\ & \lambda_i & \ddots & \\ & & \ddots & 1 \\ & & & \lambda_i \end{bmatrix}_{m_i \times m_i}, \quad i=1, \dots, s;$


$\sum_{i=1}^s m_i = n. \quad \lambda_i \text{ 为 } A \text{ 的特征值.}$



在第三章中Jordan块 J_i 的乘幂有


$$J_i^k = \begin{bmatrix} \lambda_i^k & C_k^1 \lambda_i^{k-1} & C_k^2 \lambda_i^{k-2} & \cdots & C_k^{m_i-1} \lambda_i^{k-m_i+1} \\ & \lambda_i^k & C_k^1 \lambda_i^{k-1} & \cdots & C_k^{m_i-2} \lambda_i^{k-m_i+2} \\ & & \lambda_i^k & \ddots & \vdots \\ & & & \ddots & C_k^1 \lambda_i^{k-1} \\ & & & & \lambda_i^k \end{bmatrix}_{m_i \times m_i}$$

由此 $A = PJP^{-1}$, $A^k = PJ^kP^{-1}$.




$$f(A) = \sum_{k=0}^{\infty} c_k A^k = \sum_{k=0}^{\infty} c_k (PJP^{-1})^k = \sum_{k=0}^{\infty} c_k PJ^kP^{-1} = P \left(\sum_{k=0}^{\infty} c_k J^k \right) P^{-1}$$

$$= P \begin{bmatrix} \sum_{k=0}^{\infty} c_k J_1^k & & \\ & \ddots & \\ & & \sum_{k=0}^{\infty} c_k J_i^k & \\ & & & \ddots & \\ & & & & \sum_{k=0}^{\infty} c_k J_s^k \end{bmatrix} P^{-1}$$




$$\begin{aligned}
 &= \mathbf{P} \begin{bmatrix} f(\mathbf{J}_1) & & & \\ & \ddots & & \\ & & \boxed{f(\mathbf{J}_i)} & \\ & & & \ddots \\ & & & & f(\mathbf{J}_s) \end{bmatrix} \mathbf{P}^{-1} \\
 &= \mathbf{P} f(\mathbf{J}) \mathbf{P}^{-1}.
 \end{aligned}$$




其中 $f(J_i) = \sum_{k=0}^{\infty} c_k J_i^k.$

$$= \begin{bmatrix} \sum_{k=0}^{\infty} c_k \lambda_i^k & \sum_{k=1}^{\infty} c_k C_k^1 \lambda_i^{k-1} & \cdots & \sum_{k=m_i-1}^{\infty} c_k C_k^{m_i-1} \lambda_i^{k-m_i+1} \\ & \sum_{k=0}^{\infty} c_k \lambda_i^k & \ddots & \vdots \\ & & \ddots & \sum_{k=1}^{\infty} c_k C_k^1 \lambda_i^{k-1} \\ & & & \sum_{k=0}^{\infty} c_k \lambda_i^k \end{bmatrix}_{m_i \times m_i}$$




$$= \begin{bmatrix} \boxed{f(\lambda_i)} & \frac{1}{1!} \boxed{f'(\lambda_i)} & \cdots & \frac{1}{(m_i-1)!} \boxed{f^{(m_i-1)}(\lambda_i)} \\ \boxed{f(\lambda_i)} & \ddots & & \vdots \\ & \ddots & \frac{1}{1!} \boxed{f'(\lambda_i)} & \\ & & \boxed{f(\lambda_i)} & \end{bmatrix}_{m_i \times m_i}$$

(这也说明若 $\lambda_1, \dots, \lambda_i, \dots, \lambda_n$ 是 A 的 n 个特征值, 则 $f(\lambda_1), \dots, f(\lambda_i), \dots, f(\lambda_n)$ 是 $f(A)$ 的 n 个特征值).




类似地以 A^t 代替 A ,则有

$$f(A^t) = P \begin{bmatrix} f(J_1^t) & & & \\ & \ddots & & \\ & & \boxed{f(J_i^t)} & \\ & & & \ddots \\ & & & & f(J_s^t) \end{bmatrix} P^{-1},$$




其中 $f(J_i t) = \sum_{k=0}^{\infty} c_k (J_i t)^k = \sum_{k=0}^{\infty} c_k t^k J_i^k$

$$= \begin{bmatrix} \sum_{k=0}^{\infty} c_k t^k \lambda_i^k & \sum_{k=1}^{\infty} c_k t^k C_k^1 \lambda_i^{k-1} & \cdots & \sum_{k=m_i-1}^{\infty} c_k t^k C_k^{m_i-1} \lambda_i^{k-m_i+1} \\ & \sum_{k=0}^{\infty} c_k t^k \lambda_i^k & \ddots & \vdots \\ & & \ddots & \sum_{k=1}^{\infty} c_k t^k C_k^1 \lambda_i^{k-1} \\ & & & \sum_{k=0}^{\infty} c_k t^k \lambda_i^k \end{bmatrix}_{m_i \times m_i}$$




$$= \begin{bmatrix} \sum_{k=0}^{\infty} c_k (\lambda_i t)^k & t \sum_{k=1}^{\infty} c_k C_k^1 (\lambda_i t)^{k-1} & \dots & t^{m_i-1} \sum_{k=m_i-1}^{\infty} c_k C_k^{m_i-1} (\lambda_i t)^{k-m_i+1} \\ & \sum_{k=0}^{\infty} c_k (\lambda_i t)^k & \ddots & \vdots \\ & & \ddots & t \sum_{k=1}^{\infty} c_k C_k^1 (\lambda_i t)^{k-1} \\ & & & \sum_{k=0}^{\infty} c_k (\lambda_i t)^k \end{bmatrix}_{m_i \times m_i}$$



$$= \begin{bmatrix} f(\lambda_i t) & \frac{t}{1!} f'(\lambda_i t) & \cdots & \frac{t^{m_i-1}}{(m_i-1)!} f^{(m_i-1)}(\lambda_i t) \\ & f(\lambda_i t) & \ddots & \vdots \\ & & \ddots & \frac{t}{1!} f'(\lambda_i t) \\ & & & f(\lambda_i t) \end{bmatrix}_{m_i \times m_i}.$$

$i = 1, 2, \dots, s.$



于是有


$$f(J_i t) = \begin{bmatrix} f(z) & \frac{t}{1!} f'(z) & \cdots & \frac{t^{m_i-1}}{(m_i-1)!} f^{(m_i-1)}(z) \\ & f(z) & \ddots & \vdots \\ & & \ddots & \frac{t}{1!} f'(z) \\ & & & f(z) \end{bmatrix} \Big|_{z = \lambda_i t}$$

这表明 $f(A)$ 与 A 的Jordan标准形及 $f(\lambda)$ 在 A 的特征值 λ_i 的值及前 m_i-1 阶的导数值有关($i=1,2,\dots,s$).

以上是 λ_i 仅有一个线性无关的特征向量的情况
若 $J_i = \text{diag}(J_{i1}, \dots, J_{ik}, \dots, J_{ir_i}),$

这里 $J_{ik} = \begin{bmatrix} \lambda_i & 1 & & \\ & \lambda_i & \ddots & \\ & & \ddots & 1 \\ & & & \lambda_i \end{bmatrix}_{n_{ik} \times n_{ik}},$


n_{ik} 为初等因子 $(\lambda - \lambda_i)^{n_{ik}}$ 的指数幂,
则形式更为复杂,但结论是一样的.



结论

- ①用**Jordan标准形法**定义**矩阵函数**时, 要求一元函数 $f(z)$ 在矩阵 A 的**特征值** λ_i ($i = 1, \dots, s$) 处有 $m_i - 1$ 阶导数, 这里 m_i 为 λ_i 的**代数重数**, s 为**互异特征值的个数**.
- ②若 $f(z)$ 在 $z = 0$ 能展开为**幂级数**时, 由**Jordan标准形法**定义**矩阵函数**与**定义 5.7**所定义的**矩阵函数**是**一致**的.


例 5.9 设


$$A = \begin{bmatrix} -1 & -2 & 6 \\ -1 & 0 & 3 \\ -1 & -1 & 4 \end{bmatrix},$$

求 e^A, e^{At} .

解 由例 3.5, $\lambda_1 = \lambda_2 = \lambda_3 = 1$.


A 的 Jordan 标准形 $J = \begin{bmatrix} \boxed{1} & 0 & 0 \\ 0 & \boxed{1} & 1 \\ 0 & 0 & \boxed{1} \end{bmatrix}.$



由例 3.7 求得

$$\mathbf{P} = \begin{bmatrix} -1 & 2 & -1 \\ 1 & 1 & 0 \\ 0 & 1 & 0 \end{bmatrix}, \mathbf{P}^{-1} = \begin{bmatrix} 0 & 1 & -1 \\ 0 & 0 & 1 \\ -1 & -1 & 3 \end{bmatrix},$$

$$\mathbf{P}^{-1} \mathbf{A} \mathbf{P} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix}.$$



当 $f(\lambda)=e^\lambda$ 时, $f(\lambda)=f(1)=e, f'(1)=e$, 于是有


$$e^A = P \begin{bmatrix} f(1) & 0 & 0 \\ 0 & f(1) & f'(1) \\ 0 & 0 & f(1) \end{bmatrix} P^{-1}$$

$$= \begin{bmatrix} -1 & 2 & -1 \\ 1 & 1 & 0 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} e & 0 & 0 \\ 0 & e & e \\ 0 & 0 & e \end{bmatrix} \begin{bmatrix} 0 & 1 & -1 \\ 0 & 0 & 1 \\ -1 & -1 & 3 \end{bmatrix} = e \begin{bmatrix} -1 & -2 & 6 \\ -1 & 0 & 3 \\ -1 & -1 & 4 \end{bmatrix}.$$

当 $f(z) = e^z$ 时, $f(\lambda_i t) = e^{\lambda_i t}$, $f'(\lambda_i t) = e^{\lambda_i t}$, 则

$$e^{A t} = P \begin{bmatrix} f(\lambda_i t) & 0 & 0 \\ 0 & f(\lambda_i t) & t f'(\lambda_i t) \\ 0 & 0 & f(\lambda_i t) \end{bmatrix} P^{-1}$$

$$= \begin{bmatrix} -1 & 2 & -1 \\ 1 & 1 & 0 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} e^t & 0 & 0 \\ 0 & e^t & t e^t \\ 0 & 0 & e^t \end{bmatrix} \begin{bmatrix} 0 & 1 & -1 \\ 0 & 0 & 1 \\ -1 & -1 & 3 \end{bmatrix}$$



$$= \begin{bmatrix} (1-2t)e^t & -2te^t & 6te^t \\ -te^t & (1-t)e^t & 3te^t \\ -te^t & -te^t & (1+3t)e^t \end{bmatrix}$$

$$= e^t \begin{bmatrix} 1-2t & -2t & 6t \\ -t & 1-t & 3t \\ -t & -t & 1+3t \end{bmatrix}. \quad \square$$

二.矩阵多项式法

设 $A \in C^{n \times n}$, A 的特征多项式

$$\varphi(\lambda) = \det(\lambda I - A) = (\lambda - \lambda_1)^{m_1} \dots (\lambda - \lambda_i)^{m_i} \dots (\lambda - \lambda_s)^{m_s}, \quad (5.28)$$

其中 $\lambda_1, \dots, \lambda_i, \dots, \lambda_s$ 是 A 的全部互异特征值, $\sum_{i=1}^s m_i = n$.

$$\text{设矩阵函数 } f(A t) = \sum_{k=1}^{\infty} c_k A^k t^k, \quad f(\lambda t) = \sum_{k=1}^{\infty} c_k \lambda^k t^k,$$

由带余除法

$$f(\lambda t) = q(\lambda t) \varphi(\lambda) + r(\lambda, t). \quad (5.29)$$

其中 $r(\lambda, t)$ 是含参数 t , 且次数低于 n 的 λ 的多项式, 记

$$r(\lambda, t) = a_{n-1}(t) \lambda^{n-1} + \dots + a_1(t) \lambda + a_0(t).$$

由Cayley - Hamilton定理知 $\varphi(A) = \mathbf{O}$,

于是由式(5.29)得

$$f(A\mathbf{t}) = a_{n-1}(\mathbf{t})A^{n-1} + \dots + a_1(\mathbf{t})A + a_0(\mathbf{t})\mathbf{I}. \quad (5.30)$$

由式(5.28)得

$$\varphi^{(p)}(\lambda_i) = \mathbf{O}, \quad p = 0, 1, \dots, m_i - 1; \quad i = 1, \dots, s.$$

将(5.29)两边对 λ 求导, 并将上式代入得

$$\frac{d^p}{d\lambda^p} f(\lambda\mathbf{t}) \Big|_{\lambda=\lambda_i} = \frac{d^p}{d\lambda^p} r(\lambda, \mathbf{t}) \Big|_{\lambda=\lambda_i}$$



此式即为

$$t^p \frac{d^p}{du^p} f(u) \Big|_{u=\lambda_i t} = \frac{d^p}{d\lambda^p} r(\lambda, t) \Big|_{\lambda=\lambda_i},$$

$$p = 0, 1, \dots, m_i - 1; \quad i = 1, \dots, s.$$

这就给出以 $a_0(t), a_1(t), \dots, a_{n-1}(t)$, 为未知量的共有 n 个方程的**线性方程组**. 解之代回式(5.30)即得 $f(At)$.

取 $t=1$ 时, 可得出计算 $f(A)$ 的算式.

矩阵多项式法也称为**有限级数法**或**待定系数法**.

矩阵多项式法(待定系数法)步骤如下:

①. 求 A 的特征多项式的特征值及重数;

$$\varphi(\lambda) = \det(\lambda I - A) = (\lambda - \lambda_1)^{m_1} \dots (\lambda - \lambda_i)^{m_i} \dots (\lambda - \lambda_s)^{m_s}.$$

②. 设 $r(\lambda, t) = a_0(t) + a_1(t)\lambda + \dots + a_{n-1}(t)\lambda^{n-1}$. 为简化也可写成

$$r(\lambda) = a_0 + a_1\lambda + \dots + a_{n-1}\lambda^{n-1}$$


求导得 n 个方程, n 个未知量的线性方程组:

$$t^p \frac{d^p}{du^p} f(u) \Big|_{u=\lambda_i t} = \frac{d^p}{d\lambda^p} r(\lambda, t) \Big|_{\lambda=\lambda_i},$$

$p = 0, 1, \dots, m_i - 1; i = 1, \dots, s$. 解得 $a_0, a_1, \dots, a_{n-1}$.

③. 由式(5.30)计算 $f(A, t) = a_{n-1}(t)A^{n-1} + \dots + a_1(t)A + a_0(t)I$.

上式中令 $t = 1$ 即得 $f(A)$.



例 5.10 设 $A = \begin{bmatrix} -1 & -2 & 6 \\ -1 & 0 & 3 \\ -1 & -1 & 4 \end{bmatrix}$, 求 e^A, e^{At} .

解 ① 计算的**特征多项式**

$$\varphi(\lambda) = \det(\lambda I - A) = (\lambda - 1)^3,$$

$\lambda_1 = \lambda_2 = \lambda_3 = 1$ 为**特征值**.

② 设 $r(\lambda, t) = a_0(t) + a_1(t)\lambda + a_2(t)\lambda^2$


由 $r^{(p)}(\lambda_i, t) = t^p f(\lambda_i t)$, $p = 0, 1, 2$; $f(\lambda t) = e^{\lambda t}$, 得方程组

$$\begin{cases} r(1, t) = a_0(t) + a_1(t) + a_2(t) = e^t, \\ r'(1, t) = a_1(t) + 2a_2(t) = te^t, \\ r''(1, t) = 2a_2(t) = t^2 e^t. \end{cases}$$

解之得 $a_0(t) = e^t - te^t + \frac{t^2}{2}e^t,$

$$a_1(t) = te^t - t^2 e^t,$$

$$a_2(t) = \frac{t^2}{2}e^t.$$



③ 计算 $e^{At} = a_0(t)I + a_1(t)A + a_2(t)A^2$

$$= e^t \begin{bmatrix} 1-2t & -2t & 6t \\ -t & 1-t & 3t \\ -t & -t & 1+3t \end{bmatrix}.$$

$$\text{令 } t=1, \text{ 则 } e^A = e \begin{bmatrix} -1 & -2 & 6 \\ -1 & 0 & 3 \\ -1 & -1 & 4 \end{bmatrix} = eA.$$

结果与例 5.9 一致.




当**最小多项式** $m_A(\lambda)$ 次数比**特征多项式** $\varphi(\lambda)$ 次数**低**时,可
用来代替**特征多项式**,使余式 $r(\lambda)$ 次数**降低**,从而**简化计算**.

上例中,由**例 3.11**知**最小多项式** $m_A(\lambda) = (\lambda - 1)^2$,于是
 $r(\lambda) = a_0 + a_1\lambda$,故

$$\begin{cases} r(1) = a_0 + a_1 = e^t \\ r'(1) = a_1 = te^t \end{cases}, \quad \text{解之得} \begin{cases} a_0 = e^t - te^t \\ a_1 = te^t \end{cases}.$$

$$\text{所以 } e^{At} = a_0(t)I + a_1(t)A = e^t \begin{bmatrix} 1-2t & -2t & 6t \\ -t & 1-t & 3t \\ -t & -t & 1+3t \end{bmatrix}. \quad \square$$



单纯矩阵的谱分解法


对于单纯矩阵,有如下的谱分解法来计算 e^A, e^{At}

设 $A \in \mathbb{C}^{n \times n}$ 是单纯矩阵,则它相似于对角阵.

设 $\lambda_1, \dots, \lambda_i, \dots, \lambda_s$ 是它的互异特征值,由定理 3.24 知

$$A = \sum_{i=1}^s \lambda_i E_i, \quad P^{-1} A P = D = \text{diag}(D_1, \dots, D_i, \dots, D_s).$$


其中 D_i 是对角元为 λ_i 的 m_i 阶对角阵.



将 $\mathbf{P}$ 分块为 $\mathbf{P}=(\mathbf{P}_1,\dots,\mathbf{P}_i,\dots,\mathbf{P}_s), \mathbf{P}_i \in \mathbb{C}^{n \times m_i}, i=1,2,\dots,s.$

$$\text{记 } \mathbf{P}^{-1}=(\tilde{\mathbf{P}}_1,\dots,\tilde{\mathbf{P}}_i,\dots,\tilde{\mathbf{P}}_s)^{\mathrm{T}}=\begin{bmatrix} \tilde{\mathbf{P}}_1^{\mathrm{T}} \\ \vdots \\ \tilde{\mathbf{P}}_i^{\mathrm{T}} \\ \vdots \\ \tilde{\mathbf{P}}_s^{\mathrm{T}} \end{bmatrix},$$

记 $\mathbf{E}_i=\mathbf{P}_i\tilde{\mathbf{P}}_i^{\mathrm{T}}$,有 $\mathbf{E}_i\mathbf{E}_j=\delta_{ij}\mathbf{E}_i.$



于是 $A^2 = \left(\sum_{i=1}^s \lambda_i E_i \right)^2 = \left(\sum_{i=1}^s \lambda_i E_i \right) \left(\sum_{j=1}^s \lambda_j E_j \right) = \sum_{i=1}^s \lambda_i^2 E_i.$

所以 $A^k = \sum_{i=1}^s \lambda_i^k E_i.$ 设 $f(\lambda) = \sum_{k=0}^{\infty} c_k \lambda^k$, 则

$$\begin{aligned} f(A) &= \sum_{k=0}^{\infty} c_k A^k = \sum_{k=0}^{\infty} c_k \left(\sum_{i=1}^s \lambda_i^k E_i \right) = \sum_{i=1}^s \left(\sum_{k=0}^{\infty} c_k \lambda_i^k \right) E_i \\ &= \sum_{i=1}^s (f(\lambda_i)) E_i. \end{aligned}$$

于是 $f(At) = \sum_{i=1}^s (f(\lambda_i t)) E_i.$


例 5.11 $A = \begin{bmatrix} 4 & 6 & 0 \\ -3 & -5 & 0 \\ -3 & -6 & 1 \end{bmatrix}$, 求 e^A, e^{At} .

解 本题与例 3.13* 为同一题, 现用单纯矩阵谱分解法解之.

已知 A 的互异特征值为: $\lambda_1 = \lambda_1 = 1$ (重根), $\lambda_2 = -2$.


且知 $E_1 = \begin{bmatrix} 2 & 2 & 0 \\ -1 & -1 & 0 \\ -1 & -2 & 1 \end{bmatrix}$, $E_2 = \begin{bmatrix} -1 & -2 & 0 \\ 1 & 2 & 0 \\ 1 & 2 & 0 \end{bmatrix}$.

$e^{\lambda_1} = e, e^{\lambda_1 t} = e^t; e^{\lambda_2} = e^{-2}, e^{\lambda_2 t} = e^{-2t}.$



于是 e^A 的谱分解为


$$\begin{aligned} e^A &= e \begin{bmatrix} 2 & 2 & 0 \\ -1 & -1 & 0 \\ -1 & -2 & 1 \end{bmatrix} + e^{-2} \begin{bmatrix} -1 & -2 & 0 \\ 1 & 2 & 0 \\ 1 & 2 & 0 \end{bmatrix} \\ &= e \begin{bmatrix} 2 - e^{-3} & 2 - 2e^{-3} & 0 \\ -1 + e^{-3} & -1 + 2e^{-3} & 0 \\ -1 + e^{-3} & -2 + 2e^{-3} & 1 \end{bmatrix}. \end{aligned}$$


$$\begin{aligned} e^{At} &= e^{t} \begin{bmatrix} 2 & 2 & 0 \\ -1 & -1 & 0 \\ -1 & -2 & 1 \end{bmatrix} + e^{-2t} \begin{bmatrix} -1 & -2 & 0 \\ 1 & 2 & 0 \\ 1 & 2 & 0 \end{bmatrix} \\ &= e^{t} \begin{bmatrix} 2 - e^{-3t} & 2 - 2e^{-3t} & 0 \\ -1 + e^{-3t} & -1 + 2e^{-3t} & 0 \\ -1 + e^{-3t} & -2 + 2e^{-3t} & 1 \end{bmatrix}. \end{aligned}$$

□

这与例 3.13* 的结果一致.

§ 5.4 函数矩阵及其微分



定义 5.10 设 $a_{ij}(t)(i=1, \dots, m; j=1, \dots, n)$ 都是定义在区间 $[a, b]$ 上的实函数, 则称矩阵 $A(t) = (a_{ij}(t))_{m \times n}$ 为定义在区间 $[a, b]$ 上的**函数矩阵**或**矩阵值函数**.

类似于**常数矩阵**的相应的概念及运算, 可以**定义函数矩阵**的**加法**, **数乘**, **乘法**, **转置**等运算.

还可以**定义** n 阶**函数矩阵**的**行列式**, **子式**, **代数余子式**, **伴随矩阵**, **秩**等等, 并采用相应的符号.

对于 n 阶**函数矩阵**, 若 $\text{rank } A(t) = n$, 则说它是**满秩**的.

定义 5.11 设 $A(t) = (a_{ij}(t))_{n \times n}$ 是区间 $[a, b]$ 上的 n 阶函数矩阵, 若存在 n 阶函数矩阵 $B(t) = (b_{ij}(t))_{n \times n}$, 使 $\forall t \in [a, b]$, 都有

$$A(t)B(t) = B(t)A(t) = I$$

则称 $A(t)$ 在 $[a, b]$ 上可逆, 并称 $B(t)$ 为 $A(t)$ 的逆矩阵, 记为 $A^{-1}(t)$.

n 阶函数矩阵 $A(t)$ 在 $[a, b]$ 上可逆的充要条件是 $\det A(t)$ 在 $[a, b]$ 上处处不为零. 且有

$$A^{-1}(t) = \frac{1}{\det A(t)} \operatorname{adj} A(t)$$

这里 $\operatorname{adj} A(t)$ 表示 $A(t)$ 的伴随矩阵.

和常数矩阵不同的是满秩函数矩阵未必可逆.



定义 5.12 若 $m \times n$ 的 **函数矩阵** $A(t) = (a_{ij}(t))_{m \times n}$ 的所有元素 $a_{ij}(t) (i = 1, \dots, m; j = 1, \dots, n)$ 在区间 $[a, b]$ 上 **可导, 可积**, 则称 **函数矩阵** $A(t)$ 在 $[a, b]$ 上 **可导, 可积**.

并且

$$A'(t) = \frac{dA(t)}{dt} = (a'_{ij}(t))_{m \times n},$$

$$\int_a^b A(t) dt = \left(\int_a^b a_{ij}(t) dt \right)_{m \times n}.$$

可导的函数矩阵有以下性质

① $A(t)$ 是常数矩阵的充分必要条件是 $\frac{dA(t)}{dt} = \mathbf{0}$;

②
$$\frac{d}{dt}[A(t) + B(t)] = \frac{dA(t)}{dt} + \frac{dB(t)}{dt};$$


③
$$\frac{d}{dt}[k(t)A(t)] = \frac{dk(t)}{dt}A(t) + k(t)\frac{dA(t)}{dt};$$

④
$$\frac{d}{dt}[A(t)C(t)] = \frac{dA(t)}{dt}C(t) + A(t)\frac{dC(t)}{dt};$$

⑤
$$\frac{dA(t)}{du} = \frac{dA(t)}{dt} f'(u) = f'(u) \frac{dA(t)}{dt}, t = f(u) \text{ 是 } u \text{ 的可微函数};$$

⑥ 若 n 阶可逆函数矩阵在上可导, 则

$$\frac{dA^{-1}(t)}{dt} = -A^{-1}(t) \frac{dA(t)}{dt} A^{-1}(t).$$



可积的函数矩阵有以下性质

① $\int_a^b [A(t) + B(t)]dt = \int_a^b A(t)dt + \int_a^b B(t)dt;$

② $\int_a^b kA(t)dt = k \int_a^b A(t)dt;$


③ $\int_a^b \mathbf{A} \mathbf{B}(t) \mathbf{C} dt = \mathbf{A} \left(\int_a^b \mathbf{B}(t) dt \right) \mathbf{C},$ 其中 $\mathbf{A}, \mathbf{C}$ 是常数矩阵;

④ $\frac{d}{dt} \int_a^t A(u)du = A(t);$

⑤ 当 $A(t)$ 在 $[a, b]$ 上连续可微时,

$$\int_a^b A'(t)dt = A(b) - A(a).$$

例 5.14 设 $A \in \mathbb{C}^{n \times n}$, 则


$$\frac{d}{dt} e^{At} = A e^{At} = e^{At} A.$$

证 对 $e^{At} = \sum_{k=0}^{\infty} \frac{t^k}{k!} A^k$ 逐项微分得

$$\frac{d}{dt} e^{At} = \sum_{k=0}^{\infty} \frac{d}{dt} \left(\frac{t^k}{k!} A^k \right) = \sum_{k=1}^{\infty} \frac{t^{k-1}}{(k-1)!} A^k$$

$$\stackrel{\text{左提} A}{=} A \sum_{k=1}^{\infty} \frac{t^{k-1}}{(k-1)!} A^{k-1} = A \sum_{k=0}^{\infty} \frac{t^k}{k!} A^k = A e^{At}.$$



另一方面

$$\frac{d}{dt} e^{At} = \sum_{k=0}^{\infty} \frac{d}{dt} \left(\frac{t^k}{k!} A^k \right) = \sum_{k=1}^{\infty} \frac{t^{k-1}}{(k-1)!} A^k$$

$$\underline{\underline{\text{右提} A}} \left(\sum_{k=1}^{\infty} \frac{t^{k-1}}{(k-1)!} A^{k-1} \right) A$$

$$= \left(\sum_{k=0}^{\infty} \frac{t^k}{k!} A^k \right) A = e^{At} A.$$

于是 $\frac{d}{dt} e^{At} = A e^{At} = e^{At} A.$




一.数值函数对矩阵变量的导数

定义 5.13 设 $f(X)$ 是以矩阵 $X = (x_{ij})_{m \times n}$ 为变量的 mn 元

数值函数, 并且 $\frac{\partial f}{\partial x_{ij}}$ ($i = 1, 2, \dots, m; j = 1, 2, \dots, n$) 都存在,

定义 f 对矩阵变量 X 的导数 $\frac{df}{dX}$ 为

$$\frac{df}{dX} \triangleq \left(\frac{\partial f}{\partial x_{ij}} \right)_{m \times n} = \begin{bmatrix} \frac{\partial f}{\partial x_{11}} & \cdots & \frac{\partial f}{\partial x_{1n}} \\ \vdots & \ddots & \vdots \\ \frac{\partial f}{\partial x_{m1}} & \cdots & \frac{\partial f}{\partial x_{mn}} \end{bmatrix}.$$




即数值函数 $f(\mathbf{X})$ 对矩阵 $\mathbf{X}$ 求导, 得到的是与矩阵 $\mathbf{X}$ 的同型矩阵, 其元素为 f 对 $\mathbf{X}$ 相应元素的偏导数.

作为特殊情况, 若 $\mathbf{X}$ 为列向量 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$, 则有

$$\frac{df}{d\mathbf{x}} = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right)^T$$

称为数值函数 f 对列向量的导数, 这就是我们熟知的梯度向量.



例 5.15 设 $A = (a_{ij})_{m \times n}$, 为常数矩阵, $X = (x_{ij})_{n \times m}$

是矩阵变量, $f(X) = \text{tr}(AX)$, 求 $\frac{df}{dX}$.

解 由 $AX = (\sum_{k=1}^n a_{ik} x_{kj})_{m \times m}$, 则 AX 的对角元素为

$$\sum_{k=1}^n a_{ik} x_{ki}, \quad i = 1, 2, \dots, m.$$

$$\text{于是 } f(X) = \text{tr}(AX) = \sum_{i=1}^m \sum_{k=1}^n a_{ik} x_{ki} = \sum_{i=1}^m \sum_{j=1}^n a_{ij} x_{ji} \quad (k \rightarrow j).$$



故 $\frac{\partial f}{\partial x_{ji}} = a_{ij}, \quad i = 1, 2, \dots, m; j = 1, 2, \dots, n.$

所以 $\frac{\partial f}{\partial x_{ij}} = a_{ji}, \quad i = 1, 2, \dots, m; j = 1, 2, \dots, n.$

因此 $\frac{df}{dX} = \left(\frac{\partial f}{\partial x_{ij}} \right)_{n \times m} = (a_{ji})_{n \times m} = A^T. \quad \square$

特别若 $X = (x_{ij})_{n \times n}$ 是 n 阶矩阵变量时, 取 $A = I_n$ 时,

$$\frac{d}{dX}(\text{tr} X) = I_n,$$

当然, 这也可由对矩阵求导定义直接得到.

例 5.16 设 $\mathbf{x} = (x_1, \dots, x_i, \dots, x_n)^T$, $f(\mathbf{x}) = \mathbf{x}^T \mathbf{x}$, 求

① $\frac{df}{d\mathbf{x}}$; ② $\frac{df}{d\mathbf{x}^T}$.

解 由 $f(\mathbf{x}) = \mathbf{x}^T \mathbf{x} = \sum_{i=1}^n x_i^2$,

故 $\frac{\partial f}{\partial x_i} = 2x_i, i = 1, 2, \dots, n$. 于是

① $\frac{df}{d\mathbf{x}} = (2x_1, \dots, 2x_i, \dots, 2x_n)^T = 2\mathbf{x}$;

② $\frac{df}{d\mathbf{x}^T} = (2x_1, \dots, 2x_i, \dots, 2x_n) = 2\mathbf{x}^T. \square$

即

$$\frac{d}{d\mathbf{x}} (\mathbf{x}^T \mathbf{x}) = 2\mathbf{x};$$

$$\frac{d}{d\mathbf{x}^T} (\mathbf{x}^T \mathbf{x}) = 2\mathbf{x}^T.$$


例 5.17 设 $A = (a_{ij})_{n \times n}$, $\mathbf{x} = (x_1, \dots, x_k, \dots, x_n)^T$, $f(\mathbf{x}) = \mathbf{x}^T A \mathbf{x}$, 求 $\frac{df}{d\mathbf{x}}$.

解 $f(\mathbf{x}) = \mathbf{x}^T A \mathbf{x} = \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j = \sum_{i=1}^n x_i \sum_{j=1}^n a_{ij} x_j$

$$= \sum_{i=1}^{k-1} x_i \sum_{j=1}^n a_{ij} x_j + x_k \sum_{j=1}^n a_{kj} x_j + \sum_{i=k+1}^n x_i \sum_{j=1}^n a_{ij} x_j.$$

于是 $\frac{\partial f}{\partial x_k} = \sum_{i=1}^{k-1} x_i a_{ik} + \left(\sum_{j=1}^n a_{kj} x_j + x_k a_{kk} \right) + \sum_{i=k+1}^n x_i a_{ik}$

$$= \sum_{i=1}^n a_{ik} x_i + \sum_{j=1}^n a_{kj} x_j.$$



$$\begin{aligned}
 \frac{df}{d\mathbf{x}} &= \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_k} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n a_{i1} x_i + \sum_{j=1}^n a_{1j} x_j \\ \vdots \\ \sum_{i=1}^n a_{ik} x_i + \sum_{j=1}^n a_{kj} x_j \\ \vdots \\ \sum_{i=1}^n a_{in} x_i + \sum_{j=1}^n a_{nj} x_j \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n a_{i1} x_i \\ \vdots \\ \sum_{i=1}^n a_{ik} x_i \\ \vdots \\ \sum_{i=1}^n a_{in} x_i \end{bmatrix} + \begin{bmatrix} \sum_{j=1}^n a_{1j} x_j \\ \vdots \\ \sum_{j=1}^n a_{kj} x_j \\ \vdots \\ \sum_{j=1}^n a_{nj} x_j \end{bmatrix} \\
 &= \mathbf{A}^T \mathbf{x} + \mathbf{A} \mathbf{x} = (\mathbf{A}^T + \mathbf{A}) \mathbf{x}. \quad \square
 \end{aligned}$$

特别当 $\mathbf{A}$ 为**实对称**阵时有

$$\frac{d}{d\mathbf{x}} (\mathbf{x}^T \mathbf{A} \mathbf{x}) = 2\mathbf{A} \mathbf{x}.$$


二. 矩阵值函数对矩阵变量的导数

定义5.14 设 $F(X) = (f_{st}(X))_{p \times q}$ ($s = 1, 2, \dots, p; t = 1, 2, \dots, q$)

的元素 $f_{st}(X)$ 都是矩阵变量 $X = (x_{ij})_{m \times n}$ 的 mn 元函数, 称

$F(X)$ 为矩阵值函数. 定义 $F(X)$ 对矩阵变量 X 的导数为

$$\frac{dF}{dX} = \begin{bmatrix} \frac{\partial F}{\partial x_{11}} & \cdots & \frac{\partial F}{\partial x_{1n}} \\ \vdots & \boxed{\frac{\partial F}{\partial x_{ij}}} & \vdots \\ \frac{\partial F}{\partial x_{m1}} & \cdots & \frac{\partial F}{\partial x_{mn}} \end{bmatrix}_{m \times n},$$



其中 $\frac{\partial F}{\partial x_{ij}} = \begin{bmatrix} \frac{\partial f_{11}}{\partial x_{ij}} & \dots & \frac{\partial f_{1q}}{\partial x_{ij}} \\ \vdots & \frac{\partial f_{st}}{\partial x_{ij}} & \vdots \\ \frac{\partial f_{p1}}{\partial x_{ij}} & \dots & \frac{\partial f_{pq}}{\partial x_{ij}} \end{bmatrix}_{p \times q}$

这里 $i = 1, 2, \dots, m; j = 1, 2, \dots, n.$

因为 $\frac{\partial F}{\partial x_{ij}}$ 是 $p \times q$ 矩阵, 所以 $\frac{dF}{dX}$ 是 $mp \times nq$ 的矩阵.



由定义可以看出矩阵值函数求导分**两步**进行：

1. 先**视** F 为**数值函数**,对矩阵变量 X 求导,得到与 X 同型的 $m \times n$ 矩阵,该矩阵的形式为 $(\frac{\partial F}{\partial x_{ij}})_{m \times n}$; (**先下**)

2. 再**视** F 为**函数矩阵**,求得 $\frac{\partial F}{\partial x_{ij}} = (\frac{\partial f_{st}}{\partial x_{ij}})_{p \times q}$. (**后上**)


最终得到 $mp \times nq$ 的矩阵.

例5.19 设 $\mathbf{x} = (x_1, \dots, x_i, \dots, x_n)^T$ 是向量变量, 求 ① $\frac{d\mathbf{x}^T}{d\mathbf{x}}$; ② $\frac{d\mathbf{x}}{d\mathbf{x}^T}$.

解 ①. 这是向量值函数对列向量变量的导数.


由定义5.14有

$$\frac{d\mathbf{x}^T}{d\mathbf{x}} = \begin{bmatrix} \frac{\partial \mathbf{x}^T}{\partial x_1} \\ \vdots \\ \frac{\partial \mathbf{x}^T}{\partial x_i} \\ \vdots \\ \frac{\partial \mathbf{x}^T}{\partial x_n} \end{bmatrix} = \begin{bmatrix} 1 & \dots & 0 & \dots & 0 \\ \vdots & \ddots & \vdots & & \vdots \\ 0 & \dots & 1 & \dots & 0 \\ \vdots & & \vdots & \ddots & \vdots \\ 0 & \dots & 0 & \dots & 1 \end{bmatrix} = \mathbf{I}_n \cdot \left(\frac{\partial \mathbf{x}^T}{\partial x_i} = \mathbf{e}_i^T \right)$$



②.类似地有

$$\begin{aligned}\frac{d\mathbf{x}}{d\mathbf{x}^T} &= \left(\frac{\partial \mathbf{x}}{\partial x_1}, \dots, \boxed{\frac{\partial \mathbf{x}}{\partial x_i}}, \dots, \frac{\partial \mathbf{x}}{\partial x_n} \right) \\ &= \begin{bmatrix} 1 & \dots & 0 & \dots & 0 \\ \vdots & \ddots & \vdots & & \vdots \\ 0 & \dots & 1 & \dots & 0 \\ \vdots & & \vdots & \ddots & \vdots \\ 0 & \dots & 0 & \dots & 1 \end{bmatrix} = \mathbf{I}_n \cdot \left(\boxed{\frac{\partial \mathbf{x}}{\partial x_i}} = \mathbf{e}_i \right) \quad \square\end{aligned}$$



$$\text{注} \quad \frac{d\mathbf{x}}{d\mathbf{x}} = \begin{bmatrix} \frac{\partial \mathbf{x}}{\partial x_1} \\ \vdots \\ \frac{\partial \mathbf{x}}{\partial x_i} \\ \vdots \\ \frac{\partial \mathbf{x}}{\partial x_n} \end{bmatrix} = \begin{bmatrix} \mathbf{e}_1 \\ \vdots \\ \mathbf{e}_i \\ \vdots \\ \mathbf{e}_n \end{bmatrix}_{n^2 \times 1} \cdot \left(\frac{d\mathbf{x}}{d\mathbf{x}} = \text{vec} \mathbf{I}_n \neq \mathbf{I}_n \right)$$


$$\frac{d\mathbf{x}^T}{d\mathbf{x}^T} = \left(\frac{\partial \mathbf{x}^T}{\partial x_1}, \dots, \frac{\partial \mathbf{x}^T}{\partial x_i}, \dots, \frac{\partial \mathbf{x}^T}{\partial x_n} \right) = (\mathbf{e}_1^T, \dots, \mathbf{e}_i^T, \dots, \mathbf{e}_n^T)_{1 \times n^2}$$

例5.20 设 $A = (a_{ij})_{m \times n}$, $\mathbf{x} = (x_1, \dots, x_j, \dots, x_n)^T$ 是向量变量, 求 $\frac{d(A\mathbf{x})}{d\mathbf{x}^T}$.

解 这是列向量值函数对行向量变量的导数.

$$A\mathbf{x} = \begin{bmatrix} \sum_{j=1}^n a_{1j}x_j \\ \vdots \\ \sum_{j=1}^n a_{ij}x_j \\ \vdots \\ \sum_{j=1}^n a_{nj}x_j \end{bmatrix}, \quad \frac{\partial(A\mathbf{x})}{\partial x_j} = \begin{bmatrix} a_{1j} \\ \vdots \\ a_{ij} \\ \vdots \\ a_{nj} \end{bmatrix} = \mathbf{a}_j$$

其中 $A = (\mathbf{a}_1, \dots, \mathbf{a}_j, \dots, \mathbf{a}_n)$.



$$\frac{d(\mathbf{Ax})}{d\mathbf{x}^T} = \left(\frac{\partial(\mathbf{Ax})}{\partial x_1}, \dots, \frac{\partial(\mathbf{Ax})}{\partial x_i}, \dots, \frac{\partial(\mathbf{Ax})}{\partial x_n} \right)$$


$$= \begin{bmatrix} a_{11} & \cdots & a_{1j} & \cdots & a_{1n} \\ \vdots & & \vdots & & \vdots \\ a_{i1} & \cdots & a_{ij} & \cdots & a_{in} \\ \vdots & & \vdots & & \vdots \\ a_{m1} & \cdots & a_{nj} & \cdots & a_{mn} \end{bmatrix} = \mathbf{A}. \quad \square$$



例 5.21 设 $y_i = f_i(\mathbf{x})$, 其中 $\mathbf{x} = (x_1, \dots, x_j, \dots, x_n)^T$ 是
向量变量; $i = 1, 2, \dots, m$. 记 $\mathbf{y} = (y_1, \dots, y_i, \dots, y_m)^T$,

试计算 $\frac{d\mathbf{y}}{d\mathbf{x}^T}$.

解
$$\frac{d\mathbf{y}}{d\mathbf{x}^T} = \left(\frac{\partial \mathbf{y}}{\partial x_1}, \dots, \boxed{\frac{\partial \mathbf{y}}{\partial x_i}}, \dots, \frac{\partial \mathbf{y}}{\partial x_n} \right)$$



$$= \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \dots & \frac{\partial y_1}{\partial x_j} & \dots & \frac{\partial y_1}{\partial x_n} \\ \vdots & & \vdots & & \vdots \\ \frac{\partial y_i}{\partial x_1} & \dots & \frac{\partial y_i}{\partial x_j} & \dots & \frac{\partial y_i}{\partial x_n} \\ \vdots & & \vdots & & \vdots \\ \frac{\partial y_m}{\partial x_1} & \dots & \frac{\partial y_m}{\partial x_j} & \dots & \frac{\partial y_m}{\partial x_n} \end{bmatrix}_{m \times n} \cdot \square$$

上述矩阵 $(\frac{\partial y_i}{\partial x_j})_{m \times n}$ 称为 **Jacobi 矩阵**, 当 $m = n$ 时, 其行列式

称为 **Jacobi 行列式**, 记为 $\frac{\partial(y_1, \dots, y_i, \dots, y_n)}{\partial(x_1, \dots, x_j, \dots, x_n)}$.

§ 5.5 矩阵微分的应用

定理 5.10 设 A 是 n 阶 **常系数** 矩阵, 则满足 **初始条件** 的 **线性齐次微分方程组**

$$\begin{cases} \frac{d\mathbf{x}}{dt} = A\mathbf{x}, \\ \mathbf{x}(t_0) = \mathbf{x}_0. \end{cases} \quad (5.38)$$


的解为

$$\mathbf{x}(t) = e^{A(t-t_0)} \mathbf{x}_0 \quad (5.39)$$

这里 $A = (a_{ij})_{n \times n}$, $\mathbf{x}(t) = (x_1(t), \dots, x_i(t), \dots, x_n(t))^T$,

$$\mathbf{x}(t_0) = (x_1(t_0), \dots, x_i(t_0), \dots, x_n(t_0))^T.$$

特别 $t_0 = 0$ 时, $\mathbf{x}(t) = e^{At} \mathbf{x}_0$.



证 由于 $\frac{d}{dt}(e^{-At} \mathbf{x}(t)) = e^{-At}(-A)\mathbf{x}(t) + e^{-At} \frac{d}{dt} \mathbf{x}(t)$

$$= e^{-At} \left(\frac{d}{dt} \mathbf{x}(t) - A\mathbf{x}(t) \right) = \mathbf{0}.$$

将上式两端在 $[t_0, t]$ 上积分, 得

$$\int_{t_0}^t \frac{d}{d\tau} (e^{-A\tau} \mathbf{x}(\tau)) d\tau = \mathbf{0}, \quad e^{-At} \mathbf{x}(t) - e^{-At_0} \mathbf{x}(t_0) = \mathbf{0},$$

故满足初始条件的解为

$$\mathbf{x}(t) = e^{A(t-t_0)} \mathbf{x}_0.$$

若 $t_0 = 0$ 时, 则 $\mathbf{x}(t) = e^{At} \mathbf{x}_0.$




例5.22 求解线性常系数齐次微分方程组初值问题

$$\begin{cases} \frac{dx}{dt} = Ax \\ x(0) = (1, 1, 0)^T \end{cases}, A = \begin{bmatrix} 3 & -1 & 1 \\ 2 & 0 & -1 \\ 1 & -1 & 2 \end{bmatrix}.$$

解 $|\lambda I - A| = \lambda(\lambda - 2)(\lambda - 3) = 0.$


故 $\lambda_1 = 0, \lambda_2 = 2, \lambda_3 = 3$. 由于特征值互异, 故 A 相似于对角阵, 容易求得三个特征值所对应的特征向量为


$$\xi_1 = \begin{bmatrix} 1 \\ 5 \\ 2 \end{bmatrix}, \quad \xi_2 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \quad \xi_3 = \begin{bmatrix} 2 \\ 1 \\ 1 \end{bmatrix},$$

$$\text{故 } \mathbf{P} = (\xi_1, \xi_2, \xi_3) = \begin{bmatrix} 1 & 1 & 2 \\ 5 & 1 & 1 \\ 2 & 0 & 1 \end{bmatrix},$$

$$\text{求得 } \mathbf{P}^{-1} = -\frac{1}{6} \begin{bmatrix} 1 & -1 & -1 \\ -3 & -3 & 9 \\ -2 & 2 & 4 \end{bmatrix}.$$

由矩阵函数的Jordan标准形法求得



$$e^{At} = P \begin{bmatrix} e^{0t} & & \\ & e^{2t} & \\ & & e^{3t} \end{bmatrix} P^{-1}.$$

由定理 5.10 方程组的解为

$$\mathbf{x}(t) = e^{At} \mathbf{x}_0$$

$$= \begin{bmatrix} 1 & 1 & 2 \\ 5 & 1 & 1 \\ 2 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ e^{2t} \\ e^{3t} \end{bmatrix} \left(-\frac{1}{6}\right) \begin{bmatrix} 1 & -1 & -1 \\ -3 & -3 & 9 \\ -2 & 2 & 4 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} = \begin{bmatrix} e^{2t} \\ e^{2t} \\ 0 \end{bmatrix}. \square$$



定义 5.15 设 $\mathbf{x}(t)$ 是方程(5.38)的解,如果 $\lim_{t \rightarrow +\infty} \mathbf{x}(t) = \boldsymbol{\theta}$,

则称微分方程 $\frac{d\mathbf{x}}{dt} = A\mathbf{x}$ 的解是渐近稳定的.

由上述定义知例 5.22的解不是渐近稳定的.

可以证明方程(5.38)的解 $\mathbf{x}$ 是渐近稳定的充要条件是所有的特征值的实部是负的.

若的特征值全为负实部,则称为稳定矩阵.

显然例 5.22中的矩阵 A 不是稳定矩阵.

定理 5.11 设 A 是 n 阶常系数矩阵, 则满足初始条件的
线性非齐次微分方程组

$$\begin{cases} \frac{dx}{dt} = Ax + f(t) \\ x(t_0) = x_0 \end{cases} \quad (5.40)$$


的解为

$$x(t) = e^{A(t-t_0)} x_0 + \int_{t_0}^t e^{A(t-\tau)} f(\tau) d\tau \quad (5.41)$$

这里 $f(t) = (f_1(t), \dots, f_i(t), \dots, f_n(t))^T$,

特别 $t_0 = 0$ 时,

$$x(t) = e^{At} x_0 + \int_0^t e^{A(t-\tau)} f(\tau) d\tau.$$




证 由于 $\frac{d}{dt}(e^{-At} \mathbf{x}(t))$

$$= e^{-At}(-A)\mathbf{x}(t) + e^{-At} \frac{d}{dt} \mathbf{x}(t)$$

$$= e^{-At} \left(\frac{d}{dt} \mathbf{x}(t) - A\mathbf{x}(t) \right) = e^{-At} \mathbf{f}(t),$$

将上式两端在 $[t_0, t]$ 上积分, 得

$$\int_{t_0}^t \frac{d}{d\tau} (e^{-A\tau} \mathbf{x}(\tau)) d\tau = \int_{t_0}^t e^{-A\tau} \mathbf{f}(\tau) d\tau,$$


$$e^{-A t} \mathbf{x}(t) - e^{-A t_0} \mathbf{x}(t_0) = \int_{t_0}^t e^{-A \tau} \mathbf{f}(\tau) d\tau,$$


故微分方程组(5.40)满足初始条件的解为

$$\mathbf{x}(t) = e^{A(t-t_0)} \mathbf{x}_0 + \int_{t_0}^t e^{A(t-\tau)} \mathbf{f}(\tau) d\tau.$$

若 $t_0 = 0$ 时, 则

$$\mathbf{x}(t) = e^{A t} \mathbf{x}_0 + \int_0^t e^{A(t-\tau)} \mathbf{f}(\tau) d\tau.$$





例 5.23 求解常系数线性非齐次微分方程组初值问题

$$\begin{cases} \frac{d\mathbf{x}}{dt} = A\mathbf{x} + \mathbf{f}(t) \\ \mathbf{x}(0) = (1, 0, 0)^T \end{cases} \quad (5.42)$$

其中 $A = \begin{bmatrix} -1 & -2 & 6 \\ -1 & 0 & 3 \\ -1 & -1 & 4 \end{bmatrix}, \quad \mathbf{f}(t) = \begin{bmatrix} -e^t \\ 0 \\ e^t \end{bmatrix}.$

解 (方法一 见第三章Jordan标准形例3.8*)

(方法二)

由例5.9知 $e^{At} = e^t \begin{bmatrix} 1-2t & -2t & 6t \\ -t & 1-t & 3t \\ -t & -t & 1+3t \end{bmatrix}.$

由 $t_0 = 0$, 故 $t - t_0 = t$.


计算如下各量得 $e^{At} x_0 = e^t \begin{bmatrix} 1-2t \\ -t \\ -t \end{bmatrix}.$



$$e^{A(t-\tau)} = e^{t-\tau} \begin{bmatrix} 1-2(t-\tau) & -2(t-\tau) & 6(t-\tau) \\ -(t-\tau) & 1-(t-\tau) & 3(t-\tau) \\ -(t-\tau) & -(t-\tau) & 1+3(t-\tau) \end{bmatrix}.$$

由 $f(\tau) = \begin{bmatrix} -e^{\tau} \\ 0 \\ e^{\tau} \end{bmatrix}$, 则

$$e^{A(t-\tau)} f(\tau) = e^t \begin{bmatrix} -1 + 8(t-\tau) \\ 4(t-\tau) \\ 1 + 4(t-\tau) \end{bmatrix}.$$



$$\int_0^t e^{A(t-\tau)} f(\tau) d\tau = e^t \begin{bmatrix} \int_0^t [-1+8(t-\tau)] d\tau \\ \int_0^t 4(t-\tau) d\tau \\ \int_0^t [1+4(t-\tau)] d\tau \end{bmatrix} = e^t \begin{bmatrix} 4t^2 - t \\ 2t^2 \\ 2t^2 + t \end{bmatrix}.$$

最后得到微分方程组(5.42)的解为

$$\mathbf{x}(t) = e^t \begin{bmatrix} 1-3t+4t^2 \\ -t+2t^2 \\ 2t^2 \end{bmatrix}.$$

□

§ 5.6 Laplace变换

定义 5.16 设 $f(t)$ 为在 $t \geq 0$ 上有定义的实变复值函数, 于对某些复数 s , 若下面的广义积分存在, 称

$$F(s) = \int_0^{+\infty} e^{-st} f(t) dt$$

为函数 $f(t)$ 的 Laplace 变换, 记为 $F(s) = L[f(t)]$.

当 $f(t)$ 在 $t \geq 0$ 的每个有限区间上分段连续, 且 $\exists M > 0, \sigma \geq 0$, 使对所有 $t \geq 0$, 都有

$$|f(t)| < Me^{\sigma t}$$

则 $f(t)$ 的 Laplace 变换存在, 并称满足上述条件的 $f(t)$ 为 (像) 原函数, 把 $F(s) = L[f(t)]$ 称为像函数.



Laplace 变换的性质

① Laplace变换是线性变换


$$\forall a, b \in \mathbf{C}, \text{有 } L[af(t) + bg(t)] = aL[f(t)] + bL[g(t)];$$

② 原函数的微分性质

$$L[f'(t)] = sL[f(t)] - f(0) = sF(s) - f(0);$$

③ 像函数的微分性质

$$F'(s) = -\int_0^{+\infty} te^{-st} f(t) dt.$$



常用的Laplace变换公式

$$L[1] = \frac{1}{s} \quad (\operatorname{Re} s > 0)$$

$$L[t] = \frac{1}{s^2} \quad (\operatorname{Re} s > 0)$$

$$L[t^n] = \frac{n!}{s^{n+1}} \quad (\operatorname{Re} s > 0)$$

$$L[\sin \omega t] = \frac{\omega}{s^2 + \omega^2} \quad (\operatorname{Re} s > 0) \quad L[\sin t] = \frac{1}{s^2 + 1}$$

$$L[\cos \omega t] = \frac{s}{s^2 + \omega^2} \quad (\operatorname{Re} s > 0) \quad L[\cos t] = \frac{s}{s^2 + 1}$$



$$L[e^{zt}] = \frac{1}{s - z} \quad (\operatorname{Re} s > \operatorname{Re} z)$$

$$L[e^t] = \frac{1}{s - 1}$$

$$L[te^{zt}] = \frac{1}{(s - z)^2} \quad (\operatorname{Re} s > \operatorname{Re} z)$$

$$L[te^t] = \frac{1}{(s - 1)^2}$$

$$L[t^2 e^{zt}] = \frac{2!}{(s - z)^3} \quad (\operatorname{Re} s > \operatorname{Re} z)$$

$$L[t^2 e^t] = \frac{2!}{(s - 1)^3}$$

$$L[t^n e^{zt}] = \frac{n!}{(s - z)^{n+1}} \quad (\operatorname{Re} s > \operatorname{Re} z)$$

由 $F(s)$ 求 $f(t)$ 的数学运算叫**Laplace反变换**,记为 L^{-1} ,即有 $L^{-1}[F(s)] = f(t)$,因计算较复杂,通常按照**Laplace变换表**由**像函数**查出**原函数**.

Laplace变换可推广到**向量函数**.

定义5.17 设 $f(t)$ 为 n 维**向量函数**, 如果它的每一分量都存在**Laplace变换**, 则定义

$$F(s) = L[f(t)] = \int_0^{+\infty} e^{-st} f(t) dt.$$

可以证明如果对向量函数 $f(t)$, 存在常数 $M > 0$, 及 $\sigma \geq 0$, 使不等式

$$\|f(t)\|_2 \leq Me^{\sigma t}$$

对充分大的 t 成立, 则 $f(t)$ 的**Laplace变换**存在.

同样对 $f(t)$, 也有**Laplace反变换** $L^{-1}[F(s)] = f(t)$.

像函数, **原函数**, 也有相应的**性质**. 同样对**矩阵函数**亦如此, 只需把相应的运算移到**分量**上进行.

三.用Laplace变换计算 e^{At}

考虑线性常系数微分方程组

$$\begin{cases} \frac{d\mathbf{x}(t)}{dt} = A\mathbf{x}(t), \\ \mathbf{x}(0) = \mathbf{x}_0. \end{cases}$$

记 $\mathbf{X}(s) = L[\mathbf{x}(t)]$,

则由Laplace变换原函数的微分性质有


$$s\mathbf{X}(s) - \mathbf{x}(0) = A\mathbf{X}(s),$$

于是 $(sI - A)\mathbf{X}(s) = \mathbf{x}(0)$.

在有理分式矩阵范围内 $sI - A$ 可逆, 故

$$\mathbf{X}(s) = (sI - A)^{-1} \mathbf{x}(0).$$

由Laplace反变换得


$$\underline{\underline{x(t) = L^{-1}[(sI - A)^{-1}]x(0).}}$$

而由定理5.10知上述微分方程组的解为

$$\underline{\underline{x(t) = e^{At}x(0).}}$$

由微分方程组满足初始条件解的惟一性得

$$e^{At} = L^{-1}[(sI - A)^{-1}]$$


其中

$$(sI - A)^{-1} = \frac{\text{adj}(sI - A)}{\det(sI - A)} = \frac{(sI - A)^*}{|sI - A|}.$$

例 5.25 设 $A = \begin{bmatrix} -1 & -2 & 6 \\ -1 & 0 & 3 \\ -1 & -1 & 4 \end{bmatrix}$, 用 **Laplace** 变换方法计算 e^{At} .


解 $sI - A = \begin{bmatrix} s+1 & 2 & -6 \\ 1 & s & -3 \\ 1 & 1 & s-4 \end{bmatrix}$, $\det(sI - A) = (s-1)^3$.

$$\text{adj}(sI - A) = \begin{bmatrix} (s-1)(s-3) & -2(s-1) & -6(s-1) \\ -(s-1) & (s-1)(s-2) & 3(s-1) \\ -(s-1) & -(s-1) & (s-1)(s+2) \end{bmatrix}.$$




$$(sI - A)^{-1} = \frac{\text{adj}(sI - A)}{\det(sI - A)} = \frac{(sI - A)^*}{|sI - A|}$$

$$= \begin{bmatrix} \frac{s-3}{(s-1)^2} & \frac{-2}{(s-1)^2} & \frac{6}{(s-1)^2} \\ \frac{-1}{(s-1)^2} & \frac{s-2}{(s-1)^2} & \frac{3}{(s-1)^2} \\ \frac{-1}{(s-1)^2} & \frac{-1}{(s-1)^2} & \frac{s+2}{(s-1)^2} \end{bmatrix}$$



$$= \begin{bmatrix} \frac{1}{s-1} - \frac{2}{(s-1)^2} & \frac{-2}{(s-1)^2} & \frac{6}{(s-1)^2} \\ \frac{-1}{(s-1)^2} & \frac{1}{s-1} - \frac{1}{(s-1)^2} & \frac{3}{(s-1)^2} \\ \frac{-1}{(s-1)^2} & \frac{-1}{(s-1)^2} & \frac{1}{s-1} + \frac{3}{(s-1)^2} \end{bmatrix}$$



$$e^{At} = L^{-1}[(sI - A)^{-1}]$$

$$= \begin{bmatrix} e^t - 2te^t & -2te^t & 6te^t \\ -te^t & e^t - te^t & 3te^t \\ -te^t & -te^t & e^t + 3te^t \end{bmatrix}$$

$$= e^t \begin{bmatrix} 1 - 2t & -2t & 6t \\ -t & 1 - t & 3t \\ -t & -t & 1 + 3t \end{bmatrix}$$

□

这与**例 5.9**及**例 5.10**的结果完全一致.



例 5.26 用**Laplace**变换方法求解**例 5.23**(*p*102).


解 (方法三)由例5.23知

$$\begin{cases} \frac{d\mathbf{x}}{dt} = A\mathbf{x} + \mathbf{f}(t), \\ \mathbf{x}(0) = (1, 0, 0)^T. \end{cases}$$

其中 $A = \begin{bmatrix} -1 & -2 & 6 \\ -1 & 0 & 3 \\ -1 & -1 & 4 \end{bmatrix}, \quad \mathbf{f}(t) = \begin{bmatrix} -e^t \\ 0 \\ e^t \end{bmatrix}.$

对微分方程组两边取Laplace变换得

$$sX(s) - x(0) = AX(s) + F(s).$$



$$(sI - A)X(s) = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} + \begin{bmatrix} \frac{-1}{s-1} \\ 0 \\ \frac{1}{s-1} \end{bmatrix},$$

$$X(s) = (sI - A)^{-1} \left(\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} + \begin{bmatrix} \frac{-1}{s-1} \\ 0 \\ \frac{1}{s-1} \end{bmatrix} \right),$$


由例5.25知

$$(sI - A)^{-1} = \begin{bmatrix} \frac{1}{s-1} - \frac{2}{(s-1)^2} & \frac{-2}{(s-1)^2} & \frac{6}{(s-1)^2} \\ \frac{-1}{(s-1)^2} & \frac{1}{s-1} - \frac{1}{(s-1)^2} & \frac{3}{(s-1)^2} \\ \frac{-1}{(s-1)^2} & \frac{-1}{(s-1)^2} & \frac{1}{s-1} + \frac{3}{(s-1)^2} \end{bmatrix}$$

代入上式得



$$\begin{aligned} X(s) &= \begin{bmatrix} \frac{1}{s-1} - \frac{2}{(s-1)^2} \\ \frac{-1}{(s-1)^2} \\ \frac{-1}{(s-1)^2} \end{bmatrix} + \begin{bmatrix} \frac{-1}{(s-1)^2} + \frac{8}{(s-1)^3} \\ \frac{4}{(s-1)^3} \\ \frac{1}{(s-1)^2} + \frac{4}{(s-1)^3} \end{bmatrix} \\ &= \begin{bmatrix} \frac{1}{s-1} - \frac{3}{(s-1)^2} + \frac{8}{(s-1)^3} \\ \frac{-1}{(s-1)^2} + \frac{4}{(s-1)^3} \\ \frac{4}{(s-1)^3} \end{bmatrix}. \end{aligned}$$



由 Laplace 变换的 **反变换** 即得

$$\begin{aligned} \mathbf{x}(t) &= \begin{bmatrix} e^t - 3te^t + 4t^2e^t \\ -te^t + 2t^2e^t \\ 2t^2e^t \end{bmatrix} \\ &= e^t \begin{bmatrix} 1 - 3t + 4t^2 \\ -t + 2t^2 \\ 2t^2 \end{bmatrix}. \end{aligned}$$



这与 **例 5.23** 的结果完全一致.



计算 e^{At} 的各种方法比较

例 5.27 设 $A = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}$, 计算 e^{At} .


解 方法一(矩阵指数函数展开式法)

$$A = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}, \text{经计算有 } A^0 = I, A^1 = A,$$

$$A^2 = -I, A^3 = -A, A^4 = I, \dots, A^{2m} = (-1)^m I, A^{2m+1} = (-1)^m A$$

由矩阵指数函数的定义有

$$e^{At} = \sum_{k=0}^{\infty} \frac{A^k t^k}{k!} = \sum_{m=0}^{\infty} \frac{A^{2m} t^{2m}}{(2m)!} + \sum_{m=0}^{\infty} \frac{A^{2m+1} t^{2m+1}}{(2m+1)!}$$



$$= \sum_{m=0}^{\infty} \frac{(-1)^m \mathbf{I} t^{2m}}{(2m)!} + \sum_{m=0}^{\infty} \frac{(-1)^m \mathbf{A} t^{2m+1}}{(2m+1)!}$$

$$= \left(\sum_{m=0}^{\infty} \frac{(-1)^m t^{2m}}{(2m)!} \right) \mathbf{I} + \left(\sum_{m=0}^{\infty} \frac{(-1)^m t^{2m+1}}{(2m+1)!} \right) \mathbf{A}$$

$$= (\cos t) \mathbf{I} + (\sin t) \mathbf{A}$$

$$= \begin{bmatrix} \cos t & 0 \\ 0 & \cos t \end{bmatrix} + \begin{bmatrix} 0 & \sin t \\ -\sin t & 0 \end{bmatrix} = \begin{bmatrix} \cos t & \sin t \\ -\sin t & \cos t \end{bmatrix}. \quad \square$$

方法二(Jordan标准形法)


$$|\lambda I - A| = \begin{vmatrix} \lambda & -1 \\ 1 & \lambda \end{vmatrix} = \lambda^2 + 1$$

故 A 的特征值为 $\lambda_1 = i, \lambda_2 = -i$.

由于 A 的特征值互异, 故 $A \sim D = \begin{bmatrix} i & 0 \\ 0 & -i \end{bmatrix}$.

$$\lambda_1 I - A = \begin{bmatrix} i & -1 \\ 1 & i \end{bmatrix} \rightarrow \begin{bmatrix} 1 & i \\ 0 & 0 \end{bmatrix}, \quad P_1 = \begin{bmatrix} -i \\ 1 \end{bmatrix},$$

$$\lambda_2 I - A = \begin{bmatrix} -i & -1 \\ 1 & -i \end{bmatrix} \rightarrow \begin{bmatrix} 1 & -i \\ 0 & 0 \end{bmatrix}, \quad P_2 = \begin{bmatrix} i \\ 1 \end{bmatrix}.$$



故 $\mathbf{P} = \begin{bmatrix} -i & i \\ 1 & 1 \end{bmatrix}$, 求得 $\mathbf{P}^{-1} = \frac{1}{2} \begin{bmatrix} i & 1 \\ -i & 1 \end{bmatrix}$, 于是

$$e^{At} = \mathbf{P} \mathbf{J}(t) \mathbf{P}^{-1}$$

$$= \begin{bmatrix} -i & i \\ 1 & 1 \end{bmatrix} \begin{bmatrix} e^{it} & 0 \\ 0 & e^{-it} \end{bmatrix} \frac{1}{2} \begin{bmatrix} i & 1 \\ -i & 1 \end{bmatrix}$$

$$= \frac{1}{2} \begin{bmatrix} e^{it} + e^{-it} & -ie^{it} + ie^{-it} \\ ie^{it} - ie^{-it} & e^{it} + e^{-it} \end{bmatrix} = \begin{bmatrix} \frac{e^{it} + e^{-it}}{2} & \frac{e^{it} - e^{-it}}{2i} \\ -\frac{e^{it} - e^{-it}}{2i} & \frac{e^{it} + e^{-it}}{2} \end{bmatrix}$$

$$= \begin{bmatrix} \cos t & \sin t \\ -\sin t & \cos t \end{bmatrix}.$$





方法三(多项式法)


$$|\lambda I - A| = \begin{vmatrix} \lambda & -1 \\ 1 & \lambda \end{vmatrix} = \lambda^2 + 1$$

故 A 的特征值为 $\lambda_1 = i, \lambda_2 = -i$.

设 $r(\lambda t) = a_0(t) + a_1(t)\lambda$

则 $r(it) = a_0(t) + ia_1(t) = e^{it} \quad \text{①}$

$$r(-it) = a_0(t) - ia_1(t) = e^{-it} \quad \text{②}$$




$$\textcircled{1} + \textcircled{2}: a_0(t) = \frac{e^{it} + e^{-it}}{2} = \cos t$$

$$\textcircled{1} - \textcircled{2}: a_1(t) = \frac{e^{it} - e^{-it}}{2i} = \sin t$$

$$\text{故 } e^{At} = a_0(t) \mathbf{I} + a_1(t) A$$

$$= \begin{bmatrix} \cos t & 0 \\ 0 & \cos t \end{bmatrix} + \begin{bmatrix} 0 & \sin t \\ -\sin t & 0 \end{bmatrix} = \begin{bmatrix} \cos t & \sin t \\ -\sin t & \cos t \end{bmatrix}. \quad \square$$

方法四(单纯矩阵的谱分解法)



$$|\lambda I - A| = \begin{vmatrix} \lambda & -1 \\ 1 & \lambda \end{vmatrix} = \lambda^2 + 1$$

由于 A 的特征值 $\lambda_1 = i, \lambda_2 = -i$ 互异, 故 A 为单纯矩阵.

$$\lambda_1 I - A = \begin{bmatrix} i & -1 \\ 1 & i \end{bmatrix} \rightarrow \begin{bmatrix} 1 & i \\ 0 & 0 \end{bmatrix}, \quad P_1 = \begin{bmatrix} -i \\ 1 \end{bmatrix},$$

$$\lambda_2 I - A = \begin{bmatrix} -i & -1 \\ 1 & -i \end{bmatrix} \rightarrow \begin{bmatrix} 1 & -i \\ 0 & 0 \end{bmatrix}, \quad P_2 = \begin{bmatrix} i \\ 1 \end{bmatrix}.$$

$$\text{故 } P = \begin{bmatrix} -i & i \\ 1 & 1 \end{bmatrix}, \text{ 求得 } P^{-1} = \frac{1}{2} \begin{bmatrix} i & 1 \\ -i & 1 \end{bmatrix} = \begin{bmatrix} \tilde{P}_1 \\ \tilde{P}_2 \end{bmatrix}$$



$$\mathbf{E}_1 = \mathbf{P}_1 \tilde{\mathbf{P}}_1 = \begin{bmatrix} -i \\ 1 \end{bmatrix} \frac{1}{2} (i \quad 1) = \frac{1}{2} \begin{bmatrix} 1 & -i \\ i & 1 \end{bmatrix}$$

$$\mathbf{E}_2 = \mathbf{P}_2 \tilde{\mathbf{P}}_2 = \begin{bmatrix} i \\ 1 \end{bmatrix} \frac{1}{2} (-i \quad 1) = \frac{1}{2} \begin{bmatrix} 1 & i \\ -i & 1 \end{bmatrix}$$

$$e^{At} = \sum_{i=1}^2 e^{\lambda_i t} \mathbf{E}_i = e^{it} \mathbf{E}_1 + e^{-it} \mathbf{E}_2$$

$$= e^{it} \frac{1}{2} \begin{bmatrix} 1 & -i \\ i & 1 \end{bmatrix} + e^{-it} \frac{1}{2} \begin{bmatrix} 1 & i \\ -i & 1 \end{bmatrix}$$

$$= \begin{bmatrix} \frac{e^{it} + e^{-it}}{2} & \frac{e^{it} - e^{-it}}{2i} \\ -\frac{e^{it} - e^{-it}}{2i} & \frac{e^{it} + e^{-it}}{2} \end{bmatrix} = \begin{bmatrix} \cos t & \sin t \\ -\sin t & \cos t \end{bmatrix}. \quad \square$$


方法五(Laplace变换法)

由 $sI - A = \begin{bmatrix} s & -1 \\ 1 & s \end{bmatrix}$

则 $(sI - A)^{-1} = \frac{\text{adj}(sI - A)}{\det(sI - A)} = \frac{(sI - A)^*}{|sI - A|}$


$$= \frac{1}{s^2 + 1} \begin{bmatrix} s & 1 \\ -1 & s \end{bmatrix} = \begin{bmatrix} \frac{s}{s^2 + 1} & \frac{1}{s^2 + 1} \\ -\frac{1}{s^2 + 1} & \frac{s}{s^2 + 1} \end{bmatrix}$$

于是 $e^{At} = L^{-1}[(sI - A)^{-1}] = \begin{bmatrix} \cos t & \sin t \\ -\sin t & \cos t \end{bmatrix}. \quad \square$



五种方法比较小结

- ①. 方法一(矩阵指数函数展开式法)的**前提**是矩阵 A 的乘幂具有**规律性**, 否则不可行; 要求熟练掌握矩阵指数函数, 矩阵正弦函数, 矩阵余弦函数的幂级数展开式.
- ②. 方法二(Jordan标准形法)是**基本方法**, 需求特征值, 特征向量, 相似矩阵的逆矩阵. 当矩阵相似对角阵时, 计算量有所简化.



- ③. 方法三(多项式法)需求特征值,需由待定系数法解线性方程组,也是一种常用的方法.
- ④. 方法四(单纯矩阵的谱分解法)需求特征值,特征向量,相似矩阵的逆矩阵.只适合单纯矩阵,有理论价值.
- ⑤. 方法五(Laplace变换法)不需求特征值,发挥了矩阵的分析(微分积分)性质,当特征值是复数时,较为简单.




本章总结

一. 重要定义及概念


(一) 矩阵序列与矩阵级数

- ① 矩阵序列, 收敛矩阵
- ② 矩阵级数, 矩阵级数的收敛与发散
矩阵级数的绝对收敛
- ③ 矩阵幂级数
- ④ Neumann级数 $\sum_{k=0}^{\infty} A^k$



(二) 矩阵函数


- ① 矩阵指数函数
- ② 矩阵正弦函数
- ③ 矩阵余弦函数
- ④ 矩阵函数的幂级数展开
- ⑤ 矩阵函数 $e^A, \sin A, \cos A$ 的性质



(三) 函数矩阵及其微分

- ① 函数矩阵的微分积分
- ② 数值函数对矩阵变量的导数
- ③ 矩阵值函数对矩阵变量的导数
- ④ 微分方程组解的稳定及稳定矩阵

(四) Laplace变换



二. 重要的定理, 公式.


① A 为收敛矩阵的充要条件

② 矩阵级数 $\sum_{k=0}^{\infty} A^{(k)}$ 绝对收敛的充要条件

③ Neumann 级数 $\sum_{k=0}^{\infty} A^k$ 收敛的充要条件


④ 常系数线性齐次微分方程组初值问题解的公式

⑤ 常系数线性非齐次微分方程组初值问题解的公式



三. 计算

- ① 矩阵函数的幂级数展开式
- ② Jordan标准形法计算矩阵函数
- ③ 多项式法计算矩阵函数
- ④ 单纯矩阵的谱分解法计算单纯矩阵的矩阵函数
- ⑤ Laplace变换法计算矩阵函数
- ⑥ 求解常系数线性齐次非齐次微分方程组初值问题




矩阵分析教程

(电子版)

董增福


哈尔滨工业大学数学系



第六章 特征值的估计

核心内容：

1. 特征值界的估计
2. 圆盘定理
3. Hermite矩阵的正定条件与 Rayleigh商
4. 广义特征值与广义Rayleigh商



§ 6.1 特征值界的估计

下面的定理给出矩阵的特征值与它的 F 范数的关系:

定理 6.1 (Schur不等式) 设 $\lambda_1, \dots, \lambda_i, \dots, \lambda_n$ 为 $A = (a_{ij})_{n \times n} \in \mathbb{C}^{n \times n}$ 的特征值, 则有 **Schur不等式**

$$\sum_{i=1}^n |\lambda_i|^2 \leq \sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2 = \|A\|_F^2 \quad (6.1)$$

等号成立的充要条件为 A 是正规矩阵.

证 由定理 3.25(Schur定理), $\forall A \in \mathbb{C}^{n \times n}$, 存在 $U \in \mathbb{C}^{n \times n}$, 使

$$U^H A U = R \quad (1)$$

其中 $R = (r_{ij})_{n \times n}$ 是对角元为 A 的特征值 $\lambda_1, \dots, \lambda_i, \dots, \lambda_n$ 的上三角矩阵.

取共轭转置有 $U^H A^H U = R^H \quad (2)$

上述 (2)(1) 二式相乘得

$$U^H (A^H A) U = R^H R$$

这说明 $A^H A$ 与 $R^H R$ 酉相似, 故它们的迹相等

$$\text{tr}(A^H A) = \text{tr}(R^H R) \quad (6.2)$$

因为上三角阵 R 的对角元为 A 的特征值, 故


$$\sum_{i=1}^n |\lambda_i|^2 = \sum_{i=1}^n |r_{ii}|^2 \leq \sum_{i=1}^n \sum_{j=1}^n |r_{ij}|^2 = \text{tr}(\mathbf{R}^H \mathbf{R})$$

由式(6.2)

$$\sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2 = \text{tr}(\mathbf{A}^H \mathbf{A}) = \text{tr}(\mathbf{R}^H \mathbf{R}) = \sum_{i=1}^n \sum_{j=1}^n |r_{ij}|^2,$$

故

$$\sum_{i=1}^n |\lambda_i|^2 \leq \sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2 = \|\mathbf{A}\|_F^2.$$

Schur不等式取等号的充要条件为 $\sum_{i=1}^n |r_{ii}|^2 = \sum_{i=1}^n \sum_{j=1}^n |r_{ij}|^2$,

这说明 R 是对角阵, 由定理3.26知 A (酉相似对角阵) 是正规矩阵.

注:任何一个 n 阶复数矩阵都可表成一个
Hermite矩阵与一个反Hermite矩阵之和.

设 $A \in \mathbf{C}^{n \times n}$, 则

$$A = \frac{1}{2}(A + A^{\mathrm{H}}) + \frac{1}{2}(A - A^{\mathrm{H}}) = B + C,$$

其中 $B = \frac{1}{2}(A + A^{\mathrm{H}}), \quad C = \frac{1}{2}(A - A^{\mathrm{H}}),$

显然 $B = B^{\mathrm{H}}, \quad C = -C^{\mathrm{H}}.$

用矩阵的 m_∞ 范数估计特征值

定理 6.2 设 $A = (a_{ij})_{n \times n} \in \mathbb{C}^{n \times n}$, $B = \frac{1}{2}(A + A^H)$, $C = \frac{1}{2}(A - A^H)$

$\lambda_1, \dots, \lambda_i, \dots, \lambda_n$ 为 $A \in \mathbb{C}^{n \times n}$ 的特征值, 则

$$\textcircled{1} \quad |\lambda_i| \leq n \cdot \max_{i,j} |a_{ij}| = \|A\|_{m_\infty}, \quad i = 1, 2, \dots, n;$$

$$\textcircled{2} \quad |\operatorname{Re}(\lambda_i)| \leq n \cdot \max_{i,j} |b_{ij}| = \|B\|_{m_\infty}, \quad i = 1, 2, \dots, n;$$

$$\textcircled{3} \quad |\operatorname{Im}(\lambda_i)| \leq n \cdot \max_{i,j} |c_{ij}| = \|C\|_{m_\infty}, \quad i = 1, 2, \dots, n.$$

证 ①.由定理 6.1有


$$|\lambda_i|^2 \leq \sum_{i=1}^n |\lambda_i|^2 \leq \sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2 \leq n^2 \max_{i,j} |a_{ij}|^2,$$

即 $|\lambda_i| \leq n \max_{i,j} |a_{ij}| = \|A\|_{m_\infty}, i = 1, 2, \dots, n.$

则①得证.

(若仅证①:由定理4.17有 $\rho(A) \leq \|A\|$, 故 $|\lambda_i| \leq \|A\|_{m_\infty}$.)

此处证法同时证②,③.



因 $U^H A U = \mathbf{R}$, $U^H A^H U = \mathbf{R}^H$, 由 $\mathbf{B}$, $\mathbf{C}$ 的定义,
于是有

$$U^H \mathbf{B} U = U^H \left[\frac{1}{2} (A + A^H) \right] U = \frac{1}{2} (\mathbf{R} + \mathbf{R}^H),$$

$$U^H \mathbf{C} U = U^H \left[\frac{1}{2} (A - A^H) \right] U = \frac{1}{2} (\mathbf{R} - \mathbf{R}^H),$$

由于酉相似下矩阵的Frobenius范数不变,

所以 $\left\| \frac{1}{2} (\mathbf{R} + \mathbf{R}^H) \right\|_F^2 = \|\mathbf{B}\|_F^2,$

$$\left\| \frac{1}{2} (\mathbf{R} - \mathbf{R}^H) \right\|_F^2 = \|\mathbf{C}\|_F^2.$$

因为

$$\frac{1}{2}(\mathbf{R} + \mathbf{R}^H) = \frac{1}{2} \left(\begin{bmatrix} \lambda_1 & r_{12} & \cdots & r_{1n} \\ 0 & \lambda_2 & \cdots & r_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix} + \begin{bmatrix} \overline{\lambda_1} & 0 & \cdots & 0 \\ r_{12} & \overline{\lambda_2} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ r_{1n} & r_{2n} & \cdots & \overline{\lambda_n} \end{bmatrix} \right)$$

$$= \frac{1}{2} \begin{bmatrix} \lambda_1 + \overline{\lambda_1} & r_{12} & \cdots & r_{1n} \\ r_{12} & \lambda_2 + \overline{\lambda_2} & \cdots & r_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ r_{1n} & r_{2n} & \cdots & \lambda_n + \overline{\lambda_n} \end{bmatrix} = \begin{bmatrix} \text{Re}(\lambda_1) & * & \cdots & * \\ * & \text{Re}(\lambda_2) & \cdots & * \\ \vdots & \vdots & \ddots & \vdots \\ * & * & \cdots & \text{Re}(\lambda_n) \end{bmatrix}$$

因为

$$\frac{1}{2}(\mathbf{R} - \mathbf{R}^H) = \frac{1}{2} \left(\begin{bmatrix} \lambda_1 & r_{12} & \cdots & r_{1n} \\ 0 & \lambda_2 & \cdots & r_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix} - \begin{bmatrix} \overline{\lambda_1} & 0 & \cdots & 0 \\ r_{12} & \overline{\lambda_2} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ r_{1n} & r_{2n} & \cdots & \overline{\lambda_n} \end{bmatrix} \right)$$

$$= \frac{1}{2} \begin{bmatrix} \lambda_1 - \overline{\lambda_1} & r_{12} & \cdots & r_{1n} \\ -r_{12} & \lambda_2 - \overline{\lambda_2} & \cdots & r_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ -r_{1n} & -r_{2n} & \cdots & \lambda_n - \overline{\lambda_n} \end{bmatrix} = \begin{bmatrix} i \operatorname{Im}(\lambda_1) & * & \cdots & * \\ * & i \operatorname{Im}(\lambda_2) & \cdots & * \\ \vdots & \vdots & \ddots & \vdots \\ * & * & \cdots & i \operatorname{Im}(\lambda_n) \end{bmatrix}$$

所以有 (注意 $\|\cdot\|_F^2 \leq \|\cdot\|_{m_\infty}^2$)

$$\sum_{i=1}^n \frac{1}{4} |\lambda_i + \overline{\lambda_i}|^2 + \sum_{i < j} \frac{1}{2} |r_{ij}|^2 = \sum_{i=1}^n \sum_{j=1}^n |b_{ij}|^2 \leq n^2 \max_{i,j} |b_{ij}|^2,$$

$$\sum_{i=1}^n \frac{1}{4} |\lambda_i - \overline{\lambda_i}|^2 + \sum_{i < j} \frac{1}{2} |r_{ij}|^2 = \sum_{i=1}^n \sum_{j=1}^n |c_{ij}|^2 \leq n^2 \max_{i,j} |c_{ij}|^2.$$


故

$$|\operatorname{Re}(\lambda_i)|^2 \leq \sum_{i=1}^n |\operatorname{Re}(\lambda_i)|^2 = \sum_{i=1}^n \frac{1}{4} |\lambda_i + \overline{\lambda_i}|^2 \leq n^2 \max_{i,j} |b_{ij}|^2,$$

$$|\operatorname{Im}(\lambda_i)|^2 \leq \sum_{i=1}^n |\operatorname{Im}(\lambda_i)|^2 = \sum_{i=1}^n \frac{1}{4} |\lambda_i - \overline{\lambda_i}|^2 \leq n^2 \max_{i,j} |c_{ij}|^2.$$

此即②,③的等价不等式.





推论 (1) Hermite矩阵的特征值都是实数(定理2.18);

(2) 反Hermite矩阵的特征值为零或纯虚数.

证 当 $A^H = A$ 时, $C = O$, 由定理6.2之③, $\text{Im}(\lambda_i) = 0$,
即 λ_i 为实数, $i = 1, 2, \dots, n$;

当 $A^H = -A$ 时, $B = O$, 由定理6.2之②, $\text{Re}(\lambda_i) = 0$,
即 λ_i 为零或纯虚数, $i = 1, 2, \dots, n$. ■



对于**实**矩阵**特征值虚部**的估计有比定理6.2之③更精细的结果.

定理 6.3 设 $A \in R^{n \times n}$, $C = \frac{1}{2}(A - A^T)$, 则

$$|\operatorname{Im}(\lambda)| \leq \sqrt{\frac{n-1}{2n}} \|C\|_{m_\infty}$$

这里 λ 为 A 的任一**特征值**.

证略


例6.1 设 $A = \begin{bmatrix} 0 & 1 & 1 \\ -1 & 0 & 1 \\ -1 & -1 & 0 \end{bmatrix}$, 试论述 A 的特征值与范数的关系.

解 显然 A 为反对称矩阵, 所以有

$$B = \frac{1}{2}(A + A^H) = O,$$

$$C = \frac{1}{2}(A - A^H) = A.$$

于是 $\|A\|_{m_\infty} = 3$, $\|B\|_{m_\infty} = 0$, $\|C\|_{m_\infty} = 3$.




由**定理** 6.2, 对 A 的任一特征值 λ 有

$$|\lambda| \leq 3, \quad |\operatorname{Re}(\lambda)| = 0, \quad |\operatorname{Im}(\lambda)| \leq 3.$$

由**定理** 6.3, $|\operatorname{Im}(\lambda)| \leq \sqrt{\frac{3-1}{2 \times 3}} \|C\|_{m_\infty} = \sqrt{3}.$

对于 $|\operatorname{Im}(\lambda)|$ 的估计, **定理** 6.3 明显优于 **定理** 6.2.

以下计算 A 的特征值：


$$|\lambda I - A| = \begin{vmatrix} \lambda & -1 & -1 \\ 1 & \lambda & -1 \\ 1 & 1 & \lambda \end{vmatrix} = \lambda(\lambda^2 + 3).$$

故 A 的特征值为 $\lambda_1 = 0, \lambda_2 = \sqrt{3}i, \lambda_3 = -\sqrt{3}i$.

(A 是反对称矩阵, 其特征值为零或纯虚数);

另有 $\|A\|_F^2 = \sum_{i=1}^3 \sum_{j=1}^3 |a_{ij}|^2 = 6,$

于是 $6 = \sum_{i=1}^3 |\lambda_i|^2 \leq \|A\|_F^2 = 6.$

因为 A 是正规矩阵, 等号成立, 与定理 6.1 结论一致.

显然 $\rho(A) = \sqrt{3}$,

且有 $\|A\|_{m_1} = 6, \|A\|_F = \sqrt{6}, \|A\|_{m_\infty} = 3$;

$\|A\|_1 = \|A\|_\infty = 2$,

再计算 A 的 2 范数

$$|\lambda I - A^H A| = \begin{vmatrix} \lambda - 2 & -1 & 1 \\ -1 & \lambda - 2 & -1 \\ 1 & -1 & \lambda - 2 \end{vmatrix} = \lambda(\lambda - 3)^2.$$

故 $\|A\|_2 = \sqrt{3}$, 可见 $\rho(A) \leq \|A\|$ (任一范数);

又 A 是正规矩阵, 有 $\rho(A) = \|A\|_2 = \sqrt{3}$. $\square$



§ 6.2 圆盘定理

定义 6.1 设 $A = (a_{ij})_{n \times n} \in \mathbb{C}^{n \times n}$,

$$R_i = \sum_{j=1, j \neq i}^n |a_{ij}| = |a_{i1}| + \dots + \underbrace{|a_{ii-1}| + |a_{ii+1}|}_{\text{blue}} + \dots + |a_{in}| \quad (i=1, \dots, n) \quad (6.8)$$

称复平面上的圆域

$$G_i = \{z \mid |z - a_{ii}| \leq R_i, z \in \mathbb{C}\} \quad (i=1, 2, \dots, n) \quad (6.9)$$

为矩阵 A 的第 i 个 Gershgorin 圆盘, 简称盖尔圆, 称 R_i 为盖尔圆

G_i 的半径.


圆盘定理

定理 6.4(Gershgorin 1) 矩阵 $A \in \mathbb{C}^{n \times n}$ 的 n 个特征值都在它的 n 个盖尔圆的并集中. 即 $\lambda_i \in \bigcup G_i$, λ_i 为 A 的特征值, $i = 1, 2, \dots, n$. 简称此定理为圆盘定理.

证 设 λ 为 A 的任一特征值, $\mathbf{x} = (x_1, \dots, x_j, \dots, x_n)^T \in \mathbb{C}^n$ 为 A 的属于特征值 λ 的特征向量, 故 $A\mathbf{x} = \lambda\mathbf{x}$, $\mathbf{x} \neq \mathbf{0}$.

设 $|x_k| = \max_j |x_j|$, 则 $|x_k| \neq 0$. 由于

$$\sum_{j=1}^n a_{ij} x_j = \lambda x_i, i = 1, 2, \dots, n; \quad \text{所以} \quad \sum_{j=1}^n a_{kj} x_j = \lambda x_k.$$



$$\lambda = \sum_{j=1}^n a_{kj} \frac{x_j}{x_k} = a_{k1} \frac{x_1}{x_k} + \dots + a_{kk-1} \frac{x_{k-1}}{x_k} + \boxed{a_{kk}} + a_{kk+1} \frac{x_{k+1}}{x_k} + \dots + a_{kn} \frac{x_n}{x_k},$$

$$|\lambda - \boxed{a_{kk}}| \leq \sum_{j=1, j \neq k}^n |a_{kj}| \left| \frac{x_j}{x_k} \right| \leq \sum_{j=1, j \neq k}^n |a_{kj}| = R_k,$$

这说明 $\lambda \in G_k$.

因此 λ 在 n 个盖尔圆的并集中; 由于 λ 为 A 的任一特征值, 所以 A 的 n 个特征值都在它的 n 个盖尔圆的并集中. ■

特别当 a_{ii} 是实数时, G_i 关于实轴对称; A 是实矩阵时, A 的盖尔圆为圆心都在实轴上的圆的并集.

例6.2 估计矩阵 A 的特征值的范围


$$A = \begin{bmatrix} i & 0.1 & 0.2 & 0.3 \\ 0.5 & 3 & 0.1 & 0.2 \\ 1 & 0.3 & -1 & 0.5 \\ 0.2 & -0.3 & -0.1 & -4 \end{bmatrix}.$$

解 由定理 6.2, A 的四个盖尔圆盘为

$$G_1 : |z - i| \leq 0.1 + 0.2 + 0.3 = 0.6$$

$$G_2 : |z - 3| \leq 0.5 + 0.1 + 0.2 = 0.8$$

$$G_3 : |z - (-1)| \leq 1 + 0.3 + 0.5 = 1.8$$

$$G_4 : |z - (-4)| \leq 0.2 + 0.3 + 0.1 = 0.6$$

则 A 的特征值应落在 $G_1 \cup G_2 \cup G_3 \cup G_4$ 中.




图 6.1



定义 6.2 矩阵 A 的盖尔圆中, 相交在一起的盖尔圆构成的最大连通区域称为一个连通部分, 规定孤立的盖尔圆也是一个连通部分. 这里所说的孤立就是不与其它的盖尔圆相交.

例如在上例图 6.1中, $G_1 \cup G_3$ 是一个连通部分, G_2, G_4 各是一个连通部分.

定理 6.5(Gershgorin 2) 矩阵 A 的任一个由 k 个盖尔圆组成的连通部分里, 有且仅有 A 的 k 个特征值. 若 A 的对角线有相同元素使盖尔圆重合时, 需重复计数; 特征值相同时也重复计数.

例 6.3 估计矩阵 $A = \begin{bmatrix} 10 & -8 \\ 5 & 0 \end{bmatrix}$ 的**特征值**的分布范围.

解 矩阵 A 的两个**盖尔圆**为

$$G_1: |z - 10| \leq 8, \quad G_2: |z - 0| \leq 5.$$

在复平面上 G_1, G_2 相交为一**连通部分**, 故 A 的**特征值**在 $G_1 \cup G_2$ 这个**连通部分**中.

经计算 $\lambda_1 = 5 + \sqrt{15}i, \lambda_2 = 5 - \sqrt{15}i, \lambda_1, \lambda_2$ 都不在 G_2 中, 而都在 G_1 中.




图 6.3



特征值的隔离

由**定理6.5**知在由 A 的 k 个盖尔圆组成的连通部分里有 k 个特征值,进一步我们能否实现在每个盖尔圆里仅有一个特征值呢?这就是特征值的隔离问题.

隔离办法是保持特征值不变,改变盖尔圆的半径,通常采用以下两种作法:

1.列盖尔圆 A 的列盖尔圆就是 A^T 的盖尔圆,因为 A 与 A^T 有相同的特征值,因此 A 的特征值也在 A^T 的 n 个盖尔圆的并集之中.

2.相似矩阵 设 $D = \text{diag}(d_1, \dots, d_i, \dots, d_n)$ 其中 $(d_1, \dots, d_i, \dots, d_n$

皆为正数令

$$B = DAD^{-1} = (a_{ij} \frac{d_i}{d_j})_{n \times n}$$

则 B 与 A 相似, 它们的特征值相等适当选取 $d_1, \dots, d_i, \dots, d_n$ 就可能使 B 的每个盖尔圆包含 A 的一个特征值

具体作法为: 要想 A 的第 i 个盖尔圆缩小, 可取 $d_i < 1$, 其余 $d_j = 1$; 要想 A 的第 i 个盖尔圆放大, 可取 $d_i > 1$, 其余 $d_j = 1$.



判别矩阵可逆的一种方法

定义 6.3 若矩阵 $A = (a_{ij})_{n \times n}$ 满足


$$|a_{ii}| > R_i, R_i = \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|, i = 1, \dots, n \quad (6.11)$$

则说矩阵 A 按行严格对角占优；

若满足

$$|a_{jj}| > R'_j, R'_j = \sum_{\substack{i=1 \\ i \neq j}}^n |a_{ij}|, j = 1, \dots, n \quad (6.12)$$

则说矩阵 A 按列严格对角占优。



定理 6.6 若矩阵 A 按行严格对角占优, 则 A 可逆.

证 A 可逆 $\Leftrightarrow \det A \neq 0 \Leftrightarrow A$ 的特征值均非零.

(反证法) 若 A 有零特征值, 由圆盘定理则存在 A 的盖尔圆 G_{i_0} ,

使 $0 \in G_{i_0}$, 即

$$|a_{i_0 i_0}| = |0 - a_{i_0 i_0}| \leq R_{i_0},$$

这与 A 按行严格对角占优矛盾, 所以 0 不是 A 的特征值. 即 $\det A \neq 0$, 故 A 可逆. ■

同理, 若矩阵 A 按列严格对角占优, 则 A 可逆.



例 6.5 判断矩阵 $A = \begin{bmatrix} 10 & -3 & 4 \\ 2 & 5i & 1 \\ 3i & -5 & 9 \end{bmatrix}$ 的可逆性.

解 $|10| > |-3| + |4|$

$$|5i| > |2| + |1|$$

$$|9| > |3i| + |-5|$$

故 A 按行严格对角占优, 由定理 6.6 知 A 可逆.



定义6.4 设 $A=(a_{ij})_{n \times n} \in \mathbf{C}^{n \times n}$, R_i 为 A 的第 i 个盖尔圆 G_i 的半径, 称复平面的区域

$$\Omega_{ij} = \{z \mid |z - a_{ii}| |z - a_{jj}| \leq R_i \cdot R_j, z \in \mathbf{C}\} \quad (i, j = 1, 2, \dots, n) \quad (6.13)$$

为矩阵 A 的Cassini卵形.

由上述定义可知 A 共有 $\frac{1}{2}n(n-1)$ 个Cassini卵形.

几何上Cassini卵形为到两个定点距离的乘积等于定长的点的轨迹. ($MF_1 \cdot MF_2 = a^2, F_1F_2 = 2c$)

定理 6.7(Ostrowski) 矩阵 $A \in \mathbb{C}^{n \times n}$ 的 n 个特征值都在它的Cassini卵形的并集中.

证略

定义 6.5 若矩阵 $A = (a_{ij})_{n \times n} \in \mathbb{C}^{n \times n}$ 满足

$$|a_{ii}| |a_{jj}| > R_i R_j, \text{ 其中 } R_i = \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|, i, j = 1, \dots, n \quad (6.11)$$

则说矩阵 A 按行广义严格对角占优.

定理 6.8 若矩阵 A 按行广义严格对角占优, 则 A 可逆.

例 6.6 讨论矩阵 $A = \begin{bmatrix} 10 & 5 & 6 \\ 4 & -20 & 8 \\ 7 & 12 & 25 \end{bmatrix}$ 的可逆性.

解 由第1行,第1列知 A 既不是按行严格对角占优,又不是按列严格对角占优,故无法用定理 6.6 判断 A 的可逆性.

因为 $|a_{11}||a_{22}| = 200 > 132 = R_1 \cdot R_2$

$$|a_{11}||a_{33}| = 250 > 209 = R_1 \cdot R_3$$

$$|a_{22}||a_{33}| = 500 > 228 = R_2 \cdot R_3$$

可见 A 按行广义严格对角占优,由定理 6.8 知 A 可逆. $\square$


尽管 Ostrowski 定理给出的特征值的范围比 Gershgorin 圆盘定理更精确,但因为盖尔圆比 Cassini 卵形简单直观,故圆盘定理更加适用

§ 6.3 Hermite矩阵的正定条件 与 Rayleigh商

定义 6.6 复二次齐式

$$f(\mathbf{x}) = f(x_1, \dots, x_i, \dots, x_n) = \sum_{i=1}^n \sum_{j=1}^n a_{ij} \overline{x_i} x_j \quad (6.15)$$

称为Hermite二次型, 其中 $a_{ij} = \overline{a_{ji}}$.




记 $A = (a_{ij})_{n \times n}$, 则 $A^H = A$, 故 A 为 **Hermite** 矩阵.

称 A 为 **Hermite** 二次型的(表示)矩阵, A 的秩为 **Hermite** 二次型的秩.

式 (6.15) 用 矩 阵 乘 法 可 改 写 为

$$f(\mathbf{x}) = \mathbf{x}^H A \mathbf{x}$$

其中 $\mathbf{x} = (x_1, \dots, x_i, \dots, x_n)^T$.



在可逆线性变换 $\mathbf{x} = \mathbf{P}\mathbf{y}$ 下

$$f(\mathbf{x}) = \mathbf{x}^H \mathbf{A} \mathbf{x} = \mathbf{y}^H (\mathbf{P}^H \mathbf{A} \mathbf{P}) \mathbf{y} = \mathbf{y}^H \mathbf{B} \mathbf{y},$$

其中 $\mathbf{B} = \mathbf{P}^H \mathbf{A} \mathbf{P}$, 显然 $\mathbf{B}$ 也是 Hermite 矩阵,
称 $\mathbf{A}, \mathbf{B}$ 为复相合矩阵.

在可逆线性变换 $\mathbf{x} = \mathbf{P}\mathbf{y}$ 下

$$f(\mathbf{x}) = \overline{\lambda_1} y_1 y_1 + \dots + \overline{\lambda_i} y_i y_i + \dots + \overline{\lambda_n} y_n y_n \quad (6.16)$$


则称式(6.16)为二次型的标准形.



在可逆线性变换 $x = Qz$ 下


$$f(x) = \overline{z_1} z_1 + \dots + \overline{z_p} z_p - \overline{z_{p+1}} z_{p+1} \dots - \overline{z_r} z_r \quad (6.17)$$

其中 $z = (z_1, \dots, z_i, \dots, z_n)^T$, $r = \text{rank } A$, 则称式(6.17)为二次型的规范形. p 称为正惯性指数, $q = r - p$ 称为负惯性指数.




定义 6.7 设 $f(x) = x^H A x$ 为 **Hermite** 二次型, 如果 $\forall x \in C^n$, $x \neq \theta$, 都有 $x^H A x > 0$, 则称 $f(x)$ **正定**, 且 A 是 **正定矩阵**, 记作 $A > 0$;

如果 $\forall x \in C^n$, $x \neq \theta$, 都有 $x^H A x \geq 0$, 则称 $f(x)$ **半正定** 或 **非负定**, 且 A 是 **半正定** 或 **非负定** 矩阵, 记作 $A \geq 0$;



如果 $\forall \mathbf{x} \in \mathbf{C}^n, \mathbf{x} \neq \mathbf{0}$, 都有 $\mathbf{x}^H \mathbf{A} \mathbf{x} < 0$, 则称 $f(\mathbf{x})$ **负定**,
且 $\mathbf{A}$ 是**负定矩阵**, 记作 $\mathbf{A} < 0$;

如果 $\forall \mathbf{x} \in \mathbf{C}^n, \mathbf{x} \neq \mathbf{0}$, 都有 $\mathbf{x}^H \mathbf{A} \mathbf{x} \leq 0$, 则称 $f(\mathbf{x})$ **半负定**
或**非正定**, 且 $\mathbf{A}$ 是**半负定**或**非正定**矩阵, 记作 $\mathbf{A} \leq 0$.



定理 6.9 设 A 是 n 阶 **Hermite** 矩阵, 则下列**命题等价**:

- (1) A 是**正定矩阵**;
- (2) A 与**单位矩阵合同**, 即存在 n 阶**可逆** 矩阵 P , 使 $P^H A P = I$;
- (3) 存在 n 阶**可逆** 矩阵 Q , 使 $A = Q^H Q$;
- (4) A 的**特征值全为正数**.

定理 6.10 n 阶 **Hermite** 矩阵**正定**的**充要条件**是 A 的**顺序主子式均为正数**.

Hermite矩阵的Rayleigh商

定义 6.8 设 A 是 Hermite 矩阵, 称 实数

$$R(x) = \frac{x^H A x}{x^H x} \quad \forall x \in C^n, x \neq \theta \quad (6.18)$$

为 Hermite 矩阵 A 的 Rayleigh 商.

由于 Hermite 矩阵的特征值全为实数, 不妨设 A 的特征值可按递增顺序排列如下:

$$\lambda_1 \leq \dots \lambda_i \leq \dots \leq \lambda_n,$$

定理 6.11 Rayleigh商具有以下**结论**:

① $R(k\mathbf{x}) = R(\mathbf{x})$, k 为**非零实数**, [**零次齐次函数**];

② $\lambda_1 \leq R(\mathbf{x}) \leq \lambda_n$, [**有上下界**];

③ $\min_{\mathbf{x} \neq \mathbf{0}} R(\mathbf{x}) = \lambda_1$, $\max_{\mathbf{x} \neq \mathbf{0}} R(\mathbf{x}) = \lambda_n$. [**达到最小值最大值**].


证 ①. 由**定义**显然;

②. 因为 **A** 是**Hermite**矩阵, 故可酉相似对角化,
因此存在**酉矩阵** U , 使

$$U^H A U = D = \text{diag}(\lambda_1, \dots, \lambda_i, \dots, \lambda_n).$$

不妨设 $\lambda_1 \leq \dots \leq \lambda_i \leq \dots \leq \lambda_n$. (全为实数)

令 $\mathbf{x} = \mathbf{U}\mathbf{y}$, 则


$$\boxed{R(\mathbf{x})} = \frac{\mathbf{x}^H \mathbf{A} \mathbf{x}}{\mathbf{x}^H \mathbf{x}} = \frac{\mathbf{y}^H \mathbf{U}^H \mathbf{A} \mathbf{U} \mathbf{y}}{\mathbf{y}^H \mathbf{U}^H \mathbf{U} \mathbf{y}} = \boxed{\frac{\mathbf{y}^H \mathbf{D} \mathbf{y}}{\mathbf{y}^H \mathbf{y}}}$$
$$= \frac{\lambda_1 \overline{y_1} y_1 + \lambda_2 \overline{y_2} y_2 + \dots + \lambda_n \overline{y_n} y_n}{\mathbf{y}^H \mathbf{y}}.$$

因为 $\lambda_1 \mathbf{y}^H \mathbf{y} \leq \lambda_1 \overline{y_1} y_1 + \lambda_2 \overline{y_2} y_2 + \dots + \lambda_n \overline{y_n} y_n \leq \lambda_n \mathbf{y}^H \mathbf{y}$,

于是 $\lambda_1 \mathbf{y}^H \mathbf{y} \leq \mathbf{y}^H \mathbf{D} \mathbf{y} \leq \lambda_n \mathbf{y}^H \mathbf{y}.$

故 $\lambda_1 \leq \boxed{R(\mathbf{x}) = \frac{\mathbf{y}^H \mathbf{D} \mathbf{y}}{\mathbf{y}^H \mathbf{y}}} \leq \lambda_n,$

②得证.



③.选取 $\mathbf{y}^{(1)} = (y_1, 0, \dots, 0)^T$, 记 $U\mathbf{y}^{(1)} = \mathbf{x}^{(1)}$


于是 $R(\mathbf{x}^{(1)}) = \lambda_1$, 即 $R(\mathbf{x})$ 在 $\mathbf{x}^{(1)}$ 达到 λ_1 .

选取 $\mathbf{y}^{(2)} = (0, 0, \dots, y_n)^T$, 记 $U\mathbf{y}^{(2)} = \mathbf{x}^{(2)}$

于是 $R(\mathbf{x}^{(2)}) = \lambda_n$, 即 $R(\mathbf{x})$ 在 $\mathbf{x}^{(2)}$ 达到 λ_n .

最后得到 $\min_{\mathbf{x} \neq \mathbf{0}} R(\mathbf{x}) = \lambda_1, \max_{\mathbf{x} \neq \mathbf{0}} R(\mathbf{x}) = \lambda_n$.

③得证. ■



考察单位球面 $S = \{\mathbf{x} \mid \mathbf{x} \in \mathbf{C}^n, \|\mathbf{x}\| = 1\}$, 因为 S 是闭集, $R(\mathbf{x})$ 在 S 上连续, 于是存在 $\mathbf{x}_1, \mathbf{x}_2 \in S$, 使

$$\min_{\mathbf{x} \in S} R(\mathbf{x}) = R(\mathbf{x}_1), \quad \max_{\mathbf{x} \in S} R(\mathbf{x}) = R(\mathbf{x}_2).$$

对于 $\mathbf{y} \neq \mathbf{0} \forall \mathbf{y} \in \mathbf{C}^n$, 令 $\mathbf{y}_0 = \frac{\mathbf{y}}{\|\mathbf{y}\|}$, 则 $\mathbf{y}_0 \in S$, 于是

$$R(\mathbf{x}_1) \leq R(\mathbf{y}_0) \leq R(\mathbf{x}_2).$$

由定理 6.11之 ①

$$R(\mathbf{y}) = R(\|\mathbf{y}\| \mathbf{y}_0) = R(\mathbf{y}_0)$$

故 $R(\mathbf{x}_1) \leq R(\mathbf{y}) \leq R(\mathbf{x}_2).$

由 $\mathbf{y}$ 的任意性,说明 $R(\mathbf{x})$ 的最小值和最大值可在单位球面达到. 所以在研究 $R(\mathbf{x})$ 的极值问题时,可以仅仅在单位球面上考虑.

另一方面也说明矩阵 A 的最小特征值,最大特征值可通过计算 $R(\mathbf{x})$ 在单位球面上的极值而得到.

§ 6.4 广义特征值与广义Rayleigh商

定义 6.9 设 A, B 均为 n 阶 Hermite 矩阵, 且 B 正定, 若存在


$\lambda \in \mathbb{C}$, 及 $\theta \neq 0, x \in \mathbb{C}^n$ 满足

$$Ax = \lambda Bx \quad (6.41)$$

则称 λ 为 A 相对于 B 的广义特征值, x 为属于 λ 的广义特征向量.

式(6.41)可以改写为

$$(\lambda B - A)x = 0. \quad (6.42)$$




式(6.42)有**非零解**的**充要条件**是关于 λ 的 n 次方程

$$\det(\lambda \mathbf{B} - \mathbf{A}) = |\lambda \mathbf{B} - \mathbf{A}| = 0. \quad (6.43)$$

把解得的 λ_i 代入方程(6.42), 解得**非零解向量**即为 λ_i 的**广义特征向量**, $i = 1, \dots, n$.


由于 $\mathbf{B}$ 是**Hermite正定**矩阵, **广义特征值**问题(6.41)
等价于下面的两种**常义特征值**问题:


$$(1) \boxed{B^{-1}A}x = \lambda x.$$

因为 B 是可逆矩阵, 用 B^{-1} 左乘式(6.41)两端, 即得式(6.44).

这样广义特征值问题(6.41)等价地化为矩阵 $B^{-1}A$ 的常义特征值问题.

需要指出的是尽管 A, B^{-1} 都是 Hermite 矩阵, 但是 $B^{-1}A$ 一般不一定是 Hermite 矩阵.


$$(2) \mathbf{S}\mathbf{y} = \lambda\mathbf{y}, \quad (6.45)$$


这里 $\mathbf{B} = \mathbf{L}\mathbf{L}^{\mathrm{H}}, \mathbf{y} = \mathbf{L}^{\mathrm{H}}\mathbf{x}, \mathbf{S} = \mathbf{L}^{-1}\mathbf{A}(\mathbf{L}^{-1})^{\mathrm{H}}$

因为 $\mathbf{B}$ 是 **Hermite 正定矩阵**, 故由 **定理3.21**, 存在 **正对角元** 的 **下三角** 矩阵 $\mathbf{L}$, 使 $\mathbf{B}$ 有 **Cholesky 分解**,

$$\mathbf{B} = \mathbf{L}\mathbf{L}^{\mathrm{H}}.$$

于是方程(6.41)可写成

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{L}\mathbf{L}^{\mathrm{H}}\mathbf{x} \quad (6.46)$$



令 $\mathbf{y} = \mathbf{L}^H \mathbf{x}$, 则 $\mathbf{x} = (\mathbf{L}^H)^{-1} \mathbf{y} = (\mathbf{L}^{-1})^H \mathbf{y}$, 代入上式, 则

$$\mathbf{A}(\mathbf{L}^{-1})^H \mathbf{y} = \lambda \mathbf{L} \mathbf{y},$$

左乘 $\mathbf{L}^{-1}$ 得 $\mathbf{L}^{-1} \mathbf{A}(\mathbf{L}^{-1})^H \mathbf{y} = \lambda \mathbf{y}.$

记 $\mathbf{S} = \mathbf{L}^{-1} \mathbf{A}(\mathbf{L}^{-1})^H$, 即得式(6.45).

显然 $\mathbf{S}$ 是 **Hermite** 矩阵, 于是 **广义特征值** 问题(6.41) 转化为 **Hermite** 矩阵 $\mathbf{S}$ 的 **常义特征值** 问题(6.45).



例 6.10 求解广义特征值问题 $A\mathbf{x} = \lambda B\mathbf{x}$, 其中


$$A = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}, \quad B = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix}.$$

解 方法一 直接求解 $A\mathbf{x} = \lambda B\mathbf{x}$.

$$(\lambda B - A)\mathbf{x} = \mathbf{0}.$$

$$|\lambda B - A| = \begin{vmatrix} \lambda - 1 & \lambda \\ \lambda & 2\lambda \end{vmatrix} = \lambda^2 - 2\lambda = 0,$$

广义特征值为 $\lambda_1 = 0, \lambda_2 = 2$;




对于 $\lambda_1 = 0$, $\lambda_1 \mathbf{B} - \mathbf{A} = \begin{bmatrix} -1 & 0 \\ 0 & 0 \end{bmatrix} \xrightarrow{r} \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$,

广义特征向量为 $k_1 \begin{bmatrix} 0 \\ 1 \end{bmatrix}$, $k_1 \neq 0$;

对于 $\lambda_2 = 2$, $\lambda_2 \mathbf{B} - \mathbf{A} = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} \xrightarrow{r} \begin{bmatrix} 1 & 2 \\ 0 & 0 \end{bmatrix}$,

广义特征向量为 $k_2 \begin{bmatrix} -2 \\ 1 \end{bmatrix}$, $k_2 \neq 0$.




方法二：转化求解 $\boxed{B^{-1}A}x = \lambda x$.

$$B^{-1} = \begin{bmatrix} 2 & -1 \\ -1 & 1 \end{bmatrix}, \quad B^{-1}A = \begin{bmatrix} 2 & 0 \\ -1 & 0 \end{bmatrix}.$$

$$|\lambda I - B^{-1}A| = \begin{vmatrix} \lambda - 2 & 0 \\ 1 & \lambda \end{vmatrix} = \lambda^2 - 2\lambda = 0,$$


广义特征值为 $\lambda_1 = 0, \lambda_2 = 2$;


$$\text{对于 } \lambda_1 = 0, \lambda_1 I - B^{-1}A = \begin{bmatrix} -2 & 0 \\ 1 & 0 \end{bmatrix} \xrightarrow{r} \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix},$$

广义特征向量为 $k_1 \begin{bmatrix} 0 \\ 1 \end{bmatrix}, k_1 \neq 0$.

$$\text{对于 } \lambda_2 = 2, \lambda_2 I - B^{-1}A = \begin{bmatrix} 0 & 0 \\ 1 & 2 \end{bmatrix} \xrightarrow{r} \begin{bmatrix} 1 & 2 \\ 0 & 0 \end{bmatrix},$$

广义特征向量为 $k_2 \begin{bmatrix} -2 \\ 1 \end{bmatrix}, k_2 \neq 0$.



方法三:转化求解 $Sy = \lambda y$.

$$B = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix} = LL^H, L = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}, L^{-1} = \begin{bmatrix} 1 & 0 \\ -1 & 1 \end{bmatrix}.$$

$$S = L^{-1}A(L^{-1})^H = \begin{bmatrix} 1 & 0 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix}.$$

$$|\lambda I - S| = \begin{vmatrix} \lambda - 1 & 1 \\ 1 & \lambda - 1 \end{vmatrix} = \lambda^2 - 2\lambda = 0,$$


广义特征值为 $\lambda_1 = 0, \lambda_2 = 2$;


$$\text{对于 } \lambda_1 = 0, \lambda_1 I - S = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix} \xrightarrow{r} \begin{bmatrix} 1 & -1 \\ 0 & 0 \end{bmatrix},$$

S 的常义特征向量为 $k_1 \begin{bmatrix} 1 \\ 1 \end{bmatrix}, k_1 \neq 0$.

$$\mathbf{x} = (\mathbf{L}^{-1})^H \mathbf{y} = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix} k_1 \begin{bmatrix} 1 \\ 1 \end{bmatrix} = k_1 \begin{bmatrix} 0 \\ 1 \end{bmatrix}, k_1 \neq 0,$$


为 A 的属于特征值 $\lambda_1 = 0$ 的广义特征向量.,


$$\text{对于 } \lambda_2 = 2, \lambda_2 I - S = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \rightarrow \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix},$$

S 的常义特征向量为 $k_2 \begin{bmatrix} -1 \\ 1 \end{bmatrix}, k_2 \neq 0$.

$$\mathbf{x} = (\mathbf{L}^{-1})^H \mathbf{y} = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix} k_2 \begin{bmatrix} -1 \\ 1 \end{bmatrix} = k_2 \begin{bmatrix} -2 \\ 1 \end{bmatrix}$$

为 A 的属于特征值 $\lambda_2 = 2$ 的广义特征向量. $\square$



定义 6.10 若 $\mathbf{x}_1, \dots, \mathbf{x}_i, \dots, \mathbf{x}_j, \dots, \mathbf{x}_n$ 为问题(6.41)的**线性无关**的**广义特征向量**,且满足

$$\mathbf{x}_i^H \mathbf{B} \mathbf{x}_j = \delta_{ij} \quad i, j = 1, 2, \dots, n$$

则称 $\mathbf{x}_1, \dots, \mathbf{x}_i, \dots, \mathbf{x}_j, \dots, \mathbf{x}_n$ 为 A 的**按 B 正交**的**特征向量系**.

定理 6.18 设 $A, \mathbf{B}$ 为 n 阶 **Hermite** 矩阵, 且 $\mathbf{B}$ **正定**, 则

- (1) A 的**相对于 B 的** n 个**广义特征值**全为**实数**;
- (2) A 存在一组**按 B 正交**的**特征向量系**.

证 由广义特征值问题 $A\mathbf{x} = \lambda B\mathbf{x}$ 的等价形式(6.45)有

$$S\mathbf{y} = \lambda\mathbf{y}, \quad S = L^{-1}A(L^{-1})^H, \quad \mathbf{y} = L^H\mathbf{x}.$$

因为 S 是 Hermite 矩阵, 故 λ 为实数, (1) 得证.

因 S 存在标准正交的特征向量系 $\mathbf{y}_1, \dots, \mathbf{y}_i, \dots, \mathbf{y}_j, \dots, \mathbf{y}_n$, 使

$$\mathbf{y}_i^H \mathbf{y}_j = \delta_{ij}, \quad i, j = 1, 2, \dots, n$$

令 $\mathbf{x}_i = (L^{-1})^H \mathbf{y}_i \neq \mathbf{0}$, $i = 1, 2, \dots, n$.

以下证其即为 A 的按 B 正交的特征向量系.

$$\begin{aligned} \mathbf{x}_i^H B \mathbf{x}_j &= \left[(L^{-1})^H \mathbf{y}_i \right]^H (LL^H) \left[(L^{-1})^H \mathbf{y}_j \right] \\ &= \mathbf{y}_i^H L^{-1} LL^H (L^H)^{-1} \mathbf{y}_j = \mathbf{y}_i^H \mathbf{y}_j = \delta_{ij} \quad (6.47)_{61} \end{aligned}$$



以下只要证明 $\mathbf{x}_1, \dots, \mathbf{x}_j, \dots, \mathbf{x}_n$ 线性无关即可.

考察线性表达式

$$c_1 \mathbf{x}_1 + \dots + c_j \mathbf{x}_j + \dots + c_n \mathbf{x}_n = \boldsymbol{\theta}.$$

用 $\mathbf{x}_i^H \mathbf{B}$ 左乘上式两端有 $\sum_{j=1}^n c_j \mathbf{x}_i^H \mathbf{B} \mathbf{x}_j = 0,$

由式(6.47)得 $c_i = 0, (i = 1, 2, \dots, n)$

故 $\mathbf{x}_1, \dots, \mathbf{x}_j, \dots, \mathbf{x}_n$ 线性无关. ■




定义 6.11 设 A, B 为 n 阶 **Hermite** 矩阵, 且 B **正定**, 对于 $\theta \neq \forall x \in \mathbf{C}^n$, 称

$$R_B(x) = \frac{x^H A x}{x^H B x} \quad (6.48)$$

为矩阵 A 相对于矩阵 B 的 **广义 Rayleigh 商**.

广义 Rayleigh 商(6.48) 与 **常义 Rayleigh 商**(6.18) 有 **相类似的结论**.



定理 6.19 A, B 为 n 阶 Hermite 矩阵, 且 B 正定,


广义特征值满足 $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$, 则

(1) $R_B(kx) = R_B(x)$, k 为非零实数, 即 $R_B(x)$ 为零次齐次函数;

(2) $\lambda_1 \leq R_B(x) \leq \lambda_n$;

(3) $\min_{x \neq 0} R_B(x) = \lambda_1$, $\max_{x \neq 0} R_B(x) = \lambda_n$.

关于广义 Rayleigh 商还有如下的重要结论:



定理 6.20 A, B 为 n 阶实对称矩阵, 且 B 正定, $x \in R^n$,
则 $x_0 \neq \theta$ 是 $R_B(x)$ 驻点的充要条件为 $R_B(x_0)$ 是
 $Ax = \lambda Bx$ 的广义特征值, x_0 是属于 $R_B(x_0)$ 的
广义特征向量.

证 先证必要性 $\Rightarrow$

$$\text{由 } R_B(x) = \frac{x^H Ax}{x^H Bx} \text{ 得 } x^H Bx \cdot R_B(x) = x^H Ax$$

上式两端对向量 $\mathbf{x}$ 求导得

$$2\mathbf{B}\mathbf{x} \cdot R_{\mathbf{B}}(\mathbf{x}) + \mathbf{x}^H \mathbf{B}\mathbf{x} \cdot \frac{d}{d\mathbf{x}} R_{\mathbf{B}}(\mathbf{x}) = 2\mathbf{A}\mathbf{x}$$

$$\frac{d}{d\mathbf{x}} R_{\mathbf{B}}(\mathbf{x}) = \frac{2}{\mathbf{x}^H \mathbf{B}\mathbf{x}} (\mathbf{A}\mathbf{x} - R_{\mathbf{B}}(\mathbf{x}) \cdot \mathbf{B}\mathbf{x}) \quad (*)$$

由 $\theta \neq \mathbf{x}_0$ 是 $R_{\mathbf{B}}(\mathbf{x})$ 的驻点, 有 $\left. \frac{d}{d\mathbf{x}} R_{\mathbf{B}}(\mathbf{x}) \right|_{\mathbf{x}=\mathbf{x}_0} = \theta$

由(*)式可得 $\mathbf{A}\mathbf{x}_0 = R_{\mathbf{B}}(\mathbf{x}_0) \mathbf{B}\mathbf{x}_0$

这说明 $\mathbf{x}_0$ 是 $\mathbf{A}$ 的广义特征值 $R_{\mathbf{B}}(\mathbf{x}_0)$ 的广义特征向量.

再证充分性 $\Leftarrow$

设非零向量 $\mathbf{x}_0$ 满足

$$\mathbf{A}\mathbf{x}_0 = \lambda \mathbf{B}\mathbf{x}_0,$$


用 $\mathbf{x}_0^T$ 左乘上式得

$$\mathbf{x}_0^T \mathbf{A}\mathbf{x}_0 = \lambda \mathbf{x}_0^T \mathbf{B}\mathbf{x}_0,$$

因 $\mathbf{B}$ 正定, 故 $\mathbf{x}_0^T \mathbf{B}\mathbf{x}_0 \neq 0$, $\lambda = \frac{\mathbf{x}_0^T \mathbf{A}\mathbf{x}_0}{\mathbf{x}_0^T \mathbf{B}\mathbf{x}_0} = R_B(\mathbf{x}_0).$

由(*)知 $\frac{d}{d\mathbf{x}} R_B(\mathbf{x}) \Big|_{\mathbf{x}=\mathbf{x}_0} = \mathbf{0}$, 故 $\mathbf{x}_0$ 是 $R_B(\mathbf{x})$ 的驻点,

$R_B(\mathbf{x}_0)$ 是 $\mathbf{A}\mathbf{x} = \lambda \mathbf{B}\mathbf{x}$ 的广义特征值. ■




本章总结

一. 重要定义及概念


(一) 特征值的估计

- ① 盖尔圆, 盖尔圆的半径
- ② 特征值的隔离
- ③ 按行(列)严格对角占优
- ④ Cassini卵形
- ⑤ 按行广义(列广义)严格对角占优



(二) Hermite矩阵的 Rayleigh商

- ① Hermite矩阵的二次型
- ② Hermite矩阵的 Rayleigh商
- ③ 广义特征值, 广义特征向量
- ④ 广义 Rayleigh商



二. 重要的定理, 公式.

① Schur不等式
$$\sum_{i=1}^n |\lambda_i|^2 \leq \sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2 = \|A\|_F^2$$

② $|\operatorname{Re}(\lambda_i)| \leq \|B\|_{m_\infty}, i = 1, 2, \dots, n$


$|\operatorname{Im}(\lambda_i)| \leq \|C\|_{m_\infty}, i = 1, 2, \dots, n$

③ Gershgorin圆盘定理

④ Ostrowski卵形定理


⑤ (广义)严格对角占优判断矩阵的可逆性

⑥ Hermite矩阵的 Rayleigh商与特征值的关系₇₀



三. 计算

- ① 计算盖尔圆的半径, 估计特征值的范围
- ② 计算特征值的隔离
- ③ 计算Hermite矩阵的Rayleigh商
- ④ 求解广义特征值问题



矩阵分析教程

(电子版)

董增福


哈尔滨工业大学数学系



第八章 矩阵的Kronecker积及其应用

核心内容：

1. 矩阵的 Kronecker 积
2. 矩阵Kronecker 积的特征值
3. 求解矩阵方程
4. 求解矩阵微分方程




§ 8.1 矩阵的Kronecker积

定义 8.1 设 $A = (a_{ij})_{m \times n} \in \mathbb{C}^{m \times n}$, $B = (b_{st})_{p \times q} \in \mathbb{C}^{p \times q}$,

称如下的分块矩阵

$$A \otimes B \triangleq \begin{bmatrix} a_{11}B & \cdots & a_{1j}B & \cdots & a_{1n}B \\ \vdots & & \vdots & & \vdots \\ a_{i1}B & \cdots & a_{ij}B & \cdots & a_{in}B \\ \vdots & & \vdots & & \vdots \\ a_{m1}B & \cdots & a_{mj}B & \cdots & a_{mn}B \end{bmatrix} = (a_{ij}B) \in \mathbb{C}^{mp \times nq} \quad (8.1)$$

为 A 与 B 的Kronecker积, 也称为矩阵 A 与 B 的直积
或张量积.




由上述定义有

$$\mathbf{B} \otimes \mathbf{A} = (b_{st} \mathbf{A}) \in \mathbf{C}^{pm \times qn} \quad (8.2)$$

显然 $\mathbf{A} \otimes \mathbf{B}$ 与 $\mathbf{B} \otimes \mathbf{A}$ 是同型矩阵,一般地

$$\mathbf{A} \otimes \mathbf{B} \neq \mathbf{B} \otimes \mathbf{A}$$


即矩阵的Kronecker积不满足交换律.



例 8.1 设 $A = \begin{bmatrix} 1 & 4 \\ 0 & 2 \end{bmatrix}$, $B = \begin{bmatrix} 3 & -1 \end{bmatrix}$, 则

$$A \otimes B = \begin{bmatrix} 1B & 4B \\ 0B & 2B \end{bmatrix} = \begin{bmatrix} \boxed{3} & \boxed{-1} & \boxed{12} & \boxed{-4} \\ \boxed{0} & \boxed{0} & \boxed{6} & \boxed{-2} \end{bmatrix},$$

$$B \otimes A = \begin{bmatrix} 3A & -1A \end{bmatrix} = \begin{bmatrix} \boxed{3} & \boxed{12} & \boxed{-1} & \boxed{-4} \\ \boxed{0} & \boxed{6} & \boxed{0} & \boxed{-2} \end{bmatrix}.$$



显然 $A \otimes B \neq B \otimes A$, 即矩阵的
Kronecker 积不满足交换律.

但是对于单位矩阵 I_m, I_n 有

$$I_m \otimes I_n = I_n \otimes I_m = I_{mn}. \quad (8.3)$$



定理 8.1 矩阵的 **Kronecker 积** 有如下的 **基本性质**:


(1) 设 k 为复常数, 则

$$(kA) \otimes B = A \otimes (kB) = k(A \otimes B); \quad \text{齐次性(8.4)}$$

$$(2) (A \otimes B) \otimes C = A \otimes (B \otimes C); \quad \text{结合律(8.5)}$$

$$(3) (A_1 + A_2) \otimes B = A_1 \otimes B + A_2 \otimes B, \quad \text{分配律(8.6a)}$$

$$B \otimes (A_1 + A_2) = B \otimes A_1 + B \otimes A_2; \quad (8.6b)$$



$$(4) \quad (A \otimes B)^T = A^T \otimes B^T \quad (8.7)$$

$$(A \otimes B)^H = A^H \otimes B^H \quad (8.8)$$

(5) 设 $A = (a_{ij})_{m \times n}$, $B = (b_{ij})_{p \times q}$,

$C = (c_{ij})_{n \times s}$, $D = (d_{ij})_{q \times t}$, 则

$$(A \otimes B)(C \otimes D) = (AC) \otimes (BD) \quad (8.9)$$

特别当 $A \in \mathbb{C}^{m \times m}$, $B \in \mathbb{C}^{n \times n}$ 时,

$$(A \otimes B)^k = A^k \otimes B^k$$

(6) 设 $A \in \mathbb{C}^{m \times m}$, $B \in \mathbb{C}^{n \times n}$ 都是可逆矩阵, 则 $A \otimes B$

也可逆, 且有

$$(A \otimes B)^{-1} = A^{-1} \otimes B^{-1} \quad (8.10)$$

$$(7) \quad (A \otimes B)^+ = A^+ \otimes B^+ \quad (8.11)$$

$$(8) \text{ 设 } A \in U^{m \times m}, B \in U^{n \times n}, \text{ 则 } A \otimes B \in U^{mn \times mn} \quad (8.12)$$

$$(9) \text{ 设 } A \in \mathbb{C}^{m \times m}, B \in \mathbb{C}^{n \times n}, \text{ 则 } A \otimes B \sim B \otimes A$$

证 由定义 8.1 即可证出 (1) ~ (4)

例如 (2) 表示满足结合律, 证明如下:

$$\begin{aligned} (A \otimes B) \otimes C &= \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} \otimes B \otimes C = \begin{bmatrix} a_{11}B & \cdots & a_{1n}B \\ \vdots & & \vdots \\ a_{m1}B & \cdots & a_{mn}B \end{bmatrix} \otimes C \\ &= \begin{bmatrix} (a_{11}B) \otimes C & \cdots & (a_{1n}B) \otimes C \\ \vdots & & \vdots \\ (a_{m1}B) \otimes C & \cdots & (a_{mn}B) \otimes C \end{bmatrix} = \begin{bmatrix} a_{11}(B \otimes C) & \cdots & a_{1n}(B \otimes C) \\ \vdots & & \vdots \\ a_{m1}(B \otimes C) & \cdots & a_{mn}(B \otimes C) \end{bmatrix} \\ &= A \otimes (B \otimes C) \end{aligned}$$


(4) 中(8.8)式 $(A \otimes B)^H = A^H \otimes B^H$ 证明如下:

$$\begin{aligned}
 (A \otimes B)^H &= \begin{bmatrix} a_{11}B & \cdots & a_{1n}B \\ \vdots & & \vdots \\ a_{m1}B & \cdots & a_{mn}B \end{bmatrix}^H = \begin{bmatrix} \overline{a_{11}}B^H & \cdots & \overline{a_{m1}}B^H \\ \vdots & & \vdots \\ \overline{a_{1n}}B^H & \cdots & \overline{a_{mn}}B^H \end{bmatrix} \\
 &= \begin{bmatrix} \overline{a_{11}} & \cdots & \overline{a_{m1}} \\ \vdots & & \vdots \\ \overline{a_{1n}} & \cdots & \overline{a_{mn}} \end{bmatrix} \otimes B^H = A^H \otimes B^H
 \end{aligned}$$

可见(8.8)式成立, 将 H 换成 T , 则(8.7)式成立. 11

(5). 由定义 8.1 可得

$$\begin{aligned}
 (A \otimes B)(C \otimes D) &= \begin{bmatrix} a_{11}B & \cdots & a_{1n}B \\ \vdots & & \vdots \\ a_{m1}B & \cdots & a_{mn}B \end{bmatrix} \begin{bmatrix} c_{11}D & \cdots & c_{1s}D \\ \vdots & & \vdots \\ a_{n1}D & \cdots & a_{ns}D \end{bmatrix} \\
 &= \begin{bmatrix} \sum_{k=1}^n (a_{1k}B)(c_{k1}D) & \cdots & \sum_{k=1}^n (a_{1k}B)(c_{ks}D) \\ \vdots & & \vdots \\ \sum_{k=1}^n (a_{mk}B)(c_{k1}D) & \cdots & \sum_{k=1}^n (a_{mk}B)(c_{ks}D) \end{bmatrix}
 \end{aligned}$$



$$\begin{aligned}
 &= \begin{bmatrix} \sum_{k=1}^n a_{1k} c_{k1} (\textcolor{red}{B}\textcolor{violet}{D}) & \cdots & \sum_{k=1}^n a_{1k} c_{ks} (\textcolor{red}{B}\textcolor{violet}{D}) \\ \vdots & & \vdots \\ \sum_{k=1}^n a_{mk} c_{k1} (\textcolor{red}{B}\textcolor{violet}{D}) & \cdots & \sum_{k=1}^n a_{mk} c_{ks} (\textcolor{red}{B}\textcolor{violet}{D}) \end{bmatrix} \\
 &= \begin{bmatrix} \sum_{k=1}^n a_{1k} c_{k1} & \cdots & \sum_{k=1}^n a_{1k} c_{ks} \\ \vdots & & \vdots \\ \sum_{k=1}^n a_{mk} c_{k1} & \cdots & \sum_{k=1}^n a_{mk} c_{ks} \end{bmatrix} \otimes (\textcolor{red}{B}\textcolor{violet}{D}) = (\textcolor{blue}{A}\textcolor{black}{C}) \otimes (\textcolor{red}{B}\textcolor{violet}{D})
 \end{aligned}$$

(6).由(5)有

$$(A \otimes B)(A^{-1} \otimes B^{-1}) = (AA^{-1}) \otimes (BB^{-1}) = I_m \otimes I_n = I_{mn}.$$

由 $A \otimes B$ 与 $A^{-1} \otimes B^{-1}$ 都是 mn 阶的方阵,这说明矩阵


$A \otimes B$ 可逆,并且它的逆矩阵就是 $A^{-1} \otimes B^{-1}$,即

$$(A \otimes B)^{-1} = A^{-1} \otimes B^{-1}.$$

(7).这只要验证 **Penrose** 方程中的四个等式即可

(其中用 $A \otimes B$ 代替 A ,用 $A^+ \otimes B^+$ 代替 B),

验证如下:



由(5)验证第①个, 第②个 **Penrose** 方程

$$\begin{aligned} & (A \otimes B)(A^+ \otimes B^+)(A \otimes B) \\ &= (AA^+A) \otimes (BB^+B) = A \otimes B. \end{aligned} \quad \text{①成立;}$$

$$\begin{aligned} & (A^+ \otimes B^+)(A \otimes B)(A^+ \otimes B^+) \\ &= (A^+AA^+) \otimes (B^+BB^+) = A^+ \otimes B^+ \end{aligned} \quad \text{②成立;}$$

由(5)和(4)验证第③个,第④个 **Penrose** 方程

$$\begin{aligned} [(A \otimes B)(A^+ \otimes B^+)]^H &= [(AA^+) \otimes (BB^+)]^H = (AA^+)^H \otimes (BB^+)^H \\ &= (AA^+) \otimes (BB^+) = (A \otimes B)(A^+ \otimes B^+) \quad \text{③成立;} \end{aligned}$$

$$\begin{aligned} [(A^+ \otimes B^+)(A \otimes B)]^H &= [(A^+A) \otimes (B^+B)]^H = (A^+A)^H \otimes (B^+B)^H \\ &= (A^+A) \otimes (B^+B) = (A^+ \otimes B^+)(A \otimes B) \quad \text{④成立} \end{aligned}$$

这说明 $A^+ \otimes B^+$ 是 $A \otimes B$ 的加号逆, 由其惟一性, 即得

$$(A \otimes B)^+ = A^+ \otimes B^+.$$

(8). 设 $A \in U^{m \times m}$, $B \in U^{n \times n}$, 由(4)及(5)得

$$\begin{aligned}(A \otimes B)(A \otimes B)^H &= (A \otimes B)(A^H \otimes B^H) \\ &= (AA^H)(BB^H) = I_m \otimes I_n = I_{mn}.\end{aligned}$$

$$\begin{aligned}(A \otimes B)^H (A \otimes B) &= (A^H \otimes B^H)(A \otimes B) \\ &= (A^H A)(B^H B) = I_m \otimes I_n = I_{mn}.\end{aligned}$$

故 $(A \otimes B)(A \otimes B)^H = (A \otimes B)^H (A \otimes B) = I_{mn},$

即 $A \otimes B \in U^{mn \times mn}.$

(9). 参考《矩阵分析教程》P291.16题.

Kronecker积的特性

除了具有齐次性, 结合律, 分配律之外,
矩阵的Kronecker乘积运算还可以概括出如下特性:
(假设满足运算合理性所需的条件)

① 前前后后性 $(A \otimes B)(C \otimes D) = (AC) \otimes (BD)$

② 乘幂算子性 $(A \otimes B)^* = A^* \otimes B^*$

这里 $*$ 可以代表 $T, H, -1, k, +$ 等运算

③ 酉不变性 两个酉矩阵的Kronecker乘积仍是酉矩阵.

§ 8.2 矩阵Kronecker积的特征值

定理 8.2 设 $A \in C^{m \times m}$ 的特征值为 $\lambda_1, \dots, \lambda_i, \dots, \lambda_m$,
 $B \in C^{n \times n}$ 的特征值为 $\mu_1, \dots, \mu_j, \dots, \mu_n$, 则

(1) $A \otimes B$ 的 mn 个特征值为 $\lambda_i \mu_j$

$$(i = 1, 2, \dots, m; j = 1, 2, \dots, n); \quad (8.13)$$

(2) $A \otimes I_n + I_m \otimes B^T$ 的 mn 个特征值为 $\lambda_i + \mu_j$


$$(i = 1, 2, \dots, m; j = 1, 2, \dots, n). \quad (8.14)$$

(2) 式中为 B^T 而非 B , 是为后用.

证 用**Jordan 标准形**来完成本定理的证明.


(1). 由**定理 3.10**, 对于矩阵 A 与 B , 存在**可逆**
矩阵 P_1, P_2 , 使

$$P_1^{-1}AP_1 = \begin{bmatrix} \lambda_1 & \varepsilon_1 & & & \\ & \lambda_2 & \ddots & & \\ & & \ddots & \varepsilon_{i-1} & \\ & & & \lambda_i & \ddots \\ & & & & \ddots & \varepsilon_{m-1} \\ & & & & & \lambda_m \end{bmatrix} = J_1,$$



$$P_2^{-1} B P_2 = \begin{bmatrix} \mu_1 & \delta_1 & & & \\ & \mu_2 & \ddots & & \\ & & \ddots & \delta_{j-1} & \\ & & & \mu_j & \ddots \\ & & & & \ddots & \delta_{n-1} \\ & & & & & \mu_n \end{bmatrix} = J_2$$


这里 ε_i, δ_j 为 1 或 0, 其中 $i = 1, \dots, m-1; j = 1, \dots, n-1$.



由**定理** 8.1之(5)与(6)有


$$\begin{aligned} & (P_1 \otimes P_2)^{-1} (A \otimes B) (P_1 \otimes P_2) \\ &= (P_1^{-1} \otimes P_2^{-1}) (A \otimes B) (P_1 \otimes P_2) \\ &= (P_1^{-1} A P_1) \otimes (P_2^{-1} B P_2) \\ &= J_1 \otimes J_2. \end{aligned}$$

这说明 $A \otimes B$ 与 $J_1 \otimes J_2$ 相似，
故它们的特征值相等。



$$\boxed{J_1 \otimes J_2} = \begin{bmatrix}
 \lambda_1 J_2 & \varepsilon_1 J_2 & & \\
 & \lambda_2 J_2 & & \\
 & & \ddots & \\
 & & & \varepsilon_{i-1} J_2 & \\
 & & & \boxed{\lambda_i J_2} & \\
 & & & & \ddots & \\
 & & & & & \varepsilon_{m-1} J_2 & \\
 & & & & & & \lambda_m J_2
 \end{bmatrix}$$

其中



$$\boxed{\lambda_i J_2} = \begin{bmatrix} \lambda_i \mu_1 & \lambda_i \delta_1 & & \\ & \lambda_i \mu_2 & \ddots & \\ & & \ddots & \lambda_i \delta_{j-1} \\ & & & \boxed{\lambda_i \mu_j} & \ddots \\ & & & & \ddots & \lambda_i \delta_{n-1} \\ & & & & & \lambda_i \mu_n \end{bmatrix},$$


$i = 1, \dots, m.$

可见 $J_1 \otimes J_2$ 是上三角矩阵, 它的特征值恰为
对角元 $\boxed{\lambda_i \mu_j}$ ($i = 1, \dots, m; j = 1, \dots, n$).

(2). 因 $\det(\lambda I - B) = \det(\lambda I - B^T)$, 故 B^T 与 B 特征值相同,
 则存在可逆矩阵 P_3 , 化 B^T 为它的 Jordan 标准形 J_3 ,

$$P_3^{-1}(B^T)P_3 = \begin{bmatrix} \mu_1 & \sigma_1 & & & \\ & \mu_2 & \ddots & & \\ & & \ddots & \sigma_{j-1} & \\ & & & \mu_j & \ddots \\ & & & & \ddots & \sigma_{n-1} \\ & & & & & \mu_n \end{bmatrix} = J_3$$

这里 σ_j 为 1 或 0, 其中 $j = 1, \dots, n-1$.



于是有

$$\begin{aligned} & (\mathbf{P}_1 \otimes \mathbf{P}_3)^{-1} (\mathbf{A} \otimes \mathbf{I}_n + \mathbf{I}_m \otimes \mathbf{B}^T) (\mathbf{P}_1 \otimes \mathbf{P}_3) \\ &= (\mathbf{P}_1^{-1} \otimes \mathbf{P}_3^{-1}) (\mathbf{A} \otimes \mathbf{I}_n + \mathbf{I}_m \otimes \mathbf{B}^T) (\mathbf{P}_1 \otimes \mathbf{P}_3) \\ &= (\mathbf{P}_1^{-1} \mathbf{A} \mathbf{P}_1) \otimes (\mathbf{P}_3^{-1} \mathbf{I}_n \mathbf{P}_3) + (\mathbf{P}_1^{-1} \mathbf{I}_m \mathbf{P}_1) \otimes (\mathbf{P}_3^{-1} \mathbf{B}^T \mathbf{P}_3) \\ &= \mathbf{J}_1 \otimes \mathbf{I}_n + \mathbf{I}_m \otimes \mathbf{J}_3 \end{aligned}$$

这说明

$A \otimes I_n + I_m \otimes B^T$ 与 $J_1 \otimes I_n + I_m \otimes J_3$ 相似,

故它们的特征值相等.


显然 $J_1 \otimes I_n, I_m \otimes J_3$ 都是上三角矩阵,

故 $J_1 \otimes I_n + I_m \otimes J_3$ 也是上三角矩阵.

而它的特征值恰为 $\lambda_i + \mu_j$

这里 $i = 1, 2, \dots, m; j = 1, 2, \dots, n$.

因此 $A \otimes I_n + I_m \otimes B^T$ 的 mn 个特征值
也为 $\lambda_i + \mu_j$. ■



定理 8.3 设 $A \in C^{m \times m}$ 的特征值为 $\lambda_1, \dots, \lambda_i, \dots, \lambda_m$,
 $B \in C^{n \times n}$ 的特征值为 $\mu_1, \dots, \mu_j, \dots, \mu_n$, 则

(1). $\det(A \otimes B) = (\det A)^n (\det B)^m$; (8.15)

(2). $\text{tr}(A \otimes B) = \text{tr}(A) \text{tr}(B)$. (8.16)

证 (1). 由定理 8.2 之 (1) 知

$$\begin{aligned}
 \det(A \otimes B) &= \prod_{i=1}^m \prod_{j=1}^n \lambda_i \mu_j = \prod_{i=1}^m \left(\lambda_i^n \prod_{j=1}^n \mu_j \right) \\
 &= \left(\prod_{i=1}^m \lambda_i^n \right) \left(\prod_{j=1}^n \mu_j \right)^m = \left(\prod_{i=1}^m \lambda_i \right)^n \left(\prod_{j=1}^n \mu_j \right)^m \\
 &= (\det A)^n (\det B)^m
 \end{aligned}$$

$$(2). \operatorname{tr}(A \otimes B) = \sum_{i=1}^m \sum_{j=1}^n \lambda_i \mu_j$$

$$= \left(\sum_{i=1}^m \lambda_i \right) \left(\sum_{j=1}^n \mu_j \right) = \operatorname{tr}(A) \operatorname{tr}(B).$$

定理 8.4 设 $A \in C_{r_1}^{m \times n}$, $B \in C_{r_2}^{p \times q}$, 则

$$\text{rank}(A \otimes B) = r_1 \cdot r_2 = \text{rank}(A) \cdot \text{rank}(B)$$

证 因为 $\text{rank}(A) = r_1$, $\text{rank}(B) = r_2$, 所以存在可逆矩阵 $P, Q; M, N$, 使

$$PAQ = \begin{bmatrix} I_{r_1} & O \\ O & O \end{bmatrix} = A_1, \quad MBN = \begin{bmatrix} I_{r_2} & O \\ O & O \end{bmatrix} = B_1, \text{ 且有}$$

$$\text{rank}(A_1) = r_1, \text{rank}(B_1) = r_2.$$

$$\text{于是} \quad A = P^{-1} A_1 Q^{-1}, \quad B = M^{-1} B_1 N^{-1}.$$

由定理 8.1之(5)有


$$\begin{aligned} A \otimes B &= (P^{-1} A_1 Q^{-1}) \otimes (M^{-1} B_1 N^{-1}) \\ &= (P^{-1} \otimes M^{-1})(A_1 \otimes B_1)(Q^{-1} \otimes N^{-1}). \end{aligned}$$

由定理 8.1之(6)知 $P^{-1} \otimes M^{-1}$, $Q^{-1} \otimes N^{-1}$ 都是可逆矩阵,

因此 $A \otimes B$ 与 $A_1 \otimes B_1$ 等价.

所以它们的秩相等, 即

$$\begin{aligned} \text{rank}(A \otimes B) &= \text{rank}(A_1 \otimes B_1) \\ &= r_1 \cdot r_2 = \text{rank}(A) \cdot \text{rank}(B). \end{aligned}$$



定理 8.5 设 x 是 $A \in C^{m \times m}$ 的特征向量, y 是 $B \in C^{n \times n}$ 的特征向量, 则 $x \otimes y$ 是 $A \otimes B$ 的特征向量.

证 设 $Ax = \lambda x$, $By = \mu y$, 由定理 8.1 之 (5) 有

$$\begin{aligned} (A \otimes B)(x \otimes y) &= (Ax) \otimes (By) \\ &= (\lambda x) \otimes (\mu y) = (\lambda \mu)(x \otimes y). \end{aligned}$$

由 $x \neq \theta$, $y \neq \theta$, 故 $(x \otimes y) \neq \theta$,

这说明 $x \otimes y$ 是矩阵 $A \otimes B$ 的属于特征值 $\lambda \mu$ 的特征向量. ■

例8.2 若 $A \in \mathbb{C}^{n \times n}$ 有 n 个线性无关的特征向量, 则 $A \otimes A$ 有 n^2 个线性无关的特征向量.


证 设 $x_1, \dots, x_i, \dots, x_n$ 为 A 的属于特征值 $\lambda_1, \dots, \lambda_i, \dots, \lambda_n$ 的 n 个线性无关的特征向量, 于是有

$$Ax_i = \lambda_i x_i \quad i=1, 2, \dots, n.$$

记 $P = (x_1, \dots, x_i, \dots, x_n)$, 则

$$P^{-1}AP = \text{diag}(\lambda_1, \dots, \lambda_i, \dots, \lambda_n) = D,$$

$$\begin{aligned} & (P \otimes P)^{-1} (A \otimes A) (P \otimes P) \\ &= (P^{-1}AP) \otimes (P^{-1}AP) = D \otimes D. \end{aligned}$$



显然 $D \otimes D$ 是 n^2 阶的对角阵, 因此 $A \otimes A$ 相似于 n^2 阶的对角阵, 它有 n^2 个线性无关的特征向量.

以下证它们即为 $P \otimes P$ 的 n^2 个列向量.
由矩阵直积的定义有




$$\begin{aligned} P \otimes P &= (x_1, \dots, x_i, \dots, x_n) \otimes P \\ &= (x_1 \otimes P, \dots, x_i \otimes P, \dots, x_n \otimes P) = \\ &= (x_1 \otimes x_1, \dots, x_1 \otimes x_i, \dots, x_1 \otimes x_n, x_2 \otimes x_1, \dots, x_i \otimes x_j, \dots, x_n \otimes x_n) \end{aligned}$$

可见 $x_i \otimes x_j$ ($i = 1, 2, \dots, n$; $j = 1, 2, \dots, n$.)

这 n^2 个 $P \otimes P$ 的 **列向量** 即为 $A \otimes A$ 的 n^2 个 **线性无关的特征向量** .





§ 8.3 用Kronecker积求解矩阵方程

定义 8.3 设 $A = (a_{ij})_{m \times n}$, 称 mn 维列向量

$$\text{vec } A = (a_{11}, \dots, a_{1n}, a_{21}, \dots, a_{2n}, \dots, a_{m1}, \dots, a_{mn})^T \quad (8.18)$$

为矩阵 A 的按行展开或矩阵 A 的按行拉直的列向量.

类似地可以定义矩阵 A 的按列展开或矩阵 A 的按列拉直的列向量.

例 8.3 设 $A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}$,

则 $\text{vec } A = (1, 2, 3, 4, 5, 6, 7, 8, 9)^T$. (列向量)

显然 $A^T = \begin{bmatrix} 1 & 4 & 7 \\ 2 & 5 & 8 \\ 3 & 6 & 9 \end{bmatrix} = (\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3)$, 则 $\text{vec } A = \begin{bmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \\ \mathbf{x}_3 \end{bmatrix}$.

此时 $A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix} = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \mathbf{x}_3^T \end{bmatrix}$.

定理 8.7 设 $A \in C^{m \times n}$, $X \in C^{n \times p}$, $B \in C^{p \times q}$, 则

$$\text{vec}(AXB) = (A \otimes B^T) \text{vec } X \quad (8.19)$$


证 设 $A = (a_{ij})_{m \times n}$, $X^T = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n)$, $X = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_n^T \end{bmatrix}$, 则

$$\text{vec } X = \begin{bmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \\ \vdots \\ \mathbf{x}_n \end{bmatrix}.$$

于是


$$A \mathbf{X} B = A (\mathbf{X} B)$$

$$= \begin{bmatrix} a_{11} & \cdots & a_{1j} & \cdots & a_{1n} \\ \vdots & & \vdots & & \vdots \\ a_{i1} & \cdots & a_{ij} & \cdots & a_{in} \\ \vdots & & \vdots & & \vdots \\ a_{m1} & \cdots & a_{mj} & \cdots & a_{mn} \end{bmatrix} \begin{bmatrix} \mathbf{x}_1^T B \\ \vdots \\ \mathbf{x}_j^T B \\ \vdots \\ \mathbf{x}_n^T B \end{bmatrix}$$




$$\begin{aligned}
 \mathbf{A} \mathbf{X} \mathbf{B} &= \begin{bmatrix} \sum_{j=1}^n a_{1j} \mathbf{x}_j^T \mathbf{B} \\ \vdots \\ \sum_{j=1}^n a_{mj} \mathbf{x}_j^T \mathbf{B} \end{bmatrix} = \begin{bmatrix} \left(\sum_{j=1}^n a_{1j} \mathbf{B}^T \mathbf{x}_j \right)^T \\ \vdots \\ \left(\sum_{j=1}^n a_{mj} \mathbf{B}^T \mathbf{x}_j \right)^T \end{bmatrix}
 \end{aligned}$$

The diagram illustrates the matrix multiplication $\mathbf{A} \mathbf{X} \mathbf{B}$ using block matrices. The matrix $\mathbf{A}$ is represented by a column vector of elements a_{ij} . The matrix $\mathbf{X}$ is represented by a column vector of vectors $\mathbf{x}_j^T$. The matrix $\mathbf{B}$ is represented by a column vector of vectors $\mathbf{B}^T \mathbf{x}_j$. The result is shown as a column vector of vectors $\left(\sum_{j=1}^n a_{ij} \mathbf{B}^T \mathbf{x}_j \right)^T$. The diagram uses color coding: blue for a_{ij} , red for $\mathbf{x}_j^T$, and black for $\mathbf{B}$. The result is shown as a column vector of vectors $\left(\sum_{j=1}^n a_{ij} \mathbf{B}^T \mathbf{x}_j \right)^T$. The diagram uses color coding: blue for a_{ij} , red for $\mathbf{x}_j^T$, and black for $\mathbf{B}$.




所以 $\text{vec}(\mathbf{AXB}) = \begin{bmatrix} \sum_{j=1}^n a_{1j} \mathbf{B}^T \mathbf{x}_j \\ \vdots \\ \sum_{j=1}^n a_{ij} \mathbf{B}^T \mathbf{x}_j \\ \vdots \\ \sum_{j=1}^n a_{mj} \mathbf{B}^T \mathbf{x}_j \end{bmatrix}$



$$= \begin{bmatrix} a_{11} \mathbf{B}^T & \cdots & a_{1j} \mathbf{B}^T & \cdots & a_{1n} \mathbf{B}^T \\ \vdots & & \vdots & & \vdots \\ a_{i1} \mathbf{B}^T & \cdots & a_{ij} \mathbf{B}^T & \cdots & a_{in} \mathbf{B}^T \\ \vdots & & \vdots & & \vdots \\ a_{m1} \mathbf{B}^T & \cdots & a_{mj} \mathbf{B}^T & \cdots & a_{mn} \mathbf{B}^T \end{bmatrix} \begin{bmatrix} \mathbf{x}_1 \\ \vdots \\ \mathbf{x}_j \\ \vdots \\ \mathbf{x}_n \end{bmatrix}$$

$$= (\mathbf{A} \otimes \mathbf{B}^T) \text{vec } \mathbf{X}$$





推论 设 $A \in \mathbf{C}^{m \times m}$, $B \in \mathbf{C}^{n \times n}$, $X \in \mathbf{C}^{m \times n}$, 则

$$\textcircled{1}. \text{vec}(AX) = (A \otimes I_n) \text{vec} X \quad (B = I_n)$$

$$\textcircled{2}. \text{vec}(XB) = (I_m \otimes B^T) \text{vec} X \quad (A = I_m)$$

$$\textcircled{3}. \text{vec}(AX + XB) = (A \otimes I_n + I_m \otimes B^T) \text{vec} X$$

定义 8.4 设 $A \in C^{m \times m}$, $B \in C^{n \times n}$, $X \in C^{m \times n}$, $F \in C^{m \times n}$, 则


$$AX + XB = F \quad (8.21)$$

称为Lyapunov矩阵方程.

将矩阵方程(8.21)两端矩阵按行拉直,
由式(8.20)可得

$$(A \otimes I_n + I_m \otimes B^T) \text{vec } X = \text{vec } F \quad (8.22)$$

因矩阵方程(8.21)与线性方程组(8.22)等价,
故矩阵方程的求解问题转化为线性方程组
的求解问题.



由非齐次线性方程组的Kronecker定理知道
非齐次线性方程组有解的充要条件是：

系数矩阵的秩等于增广矩阵的秩。

因此Lyapunov矩阵方程(8.21)有解的充要条件是：

$$\text{rank}(A \otimes I_n + I_m \otimes B^T) = \text{rank}(A \otimes I_n + I_m \otimes B^T : \text{vec} F)$$

定义 8.5 设 $A \in C^{m \times m}$, $B \in C^{n \times n}$, 记

$$A \oplus B \triangleq A \otimes I_n + I_m \otimes B$$

称为矩阵 A 与 B 的 **Kronecker 和**.

有了矩阵 **Kronecker 和** 的定义, 则式(8.23)可归结为

定理 8.8 Lyapunov 矩阵方程

$$AX + XB = F$$

有解的充要条件是:

$$\text{rank}(A \oplus B^T) = \text{rank}(A \oplus B^T : \text{vec } F)$$



推论 若 $\det(A \oplus B^T) \neq 0$, 则 **Lyapunov**
矩阵方程 (8.21) 有 **惟一解**.

由 **定理** 8.2 上述 **结论** 可叙述为:
若 A, B **无互为反号的特征值**,
则方程 (8.21) 有 **惟一解**.

例 8.4 求解 Lyapunov 矩阵方程 $AX + XB = F$, 其中


$$A = \begin{bmatrix} 1 & -1 \\ 0 & -1 \end{bmatrix}, \quad B = \begin{bmatrix} 0 & 2 \\ 1 & 0 \end{bmatrix}, \quad F = \begin{bmatrix} 1 & 3 \\ -2 & 2 \end{bmatrix}.$$

解 易见 A 的特征值为 $\lambda_1 = 1, \lambda_2 = -1$;

容易算得 B 的特征值为 $\mu_1 = \sqrt{2}, \mu_2 = -\sqrt{2}$.

由于 A, B 无互为反号的特征值,

故 Lyapunov 矩阵方程有惟一解.



$$\begin{aligned}
 \mathbf{A} \otimes \mathbf{I}_2 + \mathbf{I}_2 \otimes \mathbf{B}^T &= \begin{bmatrix} \boxed{1} & \boxed{0} & \boxed{-1} & \boxed{0} \\ \boxed{0} & \boxed{1} & \boxed{0} & \boxed{-1} \\ 0 & 0 & \boxed{-1} & \boxed{0} \\ 0 & 0 & \boxed{0} & \boxed{-1} \end{bmatrix} + \begin{bmatrix} \boxed{0} & \boxed{1} & 0 & 0 \\ \boxed{2} & \boxed{0} & 0 & 0 \\ 0 & 0 & \boxed{0} & \boxed{1} \\ 0 & 0 & \boxed{2} & \boxed{0} \end{bmatrix} \\
 &= \begin{bmatrix} 1 & 1 & -1 & 0 \\ 2 & 1 & 0 & -1 \\ 0 & 0 & -1 & 1 \\ 0 & 0 & 2 & -1 \end{bmatrix}
 \end{aligned}$$



设 $X = \begin{bmatrix} x_1 & x_2 \\ x_3 & x_4 \end{bmatrix}$

则由式(8.22)有

$$\begin{bmatrix} 1 & 1 & -1 & 0 \\ 2 & 1 & 0 & -1 \\ 0 & 0 & -1 & 1 \\ 0 & 0 & 2 & -1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 1 \\ 3 \\ -2 \\ 2 \end{bmatrix}$$

解之 $x_1 = 0, x_2 = 1, x_3 = 0, x_4 = -2$.

于是 $X = \begin{bmatrix} 0 & 1 \\ 0 & -2 \end{bmatrix}$ 为 **Lyapunov 矩阵方程** 的 **惟一解**. $\square$

定理8.9 如果 A, B 为稳定矩阵,即 A, B 的所有特征值都具有负实部,则Lyapunov矩阵方程

$$AX + XB = F$$

有惟一解

$$X(t) = - \int_0^{+\infty} e^{At} F e^{Bt} dt.$$

定理8.9 如果 A, B 为稳定矩阵,即 A, B 的所有特征值都具有负实部,则Lyapunov矩阵方程

$$AX + XB = F$$

有惟一解

$$X(t) = - \int_0^{+\infty} e^{At} F e^{Bt} dt.$$

证略


$$\sum_{k=1}^t A_k X B_k = F \text{ 型矩阵方程}$$

设 $A_k \in C^{m \times m}$, $B_k \in C^{n \times n}$, $X \in C^{m \times n}$, $F \in C^{m \times n}$, 求解矩阵方程

$$\sum_{k=1}^t A_k X B_k = F \quad (8.25)$$

将式(8.25)两端矩阵按行拉直有

$$\left[\sum_{k=1}^t (A_k \otimes B_k^T) \right] \text{vec } X = \text{vec } F \quad (8.26)$$

由于矩阵方程(8.25)与线性方程组(8.26)等价,
故与式(8.23)类似,可讨论方程(8.25)是否有解,
若有解是否惟一.




例 8.5 求解矩阵方程 $A_1 \mathbf{X} B_1 + A_2 \mathbf{X} B_2 = \mathbf{F}$, 其中

$$A_1 = \begin{bmatrix} 2 & 2 \\ 2 & -1 \end{bmatrix}, A_2 = \begin{bmatrix} 0 & 1 \\ -2 & -1 \end{bmatrix},$$

$$B_1 = \begin{bmatrix} 1 & 0 \\ -1 & 1 \end{bmatrix}, B_2 = \begin{bmatrix} 0 & 2 \\ -1 & 3 \end{bmatrix}, \mathbf{F} = \begin{bmatrix} 0 & -2 \\ 3 & -2 \end{bmatrix}.$$


解 $B_1^T = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix}, B_2^T = \begin{bmatrix} 0 & -1 \\ 2 & 3 \end{bmatrix}$, 设 $\mathbf{X} = \begin{bmatrix} x_1 & x_2 \\ x_3 & x_4 \end{bmatrix}$



$$\mathbf{A}_1 \otimes \mathbf{B}_1^T = \begin{bmatrix} 2\mathbf{B}_1^T & 2\mathbf{B}_1^T \\ 2\mathbf{B}_1^T & -1\mathbf{B}_1^T \end{bmatrix} = \begin{bmatrix} 2 & -2 & 2 & -2 \\ 0 & 2 & 0 & 2 \\ 2 & -2 & -1 & 1 \\ 0 & 2 & 0 & -1 \end{bmatrix},$$

$$\mathbf{A}_2 \otimes \mathbf{B}_2^T = \begin{bmatrix} 0\mathbf{B}_2^T & 1\mathbf{B}_2^T \\ -2\mathbf{B}_2^T & -1\mathbf{B}_2^T \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & -1 \\ 0 & 0 & 2 & 3 \\ 0 & 2 & 0 & 1 \\ -4 & -6 & -2 & -3 \end{bmatrix}.$$

由式(8.26)有



$$\begin{bmatrix} 2 & -2 & 2 & -3 \\ 0 & 2 & 2 & 5 \\ 2 & 0 & -1 & 2 \\ -4 & -4 & -2 & -4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 0 \\ -2 \\ 3 \\ -2 \end{bmatrix}.$$

解之该线性方程组有惟一解为

$$x_1 = 1, x_2 = 0, x_3 = -1, x_4 = 0.$$

故原矩阵方程有惟一解为

$$X = \begin{bmatrix} 1 & 0 \\ -1 & 0 \end{bmatrix}.$$



§ 8.4 矩阵微分方程

引理1 设 $A \in C^{m \times m}$, $B \in C^{n \times n}$, 则

$$(1) \quad e^{A \otimes I_n} = e^A \otimes I_n$$

$$(2) \quad e^{I_m \otimes B} = I_m \otimes e^B. \quad (8.27)$$



证 由**矩阵幂级数**的定义及**定理 8.1**之(2)可得

$$\begin{aligned} e^{A \otimes I_n} &= \sum_{k=0}^{\infty} \frac{1}{k!} (A \otimes I_n)^k = \sum_{k=0}^{\infty} \frac{1}{k!} (A^k \otimes I_n^k) \\ &= \sum_{k=0}^{\infty} \left(\frac{A^k}{k!} \otimes I_n \right) = \left(\sum_{k=0}^{\infty} \frac{A^k}{k!} \right) \otimes I_n = e^A \otimes I_n. \end{aligned}$$

故(1)成立. 同理可证(2). ■

引理2 设 $A \in C^{m \times m}$, $B \in C^{n \times n}$, 则

$$e^{(A \otimes I_n + I_m \otimes B)} = e^A \otimes e^B = e^B \otimes e^A \quad (8.28)$$

证 因为

$$(A \otimes I_n)(I_m \otimes B) = A \otimes B = (I_m \otimes B)(A \otimes I_n)$$

这说明 $(A \otimes I_n)$ 与 $(I_m \otimes B)$ 可交换.

由 **定理 5.8** 之 (1) 及 **引理 1** 可得

$$\begin{aligned} e^{(A \otimes I_n + I_m \otimes B)} &= e^{A \otimes I_n} \cdot e^{I_m \otimes B} \\ &= (e^A \otimes I_n)(I_m \otimes e^B) = e^A \otimes e^B \end{aligned}$$

同理可证另一等式成立. ■




定理 8.10 矩阵微分方程

$$\begin{cases} \frac{d\mathbf{X}(t)}{dt} = \mathbf{A}\mathbf{X}(t) + \mathbf{X}(t)\mathbf{B} \\ \mathbf{X}(0) = \mathbf{X}_0 \end{cases} \quad (8.29)$$

的解为

$$\mathbf{X}(t) = e^{\mathbf{A}t} \mathbf{X}_0 e^{\mathbf{B}t} \quad (8.30)$$

其中 $\mathbf{A} \in \mathbb{C}^{m \times m}$, $\mathbf{X} \in \mathbb{C}^{m \times n}$, $\mathbf{B} \in \mathbb{C}^{n \times n}$.



证 将**矩阵微分方程** (8.29) 两端矩阵**按行拉直**有

$$\begin{cases} \frac{d}{dt}(\text{vec } X(t)) = (A \otimes I_n + I_m \otimes B^T) \text{vec } X(t) \\ \text{vec } X(t) = \text{vec } X_0 \end{cases} \quad (8.31)$$

于是问题归结为求解**常系数齐次线性微分方程组初值问题**(8.31).

由**定理 5.10**中式(5.39)及**引理 2, 定理 8.7**可得

$$\text{vec } X(t) = e^{(A \otimes I_n + I_m \otimes B^T)t} \cdot \text{vec } X_0$$

$$= (e^{At} \otimes e^{B^T t}) \text{vec } X_0 = \text{vec}(e^{At} X_0 (e^{B^T t})^T)$$

而 $(e^{B^T t})^T = \left(\sum_{k=0}^{\infty} \frac{1}{k!} (B^T)^k t^k \right)^T = \sum_{k=0}^{\infty} \frac{1}{k!} B^k t^k = e^{Bt}$

故


$$\text{vec } X(t) = \text{vec}(e^{At} X_0 e^{Bt}).$$

于是矩阵微分方程初值问题 (8.29) 的解为

$$X(t) = e^{At} X_0 e^{Bt}.$$




例 8.6 求解矩阵微分方程的初值问题


$$\begin{cases} \frac{d\mathbf{X}(t)}{dt} = \begin{bmatrix} -1 & 0 \\ 0 & 2 \end{bmatrix} \mathbf{X}(t) + \mathbf{X}(t) \begin{bmatrix} 1 & -1 \\ 0 & 2 \end{bmatrix} \\ \mathbf{X}(0) = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix} \end{cases}$$


解 令 $\mathbf{A} = \begin{bmatrix} -1 & 0 \\ 0 & 2 \end{bmatrix}$, $\mathbf{B} = \begin{bmatrix} 1 & -1 \\ 0 & 2 \end{bmatrix}$,

因 $\mathbf{A}$ 是对角阵, 故 $e^{\mathbf{A}t} = \begin{bmatrix} e^{-t} & 0 \\ 0 & e^{2t} \end{bmatrix}$.

以下用**Laplace变换**的方法计算 e^{Bt} .


$$(sI - B)^{-1} = \begin{bmatrix} s-1 & 1 \\ 0 & s-2 \end{bmatrix}^{-1}$$
$$= \frac{1}{(s-1)(s-2)} \begin{bmatrix} s-2 & -1 \\ 0 & s-1 \end{bmatrix} = \begin{bmatrix} \frac{1}{s-1} & \frac{1}{s-1} - \frac{1}{s-2} \\ 0 & \frac{1}{s-2} \end{bmatrix}$$

$$e^{Bt} = L^{-1}[(sI - B)^{-1}] = \begin{bmatrix} e^t & e^t - e^{2t} \\ 0 & e^{2t} \end{bmatrix}$$



由定理 8.9 知

$$X(t) = e^{At} X(0) e^{Bt}$$

$$= \begin{bmatrix} e^{-t} & 0 \\ 0 & e^{2t} \end{bmatrix} \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} e^t & e^t - e^{2t} \\ 0 & e^{2t} \end{bmatrix}$$

$$= \begin{bmatrix} -1 & -1 + e^t \\ 0 & e^{5t} \end{bmatrix}.$$





例 8.7 若矩阵方程 $AXB = D$ 不相容, 则它的
极小范数最小二乘解 $X_0 = A^+DB^+$.

证 将矩阵方程两端拉直有 $\text{vec}(AXB) = \text{vec } D$

矩阵方程 $AXB = D \Leftrightarrow$ 线性方程组 $\text{vec}(AXB) = \text{vec } D$.

因为矩阵方程 $AXB = D$ 不相容, 故线性方程组

$$(A \otimes B^T) \text{vec } X = \text{vec } D$$

不相容.

其极小范数最小二乘解为

$$\begin{aligned} \text{vec } X_0 &= (A \otimes B^T)^+ \text{vec } D \\ &= [A^+ \otimes (B^T)^+] \text{vec } D \\ &= [A^+ \otimes (B^+)^T] \text{vec } D \\ &= \text{vec}(A^+ D B^+) \end{aligned}$$

这说明 与之对应地 $X_0 = A^+ D B^+$ 正是不相容的
矩阵方程 $AXB = D$ 的极小范数最小二乘解. ■